

Métodos Multivariados

Son técnicas que permiten realizar el análisis estadístico de datos, cuando se han registrado muchas características sobre un conjunto de objetos o individuos.

Objetivos:

- Analizar y simplificar la estructura de datos
- Clasificación y conglomeración
- Análisis de dependencia
- Inferencia estadística

Métodos de Interdependencia

No hay distinción entre las variables. Son métodos descriptivos que sintetizan la información, mostrar la estructura de los datos o clasificar las variables.

Método	Métricas	No métricas
Análisis de componentes principales	X	
Análisis factorial	X	
Análisis de correspondencia		X
Análisis de cluster	X	
Análisis de escalamiento multidimensional	X	X

Métodos de dependencia

Se distinguen variables dependientes e independientes. Son métodos con finalidades explicativas.

Método	Var. Dependiente		Var. Independiente	
	Met.	No Met.	Mét.	No Mét.
Análisis discriminante		X	X	
Análisis de regresión multivariado	X		X	
Análisis de regresión logística		X	X	X
Análisis de variancia	X			X

Métodos multivariados

- **Análisis de componentes principales (ACP).** Su propósito es el de reducir la dimensionalidad de las variables originales, tratando de explicar la mayor parte de la variabilidad total del conjunto de variables originales con el menor número posible de componentes principales, también es usada como un análisis descriptivo de los datos.
- **Análisis Factorial (AF).** Permite sintetizar el fenómeno en estudio a través de analizar la estructura de correlaciones entre el conjunto de variables, se resume la información e identifica una estructura subyacente del conjunto de los datos.
- **Análisis de Correspondencia (AC).** Es similar al AF, en el sentido que trata de descubrir y describir las dimensiones fundamentales de un fenómeno pero con la particularidad que las variables son categóricas que proporcionan mapas preceptúales que facilitan la interpretación y su análisis.

Métodos multivariados

- **Análisis de cluster** . A partir de un conjunto de variables métricas trata de agrupar el conjunto de observaciones (objetos o individuos) aplicando medidas de distancia, formando grupos que sean lo más homogéneos los individuos dentro de ellos y heterogéneos entre los grupos .
- **Análisis de Escalamiento Multidimensional** . Es similar al análisis de cluster, con la diferencia que trabaja con variables de escalas métricas y/o ordinales (cualitativas) , con la finalidad de formar grupos.


Métodos multivariados

- **Análisis Discriminante** . La variable dependiente es categórica (dos o más categorías) y las independientes son variables métricas. El método trata de construir una regla o función de clasificación en base de las variables independientes y conociendo a priori los grupos indicados por la variable categórica; y así poder asignar nuevas observaciones a uno de los grupos aplicando la regla o función de clasificación.
- **Análisis de Regresión Multivariada** . Es el método que trata de estudiar la relación funcional entre un grupo de variables dependientes y un conjunto de variables independientes. La relación puede ser lineal o no lineal y las variables independientes pueden ser métricas y no métricas.

Métodos multivariados

- **Análisis de Regresión Logística** . Es un caso particular del análisis de regresión en el cual la variable dependiente es dicotómica (o politómica) y las variables independientes pueden ser métricas o no métricas.
- **Análisis de Variancia** . Las variables independientes son categóricas y trata de estudiar los efectos de factores que intervienen sobre la variable dependiente (respuesta). Al existir más de dos variables independientes, se originan los arreglos factoriales.

Fases para el análisis multivariante de datos



Fundamentos del algebra matricial

Matriz. Una matriz **A** de orden o dimensión (mxn) es un conjunto de ***mxn*** elementos, ordenados en ***m*** filas y ***n*** columnas.

$$A_{(m,n)} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix}$$

a_{ij} denota cada elemento de la matriz, correspondiente a la fila **i** y columna **j**.

Ejemplos de matrices

$$A = \begin{bmatrix} 10 & 30 & 50 \\ 20 & 60 & 80 \\ 40 & 70 & 90 \end{bmatrix}$$

$$B = \begin{bmatrix} 2 & 3 \\ 5 & 8 \\ 4 & 2 \end{bmatrix}$$

Matriz de orden (3x3): $A_{3 \times 3}$ Matriz de orden (3x2): $B_{3 \times 2}$

$$a = \begin{bmatrix} 10 \\ 50 \\ 25 \end{bmatrix}$$

$$b = [10 \quad 80 \quad 30]$$

Vector columna de orden (3x1): $a_{3 \times 1}$ Vector fila (1x3): $b_{1 \times 3}$

Tipos de matrices

Matriz cuadrada. Una matriz es cuadrada cuando tiene el mismo número de filas y columnas.

$$A = \begin{bmatrix} 10 & 30 & 50 \\ 20 & 60 & 80 \\ 40 & 70 & 90 \end{bmatrix}$$

Operaciones con matrices cuadradas

Traza de una matriz. La traza de una matriz cuadrada $A_{m \times m}$, se define como la suma de los elementos de la

diagonal. $tr(A) = \sum_{i=1}^m a_{ii}$

$$tr(A) = \sum_{i=1}^m a_{ii} = a_{11} + a_{22} + a_{33} = 10 + 60 + 90 = 160$$

Operaciones con matrices cuadradas
Inversa de una matriz. Dada una matriz cuadrada A , se denota su inversa por A^{-1} tal que: $AA^{-1} = A^{-1}A = I$ (donde I es la matriz identidad)

Operaciones con matrices cuadradas

Determinante de una matriz. El determinante de una matriz cuadrada $A_{m \times m}$, es un escalar que resulta al obtener todos los productos posibles

$$|A| = a_{11} \quad [si \ n = 1]$$

$$|A| = \sum_{j=1}^m a_{ij} |A_{ij}| (-1)^{i+j} \quad [si \ n > 1]$$

Tipos de matrices

Matriz simétrica. Se dice que una matriz cuadrada es simétrica, si se cumple que: $A = A'$. Esto es, si cada fila es igual a su correspondiente columna: $a_{ij} = a_{ji} \forall i, j$.

Ejemplo.

$$A = \begin{bmatrix} 10 & 30 & 50 \\ 30 & 60 & 80 \\ 50 & 80 & 90 \end{bmatrix}$$

Tipos de matrices

Matriz identidad. Es una matriz diagonal cuyos elementos de la diagonal son unos.

Ejemplo.

$$I = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Tipos de matrices

Matriz ortogonal. Se dice que una matriz P es ortogonal si $PP' = I$ o bien $P'P = I$. Además se cumple:

- $P^{-1} = P'$

- $|P| = 1 \text{ ó } -1$

Multiplicación de matrices

Para multiplicar dos matrices, el número de columnas de la primera debe ser igual al número de filas de la segunda. Si A es una matriz de orden $(m \times n)$ y B es de orden $(n \times p)$, entonces el producto de las matrices es una matriz C de orden $(m \times p)$:

$$A_{m \times n} \times B_{n \times p} = C_{m \times p} \text{ donde: } c_{ij} = \sum_{k=1}^p a_{ik} b_{kj}$$

Ejemplos de multiplicación de matrices

$$A_{3 \times 3} \times B_{3 \times 2} = C_{3 \times 2} = \begin{bmatrix} 370 & 370 \\ 660 & 700 \\ 790 & 860 \end{bmatrix}$$

$$A_{3 \times 3} \times a_{3 \times 1} = C_{3 \times 1} = \begin{bmatrix} 2850 \\ 5200 \\ 6150 \end{bmatrix}$$

$$a'_{1 \times 3} \times B_{3 \times 2} = C_{1 \times 2} = [370 \quad 480]$$

$$a_{3 \times 1} \times b_{1 \times 3} = C_{3 \times 3} = \begin{bmatrix} 100 & 800 & 300 \\ 500 & 4000 & 1500 \\ 250 & 2000 & 750 \end{bmatrix}$$

Distribución Normal Multivariada

Si un vector aleatorio $X_{p \times 1}$ tiene distribución normal p-variante con vector de medias $\mu = (\mu_1, \dots, \mu_p)^T$ y matriz varianza covarianza Σ entonces su función densidad conjunta es:

$$f_X(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\}$$

Donde

$$\Sigma = \text{Cov}(X, X) = E \left[(X - E(X))(X - E(X))^T \right] = E[XX^T] - E[X]E[X^T]$$
$$\Sigma = \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1X_2) & \dots & \text{Cov}(X_1X_p) \\ \text{Cov}(X_2X_1) & \text{Var}(X_2) & \dots & \text{Cov}(X_2X_p) \\ \vdots & \vdots & & \vdots \\ \text{Cov}(X_pX_1) & \text{Cov}(X_pX_2) & \dots & \text{Var}(X_p) \end{pmatrix}$$

Muestra Multivariada

Esta representada por la matriz de datos X_{ij} de orden $(n \times p)$ que corresponde a seleccionar n individuos u objetos y a los cuales se han evaluado p variables

$$X = \begin{bmatrix} X_{11} & X_{12} & \dots & X_{1j} & \dots & X_{1p} \\ X_{21} & X_{22} & \dots & X_{2j} & \dots & X_{2p} \\ \vdots & \vdots & \dots & \vdots & \dots & \vdots \\ X_{i1} & X_{i2} & \dots & X_{ij} & \dots & X_{ip} \\ \vdots & \vdots & \dots & \vdots & \dots & \vdots \\ X_{n1} & X_{n2} & \dots & X_{nj} & \dots & X_{np} \end{bmatrix}$$

i -ésima fila

j -ésima columna

Vector de variables

Es el vector $\underline{X}_p$ de orden (px1), de p variables, cuyos elementos representan una característica o una variable medida sobre un individuo. Un individuo u observación está representado por un vector de p variables

$$\underline{X}_p = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} \begin{array}{l} \longrightarrow \text{ PESO} \\ \longrightarrow \text{ TALLA} \\ \\ \longrightarrow \text{ SUELDO} \end{array}$$

Como un vector transpuesta $\underline{X}'_p = [X_1, X_2, \dots, X_p]$

Vector de medias muestrales

Es el vector $\underline{\bar{X}}$ de orden $(p \times 1)$, cuyos elementos son la media muestral de la j -ésima variable.

$$\underline{\bar{X}}' = \begin{pmatrix} \bar{X}_1 & \bar{X}_2 & \cdots & \bar{X}_p \end{pmatrix} \quad \bar{X}_j = \frac{\sum_{i=1}^n x_{ij}}{n} \quad j = 1, 2, \dots, p$$

Matriz de variancia-covariancias muestrales

Es la matriz simétrica S de orden $(p \times p)$, cuyos elementos S_{jj} son la variancias de la variable X_j y S_{jk} las covariancias muestrales entre las variables X_j y X_k .

$$S = \begin{bmatrix} S_{11} & S_{12} & \cdots & S_{1p} \\ S_{21} & S_{22} & \cdots & S_{2p} \\ \vdots & \vdots & & \vdots \\ S_{p1} & S_{p2} & \cdots & S_{pp} \end{bmatrix}$$

$$S_{jj} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$$

$$S_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)$$

Matriz de correlaciones muestrales.

Es una matriz simétrica de orden $(p \times p)$, cuyos elementos r_{jk} son las correlaciones simples muestrales entre las variables X_j y X_k .

$$R = \begin{bmatrix} 1 & r_{12} & r_{13} & \cdots & r_{1p} \\ & 1 & r_{23} & \cdots & r_{2p} \\ & & 1 & & r_{3p} \\ & & & \ddots & \vdots \\ & & & & 1 \end{bmatrix}$$

$$r_{jk} = \frac{S_{jk}}{\sqrt{S_{jj} S_{kk}}}$$

Análisis previo de datos

Antes de aplicar cualquier técnica multivariada es preciso un análisis de los datos. Es necesario evaluar las variables individuales y sus relaciones, tales como datos faltantes, presencia de datos atípicos y supuestos.

- 1) Análisis exploratorio de datos
- 2) Análisis de datos faltantes (outliers)
- 3) Detección de datos atípicos
- 4) Comprobación de supuestos

Análisis exploratorio de datos

- Histogramas de frecuencias
- Gráficos
- Diagrama de tallos y hojas
- Diagrama de cajas
- Cálculo de medidas estadísticas
- Medidas de asimetría
- Medidas de curtosis

Medidas de asimetría

- **Coeficiente de FISHER (g1).** Se halla con la siguiente expresión:

$$g_1 = \frac{\sum (x_i - \bar{x})^3 n_i}{ns^3}$$

Si **g1 > 0** → *la distribución será asimétrica positiva o a derechas.*

Si **g1 < 0** → *la distribución será asimétrica negativa o a izquierdas (desplazada hacia la izquierda).*

Si **g1 = 0** → *la distribución será simétrica.*

- **Coeficiente de PEARSON (Ap).** Se calcula con la siguiente expresión.

$$A_p = \frac{3(\bar{X} - Me)}{S}$$

Si $A_p > 0 \rightarrow$ *la distribución será asimétrica positiva o hacia la derecha.*

Si $A_p < 0 \rightarrow$ *la distribución será asimétrica negativa o hacia la izquierda.*

Si $A_p = 0 \rightarrow$ *la distribución será simétrica.*

- **Coeficiente de asimetría de Bowley (Ab).** El cual esta basado en la posición de los cuartiles y la mediana. Se calcula de la siguiente manera:

$$Ab = \frac{Q_3 + Q_1 - 2Me}{Q_3 + Q_1}$$

Si $Ab > 0 \rightarrow$ *la distribución será asimétrica positiva o hacía la derecha.*

Si $Ab < 0 \rightarrow$ *la distribución será asimétrica negativa o hacía la izquierda.*

Si $Ap = 0 \rightarrow$ *la distribución será simétrica.*

Medidas de curtosis

- **Curtosis: coeficiente de Fisher.** Para calcularlo utilizaremos la expresión:

$$g_2 = \frac{\sum (x_i - \bar{X})^4 n_i}{ns^4} - 3$$

Si **$g_2 > 0$** la distribución será leptocúrtica o apuntada

Si **$g_2 = 0$** la distribución será mesocúrtica o normal

Si **$g_2 < 0$** la distribución será platicúrtica o menos apuntada que lo normal.

Usando percentiles:

$$K = \frac{P_{75} - P_{25}}{P_{90} - P_{10}} - 0.5$$

Si $K \rightarrow 0$ Distribución Normal

Medidas globales de variabilidad

- **Variancia total.** Se define como la traza de la matriz de variancias-covariancias.

$$T = \text{Traza}[S] = \sum_{j=1}^p S_{jj}$$

- Si la dependencia entre las variables es alta, la variabilidad conjunta es pequeña.
- Un inconveniente es que no toma en cuenta la estructura de dependencia de las variables
- Variancia media $\bar{T} = \frac{1}{p} \sum_{j=1}^p S_{jj}$

- **Variancia generalizada.** Es una medida que mejor mide la variabilidad global. Se define como el determinante de la matriz de variancias-covariancias

$$VG = |S|$$

- Si las variables son independientes, la variabilidad será mayor.
- Un inconveniente es que no sirve para comparar conjuntos de datos con distintos número de variables.

- **Variancia efectiva.** Es una alternativa para solucionar el problema de la VG. Es definida como la raíz p-ésima del determinante de la matriz de variancias-covariancias.

$$VE = |S|^{1/p}$$

- La VE tiene en cuenta la dependencia conjunta, ya que si una variable es combinación lineal de las demás al existir un valor propio cero.

Medidas de distancias

Son medidas alternativas para medir la variabilidad entre variables.

- **Distancia Euclidiana.** Esta medida depende de las unidades de medida de las variables originales, y por lo tanto generalmente se aplicarán a variables estandarizadas o tipificadas.

$$d_{ij} = \left[\sum_{k=1}^p (x_{ik} - x_{jk})^2 \right]^{\frac{1}{2}}$$

- Un defecto de esta métrica es que no tiene en cuenta la correlación alta que puede existir entre varias las variables, aportando información similar (todas las variables ingresan con igual peso).

- **Distancia de Mahalanobis.** Esta métrica si considera la existencia de unidades de medida entre las variables originales. Utiliza la inversa de la matriz de covariancias de las variables para eliminar la influencia de unidades entre las variables.

$$d_{ij}^2 = (\underline{x}_i - \underline{x}_j)' S^{-1} (\underline{x}_i - \underline{x}_j)$$

Análisis de datos faltantes

- Supresión de datos
 - Eliminación de casos o variables
 - Eliminación de datos según parejas de variables
- Imputación de datos
 - Sustitución por la media o mediana (hay outliers)
 - Sustitución por interpolación (alta variabilidad).
Uso de valores adyacentes
 - Sustitución por datos constante. Uso de fuentes externas
 - Sustitución por análisis de regresión

Detección de datos atípicos (outliers)

- Diagrama de cajas simples y múltiples
- Gráficos de dispersión
- Gráfico de dispersión matricial
- Gráficos de control
- Estadísticas descriptivas