Método del Análisis de Correspondencia

1. Introducción
2. Metodología Estadística
   - 2.1 Prueba estadística preliminar
   - 2.2 Análisis de correspondencia simple
     1) Formulación del ACS
     2) Tabla de perfiles de filas y columnas
     3) Inercia de filas y columnas
     4) Matriz de inercia de filas y columnas
     5) Interpretación del ACS
     6) Ejemplo de aplicación
   - 2.3 Análisis de correspondencia múltiple

1. Introducción

El Análisis de Correspondencia (AC), está considerada dentro de los métodos de interdependencia. Es una técnica similar al análisis factorial con la diferencia que es aplicado a variables no métricas (variables cualitativas o categóricas). El AC, describe las dimensiones estructurales de las variables cualitativas utilizando la estadística X^2 como la forma de medir las distancias, en lugar de métricas euclidianas.

El objetivo del AC es establecer relaciones entre variables categóricas dispuestas en una tabla de contingencia para analizar e interpretar la estructura de las relaciones internas entre los diferentes atributos de las variables. El AC, es utilizado también como un método de extracción de variables no observables (factores). La Inercia permite medir el grado de dispersión o variancia que será explicado por los factores seleccionados.

2.1 Prueba estadística preliminar

Probar si dos variables cualitativas dispuestas en una tabla de contingencia están relacionadas o no.

1) Formulación de hipótesis.

Hp: Las dos variables son independientes

Ha: Las dos variables no son independientes

2) Prueba estadística de Chi-Cuadrado

$$\chi_c^2 = \sum_{i=1}^{r}\sum_{j=1}^{c}\left[\frac{\left(O_{ij}-E_{ij}\right)^2}{E_{ij}}\right]$$

Frecuencia esperada:

$$E_{ij} = \frac{O_{i.}O_{.j}}{O..}$$

Frecuencia observada: O_{ij}

3) Decisión estadística. Si $\chi_c^2 \geq \chi^2_{(1-\alpha),(r-1)(c-1)gl}$ entonces se rechaza la Hp.

2.2 Análisis de correspondencia simple

1) Formulación del ACS

La matriz de datos para el ACS se presenta en una tabla de contingencia. Sea las variables I (en fila) con n modalidades y la variables J (en columna) con p modalidades. Entonces las frecuencias absolutas se presenta en la siguiente tabla de contingencia.

J / I	1	2	. . .	j	. . .	p	Total Fila
1							$k_{1\bullet}$
2							$k_{2\bullet}$
.							
i				k_{ij}			$k_{i\bullet}$
.							
n							$k_{n\bullet}$
Total Columna	$k_{\bullet 1}$	$k_{\bullet 2}$		$k_{\bullet j}$		$k_{\bullet p}$	k

k_{ij} Es el número de observaciones que tiene la modalidad *i* de la variable I y modalidad *j* de la variable J

$k_{i\bullet} = \sum_j k_{ij}$ Número total de observaciones de la fila i

$k_{\bullet j} = \sum_i k_{ij}$ Número total de observaciones de la columna j

$k = \sum_i \sum_j k_{ij}$ Número total de observaciones

2.2 Análisis de correspondencia simple

2) Tablas de perfiles de filas y columnas

La *Tabla de perfiles de filas* o columnas muestra las frecuencias relativas de cada celda con respecto a su total de su fila o columna

Perfiles de fila:

$$f_{ij} = \frac{k_{ij}}{k_{i\bullet}}$$

Perfiles de columna:

$$f_{ij} = \frac{k_{ij}}{k_{\bullet j}}$$

La masa de fila o columna (frecuencia marginal de fila o columna), es la frecuencia relativa del total de fila o columna con respecto al total de observaciones.

Masa de fila:

$$f_{i\bullet} = \frac{k_{i\bullet}}{k} = \sum_{j} f_{ij}$$

Masa de columna:

$$f_{\bullet j} = \frac{k_{\bullet j}}{k} = \sum_{i} f_{ij}$$

2.2 Análisis de correspondencia simple

3) Inercia de filas y columnas

La inercia (variancia) se mide a través de la distancia que existe entre una fila o columna con respecto a su centro de gravedad (su media).

La distancia de cada fila o columna a su centro de gravedad (media): G_f o G_c

$$d^2(i,G_f)=\sum_{j=1}^{p}\frac{1}{f_{\bullet j}}\left(\frac{f_{ij}}{f_{i\bullet}}-f_{\bullet j}\right)^2 \qquad d^2(i,G_c)=\sum_{i=1}^{n}\frac{1}{f_{i\bullet}}\left(\frac{f_{ij}}{f_{\bullet j}}-f_{i\bullet}\right)^2$$

La inercia de las filas o columnas es la suma de las distancias de cada punto respecto al centro de gravedad ponderada por la masa de cada columna o fila.

$$I=\sum_i f_{i\bullet}d^2(i,G_f)=\sum_i f_{i\bullet}\sum_j\frac{1}{f_{\bullet j}}\left(\frac{f_{ij}}{f_{i\bullet}}-f_{\bullet j}\right)^2=\sum_{i,j}\frac{(f_{ij}-f_{i\bullet}f_{\bullet j})^2}{f_{i\bullet}f_{\bullet j}}$$

2.2 Análisis de correspondencia simple

4) Matriz de inercia para filas y columnas

La matriz de inercia o dispersión para las filas y para las columnas, contienen en su diagonal las inercias de filas o columnas y el resto de elementos representan las respectivas covariancias.

$V_f = X'X$ el espacio de puntos se define $i \; en \; R^p$

$V_c = X'X$ el espacio de puntos se define $j \; en \; R^n$

Donde los elementos de la matriz: $$X_{ij} = \frac{f_{ij} - f_{i\bullet} f_{\bullet j}}{\sqrt{f_{i\bullet} f_{\bullet j}}}$$

Las matrices de inercia son simétricas y son las que se diagonalizan (autovalores y autovectores) para obtener los factores.

2.2 Análisis de correspondencia simple

5) Interpretación de ACS

- **Diagonalización de la matriz de inercia**

  El propósito de diagonalizar las matrices de inercia es para obtener los valores y vectores propios. La traza de las matrices de inercia vienen a ser las variancias de las filas o columnas y la suma de ellas es la inercia o dispersión que es explicada por las nuevas variables (factores).

- **Representación Gráfica de filas y columnas**

  Para representar e interpretar las distancias entre filas y columnas, se utilizan los llamados ***mapas simétricos***. Estos mapas permiten visualizar mejor las posiciones de las filas y columnas para llevar a cabo una interpretación de los ejes.

- **Contribución absoluta de una categoría a un factor.**

  Es la proporción de inercia explicada por un factor debido a una fila o a una columna. Esto es, el porcentaje de inercia que cada categoría aporta a cada uno de los factores.

- **Contribución relativa de un factor a una categoría.**

Indica la proporción de la inercia de la categoría explicada por un factor.

2.2 Análisis de correspondencia simple

6) Ejemplo de aplicación del ACS

Se hizo un estudio, con estudiantes de pregrado, para determinar la correspondencia que puede existir entre el promedio general de sus calificaciones (A, B, C, D y E) y el número de horas semanales que pasa viendo TV o chateando (H1= <5 h, H2=5-10 h, H3=11-20 h y H4= +de 20 h).

2.2 Análisis de correspondencia simple

Tabla de contingencia

Tabla de correspondencias						
	Calificacion					
Horas	A	B	C	D	E	Margen activo
H1	13	10	11	16	5	55
H2	20	27	27	19	2	95
H3	9	27	71	16	32	155
H4	8	11	41	24	11	95
Margen activo	50	75	150	75	50	400

2.2 Análisis de Correspondencia Simple

- Se quiere saber si existe relación entre el nivel de ingresos y características de las viviendas entrevistadas en la encuesta nacional de hogares realizada por el Instituto Nacional de Estadística e Informática (INEI) en el año 2009. Los datos que se usarán para el análisis corresponden a los resultados obtenidos de la encuesta nacional de hogares (ENAHO), en la sección "Características de la vivienda y del hogar". Ya que esta encuesta abarca todos los departamentos del Perú, se escogió para el análisis únicamente el Departamento de Huancavelica. Con los datos hallados haga el Análisis de Correspondencia Simple.

2.2 Análisis de Correspondencia Simple

Nivel de ingresos y características de las viviendas en Huancavelica

Tabla de correspondencias

	ingreso de los encuestados					
tipo de pared exterior	[0-550]	[551-800]	[801-1200]	[1201-2000]	[mas de 2000]	Margen activo
Ladrillo o bloque	3	5	9	19	47	83
Piedra o sillar	6	9	13	19	23	70
Adobe	9	13	15	14	9	60
Tapia	24	32	34	36	25	151
Quincha	8	9	7	6	4	34
Piedra con barro	28	30	28	23	15	124
Madera	24	22	20	16	7	89
Estera	39	31	24	16	6	116
Otros	9	7	5	2	1	24
Margen activo	150	158	155	151	137	751

2.3 Análisis de correspondencia múltiple

Formulación del ACM

Para el ACM se tienen n individuos, s variables categóricas y p categorías (que es la suma de todas las categorías de las s variables).

Se construye una tabla binaria representada por Z (contiene 0 y 1) de n individuos y p categorías que tiene el nombre de tabla disyuntiva completa y es una yuxtaposición de s tablas. La tabla contiene n*s ceros o unos. Los marginales fila serán 1/n y los marginales columna son nj/(n*s) donde nj es el número de individuos que asumen la categoría j (nj se obtiene de la matriz de Burt)

También se construye la tabla de Burt o tabla de contingencias múltiples que se obtiene de la siguiente manera B=Z'Z, que es simétrica y cuadrada de orden p*p. B es una yuxtaposición de tablas de contingencia cruzando todas las variables por parejas y en la diagonal tiene matrices diagonales con las frecuencias de las categorías de la respectiva variable.

Ejemplo: Admitidos a una universidad

- Se hizo un estudio con 445 admitidos a una universidad de Colombia en el ciclo 2013-I. Se aplicó el ACM para establecer la correspondencia entre las variables: Género, Edad, Estrato y Procedencia.

Variables categóricas y sus categorías

- 1. **Género**: femenino, masculino.
- 2. **Edad**: 16 o menos, 17, 18, 19 o más.
- 3. **Estrato**: bajo, medio, alto;
- 4. **Procedencia**: Bogotá, Cundinamarca, otro.

Se tienen 4 variables que en total suman 12 categorías.

Ejercicio de Aplicación del ACM

Se tiene una investigación con una muestra de 50 personas. El estudio tiene como propósito detectar correspondencias entre las variables: estado civil, sexo y lo que más le preocupa. Ver el archivo **Aplicación-ACM1**

Variables y sus categorías del ejercicio del ACM

Estado Civil:

1. Soltero
2. Casado
3. Otro

Aspecto que más le preocupa:

1. Su vida afectiva
2. El dinero
3. Armonía familiar
4. Su salud

Sexo

1. Hombre
2. Mujer

FAMD: Análisis Factorial con Datos Mixtos

- El FAMD combina el Análisis Factorial con el Análisis de Correspondencia Múltiple.
- Ver el Script: Factorial_Datos_Mixtos.R