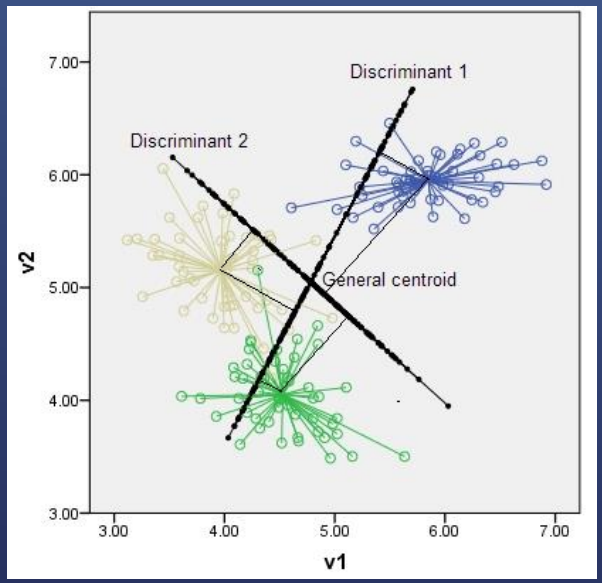
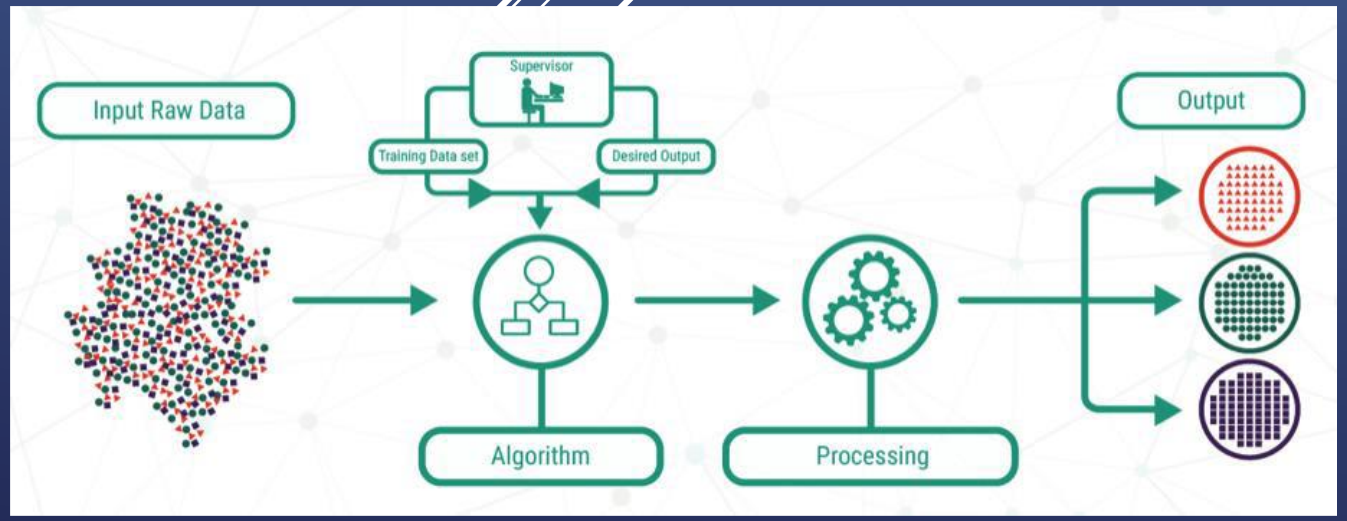
ANÁLISIS DISCRIMINANTE

Mg.Sc. Fernando Miranda V.

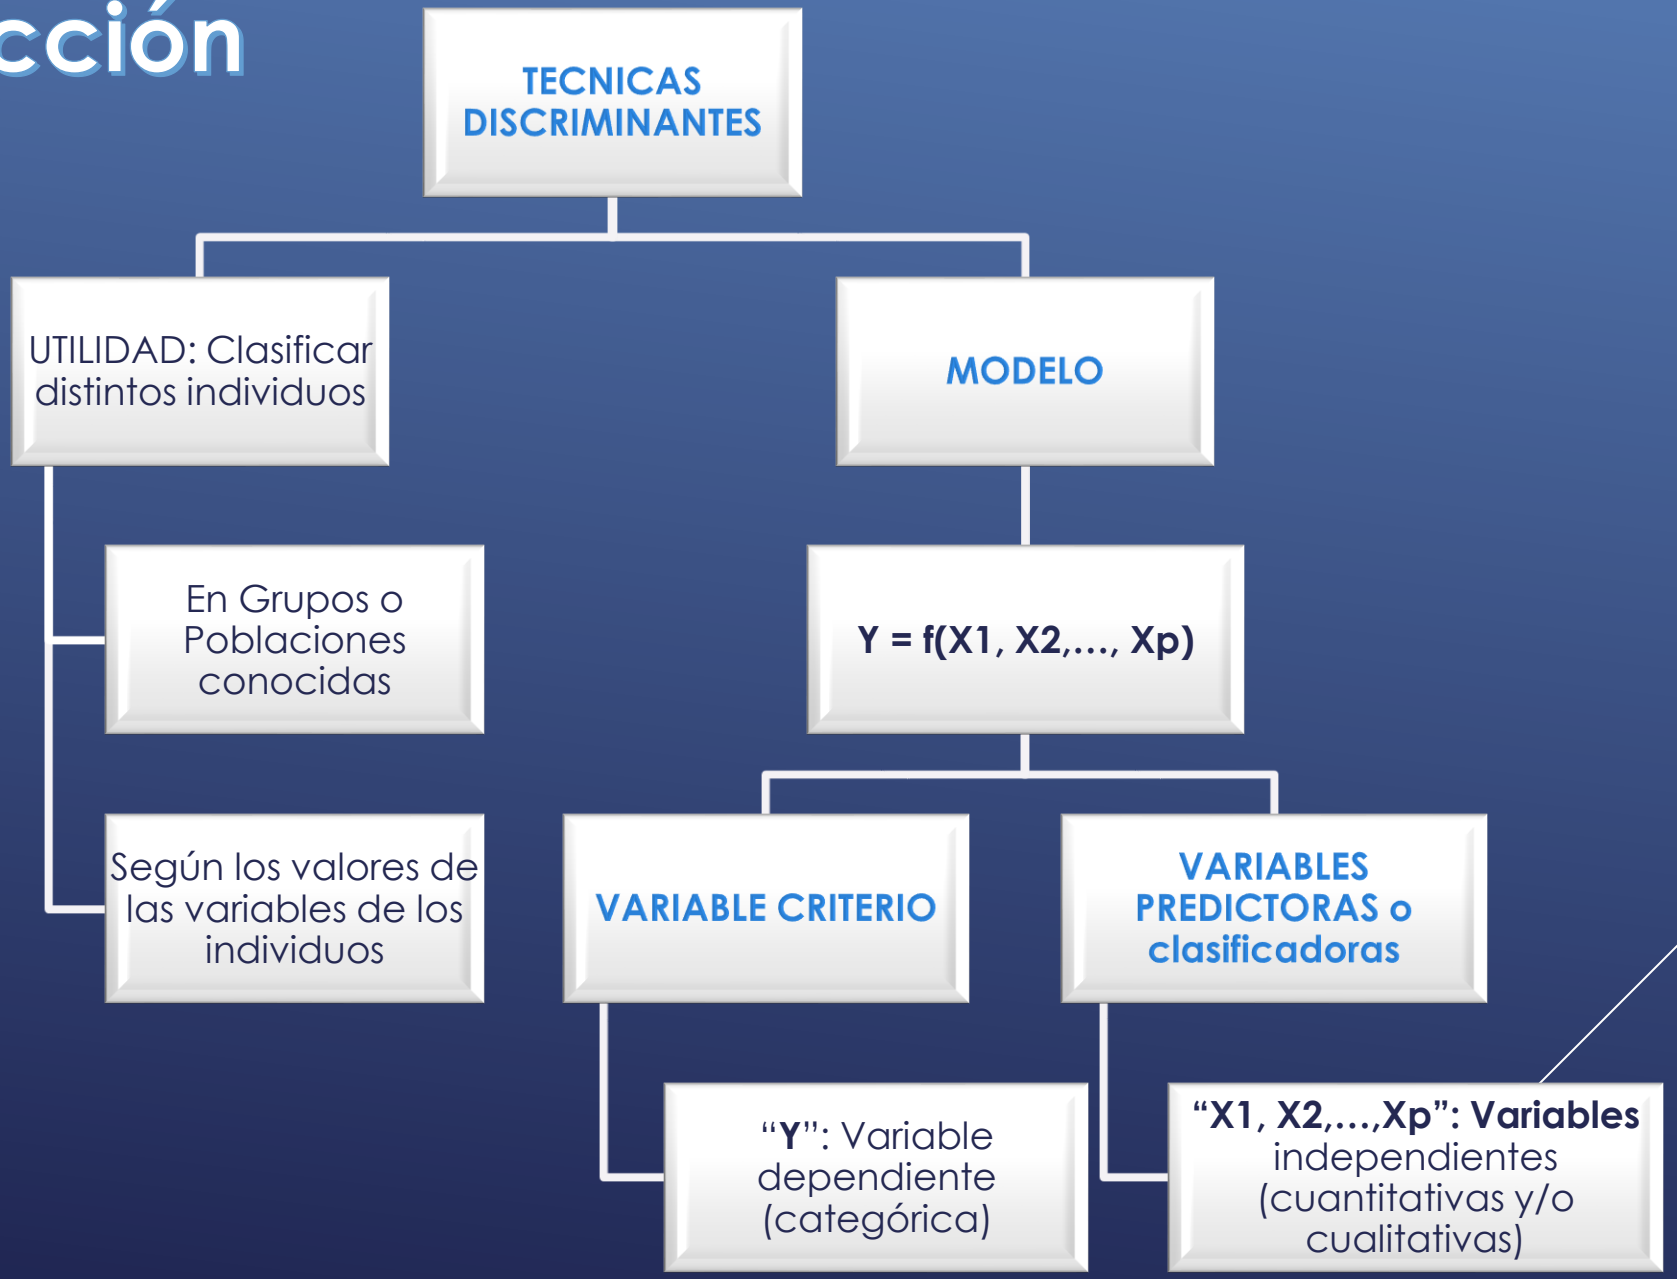
cfmiranda@lamolina.edu.pe



Técnicas discriminantes



Introducción



Finalidad de las TD

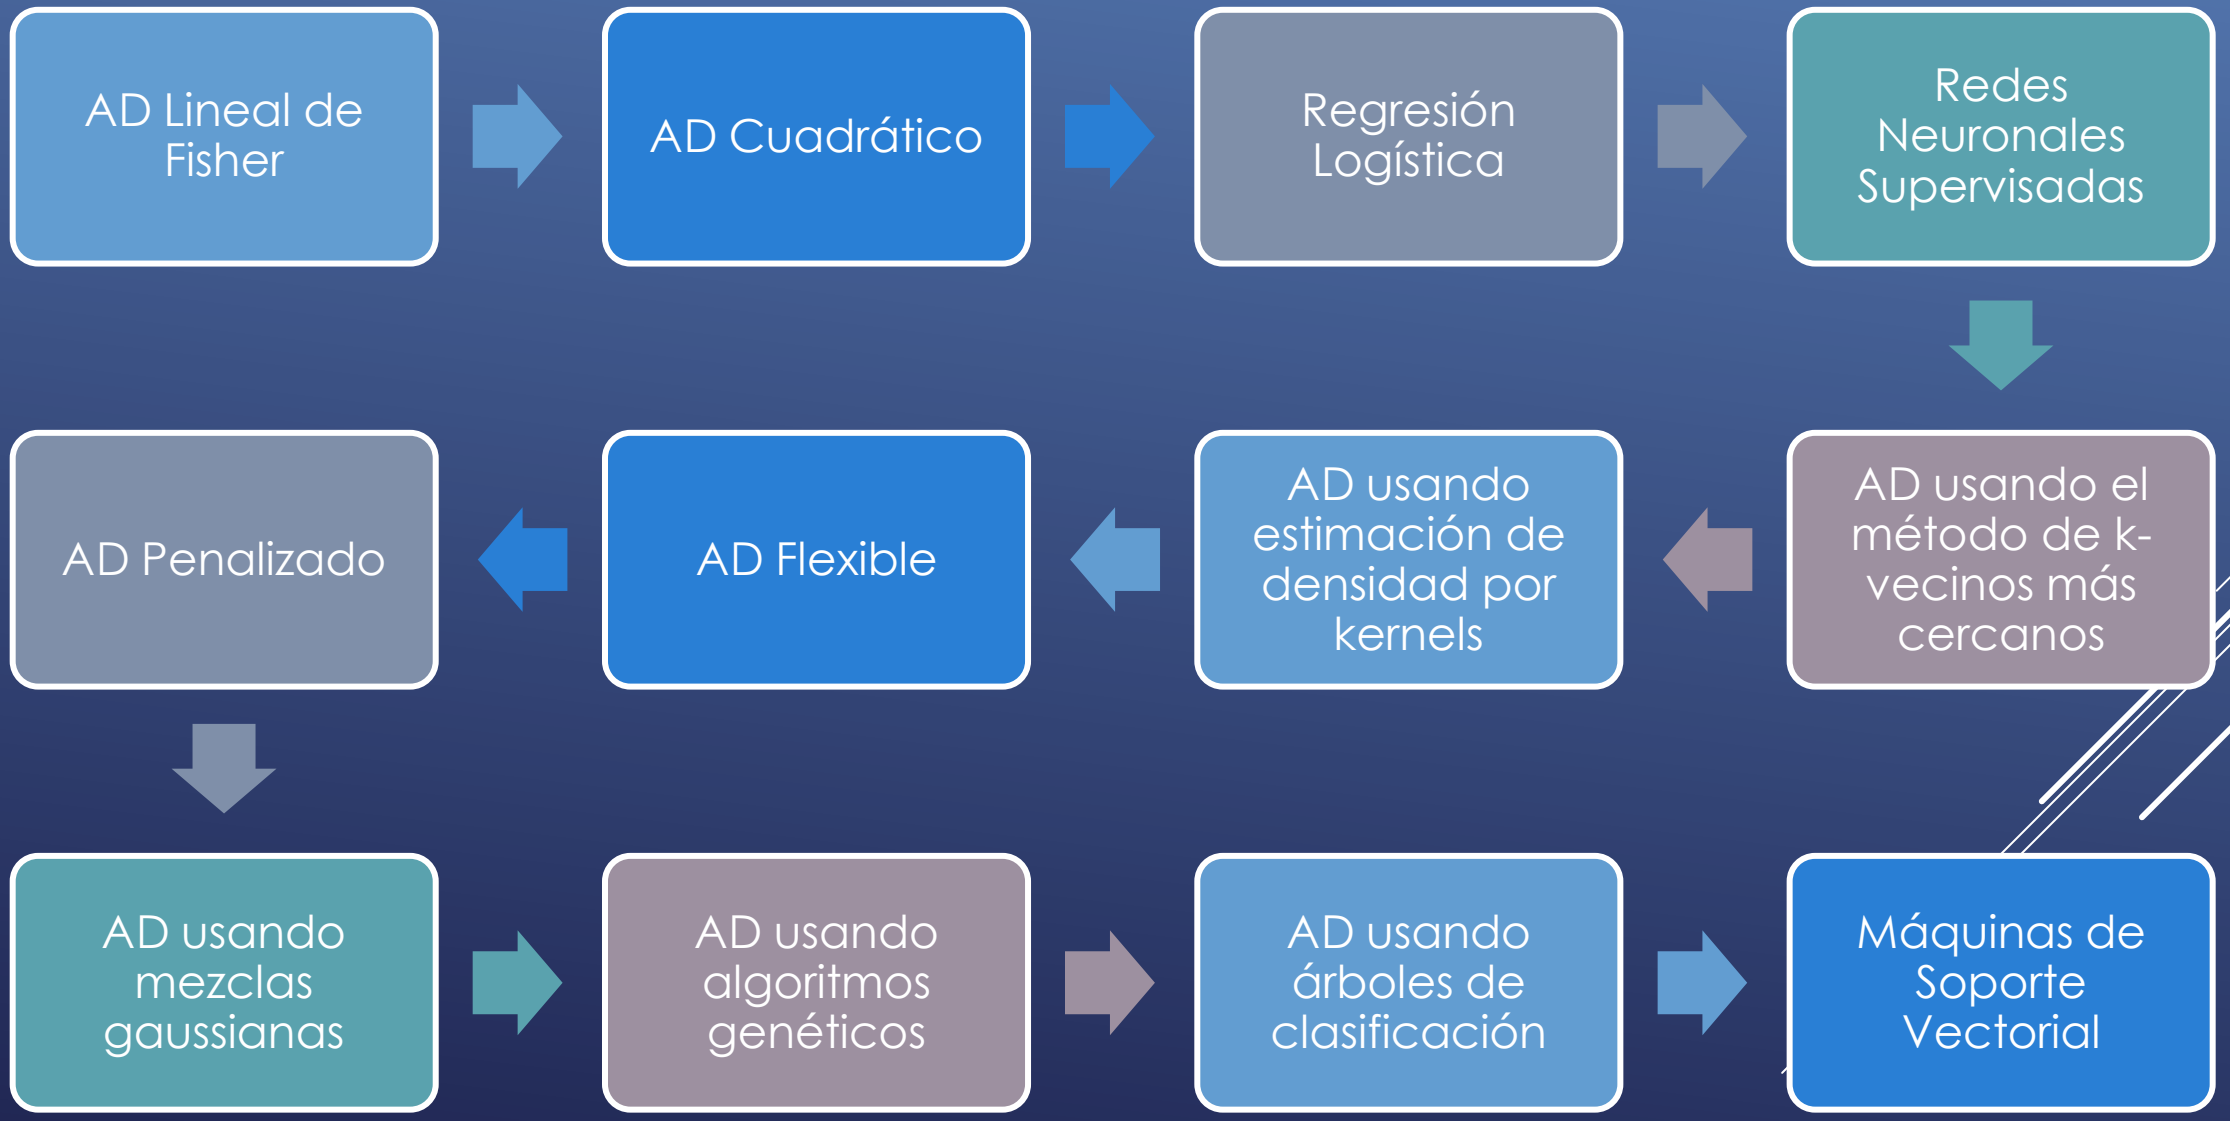
EXPLICATIVA

Se trata de determinar la contribución de cada variable predictora a la clasificación correcta de cada uno de los individuos.

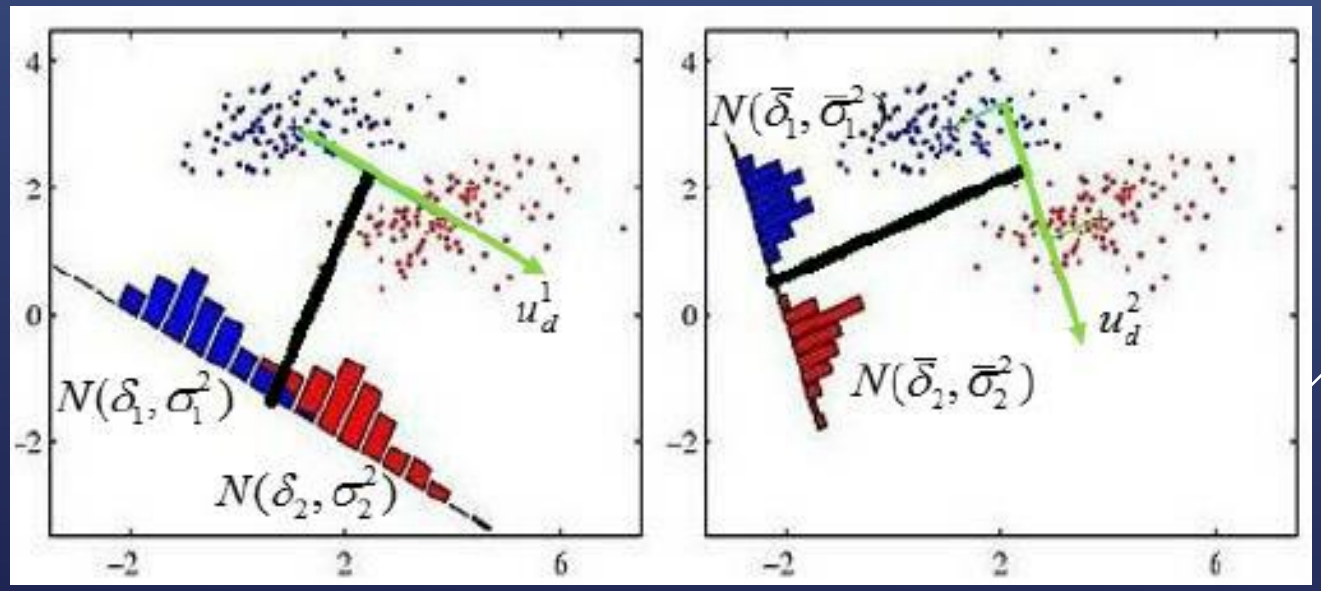
PREDICTIVA

Se trata de determinar el grupo al que pertenece un individuo para el que se conocen los valores que toman las variables predictoras.

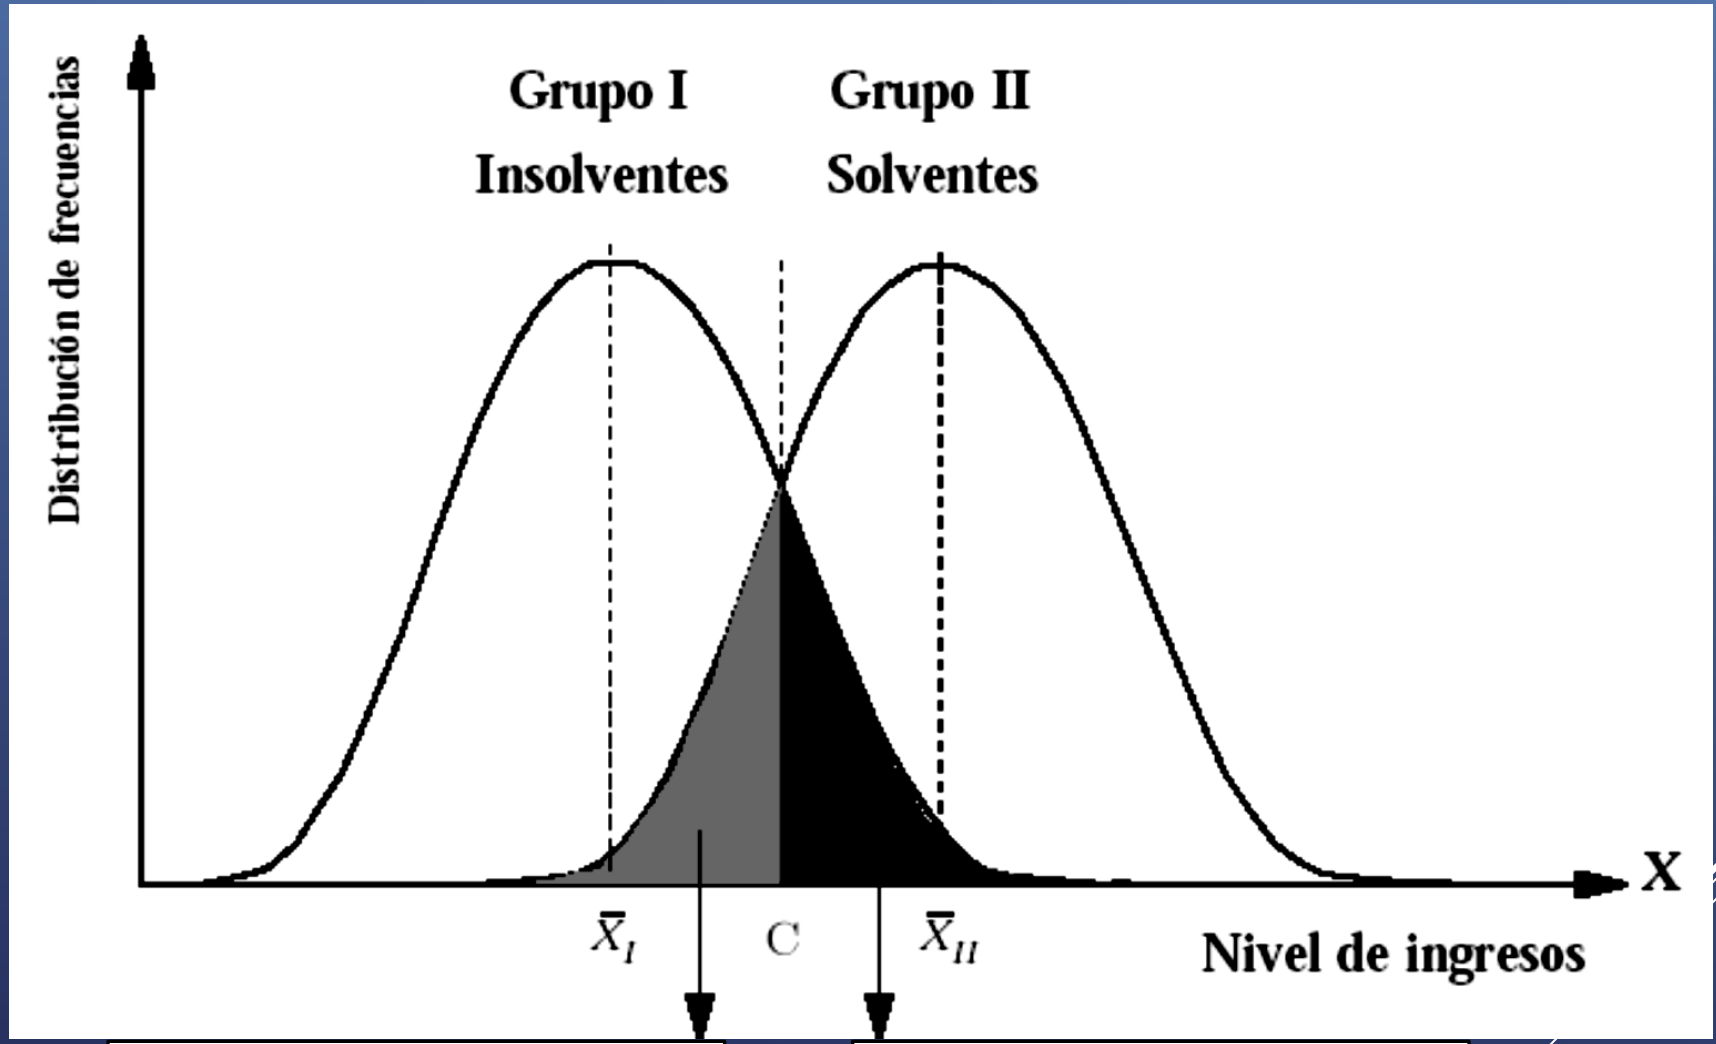
Principales Técnicas Discriminantes



Análisis Discriminante Lineal



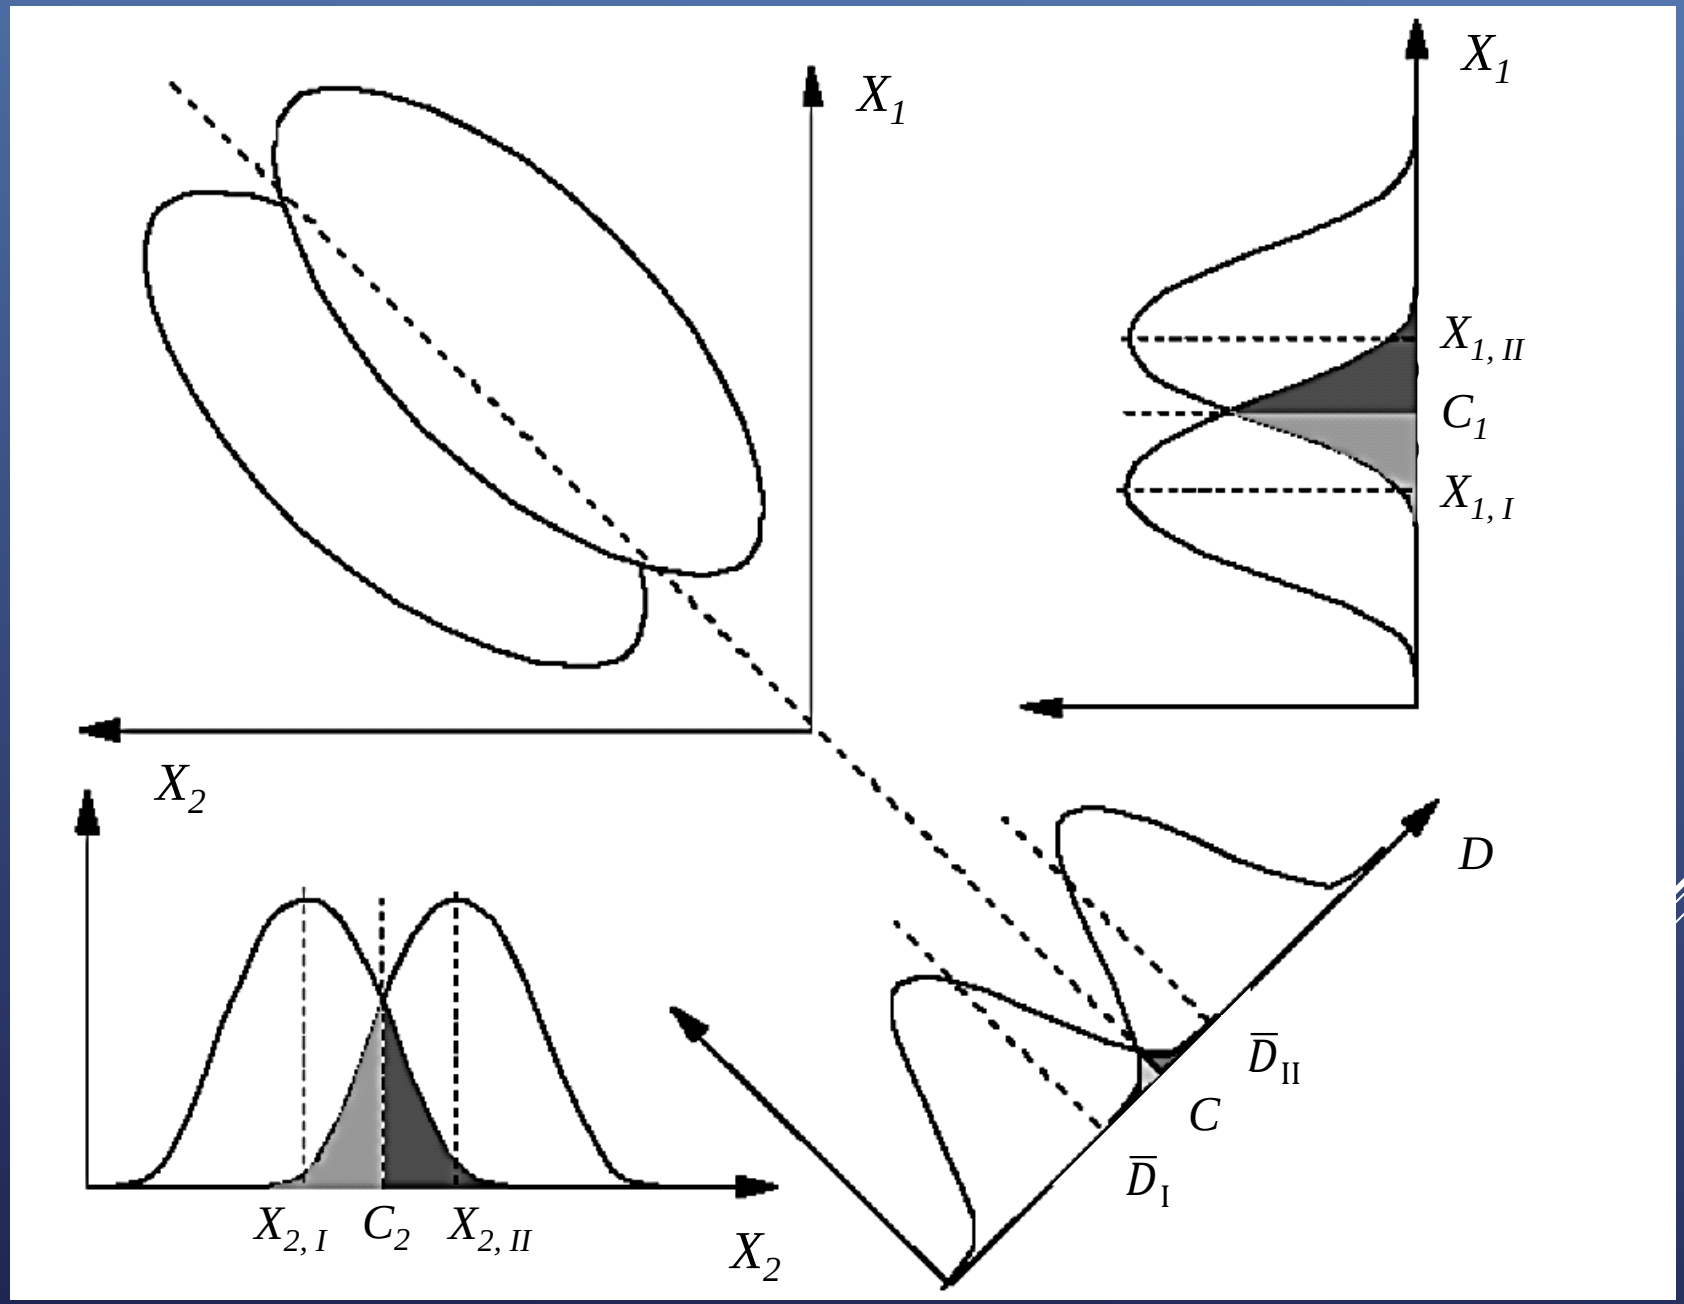
Funciones de Distribución hipotéticas de dos grupos



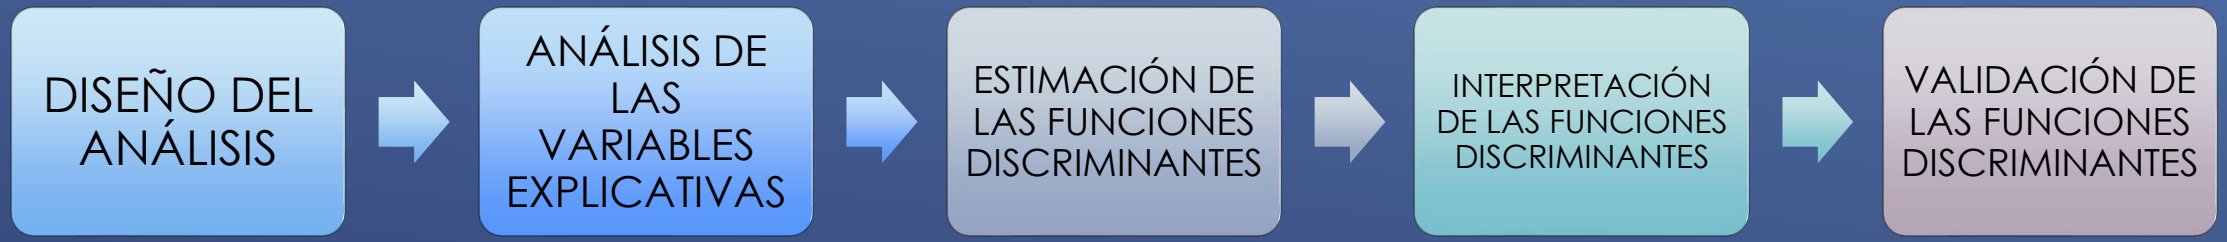
Miembros del Grupo II, incorrectamente clasificados como del Grupo I.

Miembros del Grupo I, incorrectamente clasificados como del Grupo II.

Análisis discriminante de dos variables explicativas



Esquema metodológico del AD Lineal



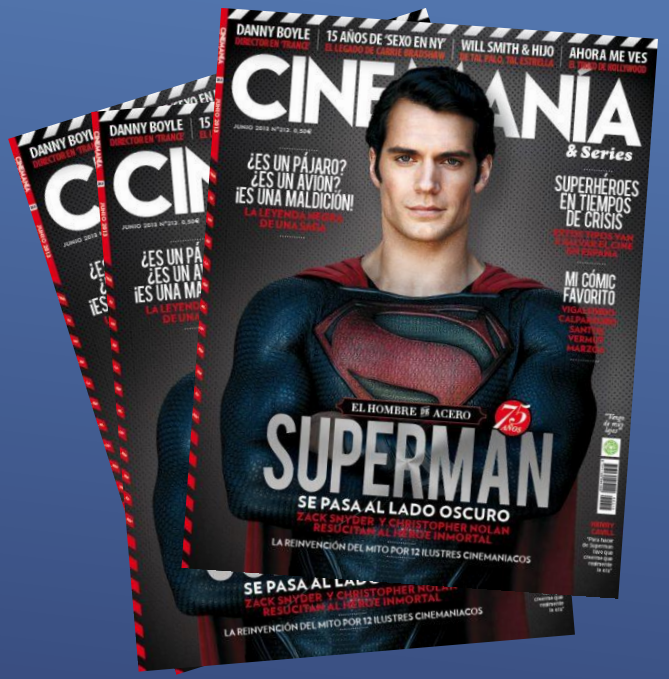
¿Cuál es el proceso utilizado en la obtención de las funciones discriminantes?

¿Cuál es el nivel explicativo de las funciones discriminantes?

¿Cuáles son las variables explicativas diferenciadoras?

¿Cuál es el perfil de cada grupo?

Ejemplo de Aplicación: Suscripción a revista de cine



- La compañía de cable edita y promociona una revista de cine (de edición mensual) a un grupo (442) de sus suscriptores durante 6 meses.
- Al cabo de dicho periodo le ofrece la posibilidad de suscribirse a dicha revista.
- De los 442 clientes a los que se ofreció la promoción, se suscribieron a la revista 329 y no se suscribieron 113.

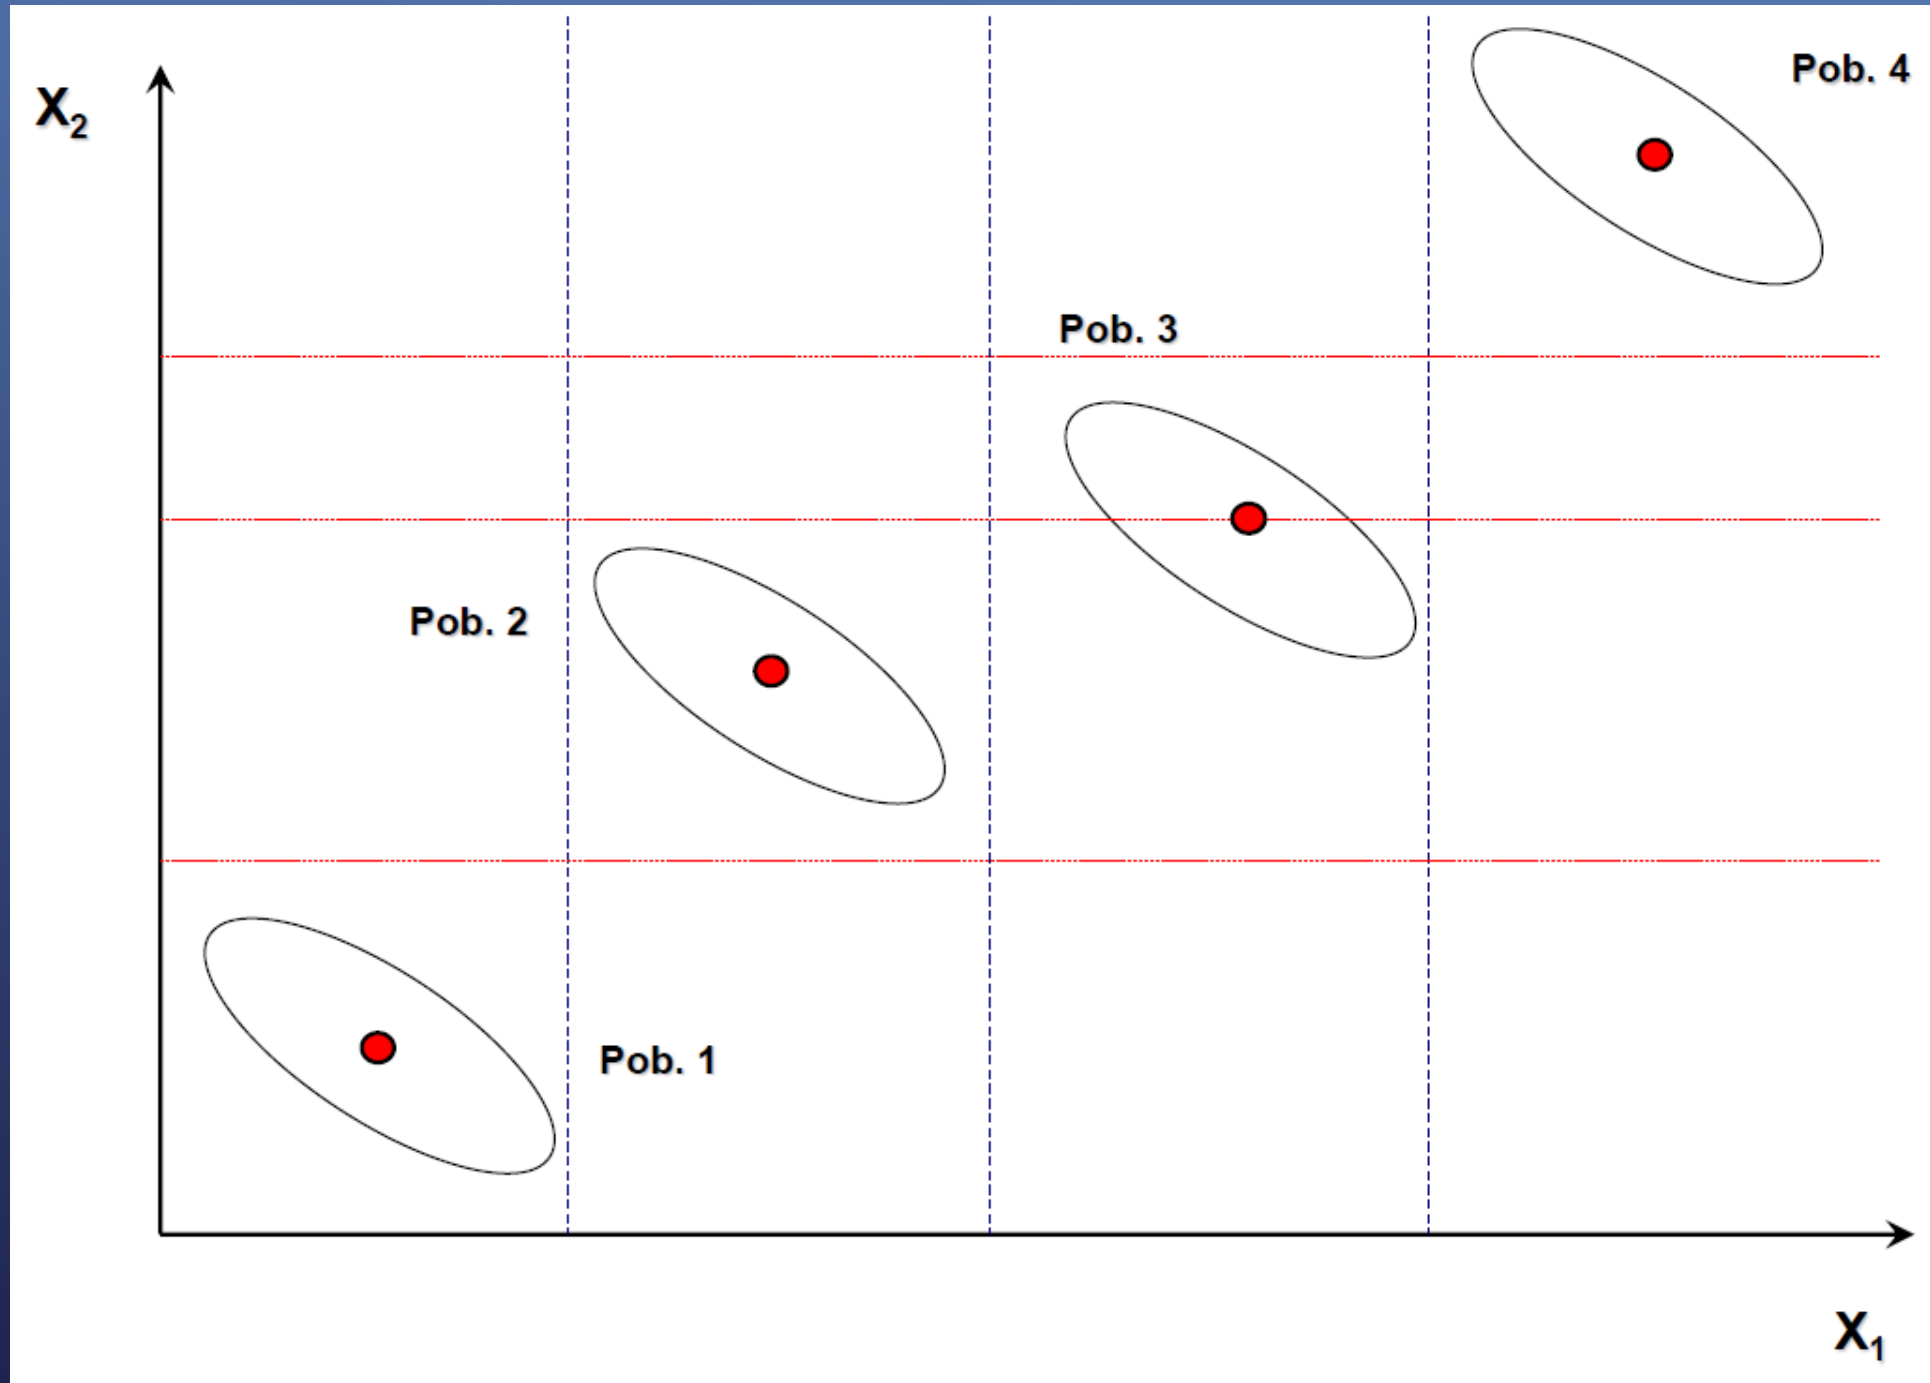


VARIABLE	DESCRIPCIÓN
Educación	Educación en años
Edad	Edad en años
Tvdiario	Horas de TV al día durante los fines de semana
Organizaciones	Número de clubes al que pertenece
Hijos	Número de hijos
Suscripción	Decisión de suscribirse

Consideraciones en la selección de variables

Dallas, 2000:

- Los **métodos de selección** se basan en pruebas acerca de las medias de los grupos sobre las variables candidatas y **las poblaciones pueden tener media diferentes y, sin embargo, traslaparse.**
- El que las **variables discriminen bien** no depende de si las medias son diferentes, sino **de si las poblaciones se traslapan**.
- Sólo porque las poblaciones tengan media diferentes en más de una variable **no se concluye la necesidad que se requerirán todas las variables para discriminar adecuadamente.**


X2
Pob. 4
Pob. 3
Pob. 2
Pob. 1
X1

LAMBDA DE WILKS

$$\Lambda = \frac{SCIntragrupos}{SCEntregrupos + SCIntragrupos}$$

La variable que se incluye es la que minimiza la lambda, sin tener en cuenta el efecto de las variables que hayan podido entrar en el modelo

Estimación de la función discriminante

Obtención de la ecuación asociada a cada función discriminante

Si la variable a explicar es de m grupos, el AD calcula m-1 funciones discriminantes

$$Z_i = b_o + b_1 X_{1i} + \ldots\ldots + b_p X_{pi}$$

Estimación Coeficientes discriminantes B_p

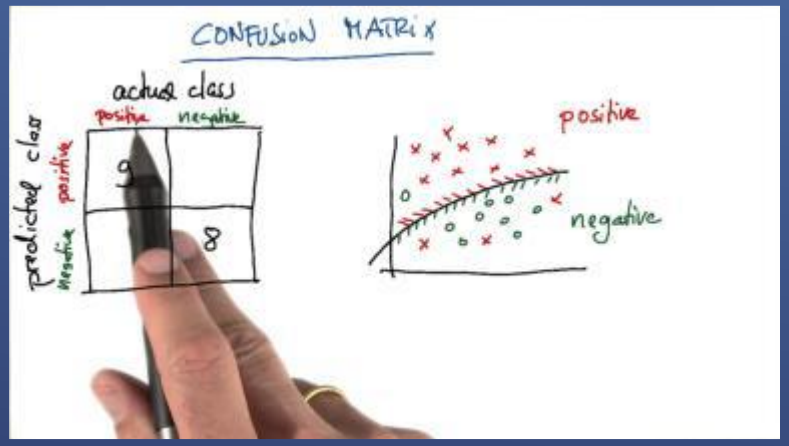
Los coeficientes se estiman teniendo en cuenta que las puntuaciones discriminantes de los individuos de un grupo sean lo más distintas posible de las puntuaciones discriminantes de los individuos de otro grupo.

Esto ocurre cuando el ratio: $SCinter / SCintra$, es máximo.

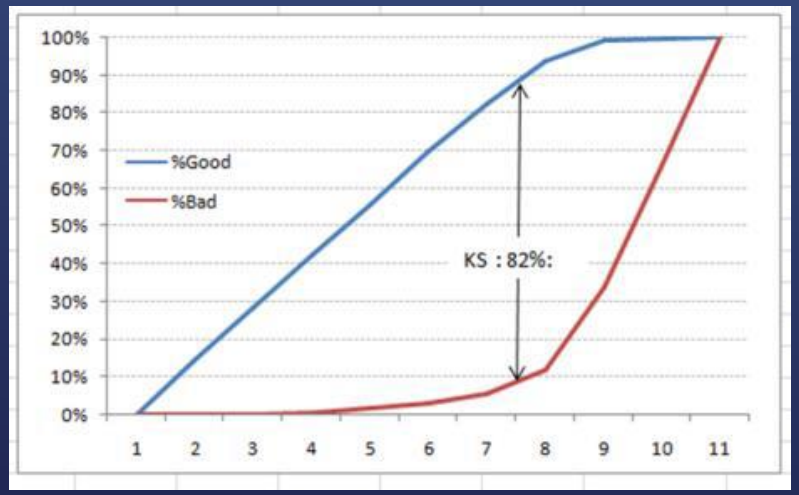
Indicadores para evaluación de modelos de clasificación

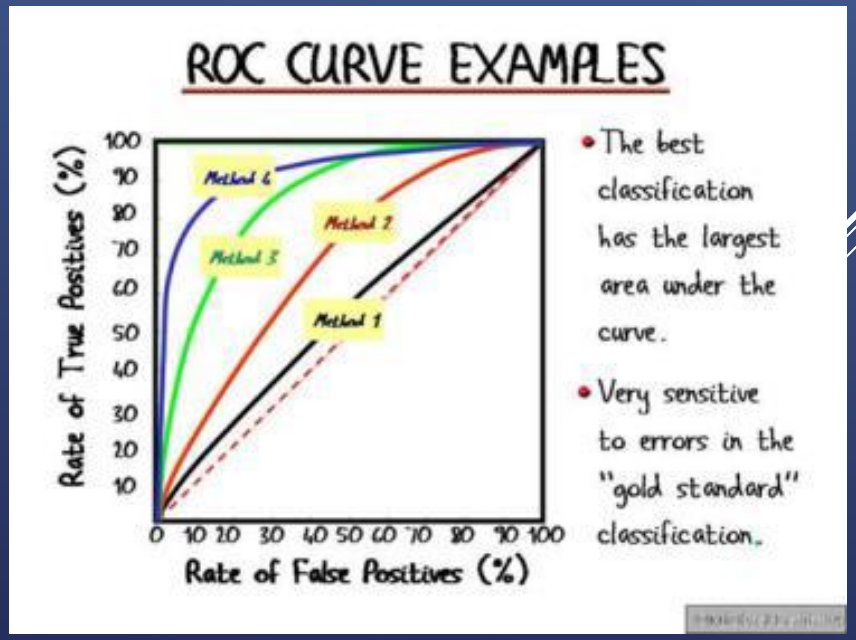


Indicadores para evaluar modelos de clasificación

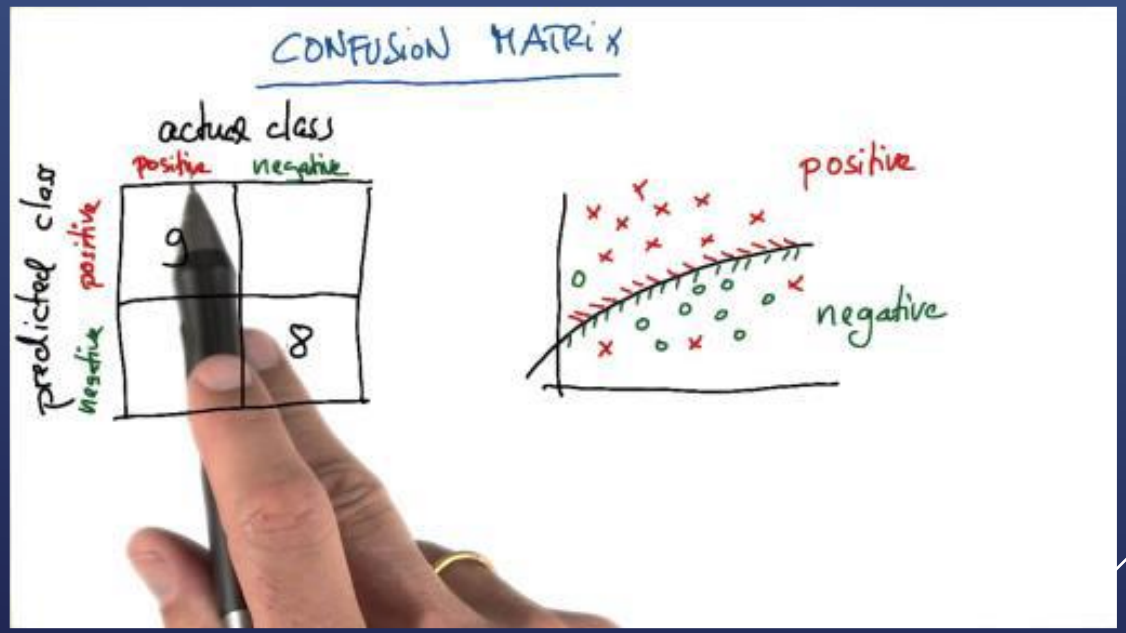


$$\kappa = \frac{Pr(a) - Pr(e)}{1 - Pr(e)}$$

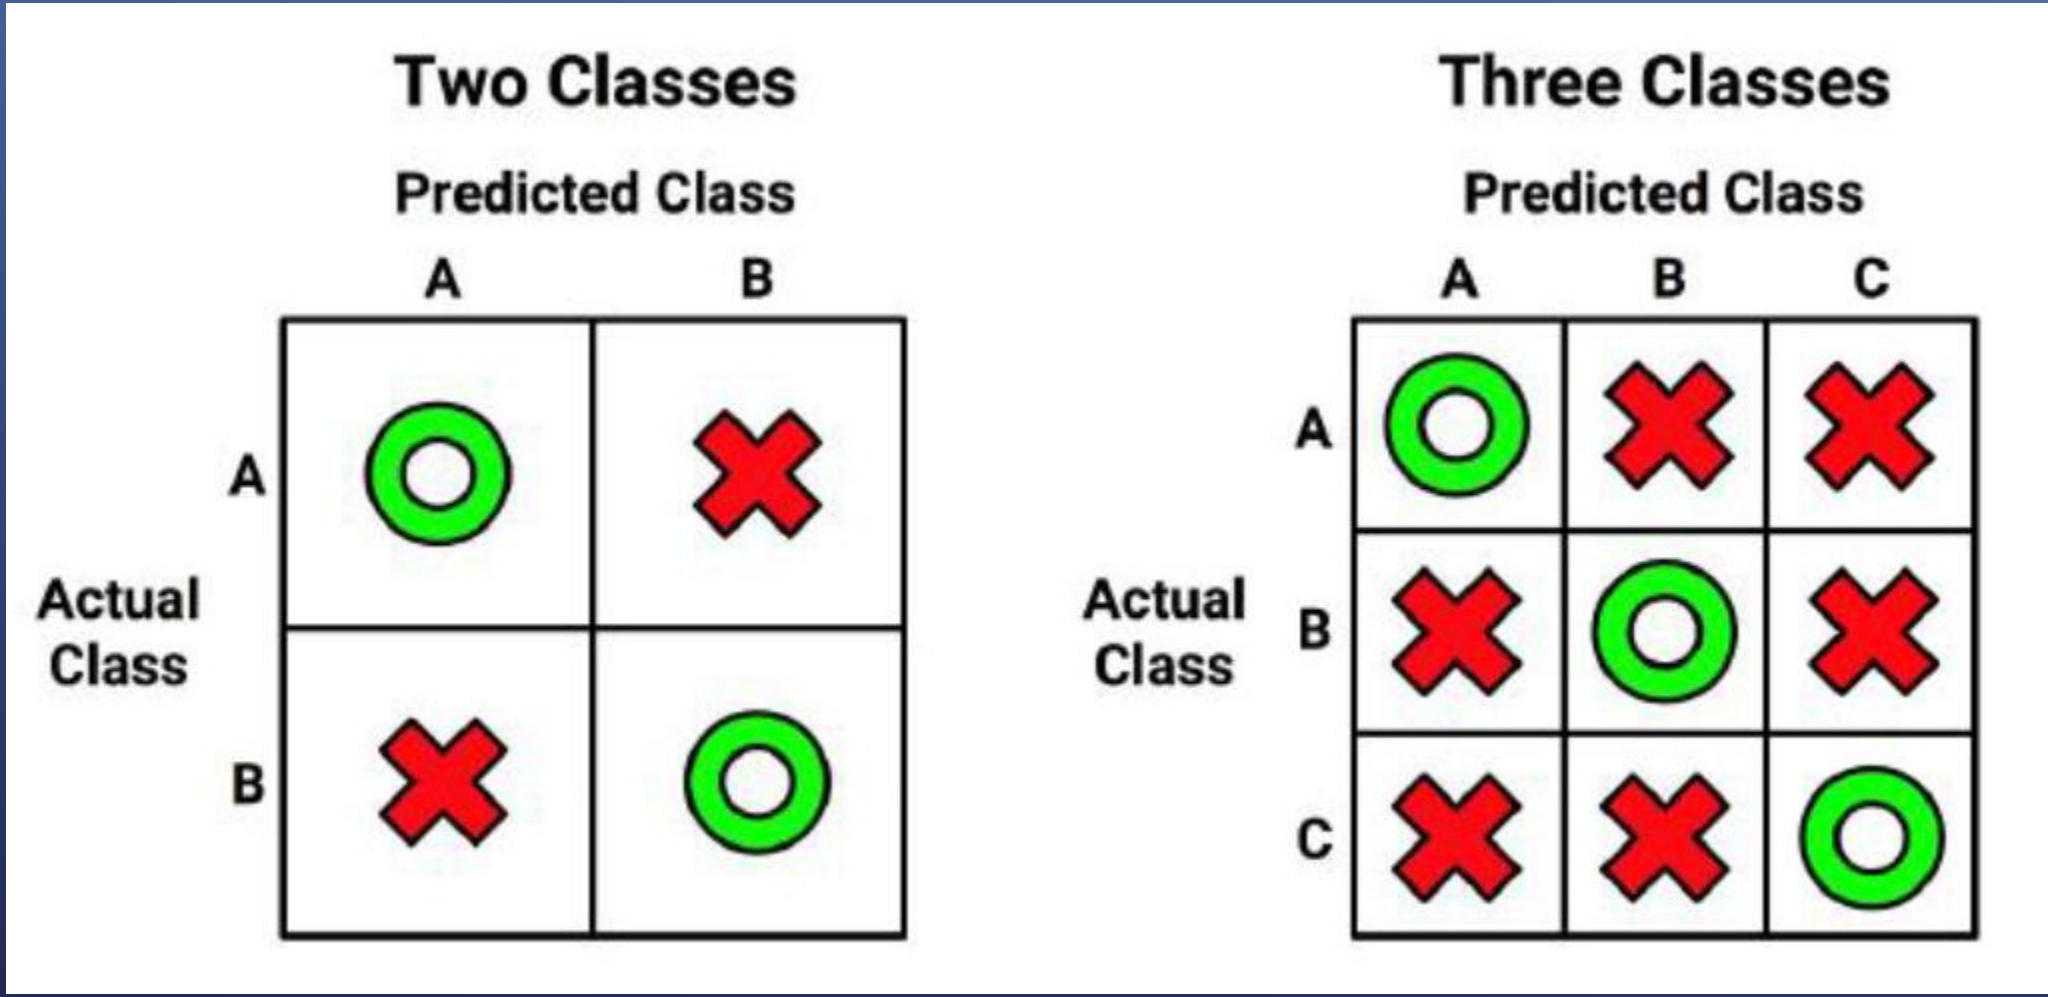




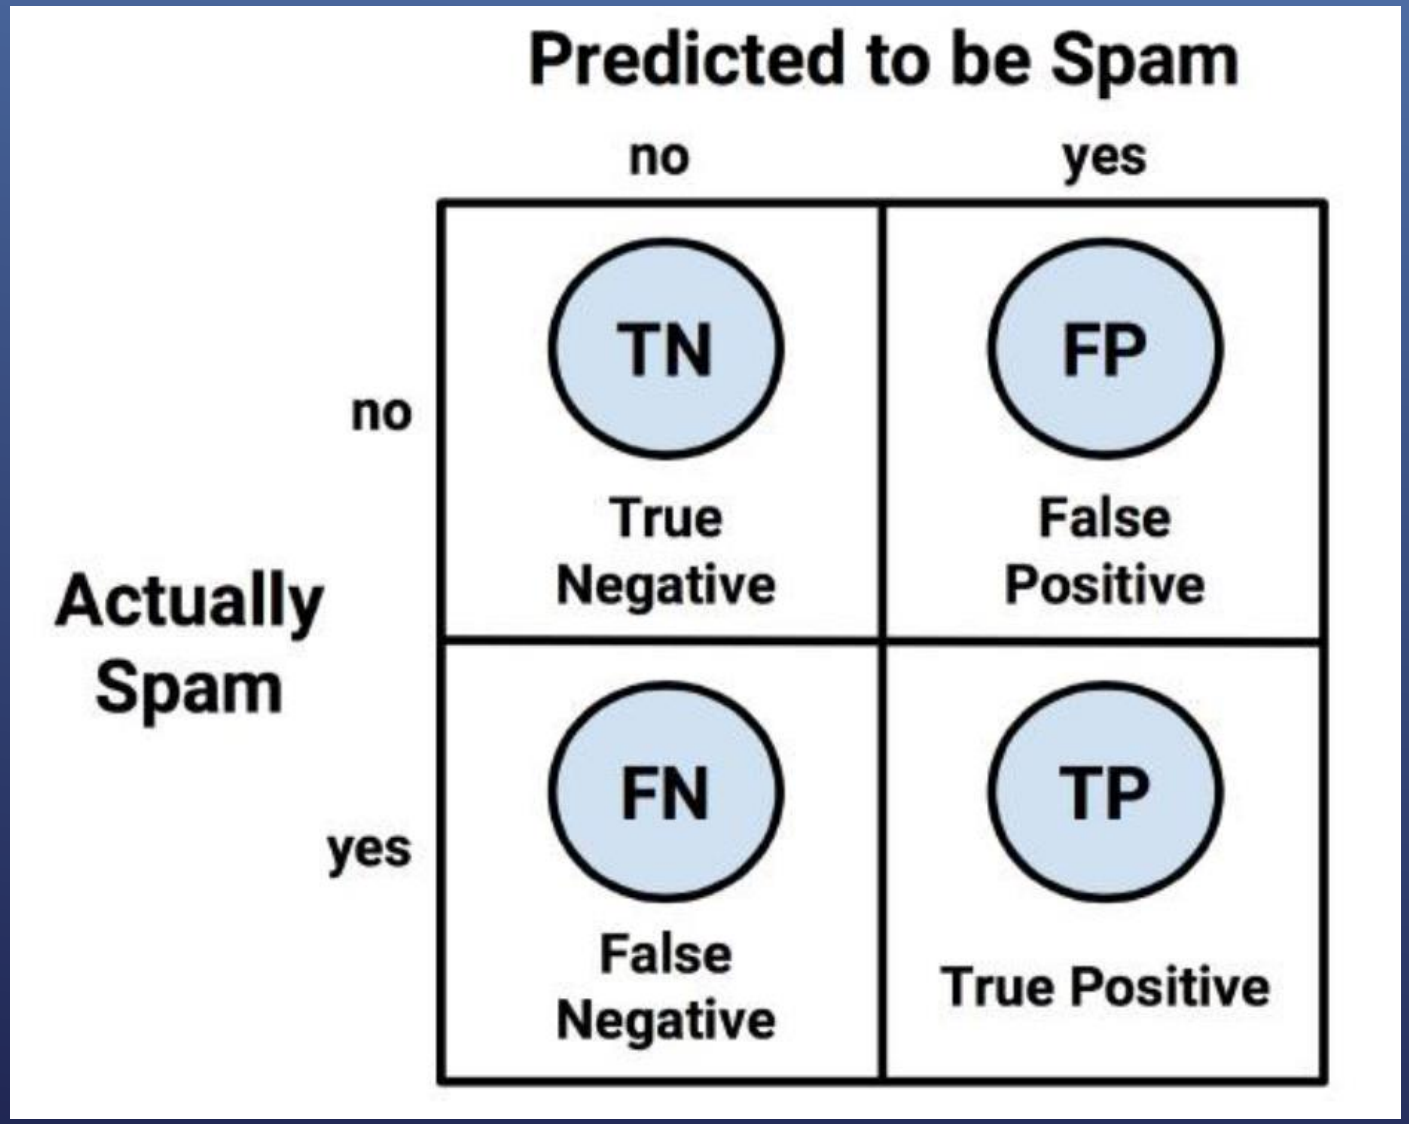
Matriz de Confusión



Matriz de Confusión



Matriz de Confusión



Matriz de Confusión

Clase Real		Clase Predicha: 0	Clase Predicha: 1	
	0	**Verdadero Negativo (VN)**	**Falso Positivo (FP)**	Negativos Reales (VN + FP)
	1	**Falso Negativo (FN)**	**Verdadero Positivo (VP)**	Positivos Reales (FN+VP)
		Negativos Predichos (VN+FN)	Positivos Predichos (FP+VP)	

Matriz de Confusión

Accuracy	• (VP + VN)/Total de casos
Tasa de error	• (FP + FN)/Total de casos • 1 -Accuracy
Sensibilidad	• Verdadero Positivo/Positivos Reales • VP/(FN+VP)
Especificidad	• Verdadero Negativo/Negativos Reales • VN/(VN+FP)
Precisión	• Valor Predictivo Positivo (VP+) • Verdadero Positivo/Positivos Predichos • VP/(FP+VP)
Valor Predictivo Negativo (VP-)	• Verdadero Negativo/Negativos Predichos • VN/(VN+FN)

SENSIBILIDAD Y ESPECIFICIDAD

La **sensibilidad** nos indica la capacidad de nuestro estimador para dar como casos positivos los casos realmente enfermos; proporción de enfermos correctamente identificados. Es decir, la sensibilidad caracteriza la capacidad de la prueba para detectar la enfermedad en sujetos enfermos. A la sensibilidad se le conoce como razón de TP (TPR), o recall, probabilidad de detección, Potencia. Una alta sensibilidad indica algunos FN.

La **especificidad** nos indica la capacidad de nuestro estimador para dar como casos negativos los casos realmente sanos; proporción de sanos correctamente identificados. Es decir, la especificidad caracteriza la capacidad de la prueba para detectar la ausencia de la enfermedad en sujetos sanos. También se le llama razón de verdaderos negativos (TNR) o selectividad. Una alta especifidad indica algunos FP.

FPR: Es el porcentaje de personas sanas quienes fueron incorrectamente identificadas como enfermas. Es lo opuesto al TPR o sensibilidad. También se le llama Error Tipo I o probabilidad de falsa alarma, fall-out.

FNR: Es el porcentaje de personas enfermas quienes fueron incorrectamente identificadas como sanas. FNR es lo opuesto de TNR o especificidad. Se le llama Error Tipo II o Tasa de fallos.

El Error Tipo II es peor que el Error tipo I: se comete Error Tipo I, si a una persona erróneamente se le diagnostica cáncer, pero después de nuevas pruebas y un mayor tiempo resulta que está sana. Aterrador pero no fatal. El Error Tipo II se comete, si la primera prueba de una persona resulta negativa, pero después de nuevas pruebas y un mayor tiempo resulta que está con cáncer avanzado. Muy aterrador y fatal.

Lo ideal es que la sensibilidad y la especificidad sean altas pero frecuentemente esto no es posible. Típicamente hay una compensación, se puede cambiar el umbral dependiendo de nuestro objetivo.

Para no asustar a ninguna persona sana (pocos falsos positivos), necesitamos una prueba muy específica (a menudo la segunda), por lo que aumentamos el umbral. También es importante no gastar mucho dinero, medicamentos raros o cualquier otro recurso en pacientes sanos.

RAZÓN DE FALSOS POSITIVOS (FPR), RAZÓN DE FALSOS NEGATIVOS (FNR) Y ERRORES TIPO I Y II

VALORES PREDICTIVOS POSITIVOS O NEGATIVOS

En epidemiología, se denomina **prevalencia** a la proporción de individuos de un grupo o una población (en medicina, personas), que presentan una característica o evento determinado (en medicina, enfermedades). Por lo general, se expresa como una fracción, un porcentaje o un número de casos por cada 10.000 o 100.000 personas.

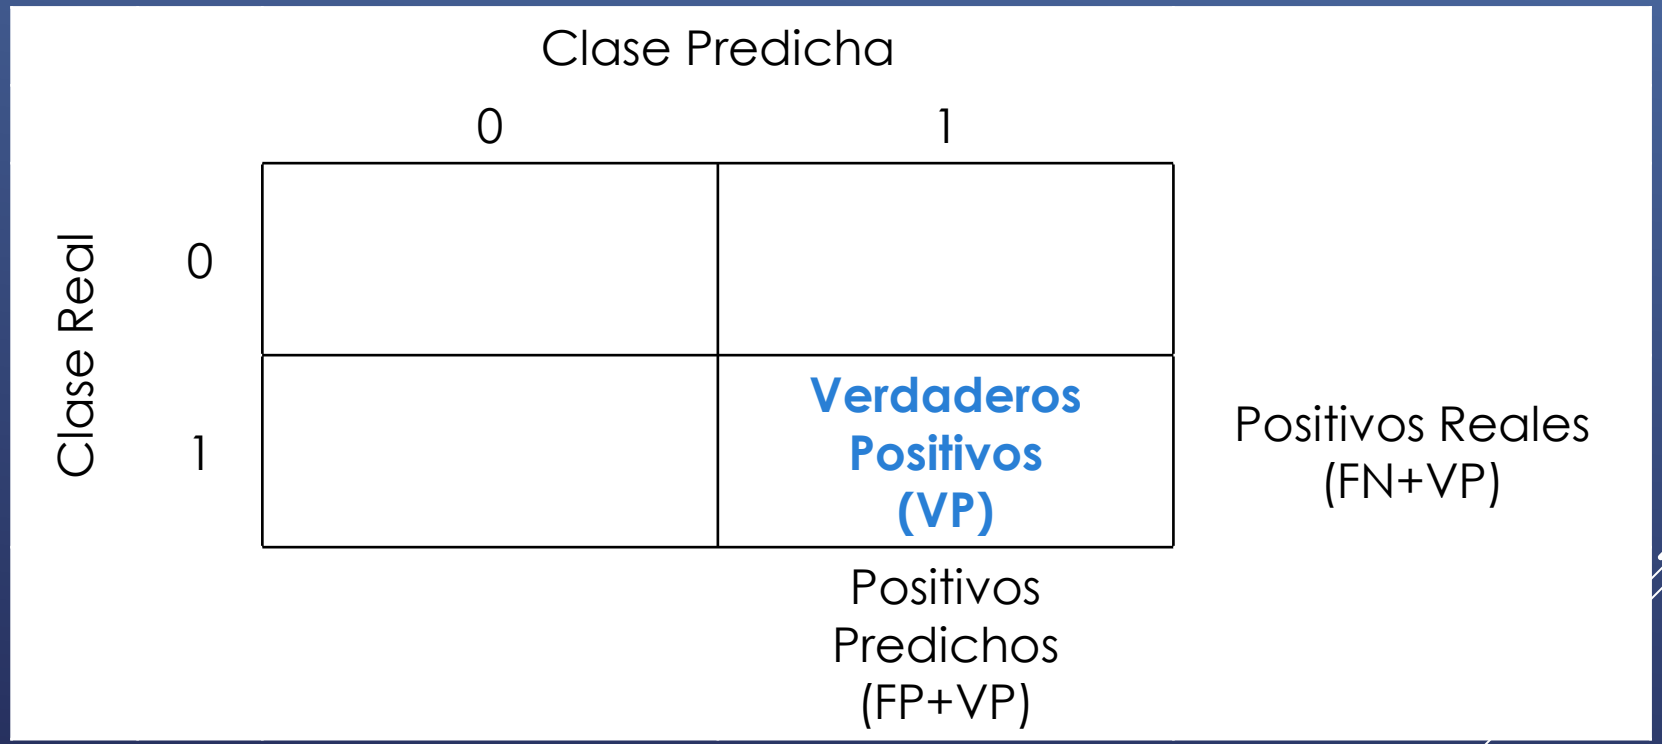
Los **valores predictivos** (positivo y negativo) miden la eficacia real de una prueba diagnóstica. Son probabilidades del resultado, es decir, dan la probabilidad de padecer o no una enfermedad una vez conocido el resultado de la prueba diagnóstica. Se trata de valores post-test y dependen de la prevalencia de una enfermedad, es decir, del porcentaje de una población que está afectada por esa determinada patología.

¿Por qué son útiles los valores predictivos? La sensibilidad, especificidad y AUC (área bajo curva) son valores intrínsecos al test diagnóstico. Esto quiere decir que son valores teóricos, que no varían entre poblaciones y, por tanto, no tienen utilidad práctica por sí solos. En cambio, los valores predictivos (positivo y negativo) son índices que evalúan el comportamiento de la prueba diagnóstica en una población con una determinada proporción de enfermos por lo que sirven para medir la relevancia de la sensibilidad y especificidad en una determinada población.

Sensibilidad y VP+

Valor predictivo positivo (VP+): Verdaderos positivos/positivos predichos

Sensibilidad: Verdaderos Positivos/Positivos reales



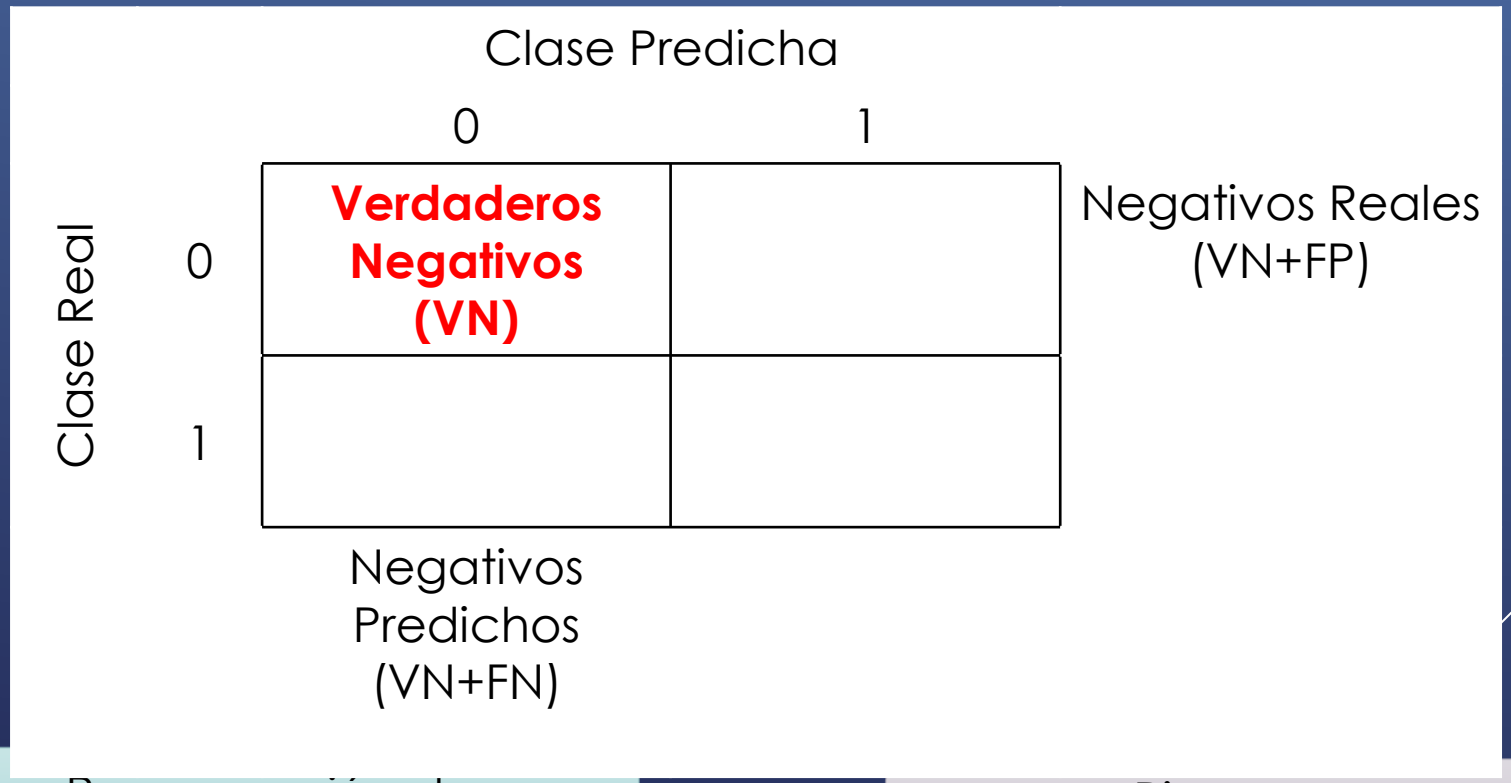
Detección fraude: Sensibilidad

Marketing directo: VP+

Especificidad y VP-

Especificidad:
Verdadero negativo/Negativo Real

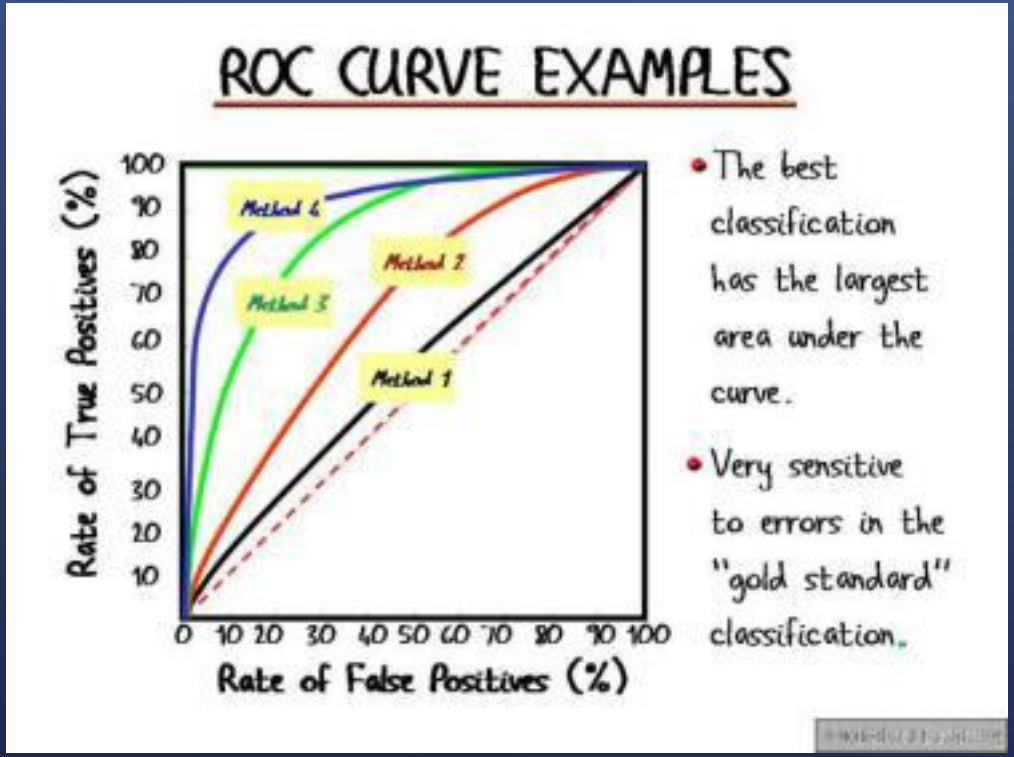
Valor predictivo negativo (VP-):
Verdadero negativo/Negativo Predicho



Recuperación de información: Especificidad

Riesgo:
VP-

Curva ROC


ROC CURVE EXAMPLES
Rate of True Positives (%)
100
90
80
70
60
50
40
30
20
10
Method 4
Method 3
Method 2
Method 1
0 10 20 30 40 50 60 70 80 90 100
Rate of False Positives (%)
• The best classification has the largest area under the curve.
• Very sensitive to errors in the "gold standard" classification.

ÁREA BAJO LA CURVA ROC (RECEIVER OPERATING CURVE)

En la curva ROC se representa la sensibilidad de la técnica diagnóstica frente al valor que se obtiene al restarle la especificidad a la unidad (1-especificidad). El área bajo la curva obtenida oscila entre un valor de 0.5 (no discrimina entre un positivo y un falso positivo) y 1 (test diagnóstico perfecto). Sabiendo esto, se puede jugar con los valores de especificidad y sensibilidad hasta ajustar nuestra técnica diagnóstica a lo deseado.

En diagnóstico clínico, cuando el valor de especificidad supera el 80%, se considera buena.

Por regla general, se elige una prueba muy específica cuando prefieres obtener falsos negativos en lugar de falsos positivos, por ejemplo, para asegurar de que un paciente tiene realmente una enfermedad. Por ejemplo, una prueba para detectar una enfermedad que implique una operación, es imprescindible asegurarse de que el paciente está enfermo y necesita la operación, para no operar a un paciente sano. Otros casos en los que se usa una prueba muy específica son: al tratarse de una enfermedad grave y prácticamente incurable, cuando es importante desde el punto de vista sanitario y psicológico saber que no se padece la enfermedad, cuando un resultado positivo falso supone un trauma económico y psicológico para el sujeto... En estas situaciones se utiliza una prueba con un valor predictivo positivo alto, que aumenta de valor conforme la prevalencia de la enfermedad es mayor.

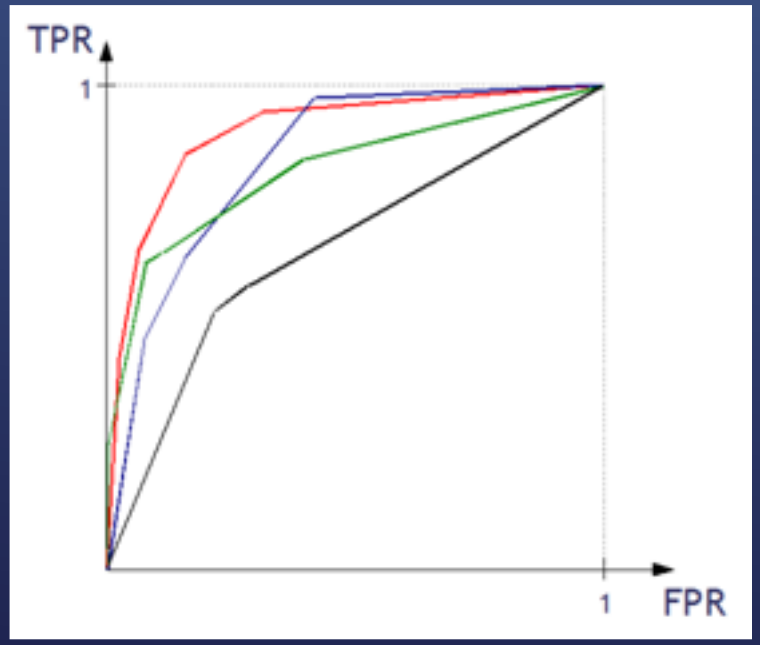
En cambio, se elige una prueba muy sensible cuando se prefiere obtener falsos positivos en lugar de falsos negativos, es decir, se desea que el número de enfermos sin detectar sea mínimo. Por ejemplo, en una epidemia es importante usar una prueba muy sensible, puesto que es necesario aislar a los enfermos y para ello todos deben ser detectados. Se usa en casos en que la enfermedad es grave pero curable, existiendo tratamiento para ella. En estos casos se usan pruebas con valor predictivo negativo alto, cuyo valor aumenta conforme disminuye la prevalencia de la enfermedad.

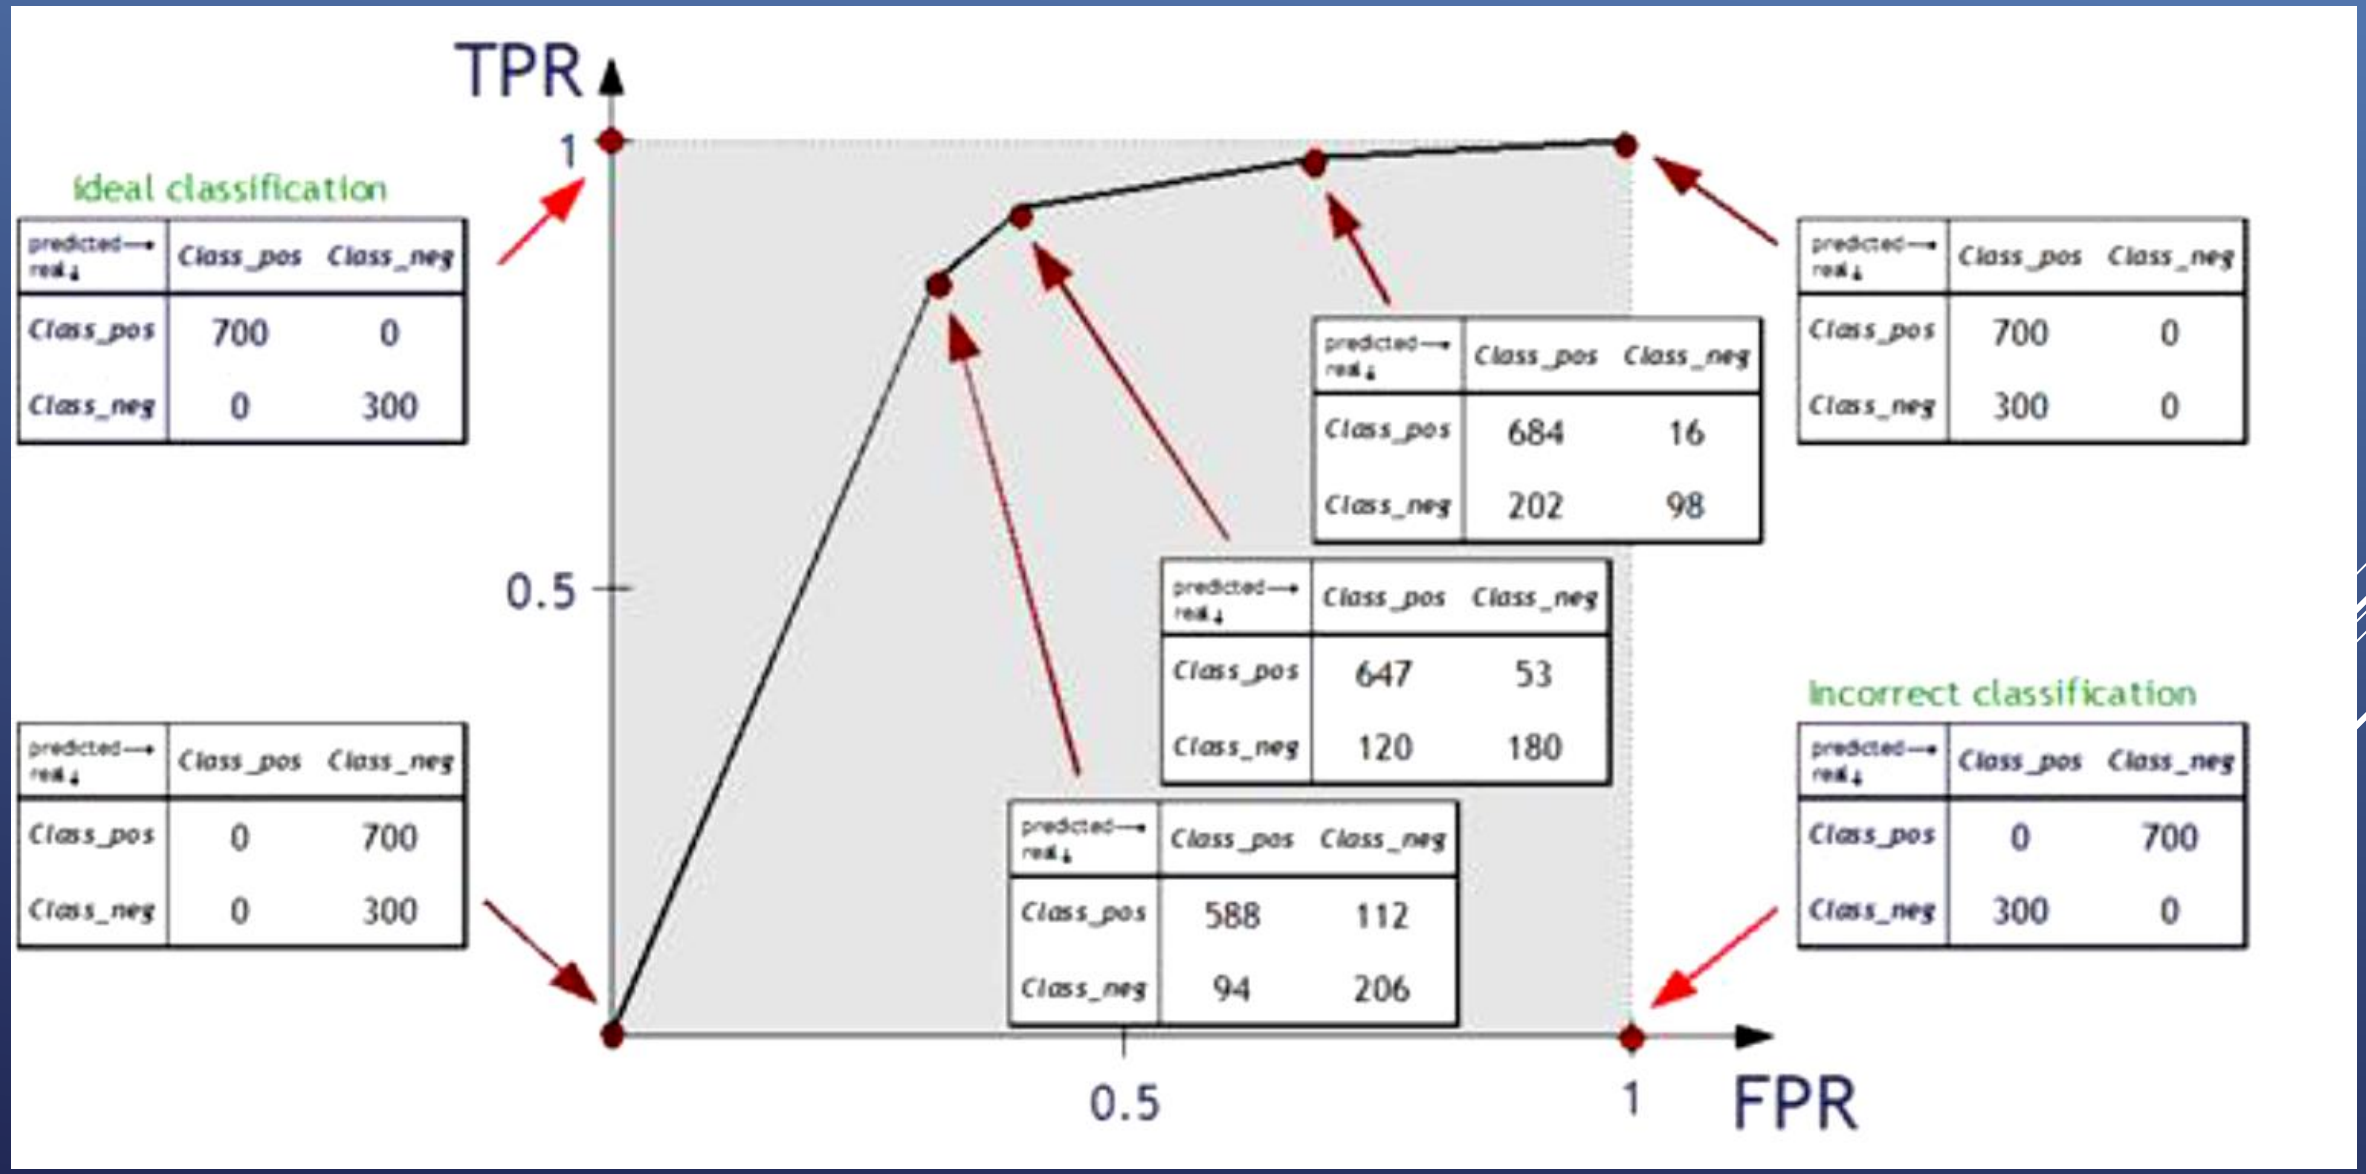
Curva ROC

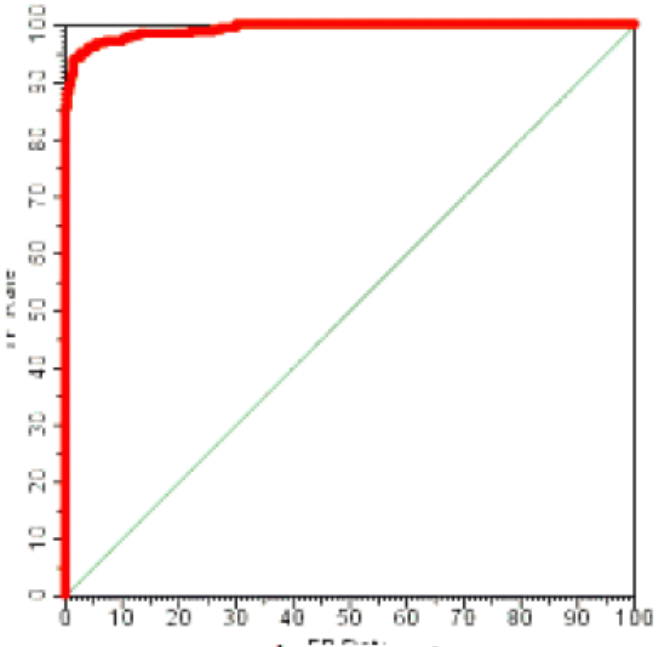
predicted → / real ↓	*Class_pos*	*Class_neg*
Class_pos	TP	FN
Class_neg	FP	TN

$$\text{TPR (sensitivity)} = \frac{TP}{TP + FN}$$

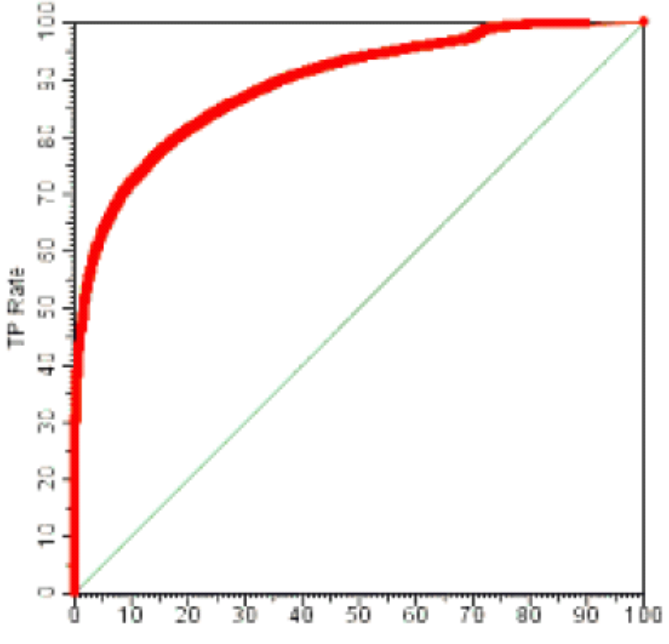
$$\text{FPR (1-specificity)} = \frac{FP}{TN + FP}$$



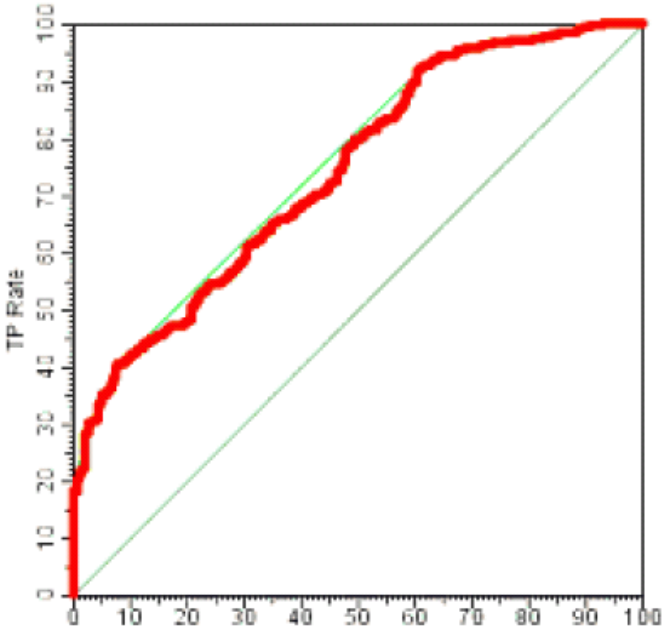

TPR
1
0.5
0.5
1
FPR
Ideal classification
predicted→ real↓ | Class_pos | Class_neg
Class_pos | 700 | 0
Class_neg | 0 | 300
predicted→ real↓ | Class_pos | Class_neg
Class_pos | 684 | 16
Class_neg | 202 | 98
predicted→ real↓ | Class_pos | Class_neg
Class_pos | 647 | 53
Class_neg | 120 | 180
predicted→ real↓ | Class_pos | Class_neg
Class_pos | 588 | 112
Class_neg | 94 | 206
predicted→ real↓ | Class_pos | Class_neg
Class_pos | 700 | 0
Class_neg | 300 | 0
predicted→ real↓ | Class_pos | Class_neg
Class_pos | 0 | 700
Class_neg | 0 | 300
Incorrect classification
predicted→ real↓ | Class_pos | Class_neg
Class_pos | 0 | 700
Class_neg | 300 | 0



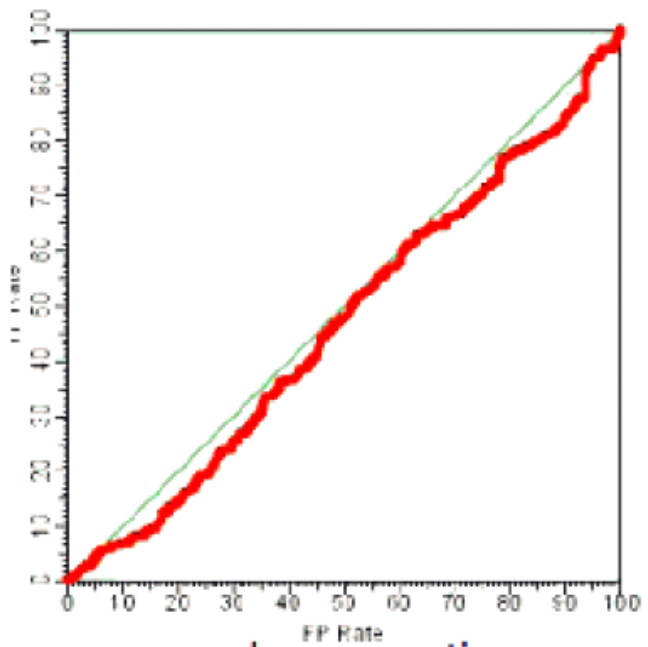
good separation



reasonable



poor separation



random separation

CALIDAD DEL MÉTODO

Valores AUC	Calidad del Método
0.9 – 1.0	Excelente
0.8 – 0.9	Muy Bueno
0.7 – 0.8	Bueno
0.6 – 0.7	Satisfactorio
0.5 – 0.6	Insatisfactorio

Coeficiente de Gini

Coeficiente de Gini



GRACIAS POR SU ATENCIÓN

