Modelos de elección discreta logit (Modelo de Regresión Logística)

Introducción

Si $Y_i \sim \text{Binomial}(1, P_i) \rightarrow f(y) = P_i^{y_i}(1-P_i)^{1-y_i}$, $y_i = 0,1$ se dice que Y_i tiene distribución binomial puntual o de Bernoulli. Se denomina odds (o ventaja) al cociente $\text{Odds}_i = \pi_i = \dfrac{P_i}{1-P_i}$ e indica cuánto más o menos probable es el éxito que el fracaso. En consecuencia, como $\pi_i = \dfrac{P_i}{1-P_i} \rightarrow P_i = \dfrac{\pi_i}{\pi_i + 1} = \dfrac{\text{odds}_i}{\text{odds}_i + 1}$

Ejemplo

Si la probabilidad de que un joven padezca de ludopatía es $P_1 = 0.8$ entonces el odds_i será $\pi_1 = \dfrac{P_1}{1-P_1} = \dfrac{0.8}{0.2} = 4$ y se interpreta diciendo que el éxito (tener ludopatía) es el cuádruple que el fracaso (no padecer ludopatía), o que el odds (la posibilidad) de que un joven padezca ludopatía es 4 a 1. Como $\pi_1 = 4 \rightarrow P_1 = \dfrac{\pi_1}{1+\pi_1} = \dfrac{4}{4+1} = 0.8$. Si $p = 0.25$ es la probabilidad de morir por una determinada enfermedad, entonces $\pi = \dfrac{p}{1-p} = \dfrac{0.25}{0.75} = \dfrac{1}{3} = 0.333$: el odds (la posibilidad) de morir (a no morir) es de 1 a 3.

Observaciones

Se denomina odds ratio (o riesgo relativo o ventaja comparativa) de dos sucesos a $OR_{1,2} = \theta_{1,2} = \dfrac{\pi_1}{\pi_2}$. Si $\theta_{1,2} = \dfrac{\pi_1}{\pi_2} > 1$, el éxito es más ventajoso que el fracaso en el primer suceso. Por ejemplo, si el odds de un varón respecto a la ludopatía es $\pi_1 = 4$, y el odds para una joven es $\pi_2 = \dfrac{1}{3}$ entonces el odds ratio del varón respecto a la chica será $OR_{1,2} = \theta_{1,2} = \dfrac{\pi_1}{\pi_2} = 12 > 1$, y se interpretará de la siguiente manera: padecer ludopatía es 12 más ventajoso ("probable") en varones. Si $OR_{1,2} = \theta_{1,2} = \dfrac{\pi_1}{\pi_2} < 1$, el éxito es más ventajoso que el fracaso en el segundo suceso. Si $\theta_{1,2} = \dfrac{\pi_1}{\pi_2} = 1$, los odds en ambos sucesos serán iguales.

1. El odds ratio (OR) nos dice cuántas veces un odds difiere del otro. En el caso de la ludopatía, el $\theta_{1,2} = \dfrac{\pi_1}{\pi_2} = 12 > 1$ indica que el odds de ludopatía en hombres es 12 más que los de mujeres. El $\theta_{2,1} = \dfrac{\pi_2}{\pi_1} = \dfrac{\frac{1}{3}}{4} = \dfrac{1}{12} < 1$ nos dice que el odds de ludopatía en mujeres es 12 menos que el de hombres.
2. El odds ratio (OR) nos dice en cuanto por ciento cambia un odds respecto a otro.
   a. Si $OR > 1$, Cambio en porcentaje $= (OR - 1) \times 100$

b. Si $OR < 1$, Cambio en porcentaje $= \left(\frac{1}{OR} - 1\right) \times (-100)$

Con el ejemplo: $\theta_{1,2} = 12 > 1 \rightarrow (12-1) \times 100 = 1100\%$, nos dice que el odds de ludopatía en hombres es 1100% superior al odds de mujeres. $\theta_{2,1} = \frac{1}{12} < 1 \rightarrow \left(\frac{1}{\frac{1}{12}} - 1\right) \times (-100) = -1100\%$, indica que el odds de ludopatía en mujeres es 1100% inferior al odds de hombres.

RR = Risk Ratio o Relative Risk = Razòn de Riesgo o Riesgo Relativo

$RR_{1,2} = \frac{P_1}{P_2}$.

Siguiendo con el caso de ludopatía.

$$\pi_2 = \frac{1}{3} \rightarrow P_2 = \frac{\pi_2}{1+\pi_2} = \frac{\frac{1}{3}}{1+\frac{1}{3}} = \frac{1}{4}$$

$RR_{1,2} = \frac{P_1}{P_2} = \frac{0.8}{0.25} = \frac{16}{5} = 3.2$. Interpretación: la probabilidad de que un joven tenga ludopatía es 3.2 veces mayor que la probabilidad de que una joven tenga ludopatía (mayor en 220% en términos relativos).

Relación entre OR y RR

$$RR = \frac{OR}{1 - I_0 \times (1 - OR)}$$

$$OR = \frac{RR \times (1 - I_0)}{1 - I_0 \times RR}$$

Donde I_0 es igual a P_2 (en este caso la probabilidad de que una chica tenga ludopatía). Se toma en cuenta la probabilidad del segundo evento.

RD = Absolute Risk Difference = Diferencia de Riesgo Absoluto

$P_1 = 0.8$ y $P_2 = 0.25$

$RD = P_1 - P_2 = 0.55$

Interpretación: La probabilidad de que tenga ludopatía un hombre es mayor en 0.55 (o mayor en 55% en términos absolutos) que la probabilidad de que tenga ludopatía una mujer.

Probabilidad Acumulada

Se define como la probabilidad de que una variable sea menor o igual a una categoría ordenada (o valor).

Sea la variable X definida como el grado de instrucción de una persona adulta con las categorías: primaria, secundaria incompleta, secundaria completa, universidad incompleta y universidad completa.

Por ejemplo: la probabilidad de que una persona tenga secundaria completa o menos es 0.24.

Probabilidad de Excedencia
Se define como la probabilidad de que una variable sea mayor que una categoría ordenada (o valor).
Sea la variable X definida como el grado de instrucción de una persona adulta con las categorías: primaria, secundaria incompleta, secundaria completa, universidad incompleta y universidad completa.
La probabilidad acumulada es complementaria con la probabilidad de excedencia.
Por ejemplo: la probabilidad de que una persona tenga más que secundaria completa es 0.76.

Modelos de Regresión Logística

Un modelo de regresión con variable dependiente binomial (o multinomial) será un modelo que permita estudiar si dicha variable discreta depende o no, de otra u otras variables.

1. Los Modelos Dicotómicos

Se considera que la variable dependiente Y o clase es una variable dicotómica que toma dos alternativas, de tal manera que cada individuo de la muestra tiene que pertenecer a una y sólo una, de estas alternativas (clases o grupos).

Es posible representar a una variable dicotómica de la siguiente manera:

$$Y_i = \begin{cases} 1 & \text{Prob}\left(Y_i = 1\right) = P_i \\ 0 & \text{Prob}\left(Y_i = 0\right) = 1 - P_i \end{cases} \qquad (1)$$

De lo anterior se puede hallar el valor esperado de Y_i de la siguiente manera:

$$E\left(Y_i\right) = 1 \times P_i + 0 \times \left(1 - P_i\right) = P_i \qquad (2)$$

Asumiendo que Y_i es explicado por un conjunto de regresores (o variables independientes que pueden ser cuantitativas o cualitativas) $X_{2i}, X_{3i}, \ldots, X_{ki}$. Se le llama Z_i a la siguiente función lineal de estos regresores:

$$Z_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \ldots + \beta_k X_{ki} = \left[1\, X_{2i} \cdots X_{ki}\right] \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix} = x_i' \beta \qquad (3)$$

En la igualdad anterior los β_j son parámetros desconocidos.

Por lo tanto, se puede representar el valor esperado de Y_i condicionada a las variables explicativas (o regresores) de la siguiente manera.

$$E\left(Y_i / X_{2i}, X_{3i}, \cdots, X_{ki}\right) = F\left(\beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \ldots + \beta_k X_{ki}\right) = F\left(Z_i\right) \quad (4)$$

En consecuencia, el Modelo Estocástico (o Aleatorio) puede ser representado así:

$$Y_i = E\left(Y_i / X_{2i}, X_{3i}, \cdots, X_{ki}\right) + u_i = F\left(Z_i\right) + u_i \qquad (5)$$

En la igualdad anterior u_i es una perturbación aleatoria (o estocástica).

Dependiendo cuál sea la función F seleccionada se obtienen diferentes Modelos Dicotómicos.

Se considerará el Modelo Logit (o sea cuando F es la Distribución Logística).
Con la finalidad de que las predicciones del Modelo Dicotómico tengan relación lógica con los aspectos teóricos se tiene que establecer las siguientes propiedades:

$$\lim_{Z_i \to +\infty} \text{Prob}\left(Y_i = 1\right) = 1$$

$$\lim_{Z_i \to -\infty} \text{Prob}\left(Y_i = 0\right) = 0$$

Lo anterior se cumple perfectamente si F es una función de distribución aleatoria. Por lo tanto, si F es la Distribución Logística se obtiene el Modelo Logit pero si F es la Distribución Normal estándar se obtiene el Modelo Probit. Es posible considerar otras distribuciones, pero generalmente se usan las dos mencionadas anteriormente. Se utilizará la Distribución Logística (Modelo Logit).

En un Modelo Logit se cumple lo siguiente:

$$P_i = E\left(Y_i / X_{2i}, X_{3i}, \cdots, X_{ki}\right) = F\left(Z_i\right) = \frac{1}{1 + e^{-Z_i}} = \frac{e^{Z_i}}{1 + e^{Z_i}} = \Lambda\left(Z_i\right) \quad (6)$$

En la igualdad anterior $\Lambda(.)$ es la notación usual para la función de Distribución Acumulativa Logística.

La Función de Densidad Logística está dada por:

$$f\left(Z_i\right)=\Lambda\left(Z_i\right)\left(1-\Lambda\left(Z_i\right)\right) \qquad (7)$$

Con los Modelos de Elección Discreta es común el uso del concepto de razón de apuestas (en inglés odds) en lugar que el concepto de probabilidad. La razón de apuestas es una relación entre dos probabilidades. Es la razón entre la probabilidad de que se produzca un suceso y la probabilidad de que no se produzca ese suceso. La expresión de razón de apuestas tiene el mismo significado que en el juego, es decir, si en una apuesta donde existen solamente dos posibilidades, se dice que las apuestas están a la par, eso quiere decir que la razón de apuestas será 1:1. Hay que tener en cuenta que la razón de apuestas no es nunca una probabilidad, sino una razón de probabilidades, con base a lo anterior se hará su deducción para el Modelo Logit. La probabilidad de que el suceso no tome el valor 1 es:

$$1-P_i=1-\frac{1}{1+e^{-Z_i}}=\frac{1+e^{-Z_i}-1}{1+e^{-Z_i}}=\frac{1}{e^{Z_i}\left(1+e^{-Z_i}\right)}=\frac{1}{1+e^{Z_i}}$$

En consecuencia, la razón de apuestas (odds), se da por la siguiente expresión:

$$\pi_i=\frac{P_i}{1-P_i}=\frac{1+e^{Z_i}}{1+e^{-Z_i}}=\frac{1+e^{Z_i}}{1+\frac{1}{e^{Z_i}}}=e^{Z_i}=e^{\beta_1+\beta_2X_{2i}+\beta_3X_{3i}+\ldots+\beta_kX_{ki}} \qquad (8)$$

NOTA: Asumiendo que sólo hay una variable independiente X_2 que sólo puede tomar valores 0 o 1, la ventaja u odds de la opción 1 $\left(Y_i=1\right)$ para $x_2=1$ será $\pi_1=\frac{P\left(Y_i=1\right)}{1-P\left(Y_i=1\right)}=\frac{P_1}{1-P_1}$, y para $x_2=0$, $\pi_0=\frac{P\left(Y_i=0\right)}{1-P\left(Y_i=0\right)}=\frac{P_0}{1-P_0}$. Entonces el odds ratio (o riesgo relativo o ventaja comparativa) de $x_2=1$ respecto a $x_2=0$ será:

$$\theta_{1,0}=\frac{\pi_1}{\pi_0}=\frac{\frac{e^{\beta_1+\beta_2}/\left(1+e^{\beta_1+\beta_2}\right)}{1/\left(1+e^{\beta_1+\beta_2}\right)}}{\frac{e^{\beta1}/\left(1+e^{\beta_1}\right)}{1/\left(1+e^{\beta_1}\right)}}=\frac{e^{\beta_1+\beta_2}}{e^{\beta_1}}=e^{\beta_2}$$

Este resultado nos indica cómo la razón de apuestas de observar $Y_i=1$ cambia ante un incremento unitario en la variable X_2. Cuando $e^{\beta_2}>1$ la variable X_2 incrementa la razón

de apuestas de observar $Y_i = 1$. Cuando $e^{\beta_2} < 1$ la variable X_2 reduce la razón de apuestas de observar $Y_i = 1$.

VOLVIENDO AL MODELO GENERAL

Con esta clase de modelos, en lugar de la razón de apuestas, se usa el logaritmo neperiano de esa razón. Por lo tanto y teniendo en cuenta (3):

$$\ln \pi_i = \ln\left[\frac{P_i}{1-P_i}\right] = Z_i = \beta_1 + \sum_{j=2}^{k} \beta_j X_j \qquad (9)$$

Se aprecia que, por una parte, la razón de apuestas es una función no lineal de los parámetros β, de otro lado el logaritmo de la razón de apuestas si es una función lineal de los β.

Derivando: $\partial \frac{\ln \pi_i}{\partial X_h} = \beta_h$ entonces β_h es el cambio en el logaritmo de la razón de apuestas cuando la variable X_h cambia en una unidad permaneciendo constantes las demás variables.

Supuestos

Ver el archivo R.

Estimación de los parámetros β_j

El modelo Logit es no lineal. El método de estimación es el de máxima verosimilitud y con procedimientos iterativos.

Contraste de significación para un β_j

Para probar $\begin{matrix} H_0 : \beta_j = 0 \\ H_1 : \beta_j \neq 0 \end{matrix}$ se utiliza el estadístico de Wald.

Contraste de significación para todos los β_j

Para verificar: $\begin{matrix} H_0 : \beta_2 = \beta_3 = \ldots = \beta_k = 0 \\ H_1 : \text{Al menos un } \beta_j \neq 0 \end{matrix}$ se utiliza el estadístico de razón de verosimilitud

$RV_0 = -2\left[\ln L_0 - \ln L\right]$, donde $\ln L$ es el logaritmo de la función de verosimilitud que se ha obtenido al estimar el modelo completo, mientras que $\ln L_0$ es el logaritmo de la función de verosimilitud al estimar el modelo con sólo el término independiente. Se cumple que $RV_0 = \ln L_0 - \ln L \sim \chi^2_{(k-1)}$ cuando el tamaño de muestra (n) tiende al infinito.

Prueba de bondad de ajuste de la Devianza

H_0 : El modelo se ajusta bien a los datos . El estadístico de prueba es:

$$D = -2\left[\frac{\text{F. de verosimilitud del modelo seleccionado}}{\text{F. de verosimilitud del modelo saturado}}\right] \sim \chi^2_{(n-k)}$$

Prueba de bondad de ajuste de Hosmer Lemeshow

H_0 : El modelo ajustado es el adecuado o que no existen diferencias entre valores observados y predichos.

Para esta prueba se dividen todos los casos en deciles basados en probabilidades predichas. A partir de las probabilidades predichas y de los datos observados se considera el siguiente estadístico: $HL = \sum_{i=1}^{10} \frac{\left[O_i - N_i \bar{\pi}_i\right]^2}{N_i \bar{\pi}_i \left(1 - \bar{\pi}_i\right)} \sim \chi^2_8$ donde:

O_i : es el número de unos del decil i.

$\bar{\pi}_i$: es la media de las probabilidades predichas en el decil i.

N_i : es el número de observaciones del decil i.

2. Los Modelos Logit Multinomiales

En los casos anteriores se han considerado Modelos de Elección Discreta en los que existen dos alternativas (clases o grupos). Pero muchas veces son más de dos las alternativas de donde elegir para tomar una decisión. Para resolver este problema aparecen los Modelos Multinomiales.

A los Modelos de Elección Discreta con más de dos alternativas (clases o grupos) se les llama Modelos Multinomiales. Con los Modelos Multinomiales ocurre lo mismo que con los Modelos Dicotómicos, se puede utilizar Modelos Logit o Modelos Probit, aunque los Modelos Logit (asumiendo Distribución Logística) son los que más se usan, tanto en la literatura, así como en los programas estadísticos.

En el Modelo Logit se considera que el número de alternativas o clases es J+1 (0, 1, 2, ..., J), pero considerando la alternativa 0 como la categoría de referencia. Como se apreció, en los Modelos Dicotómicos sólo hay un vector de parámetros. Entonces, para trabajar con el Modelo Logit Multinomial son necesarios J vectores de parámetros. El número de vectores de parámetros es igual al número de categorías sin considerarse la categoría de referencia.

Supóngase que se tiene la siguiente relación,

$$Z_{ij} = \beta_{1j} + \beta_{2j} X_{2i} + \beta_{3j} X_{3i} + \ldots + \beta_{kj} X_{ki} = \begin{bmatrix} 1 & X_{2i} & \cdots & X_{ki} \end{bmatrix} \begin{bmatrix} \beta_{1j} \\ \beta_{2j} \\ \vdots \\ \beta_{kj} \end{bmatrix} = x_i' \beta_j$$

Entonces las probabilidades de cada alternativa o clase en un Modelo Logit Multinomial son representadas como sigue:

$$P_{ij} = \text{Prob}\left(Y_i = j\right) = \frac{e^{x_i' \beta_j}}{1 + \sum_{K=1}^{J} e^{x_i' \beta_K}} \quad j = 1, 2, \cdots, J$$

$$P_{i0} = \text{Prob}\left(Y_i = 0\right) = \frac{1}{1 + \sum_{K=1}^{J} e^{x_i' \beta_K}} \qquad (10)$$

Hay que notar que, si J es igual a uno, el Modelo Multinomial es igual al Dicotómico.
El logaritmo neperiano de la razón de apuesta entre la alternativa j y la alternativa de la categoría de referencia (0) está dada por:

$$\ln\left(\frac{P_{ij}}{P_{i0}}\right) = x_i' \beta_j = Z_{ij} = \beta_{1j} + \beta_{2j} X_{2i} + \beta_{3j} X_{3i} + \ldots + \beta_{kj} X_{ki} \qquad (11)$$

Es posible hallar el logaritmo de la razón de apuestas entre cualquier par de alternativas o clases. Como, por ejemplo, entre las alternativas j y h se tendrá:

$$\ln\left(\frac{P_{ij}}{P_{ih}}\right) = x_i' \left(\beta_j - \beta_h\right) \qquad (12)$$

Ejemplo de Regresión Logística Dicotómica (Archivo: Empresas1)

En un estudio de mercado se desea investigar los principales factores que pueden influir en aumentar la probabilidad de que un nuevo producto sea introducido con éxito en el mercado. Con esta finalidad, se ha aplicado una encuesta a 240 empresas industriales de las cuales 156 declararon haber intentado introducir en el mercado un nuevo producto. Entonces, el objetivo es explicar el comportamiento en términos de probabilidad de una variable dependiente dicotómica (éxito o fracaso en el lanzamiento de un nuevo producto), en función de un conjunto de variables predictoras.

Variables	Descripción	Respuestas
resultado	Resultado de lanzar un nuevo producto al mercado	exito o fracaso
publicid	Gasto en publicidad	um
gradnove	Grado de novedad del producto (mejoras sustanciales o productos nuevos)	mejoras_sust o prod_nuevos
tipo	Tipo de producto (consumo final o consumo industrial)	cons_final o cons_indus
investigacion	La empresa tiene departamento de investigación	no o si
secteng	Sector tecnológico al que pertenece la empresa	bajo, medio o alto
personal	Número de personas que trabajan en la empresa	Cantidad de personas

Prueba Ómnibus

$H_0 : \beta_2 = \beta_3 = \ldots = \beta_7 = 0$

$H_1 :$ Al menos un $\beta_j \neq 0$

Valor calculado 81.46027 y pvalor = 1.783e-15

Prueba de Hosmer Lemeshow

$H_0 :$ El modelo ajustado es el adecuado o que no existen diferencias entre valores observados y predichos.

pvalor=0.7243

Pruebas de Wald

$H_0 : \beta_j = 0$

$H_1 : \beta_j \neq 0$

De abajo para arriba:

pvalores= La mayoría de los pvalores indican significación.

Algunas interpretaciones

$\hat{\beta}_1 = -6.82$, es el valor del $\ln\left(\frac{\hat{P}_1}{1-\hat{P}_1}\right)$ cuando las otras variables toman el valor de cero.

$\hat{\beta}_2 = 1.86$, el valor del $\ln\left(\frac{\hat{P}_1}{1-\hat{P}_1}\right)$ se incrementa en 1.86 cuando el gasto en publicidad aumenta en 1 um. y las demás variables permanecen constantes.

$\hat{\beta}_3 = 1.28$, el valor del $\ln\left(\frac{\hat{P}_1}{1-\hat{P}_1}\right)$ se incrementa en 1.28 cuando el grado de novedad es por mejoras sustanciales y las demás variables permanecen constantes.

$\hat{\beta}_6 = -1.74$, el valor del $\ln\left(\frac{\hat{P}_1}{1-\hat{P}_1}\right)$ decrece en 1.74 cuando Intensidad Tecnológica del Sector de Actividad de la Empresa es baja y las demás variables permanecen constantes.

$\hat{\beta}_7 = -0.29$, el valor del $\ln\left(\frac{\hat{P}_1}{1-\hat{P}_1}\right)$ decrece en 0.29 cuando Intensidad Tecnológica del Sector de Actividad de la Empresa es media y las demás variables permanecen constantes.

$e^{\hat{\beta}_2} = 6.39$, el Resultado de introducir un nuevo producto al mercado como éxito es 6.39 más ventajoso (probable) por cada um de gasto en publicidad.

$e^{\hat{\beta}_4} = 3.61$, el Resultado de introducir un nuevo producto al mercado como éxito, para Grado de novedad de mejoras sustanciales es 3.61 más ventajoso (probable) que para productos nuevos.

$e^{\hat{\beta}_7} = 0.74$, el Resultado de introducir un nuevo producto al mercado como éxito, cuando la intensidad tecnológica del sector de actividad de la empresa es media es 0.74 menos ventajoso (probable) que cuando la intensidad tecnológica es alta.

$e^{\hat{\beta}_8} = 1.54$, el Resultado de introducir un nuevo producto al mercado como éxito es 1.54 más ventajoso (probable) cuando el personal aumenta en uno.

Clasificar a una empresa

Si se tiene otras empresas con valores conocidos de las variables, con el modelo hallado utilizando la data de entrenamiento, se puede clasificar a esas empresas (van a tener éxito o no al lanzar un nuevo producto al mercado)

Coeficiente de concordancia de Kappa (k)

Índice de Kappa	Grado de concordancia
0,00	sin acuerdo
< 0,00 - 0,20]	insignificante
[0,21 - 0,40]	Discreto
[0,41 - 0,60]	Moderado
[0,61 - 0,80]	Sustancial
[0,81 - 1,00]	casi perfecto

Ejemplo de Regresión Logística Multinomial (Archivo: PesoNinos)

Para hacer una regresión logística multinomial la variable respuesta tiene que ser nominal o categórica ordinal (pero en este caso hay que hacer la prueba de Brant para decidir si usar una regresión logística ordinal o una multinomial).

Con la data PesoNinos se tiene una variable dependiente categórica ordinal. Para decidir si se hace una regresión logística ordinal en lugar de una regresión logística multinomial no se debe rechazar la hipótesis nula que indica que los coeficientes de las dos siguientes regresiones son las mismas. También se conoce como el supuesto de regresión paralela o supuesto de probabilidades proporcionales. Asumiendo que la variable dependiente tiene tres categorías ordinales, las dos regresiones que se mencionaron anteriormente son:

$$\ln\left[\frac{P(Y=2)}{P(Y=0/1)}\right]=\beta_{1j}+\beta_{2j}X_{2i}+\beta_{3j}X_{3i}+\ldots+\beta_{kj}X_{ki}+\varepsilon$$

$$\ln\left[\frac{P(Y=1/2)}{P(Y=0)}\right]=\beta_{1j}+\beta_{2j}X_{2i}+\beta_{3j}X_{3i}+\ldots+\beta_{kj}X_{ki}+\varepsilon$$

En el R se hace la prueba de Brant y resulta que el pvalor de “Omnibus” es 0 por lo tanto no se cumple el supuesto de regresión paralela. Esto nos indica que debemos hacer la regresión logística multinomial.

Se concluye que las probabilidades de caer en una categoría de nivel superior o inferior en el peso no son las mismas en todas las categorías. En términos simples, los efectos de los predictores no son los mismos en todos los niveles de la variable dependiente peso. Las probabilidades de caer en una categoría superior no son las mismas que las de caer en una categoría inferior.

Variable Dependiente

Peso_RN_1: Peso del recién nacido-Clasificado

1. Bajo Peso
2. Peso Normal
3. Sobre Peso

Variables Independientes

Edad_Madre: Edad de la madre.

Num_Partos: Número de partos(Paridad).

Tipo_de_Parto: Tipo de parto (1=Cesárea, 2=Parto Normal)

Sexo_RN: Sexo del recién nacido (1=Femenino, 2=Masculino)

Talla_RN: Talla del recién nacido

Edad_Gestacional: Edad gestacional en semanas

Regresión Logística Ordinal

Los supuestos para la regresión logística ordinal son:

1. La variable dependiente está ordenada.
2. Una o más de las variables independientes son continuas, categóricas u ordinales.
3. No hay multicolinealidad.
4. Se cumple el supuesto de probabilidades proporcionales o supuesto de regresión paralela (hacer el test de Brant).

Ejemplo: Se trabaja con datos de la Universidad de Ucla.

Aquí hay cuatro variables. La variable de **apply** es una variable categórica ordenada con respuestas a una encuesta sobre si un estudiante siente que es "Improbable" (0), "Algo probable" (1) o "Muy probable" (2) para postularse a la escuela de posgrado. La variable **pared** es una variable binaria que indica si al menos uno de los padres ha asistido a la escuela de posgrado. La variable **public** es una variable binaria que indica si la institución de pregrado es pública (en lugar de privada), y la variable **gpa** es el GPA de pregrado. Observe que el orden de los valores en **apply** corresponde al orden de la variable.

La regresión logística ordinal utiliza el comando polr (), que significa "regresión logística de probabilidades proporcionales" que es la traducción de “proportional odds logistic regression”.