Regresión Log Binomial

Resumen del modelo y comparación con la regresión logística

La regresión log binomial analiza una respuesta dicotómica y permite estimar directamente razones de riesgo ajustadas. Su principal atractivo es la interpretación de los coeficientes como cambios relativos en la probabilidad del evento; su principal dificultad es mantener probabilidades válidas durante el ajuste y la predicción.

Descripción del modelo

Para cada observación, Y toma el valor 1 si ocurre el evento de interés y 0 si no ocurre. Se supone una distribución Bernoulli, con probabilidad p, y se relaciona el logaritmo de esa probabilidad con los predictores:

$$Y_i \sim \text{Bernoulli}(p_i)$$

$$\log(p_i) = \eta_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik}$$

Por tanto, $p_i = \exp(\eta_i)$. Para que la probabilidad no supere 1, el predictor lineal debe satisfacer $\eta_i \leq 0$ en cada perfil evaluado. Los parámetros se estiman por máxima verosimilitud. Las observaciones deben ser independientes, salvo que se utilice una extensión que modele su dependencia.

Para una respuesta binaria no se exige normalidad de los predictores ni de los residuos, ni varianza constante: la varianza condicional es $p_i(1 - p_i)$. La forma de log(p) debe representar razonablemente la relación con las covariables.

Importancia e interpretación del risk ratio

$$\text{RR} = \frac{p_1}{p_0} = \exp(\beta_j)$$

Sin interacciones que modifiquen el contraste, $\exp(\beta_j)$ es el RR asociado con aumentar una unidad una variable continua o comparar una categoría con su referencia, manteniendo constantes las otras covariables y siempre que ambos perfiles sean factibles.

RR = 1 indica igual probabilidad; RR > 1, una probabilidad mayor; y RR < 1, una probabilidad menor. Por ejemplo, RR = 1.50 significa una probabilidad 50% mayor, no un aumento de 50 puntos porcentuales. Si la probabilidad de referencia es 0.20, la del grupo comparado es 0.30: la diferencia absoluta es de 10 puntos.

En un estudio transversal, el cociente suele denominarse razón de prevalencias. Hablar de riesgo prospectivo requiere un diseño y un período de seguimiento apropiados. Un RR ajustado no demuestra, por sí solo, un efecto causal.

Diferencias con la regresión logística

Ambos modelos usan una respuesta binaria y una distribución binomial. La diferencia central está en el enlace y, por ello, en la medida de asociación que producen directamente.

Aspecto	Log binomial	Logística
Enlace	Logaritmo de la probabilidad	Logaritmo de los odds
Probabilidad	$p = \exp(\eta)$	$p = \exp(\eta) / [1 + \exp(\eta)]$
Coeficiente exponenciado	Risk ratio ajustado	Odds ratio ajustado
Dominio	Requiere $\eta \leq 0$ en cada perfil	Todo η real produce $0 < p < 1$
Ajuste numérico	Puede presentar falta de convergencia o soluciones de frontera	Generalmente más estable; puede fallar con separación
Interpretación directa	Cambio relativo de probabilidad	Cambio relativo de odds

Por qué RR y OR pueden diferir

Los odds son $p/(1 - p)$. Si dos grupos tienen probabilidades 0.50 y 0.75, su RR es 1.50, mientras que su OR es 3.00. El OR indica odds triples, no una probabilidad triple. Cuando el evento es raro en ambos grupos, el OR se aproxima al RR; con eventos frecuentes, la diferencia puede ser importante.

El RR suele preferirse cuando interesa comunicar cuántas veces cambia la probabilidad. Esto no vuelve incorrecto al OR ni hace superior al modelo log binomial en toda situación. En estudios de casos y controles, el OR es especialmente útil; el RR poblacional no se estima directamente sin información adicional del muestreo.

Aspectos prácticos para elegir el modelo

La elección debe considerar el objetivo, el diseño, la convergencia, la calibración y el desempeño predictivo. En el log binomial conviene revisar probabilidades próximas a 1 y perfiles nuevos que produzcan valores no válidos. No se deben recortar esas predicciones a 1 como solución al problema.

Si el log binomial no se ajusta adecuadamente, pueden explorarse algoritmos específicos, una Poisson modificada con varianza robusta o una logística con estandarización de probabilidades para obtener RR marginales. Estas alternativas requieren justificar sus supuestos y definir el contraste; no producen automáticamente el mismo estimando.

Referencia

Donoghoe, M. W. y Marschner, I. C. (2018). logbin: An R Package for Relative Risk Regression Using the Log-Binomial Model. Journal of Statistical Software, 86(9), 1–22. https://doi.org/10.18637/jss.v086.i09