5 Análisis de componentes principales (ACP)

Ficha de la pregunta

- **Técnica:** ACP sobre la matriz de correlaciones, análisis paralelo de Horn, rotación varimax y conglomerados jerárquicos (HCPC)
- **Base de datos:** `Encuesta.xlsx` — encuesta de satisfacción a 300 clientes de una cadena de supermercados
- **Variables activas:** `AMABILIDAD`, `RAPIDEZ`, `RESOLUCION`, `CAL_PROD`, `VAR_PROD`, `PRECIO`, `LIMPIEZA` y `ORDEN` (escala 0–100)
- **Variable ilustrativa:** `CLIENTE_FRECUENTE` (Sí / No)

5.1 Data general

5.1.1 Contexto del problema

Se aplicó una encuesta de satisfacción a 300 clientes de una cadena de supermercados. El objetivo del Análisis de Componentes Principales (ACP) es reducir las respuestas de la encuesta a factores latentes que expliquen la experiencia del cliente.

Diccionario de variables

Variable	Tipo en el ACP	Descripción
`ID_ENCUESTA`	Identificador	Identificador único del cliente
`AMABILIDAD`	0 - 100	Amabilidad del personal
`RAPIDEZ`	0 - 100	Velocidad de atención en caja
`RESOLUCION`	0 - 100	Capacidad del personal para resolver dudas
`CAL_PROD`	0 - 100	Calidad de los productos
`VAR_PROD`	0 - 100	Variedad de marcas y opciones
`PRECIO`	0 - 100	Percepción de relación calidad–precio
`LIMPIEZA`	0 - 100	Higiene de las instalaciones
`ORDEN`	0 - 100	Distribución y orden en los pasillos
`CLIENTE_FRECUENTE`	Cualitativa	Afiliado al programa de lealtad (“Sí” / “No”)

5.1.2 Lectura de la base de datos

Los paquetes necesarios se cargan en la configuración inicial del documento.

```
# Lectura de datos
datos <- read_excel("Encuesta.xlsx")
datos$CLIENTE_FRECUENTE <- factor(datos$CLIENTE_FRECUENTE, levels = c("No", "Sí"))

# Base sin el identificador
datos1 <- as.data.frame(datos[, -1])

# Variables para realizar el ACP
datosacp <- datos1[, -9]
tt(head(datosacp))
```

AMABILIDAD	RAPIDEZ	RESOLUCION	CAL_PROD	VAR_PROD	PRECIO	LIMPIEZA	ORDEN
56	60	62	83	81	77	94	90
87	86	93	63	65	69	73	74
83	82	72	66	65	81	83	86
46	53	46	83	85	80	77	79

AMABILIDAD	RAPIDEZ	RESOLUCION	CAL_PROD	VAR_PROD	PRECIO	LIMPIEZA	ORDEN
60	58	53	77	81	67	95	97
94	88	91	82	93	88	85	83

```
dim(datos)
```

```
#> [1] 300  10
```

La base tiene 300 clientes y 10 columnas: el identificador, las 8 variables activas y la variable ilustrativa `CLIENTE_FRECUENTE` (140 afiliados y 160 no afiliados).

5.2 Introducción

La satisfacción de un cliente con un supermercado no es una sola percepción: se forma a partir de la atención del personal, de lo que se compra (calidad, variedad, precio) y del lugar donde se compra (limpieza, orden). Una encuesta con ocho preguntas de satisfacción genera ocho variables que, al estar relacionadas entre sí, contienen información repetida. El Análisis de Componentes Principales (ACP) transforma esas variables correlacionadas en un conjunto menor de componentes no correlacionados que conservan la mayor parte de la variabilidad, lo que permite identificar los factores latentes de la experiencia del cliente.

Objetivo general. Reducir las respuestas de la encuesta a factores latentes que expliquen la experiencia del cliente.

Objetivos específicos

1. Verificar la calidad de los datos (datos perdidos y valores atípicos) y describirlos.
2. Evaluar si la matriz de correlaciones justifica aplicar un ACP.
3. Extraer los componentes principales y decidir cuántos retener (criterio de Kaiser, porcentaje de varianza, gráfico de sedimentación y análisis paralelo de Horn).
4. Interpretar los componentes mediante los vectores propios y las correlaciones variable–componente.
5. Proyectar la variable ilustrativa `CLIENTE_FRECUENTE` sobre el plano factorial.
6. Agrupar a los clientes (conglomerados jerárquicos sobre componentes principales) y perfilar cada grupo.

Variables activas: `AMABILIDAD`, `RAPIDEZ`, `RESOLUCION`, `CAL_PROD`, `VAR_PROD`, `PRECIO`, `LIMPIEZA` y `ORDEN`, todas en escala de 0 a 100. Como comparten escala, el ACP se aplica sobre la matriz de correlaciones (variables estandarizadas, `scale = TRUE`).

5.3 Desarrollo

5.3.1 Calidad de los datos

Datos perdidos.

```
per.miss.col <- 100 * colSums(is.na(datosacp)) / dim(datosacp)[1]
kable(data.frame(Variable = names(per.miss.col), Porcentaje_perdidos = as.numeric(per.miss.co
        l)),
      digits = 2, row.names = FALSE, caption = "Porcentaje de datos perdidos por variable")
```

Porcentaje de datos perdidos por variable

Variable	Porcentaje_perdidos
AMABILIDAD	0
RAPIDEZ	0
RESOLUCION	0
CAL_PROD	0
VAR_PROD	0
PRECIO	0

Variable	Porcentaje_perdidos
LIMPIEZA	0
ORDEN	0

No hay datos perdidos en ninguna de las variables activas, por lo que no se requiere imputación.

Valores atípicos (criterio de la puntuación Z, |Z| > 3).

```
is_outlier3 <- function(x, k = 3) {
  return(abs(scale(x)) > k)
}

# Número de observaciones atípicas por variable
mat_out <- sapply(datosacp, is_outlier3)
kable(data.frame(Variable = colnames(mat_out), N_atipicos = colSums(mat_out)),
      row.names = FALSE, caption = "Observaciones con |Z| > 3 por variable")
```

Observaciones con |Z| > 3 por variable

Variable	N_atipicos
AMABILIDAD	1
RAPIDEZ	0
RESOLUCION	0
CAL_PROD	0
VAR_PROD	0
PRECIO	0
LIMPIEZA	1
ORDEN	0

```
# Detalle de las filas señaladas (equivale a datosacp[is_outlier3(variable), ] para cada variabl
        e)
filas_atipicas <- which(rowSums(mat_out) > 0)
kable(cbind(Fila = filas_atipicas, ID = datos$ID_ENCUESTA[filas_atipicas],
            datosacp[filas_atipicas, ]),
      row.names = FALSE, caption = "Clientes con al menos una puntuación atípica")
```

Clientes con al menos una puntuación atípica

FilaID	AMABILIDAD	RAPIDEZ	RESOLUCION	CAL_PROD	VAR_PROD	PRECIO	LIMPIEZA	ORDEN
165ENC-1165	82	93	66	82	82	87	47	55
196ENC-1196	13	35	27	85	75	83	68	68

Solo dos puntuaciones superan |Z| > 3: una en `LIMPIEZA` (valor 47) y otra en `AMABILIDAD` (valor 13). Ambas son valores posibles dentro de la escala 0–100 (clientes realmente insatisfechos y no errores de registro) y representan menos del 1 % de la muestra, de modo que se conservan.

5.3.2 Análisis descriptivo

Estadísticos descriptivos globales y por tipo de cliente.

```
desc_global <- as.data.frame(summarytools::descr(datosacp, transpose = TRUE))
kable(round(desc_global, 2), caption = "Estadísticos descriptivos de las variables activas")
```

Estadísticos descriptivos de las variables activas

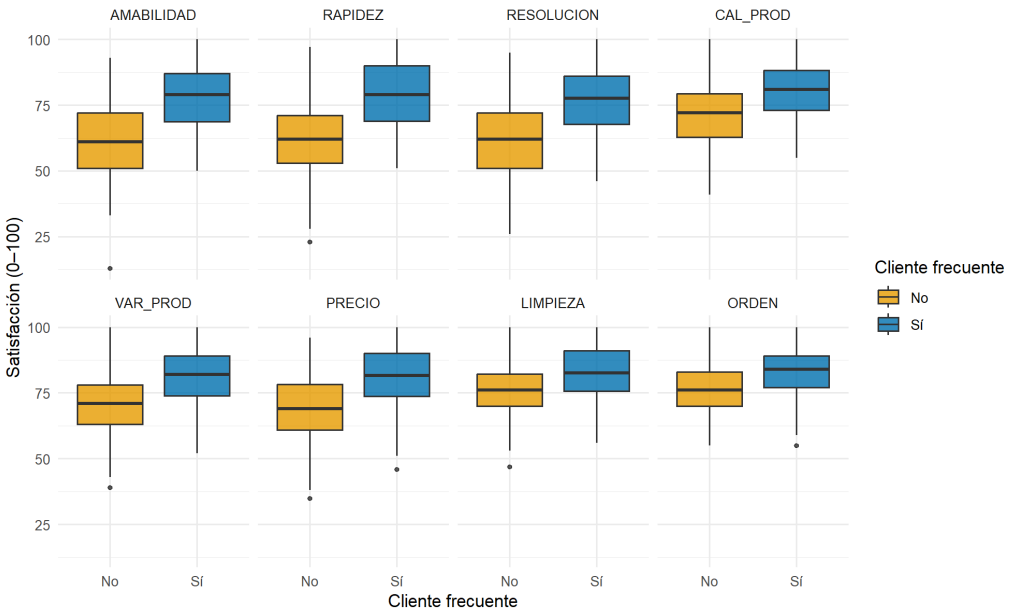
	Mean	Std.Dev	Min	Q1	Median	Q3	Max	MAD	IQR	CV	Skewness	SE.Skewness	Kurtosis	N.Valid	N	Pct.Valid
AMABILIDAD	69.18	15.70	13	59.0	70.0	80.0	100	16.31	21.00	0.23	-0.18	0.14	-0.19	300	300	100
CAL_PROD	75.33	12.28	41	68.0	76.0	84.0	100	11.86	16.00	0.16	-0.26	0.14	-0.19	300	300	100
LIMPIEZA	79.16	10.50	47	72.0	79.0	86.5	100	10.38	14.25	0.13	-0.03	0.14	-0.42	300	300	100
ORDEN	79.74	10.35	55	72.0	79.0	88.0	100	11.86	16.00	0.13	-0.03	0.14	-0.63	300	300	100
PRECIO	74.72	13.95	35	65.0	75.0	85.0	100	14.83	20.00	0.19	-0.24	0.14	-0.32	300	300	100
RAPIDEZ	69.89	15.92	23	59.0	70.0	81.0	100	16.31	22.00	0.23	-0.07	0.14	-0.36	300	300	100
RESOLUCION	68.81	15.26	26	58.5	69.5	78.5	100	15.57	19.50	0.22	-0.10	0.14	-0.35	300	300	100
VAR_PROD	75.22	12.45	39	66.0	75.0	85.0	100	14.83	19.00	0.17	-0.15	0.14	-0.45	300	300	100

```r
# Estadísticos por CLIENTE_FRECUENTE (equivale a stby(variable, CLIENTE_FRECUENTE, descr))
desc_grupos <- datos1 %>%
  pivot_longer(cols = -CLIENTE_FRECUENTE, names_to = "Variable", values_to = "Puntaje") %>%
  mutate(Variable = factor(Variable, levels = names(datosacp))) %>%
  group_by(Variable, CLIENTE_FRECUENTE) %>%
  summarise(n = n(), Media = mean(Puntaje), DE = sd(Puntaje), Min = min(Puntaje),
            Mediana = median(Puntaje), Max = max(Puntaje), .groups = "drop")
kable(desc_grupos, digits = 2, caption = "Estadísticos por tipo de cliente")
```

Estadísticos por tipo de cliente

Variable	CLIENTE_FRECUENTE	n	Media	DE	Min	Mediana	Max
AMABILIDAD	No	160	61.34	13.68	13	61.0	93
AMABILIDAD	Sí	140	78.14	12.83	50	79.0	100
RAPIDEZ	No	160	61.89	13.58	23	62.0	97
RAPIDEZ	Sí	140	79.04	13.28	51	79.0	100
RESOLUCION	No	160	61.44	13.47	26	62.0	95
RESOLUCION	Sí	140	77.23	12.63	46	77.5	100
CAL_PROD	No	160	70.65	11.80	41	72.0	100
CAL_PROD	Sí	140	80.69	10.54	55	81.0	100
VAR_PROD	No	160	70.21	11.48	39	71.0	100
VAR_PROD	Sí	140	80.96	10.97	52	82.0	100
PRECIO	No	160	69.08	12.90	35	69.0	96
PRECIO	Sí	140	81.16	12.24	46	81.5	100
LIMPIEZA	No	160	76.30	10.24	47	76.0	100
LIMPIEZA	Sí	140	82.43	9.84	56	82.5	100
ORDEN	No	160	76.96	10.24	55	76.0	100
ORDEN	Sí	140	82.91	9.56	55	84.0	100

```r
datos1 %>%
  pivot_longer(cols = -CLIENTE_FRECUENTE, names_to = "Variable", values_to = "Puntaje") %>%
  mutate(Variable = factor(Variable, levels = names(datosacp))) %>%
  ggplot(aes(x = CLIENTE_FRECUENTE, y = Puntaje, fill = CLIENTE_FRECUENTE)) +
  geom_boxplot(alpha = 0.8, outlier.size = 1) +
  facet_wrap(~Variable, nrow = 2) +
  scale_fill_manual(values = c("No" = "#E69F00", "Sí" = "#0072B2")) +
  labs(x = "Cliente frecuente", y = "Satisfacción (0-100)", fill = "Cliente frecuente") +
  theme_minimal()
```



> **🔎 Interpretación**
>
> **Interpretación.** Las puntuaciones medias son más altas en `ORDEN` (79.7) y `LIMPIEZA` (79.2), y más bajas en `RESOLUCION` (68.8), `AMABILIDAD` (69.2) y `RAPIDEZ` (69.9): el punto débil de la experiencia es el personal. Esas tres variables son además las más dispersas (desviación estándar ≈ 15–16 puntos), mientras que `LIMPIEZA` y `ORDEN` son las más homogéneas (≈ 10 puntos). La asimetría y la curtosis son cercanas a 0 en todas las variables (distribuciones aproximadamente simétricas). Los clientes frecuentes puntúan más alto en las ocho variables, con la mayor diferencia en las tres variables del personal (≈ 78 frente a ≈ 61 puntos).

5.3.3 Análisis de correlación

Matriz de correlaciones, prueba estadística y gráficos.

```
# Coeficientes de correlación de Pearson
kable(round(cor(datosacp), 3), caption = "Matriz de correlaciones de Pearson")
```

Matriz de correlaciones de Pearson

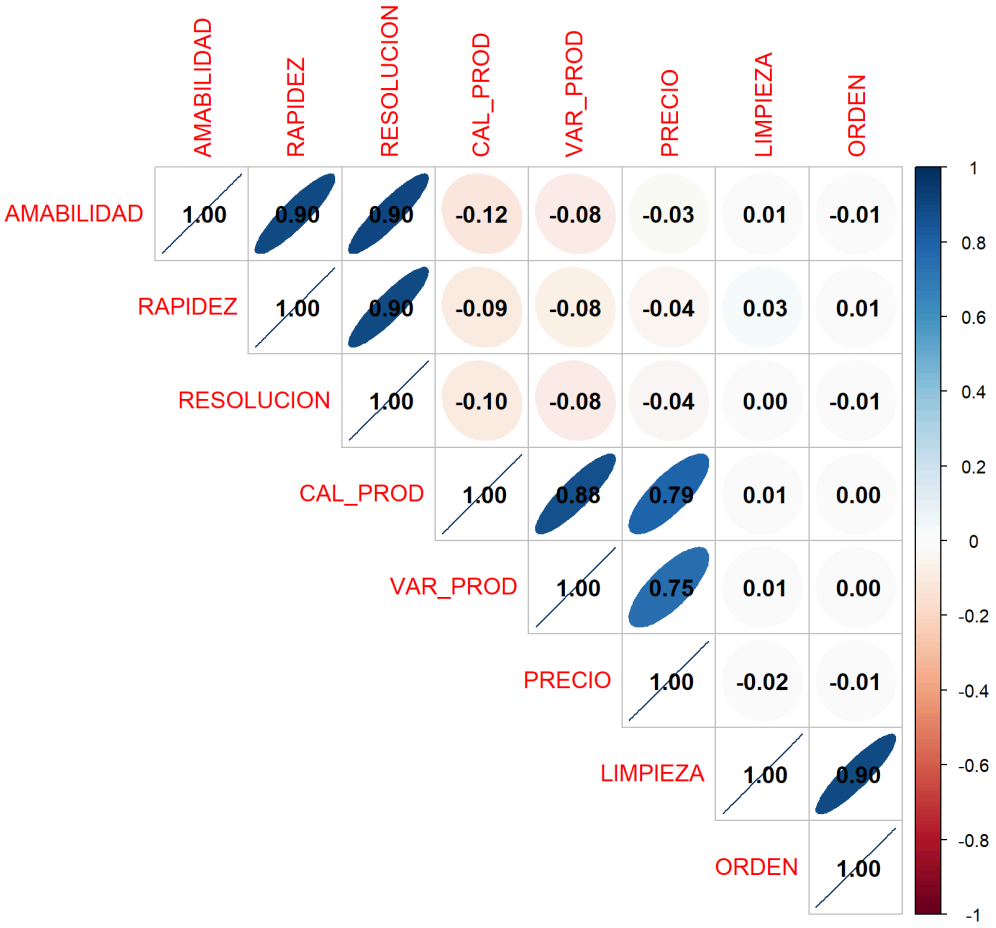
	AMABILIDAD	RAPIDEZ	RESOLUCION	CAL_PROD	VAR_PROD	PRECIO	LIMPIEZA	ORDEN
AMABILIDAD	1.000	0.896	0.902	-0.119	-0.084	-0.029	0.008	-0.006
RAPIDEZ	0.896	1.000	0.900	-0.093	-0.075	-0.042	0.032	0.009
RESOLUCION	0.902	0.900	1.000	-0.100	-0.083	-0.037	0.005	-0.014
CAL_PROD	-0.119	-0.093	-0.100	1.000	0.878	0.790	0.008	0.000
VAR_PROD	-0.084	-0.075	-0.083	0.878	1.000	0.754	0.012	-0.005
PRECIO	-0.029	-0.042	-0.037	0.790	0.754	1.000	-0.018	-0.013
LIMPIEZA	0.008	0.032	0.005	0.008	0.012	-0.018	1.000	0.898
ORDEN	-0.006	0.009	-0.014	0.000	-0.005	-0.013	0.898	1.000

```
# Prueba estadística : p-valores sin ajuste (debajo de la diagonal)
# y ajustados por Holm (encima de la diagonal)
ct <- corr.test(datosacp)
kable(round(ct$p, 4), caption = "p-valores de la prueba de correlación")
```

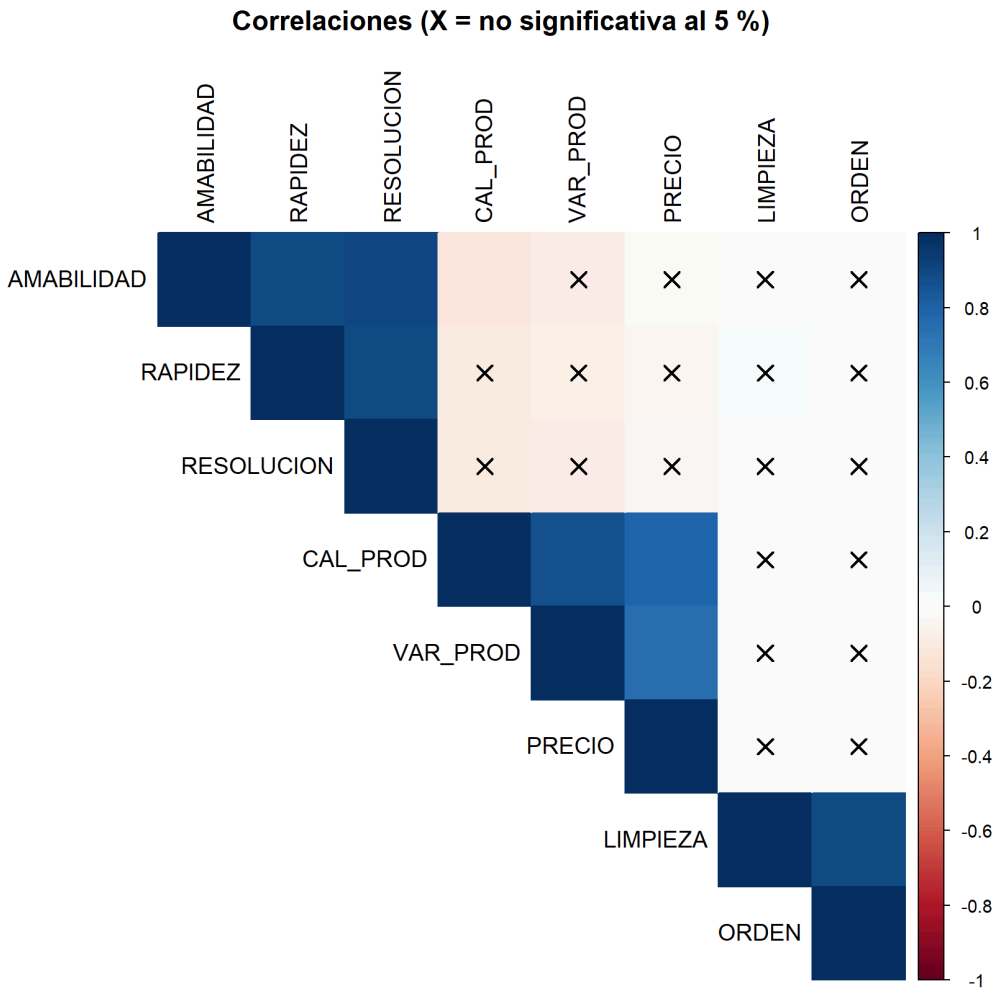
p-valores de la prueba de correlación

	AMABILIDAD	RAPIDEZ	RESOLUCION	CAL_PROD	VAR_PROD	PRECIO	LIMPIEZA	ORDEN
AMABILIDAD	0.0000	0.0000	0.0000	0.8173	1.0000	1.0000	1	1
RAPIDEZ	0.0000	0.0000	0.0000	1.0000	1.0000	1.0000	1	1
RESOLUCION	0.0000	0.0000	0.0000	1.0000	1.0000	1.0000	1	1
CAL_PROD	0.0389	0.1084	0.0838	0.0000	0.0000	0.0000	1	1
VAR_PROD	0.1454	0.1922	0.1534	0.0000	0.0000	0.0000	1	1
PRECIO	0.6224	0.4734	0.5242	0.0000	0.0000	0.0000	1	1
LIMPIEZA	0.8952	0.5841	0.9328	0.8847	0.8365	0.7621	0	0
ORDEN	0.9232	0.8751	0.8040	0.9937	0.9338	0.8182	0	0

```
# Gráfico de correlación
i <- cor(datosacp, method = "pearson")
corrplot(i, method = "ellipse", order = "original", addCoef.col = "black", type = "upper")
```




```
# Matriz de p-valores
res1 <- cor.mtest(datosacp, conf.level = 0.95)
corrplot(i, method = "color", type = "upper", p.mat = res1$p, sig.level = 0.05,
         insig = "pch", pch.cex = 1.5, tl.col = "black",
         title = "Correlaciones (X = no significativa al 5 %)", mar = c(0, 0, 2, 0))
```



Interpretación. La matriz muestra tres bloques de variables muy correlacionadas entre sí y casi incorrelacionadas con los demás:

- **Personal:** `AMABILIDAD`, `RAPIDEZ` y `RESOLUCION` ($r \approx 0.90$).
- **Oferta comercial:** `CAL_PROD`, `VAR_PROD` y `PRECIO` (r entre 0.75 y 0.88).
- **Instalaciones:** `LIMPIEZA` y `ORDEN` ($r \approx 0.90$).

Las correlaciones entre bloques son prácticamente nulas ($|r| \leq 0.12$); la única con $p < 0.05$ sin ajuste, `AMABILIDAD` – `CAL_PROD` ($r = -0.12$), deja de ser significativa al ajustar por Holm. Esta estructura anticipa tres factores latentes.

Adecuación de los datos para el ACP . Se aplican la prueba de esfericidad de Bartlett (H_0: la matriz de correlaciones es la identidad) y la medida de Kaiser–Meyer–Olkin (KMO).

```
bart <- cortest.bartlett(cor(datosacp), n = nrow(datosacp))
kmo  <- KMO(datosacp)

kable(data.frame(Estadístico = c("Chi-cuadrado de Bartlett", "gl", "p-valor",
                                 "Determinante de R", "KMO global"),
                 Valor = c(round(bart$chisq, 2), bart$df, format.pval(bart$p.value, eps = 0.00
        1),
                           signif(det(cor(datosacp)), 3), round(kmo$MSA, 3))),
      caption = "Pruebas de adecuación muestral")
```

Pruebas de adecuación muestral

Estadístico	Valor
Chi-cuadrado de Bartlett	2292.2
gl	28

Estadístico	Valor
p-valor	< 0.001
Determinante de R	0.000428
KMO global	0.7

```
kable(data.frame(Variable = names(kmo$MSAi), MSA = round(kmo$MSAi, 3)),
      row.names = FALSE, caption = "KMO individual (MSA) por variable")
```

KMO individual
(MSA) por variable

Variable	MSA
AMABILIDAD	0.770
RAPIDEZ	0.786
RESOLUCION	0.777
CAL_PROD	0.675
VAR_PROD	0.717
PRECIO	0.834
LIMPIEZA	0.497
ORDEN	0.498

La prueba de Bartlett rechaza que la matriz de correlaciones sea la identidad ($\chi^2 = 2292.2$, gl = 28, $p < 0.001$) y el determinante de la matriz es muy cercano a cero (0.000428), lo que confirma que existen correlaciones que el ACP puede resumir. El KMO global es 0.7 (aceptable). `LIMPIEZA` y `ORDEN` obtienen un MSA cercano a 0.50 porque solo se correlacionan entre ellas y con ninguna otra variable; esto no indica un problema de ajuste, sino que forman una dimensión propia e independiente de las demás.

5.3.4 Análisis de Componentes Principales

Extracción de los componentes. ACP sobre la matriz de correlaciones (`scale = TRUE`), conservando inicialmente los 8 componentes.

```
acp <- dudi.pca(datosacp, scannf = FALSE, scale = TRUE, nf = ncol(datosacp))
summary(acp)
```

```
#> Class: pca dudi
#> Call: dudi.pca(df = datosacp, scale = TRUE, scannf = FALSE, nf = ncol(datosacp))
#>
#> Total inertia: 8
#>
#> Eigenvalues:
#>     Ax1     Ax2     Ax3     Ax4     Ax5
#>  2.9493  2.4681  1.8990  0.2650  0.1247
#>
#> Projected inertia (%):
#>     Ax1     Ax2     Ax3     Ax4     Ax5
#>  36.867  30.851  23.737   3.312   1.559
#>
#> Cumulative projected inertia (%):
#>     Ax1   Ax1:2   Ax1:3   Ax1:4   Ax1:5
#>   36.87   67.72   91.46   94.77   96.33
#>
#> (Only 5 dimensions (out of 8) are shown)
```

```
# Valores propios (autovalores)
varianza <- 100 * acp$eig / sum(acp$eig)
tab_eig <- data.frame(Componente = paste0("CP", seq_along(acp$eig)),
                      Autovalor = acp$eig,
                      Varianza_pct = varianza,
                      Acumulada_pct = cumsum(varianza))
kable(tab_eig, digits = 3, caption = "Valores propios y varianza explicada")
```

Valores propios y varianza explicada

Componente	Autovalor	Varianza_pct	Acumulada_pct
CP1	2.949	36.867	36.867
CP2	2.468	30.851	67.718
CP3	1.899	23.737	91.455
CP4	0.265	3.312	94.767
CP5	0.125	1.559	96.327
CP6	0.104	1.297	97.623
CP7	0.099	1.234	98.857
CP8	0.091	1.143	100.000

```
inertia.dudi(acp)
```

```
#> Inertia information:
#> Call: inertia.dudi(x = acp)
#>
#> Decomposition of total inertia:
#>     inertia     cum  cum(%)
#> Ax1 2.94934   2.949   36.87
#> Ax2 2.46808   5.417   67.72
#> Ax3 1.89899   7.316   91.46
#> Ax4 0.26498   7.581   94.77
#> Ax5 0.12475   7.706   96.33
#> Ax6 0.10373   7.810   97.62
#> Ax7 0.09871   7.909   98.86
#> Ax8 0.09142   8.000  100.00
```

> 🔎 **Interpretación**
>
> Los dos primeros autovalores (2.949 y 2.468) explican 67.72 % de la varianza ; con el tercero (1.899) se llega a **91.46 %**.

Vectores propios y correlaciones variable–componente.

```
# Vectores propios (coeficientes de las combinaciones lineales)
kable(round(acp$c1, 3), caption = "Vectores propios (acp$c1)")
```

Vectores propios (acp$c1)

	CS1	CS2	CS3	CS4	CS5	CS6	CS7	CS8
AMABILIDAD	-0.481	-0.318	0.011	0.059	0.361	0.310	-0.074	0.657
RAPIDEZ	-0.478	-0.322	-0.004	-0.081	-0.246	-0.471	-0.579	-0.206
RESOLUCION	-0.480	-0.321	0.016	-0.025	-0.135	0.182	0.645	-0.445
CAL_PROD	0.342	-0.479	-0.008	-0.288	-0.657	0.190	0.035	0.320
VAR_PROD	0.327	-0.481	-0.007	-0.492	0.594	-0.078	-0.036	-0.243
PRECIO	0.292	-0.481	0.010	0.812	0.075	-0.108	-0.002	-0.082
LIMPIEZA	-0.013	-0.009	-0.707	-0.037	0.026	-0.541	0.355	0.283
ORDEN	-0.006	0.003	-0.707	0.058	-0.019	0.550	-0.338	-0.283

```
# Correlaciones entre las variables originales y las componentes principales (cargas)
kable(round(acp$co, 3), caption = "Correlaciones variable-componente (acp$co)")
```

Correlaciones variable–componente (acp$co)

	Comp1	Comp2	Comp3	Comp4	Comp5	Comp6	Comp7	Comp8
AMABILIDAD	-0.827	-0.499	0.015	0.030	0.127	0.100	-0.023	0.199
RAPIDEZ	-0.821	-0.506	-0.006	-0.042	-0.087	-0.152	-0.182	-0.062
RESOLUCION	-0.825	-0.504	0.021	-0.013	-0.048	0.059	0.203	-0.134
CAL_PROD	0.587	-0.752	-0.011	-0.148	-0.232	0.061	0.011	0.097
VAR_PROD	0.561	-0.756	-0.010	-0.253	0.210	-0.025	-0.011	-0.073

	Comp1	Comp2	Comp3	Comp4	Comp5	Comp6	Comp7	Comp8
PRECIO	0.501	-0.756	0.014	0.418	0.027	-0.035	-0.001	-0.025
LIMPIEZA	-0.022	-0.014	-0.974	-0.019	0.009	-0.174	0.111	0.086
ORDEN	-0.010	0.004	-0.974	0.030	-0.007	0.177	-0.106	-0.086

```
# Comunalidad con 3 componentes: proporción de la varianza de cada variable que retienen
kable(data.frame(Variable = rownames(acp$co),
                 Comunalidad_3CP = round(rowSums(acp$co[, 1:3]^2), 3)),
      row.names = FALSE, caption = "Comunalidad de cada variable con los 3 primeros componente
        s")
```

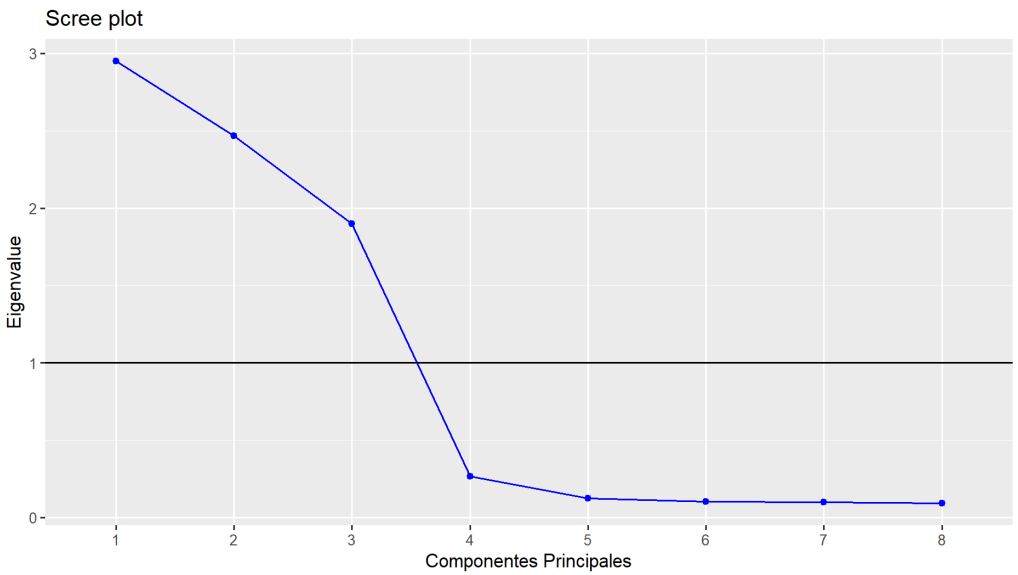
Comunalidad de cada variable con los 3 primeros componentes

Variable	Comunalidad_3CP
AMABILIDAD	0.933
RAPIDEZ	0.931
RESOLUCION	0.935
CAL_PROD	0.911
VAR_PROD	0.886
PRECIO	0.823
LIMPIEZA	0.950
ORDEN	0.949

5.3.4.1 Cuántos componentes retener

Gráfico de sedimentación (criterio de Kaiser).

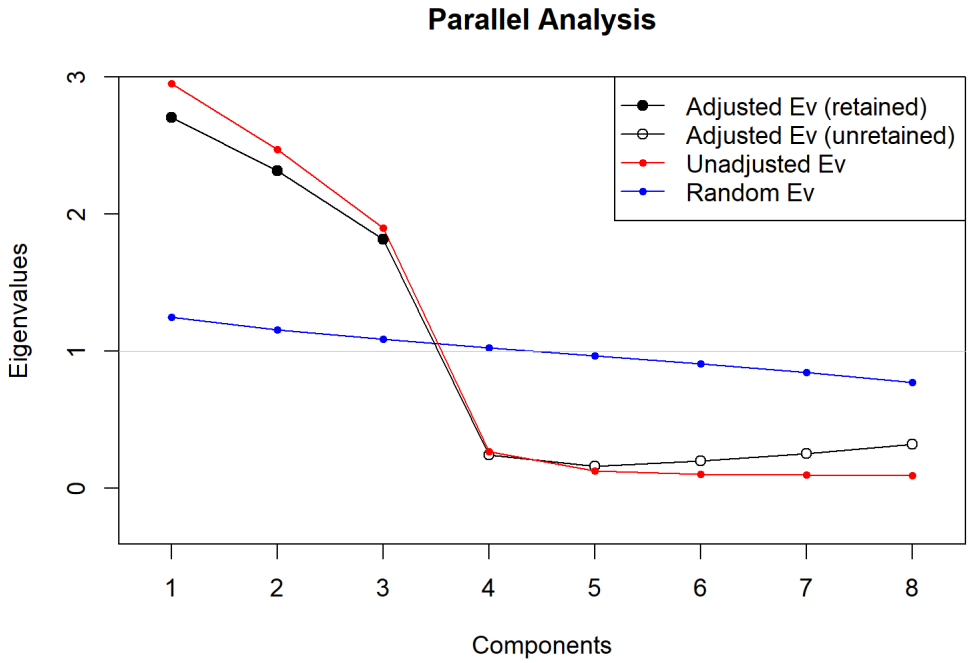
```
a <- fviz_eig(acp, choice = 'eigenvalue', geom = "line", linecolor = 'blue',
              xlab = 'Componentes Principales') +
  geom_hline(yintercept = 1, color = 'black') +
  theme_grey()
a
```



Método paralelo de Horn. Un componente se retiene si su autovalor supera al que se obtendría con datos aleatorios no correlacionados del mismo tamaño.

```
paran(datosacp, iterations = 5000, graph = TRUE, color = TRUE)
```

```
#>
#> Computing: 10%  20%  30%  40%  50%  60%  70%  80%  90%  100%
```




```
# Comprobación: autovalores observados vs. percentil 95 de autovalores de datos aleatorios
set.seed(2024)
n <- nrow(datosacp); p <- ncol(datosacp)
sim <- replicate(2000, eigen(cor(matrix(rnorm(n * p), n, p)), only.values = TRUE)$values)
tab_horn <- data.frame(Componente = paste0("CP", 1:p),
                       Observado = acp$eig,
                       Aleatorio_p95 = apply(sim, 1, quantile, probs = 0.95),
                       Retener = ifelse(acp$eig > apply(sim, 1, quantile, probs = 0.95), "Sí",
        "No"))
kable(tab_horn, digits = 3, caption = "Análisis paralelo de Horn (2 000 simulaciones)")
```

Análisis paralelo de Horn (2 000 simulaciones)

Componente	Observado	Aleatorio_p95	Retener
CP1	2.949	1.329	Sí
CP2	2.468	1.214	Sí
CP3	1.899	1.131	Sí
CP4	0.265	1.065	No
CP5	0.125	1.004	No
CP6	0.104	0.950	No
CP7	0.099	0.892	No
CP8	0.091	0.829	No

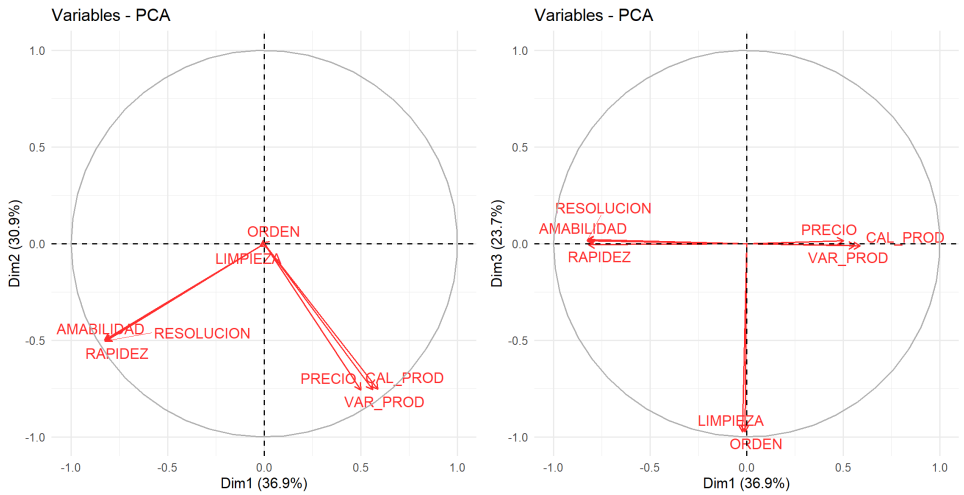
Decisión

Decisión. Los tres criterios coinciden: (i) hay 3 autovalores mayores que 1; (ii) el gráfico de sedimentación muestra una caída brusca entre el tercer (1.90) y el cuarto autovalor (0.27); (iii) el análisis paralelo retiene 3 componentes, y (iv) estos explican 91.46 % de la varianza total. Se retienen 3 componentes principales.

5.3.4.2 Representación de las variables

Círculo de correlaciones.

```
b <- fviz_pca_var(acp, col.var = "#FF3030", repel = TRUE) + theme_minimal()
b13 <- fviz_pca_var(acp, axes = c(1, 3), col.var = "#FF3030", repel = TRUE) + theme_minimal()
b + b13
```



5.3.4.3 Interpretación de los componentes

Con el umbral |r| ≥ 0.45 se resume la estructura retenida:

```
cargas <- round(acp$co[, 1:3], 3)
cargas_mostrar <- apply(cargas, c(1, 2), function(v) ifelse(abs(v) >= 0.45, sprintf("%.3f", v),
        ""))
kable(cargas_mostrar, caption = "Cargas con |r| ≥ 0.45 (resto omitido)", align = "ccc")
```

Cargas con |r| ≥ 0.45 (resto omitido)

	Comp1	Comp2	Comp3
AMABILIDAD	-0.827	-0.499	
RAPIDEZ	-0.821	-0.506	
RESOLUCION	-0.825	-0.504	
CAL_PROD	0.587	-0.752	
VAR_PROD	0.561	-0.756	
PRECIO	0.501	-0.756	
LIMPIEZA			-0.974
ORDEN			-0.974

- **CP1 (36.9 %) — "Preferencia a la atención del personal".** Es un eje *bipolar*: `AMABILIDAD`, `RAPIDEZ` y `RESOLUCION` cargan con signo negativo (≈ −0.82) y `CAL_PROD`, `VAR_PROD` y `PRECIO` con signo positivo (0.50–0.59). Separa a los clientes que valoran más el trato de los que valoran más el producto.
- **CP2 (30.9 %) — "Satisfacción total con personal y productos".** Las seis variables cargan con el mismo signo (−0.50 a −0.76): es un eje de satisfacción global con la atención y la oferta. Al ser el signo negativo, *las puntuaciones más negativas en CP2 indican clientes más satisfechos*.
- **CP3 (23.7 %) — "Preferencia a las instalaciones".** `LIMPIEZA` y `ORDEN` cargan casi exclusivamente aquí (−0.974 ambas) y las demás variables no tienen relación con este eje.

Los dos primeros autovalores son parecidos (2.95 y 2.47), por lo que el plano CP1–CP2 es en la práctica un plano en el que las direcciones "personal" y "oferta" pueden girar. Como verificación se aplica una rotación varimax a los 3 componentes retenidos:

```
pc_var <- principal(datosacp, nfactors = 3, rotate = "varimax")
kable(round(unclass(pc_var$loadings), 3), caption = "Cargas rotadas (varimax)")
```

Cargas rotadas (varimax)

	RC1	RC2	RC3
AMABILIDAD	0.965	-0.042	-0.003
RAPIDEZ	0.964	-0.034	0.019
RESOLUCION	0.966	-0.037	-0.009
CAL_PROD	-0.073	0.952	0.007
VAR_PROD	-0.048	0.940	0.006

	RC1	RC2	RC3
PRECIO	0.002	0.907	-0.017
LIMPIEZA	0.013	0.003	0.974
ORDEN	-0.007	-0.006	0.974

```
kable(round(pc_var$Vaccounted[1:3, ], 3), caption = "Varianza explicada tras la rotación")
```

Varianza explicada tras la rotación

	RC1	RC2	RC3
SS loadings	2.801	2.616	1.899
Proportion Var	0.350	0.327	0.237
Cumulative Var	0.350	0.677	0.915

> **Interpretación**
>
> Tras la rotación la estructura es nítida: RC1 = Atención del personal (cargas ≈ 0.96), RC2 = Oferta comercial (0.91–0.95) y RC3 = Instalaciones (0.97), con la misma varianza acumulada (91.5 %). Es decir, las ocho variables se resumen en tres factores latentes de la experiencia del cliente.

5.3.4.4 Puntuaciones (Scores) de los clientes

Coordenadas de los individuos y biplot.

```
# Scores (primeros 10 clientes)
kable(cbind(ID = datos$ID_ENCUESTA[1:10], round(acp$li[1:10, 1:3], 3)),
      caption = "Scores de los 10 primeros clientes en los 3 primeros componentes")
```

Scores de los 10 primeros clientes en los 3 primeros componentes

ID	Axis1	Axis2	Axis3
ENC-1001	1.307	-0.001	-1.724
ENC-1002	-2.516	-0.118	0.852
ENC-1003	-1.295	-0.051	-0.661
ENC-1004	2.524	0.434	0.154
ENC-1005	1.146	0.729	-2.280
ENC-1006	-1.085	-2.749	-0.587
ENC-1007	2.842	3.215	-2.850
ENC-1008	1.245	0.195	1.139
ENC-1009	-1.132	-2.015	-1.138
ENC-1010	1.324	1.083	0.246

```
options(scipen = 999)
# Matriz de covarianzas de los scores: la diagonal son los autovalores y el resto es 0
kable(round(cov(acp$li), 4), caption = "Covarianza de los componentes (diagonal = autovalores)")
```

Covarianza de los componentes (diagonal = autovalores)

	Axis1	Axis2	Axis3	Axis4	Axis5	Axis6	Axis7	Axis8
Axis1	2.9592	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
Axis2	0.0000	2.4763	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
Axis3	0.0000	0.0000	1.9053	0.0000	0.0000	0.0000	0.0000	0.0000
Axis4	0.0000	0.0000	0.0000	0.2659	0.0000	0.0000	0.0000	0.0000
Axis5	0.0000	0.0000	0.0000	0.0000	0.1252	0.0000	0.0000	0.0000
Axis6	0.0000	0.0000	0.0000	0.0000	0.0000	0.1041	0.0000	0.0000
Axis7	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0990	0.0000
Axis8	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0917

```
kable(round(cor(acp$li), 4), caption = "Correlación de los componentes (ortogonales)")
```

Correlación de los componentes (ortogonales)

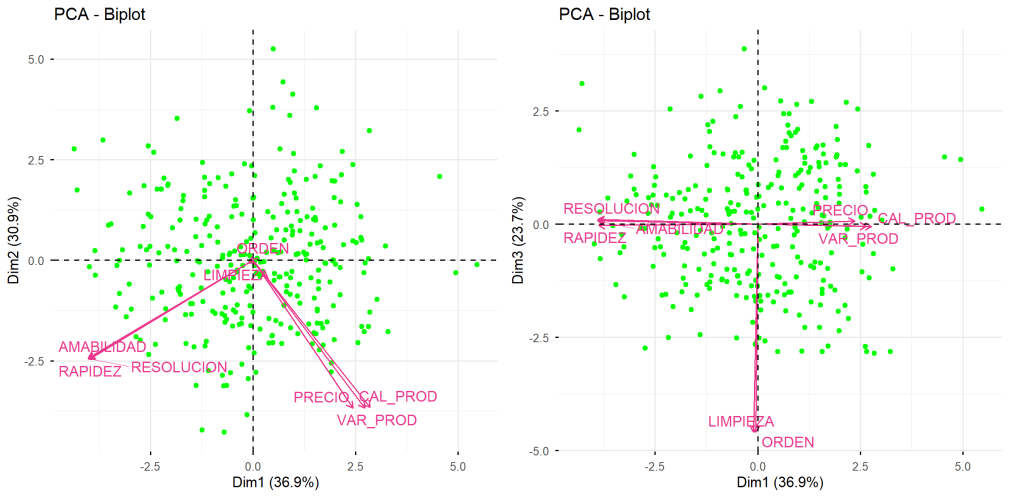
	Axis1	Axis2	Axis3	Axis4	Axis5	Axis6	Axis7	Axis8
Axis1	1	0	0	0	0	0	0	0
Axis2	0	1	0	0	0	0	0	0
Axis3	0	0	1	0	0	0	0	0
Axis4	0	0	0	1	0	0	0	0
Axis5	0	0	0	0	1	0	0	0
Axis6	0	0	0	0	0	1	0	0
Axis7	0	0	0	0	0	0	1	0
Axis8	0	0	0	0	0	0	0	1

```
kable(round(describe(acp$li)[, c("n", "mean", "sd", "min", "max", "skew", "kurtosis")], 3),
      caption = "Descriptivos de los scores")
```

Descriptivos de los scores

	n	mean	sd	min	max	skew	kurtosis
Axis1	300	0	1.720	-4.354	5.463	-0.105	-0.152
Axis2	300	0	1.574	-4.279	5.247	0.217	0.134
Axis3	300	0	1.380	-2.850	3.863	0.017	-0.534
Axis4	300	0	0.516	-1.372	1.563	-0.070	0.117
Axis5	300	0	0.354	-1.101	0.991	-0.297	0.054
Axis6	300	0	0.323	-1.156	0.965	-0.058	0.472
Axis7	300	0	0.315	-1.302	0.869	-0.319	0.724
Axis8	300	0	0.303	-0.935	0.830	-0.044	-0.155

```
# Individuos y variables sobre el primer plano (biplot)
c1 <- fviz_pca_biplot(acp, repel = TRUE, geom.ind = "point", col.var = "#EE3A8C", col.ind = "gre
   en")
c2 <- fviz_pca_biplot(acp, axes = c(1, 3), repel = TRUE, geom.ind = "point", col.var = "#EE3A8
   C", col.ind = "green")
c1 + c2
```



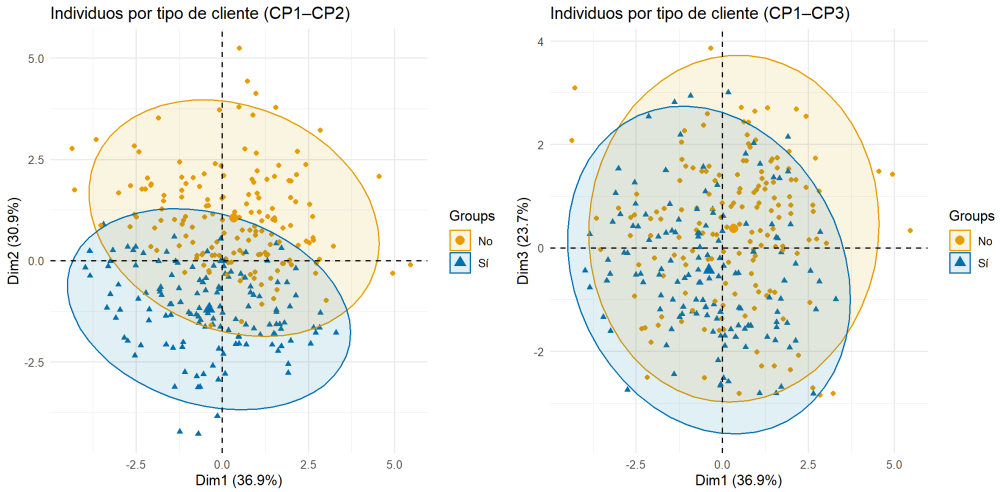
> **🔎 Interpretación**
>
> Los scores son incorrelacionados (covarianzas 0) y su varianza es igual al autovalor correspondiente, como exige la teoría del ACP.

5.3.5 Variable cualitativa: `CLIENTE_FRECUENTE`

Proyección de la variable cualitativa ilustrativa. La variable no interviene en el cálculo de los componentes; solo se utiliza para colorear los individuos y comparar los grupos sobre los ejes.

```
grupo <- datos1$CLIENTE_FRECUENTE

p12 <- fviz_pca_ind(acp, geom.ind = "point", habillage = grupo, addEllipses = TRUE,
                    ellipse.level = 0.95, palette = c("#E69F00", "#0072B2"),
                    title = "Individuos por tipo de cliente (CP1-CP2)") + theme_minimal()
p13 <- fviz_pca_ind(acp, axes = c(1, 3), geom.ind = "point", habillage = grupo, addEllipses = TR
       UE,
                    ellipse.level = 0.95, palette = c("#E69F00", "#0072B2"),
                    title = "Individuos por tipo de cliente (CP1-CP3)") + theme_minimal()
p12 + p13
```




```
scores3 <- data.frame(Grupo = grupo, acp$li[, 1:3])
kable(aggregate(. ~ Grupo, data = scores3, FUN = mean), digits = 3,
      caption = "Centroides de cada categoría en los tres primeros ejes")
```

Centroides de cada categoría en los tres primeros ejes

Grupo	Axis1	Axis2	Axis3
No	0.338	1.05	0.374
Sí	-0.387	-1.20	-0.428

```
# Comparación de los scores entre grupos (t de Welch) y tamaño del efecto (d de Cohen)
comp <- do.call(rbind, lapply(1:3, function(k) {
  s  <- acp$li[[k]]
  tt_ <- t.test(s ~ grupo)
  d  <- (mean(s[grupo == "Sí"]) - mean(s[grupo == "No"])) /
        sqrt((var(s[grupo == "Sí"]) + var(s[grupo == "No"])) / 2)
  data.frame(Eje = paste0("CP", k), t = unname(tt_$statistic), p_valor = tt_$p.value, d_Cohen =
        d)
}))
kable(comp, digits = c(0, 2, 6, 2), caption = "Diferencias entre clientes frecuentes y no frecue
        ntes")
```

Diferencias entre clientes frecuentes y no frecuentes

Eje	t	p_valor	d_Cohen
CP1	3.73	0.000233	-0.43
CP2	17.82	0.000000	-2.05

Eje	t	p_valor	d_Cohen
CP3	5.26	0.000000	-0.61

> **🔎 Interpretación**
>
> Los clientes frecuentes (`Sí`) se ubican hacia los valores negativos de CP2 y CP3, es decir, hacia mayor satisfacción. La diferencia es enorme en CP2 (t = 17.8; d ≈ −2.05), moderada en CP3 (d ≈ −0.61) y pequeña en CP1 (d ≈ −0.43). Los centroides están bien separados en el eje de satisfacción general, aunque las elipses se solapan parcialmente en los otros ejes.

5.3.6 Conglomerados jerárquicos sobre componentes principales

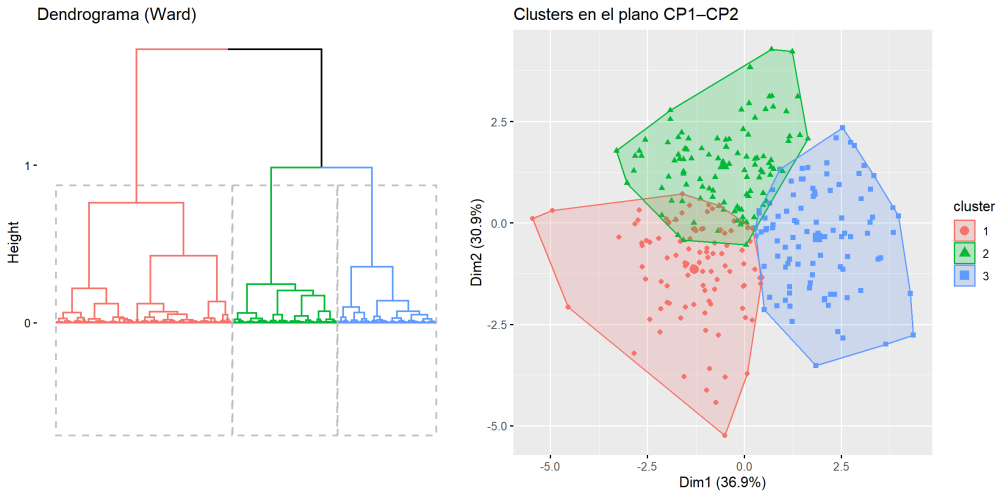
Clasificación jerárquica (HCPC).

```
respca <- PCA(datosacp, scale.unit = TRUE, ncp = 8, graph = FALSE)
res.hcpc <- HCPC(respca, nb.clust = 3, graph = FALSE)

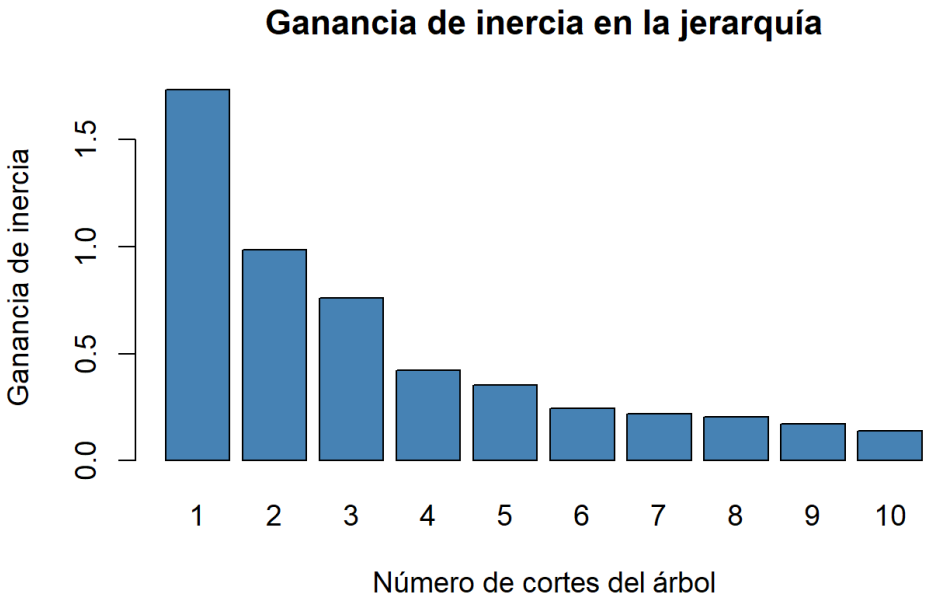
Grupos <- res.hcpc$data.clust$clust
table(Grupos)
```

```
#> Grupos
#>   1   2   3
#>  98 105  97
```

```
d1_ <- fviz_dend(res.hcpc, show_labels = FALSE, rect = TRUE, main = "Dendrograma (Ward)")
d2_ <- fviz_cluster(res.hcpc, geom = "point", show.clust.cent = TRUE, main = "Clusters en el pla
       no CP1-CP2")
d1_ + d2_
```




```
barplot(res.hcpc$call$t$inert.gain[1:10], names.arg = 1:10, col = "steelblue",
        xlab = "Número de cortes del árbol", ylab = "Ganancia de inercia",
        main = "Ganancia de inercia en la jerarquía")
```



> **🔎 Interpretación**
>
> El criterio automático de HCPC (mayor ganancia de inercia) sugiere 3 grupos, que es la solución adoptada. Cada grupo tiene un perfil distinto e interpretable en términos de los tres factores (ver tabla de medias) y los tamaños son parecidos (97 a 105 clientes). Los clusters se solapan en el plano CP1–CP2 porque parte de lo que los distingue (instalaciones) está en CP3.

Descripción de los clusters.

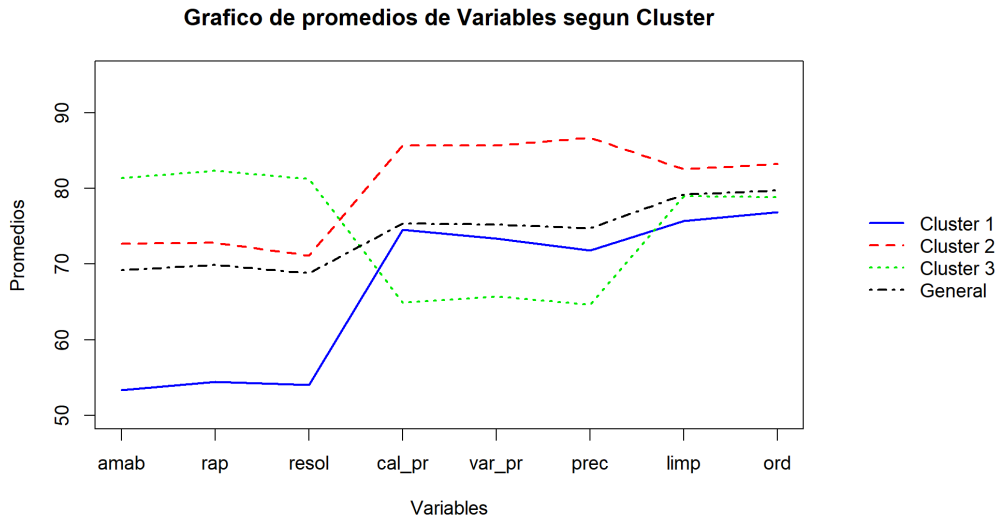
```
datosf <- cbind(datos1, Grupos)

# Perfil en base a las medias de cada variable por cluster
medias <- t(sapply(datosacp, function(v) tapply(v, Grupos, mean)))
colnames(medias) <- paste("Cluster", colnames(medias))
medias <- cbind(medias, General = colMeans(datosacp))
kable(round(medias, 2), caption = "Medias de cada variable por cluster")
```

Medias de cada variable por cluster

	Cluster 1	Cluster 2	Cluster 3	General
AMABILIDAD	53.38	72.70	81.35	69.18
RAPIDEZ	54.43	72.84	82.33	69.89
RESOLUCION	54.02	71.14	81.22	68.81
CAL_PROD	74.57	85.69	64.90	75.33
VAR_PROD	73.39	85.69	65.75	75.22
PRECIO	71.83	86.71	64.66	74.72
LIMPIEZA	75.70	82.53	79.00	79.16
ORDEN	76.88	83.21	78.87	79.74

```
layout(matrix(1:2, nrow = 1), widths = c(4, 1))
colores <- c("blue", "red", "green2", "black")
nombres <- c("Cluster 1", "Cluster 2", "Cluster 3", "General")
par(mar = c(5, 4, 4, 1))
matplot(medias,
        main = "Grafico de promedios de Variables segun Cluster",
        xlab = "Variables",
        ylab = "Promedios",
        type = "l",
        xaxt = "n",
        ylim = c(50, 95),
        col  = colores,
        lty  = 1:4,
        lwd  = 2)
axis(1, at = 1:8,
     labels = c("amab", "rap", "resol", "cal_pr", "var_pr", "prec", "limp", "ord"))
par(mar = c(0, 0, 0, 0))
plot.new()
legend("center", legend = nombres, col = colores, lty = 1:4, lwd = 2, cex = 1, bty = "n")
```




```
layout(1)
```

```
# Relación de los clusters con la variable ilustrativa
tab_cf <- table(Cluster = Grupos, Cliente_frecuente = datosf$CLIENTE_FRECUENTE)
kable(cbind(tab_cf, `% Sí` = round(100 * prop.table(tab_cf, 1)[, "Sí"], 1)),
      caption = "Clusters según cliente frecuente")
```

Clusters según cliente frecuente

	No	Sí	% Sí
1	98	0	0.0
2	11	94	89.5
5	146	131	47.4

```
# Prueba chi-cuadrado de independencia
ch <- chisq.test(tab_cf)
ch
```

```
#>
#>  Pearson's Chi-squared test
#>
#> data:  tab_cf
#> X-squared = 163.26, df = 2, p-value < 0.00000000000000022
```

```
# Frecuencias esperadas bajo independencia (deben ser >= 5)
round(ch$expected, 1)
```

```
#>        Cliente_frecuente
#> Cluster   No   Sí
#>       1 52.3 45.7
#>       2 56.0 49.0
#>       3 51.7 45.3
```

```
# V de Cramér: magnitud de la asociación (0 = nula, 1 = perfecta)
V <- sqrt(unname(ch$statistic) / (sum(tab_cf) * (min(dim(tab_cf)) - 1)))
round(V, 3)
```

```
#> [1] 0.738
```

> 🔎 **Interpretación**
>
> **Interpretación de la prueba chi-cuadrado.** Se contrasta H_0: el cluster al que pertenece un cliente es independiente de que sea cliente frecuente, frente a H_1: existe asociación entre ambas variables. El estadístico es $\chi^2 = 163.26$ con gl = 2 (= (3 − 1)(2 − 1)) y p < 2.2e-16, muy inferior a $\alpha = 0.05$. Por tanto se rechaza H_0: hay evidencia muy fuerte de que los clusters y la afiliación al programa de lealtad están asociados.

Esto es relevante porque los clusters se construyeron solo con las 8 variables de satisfacción, sin usar `CLIENTE_FRECUENTE`, y aun así reproducen diferencias reales entre afiliados y no afiliados: el cluster 1 (los más insatisfechos con el personal) no tiene ningún cliente frecuente (0 %), el cluster 2 (los más satisfechos) es casi todo afiliado (89.5 %) y el cluster 3 es intermedio (47.4 %). El V de Cramér es 0.74, lo que indica una asociación fuerte. La aproximación chi-cuadrado es válida porque todas las frecuencias esperadas son mayores que 5 (la menor es 45.3). La prueba muestra que existe asociación, pero no su causa: no permite saber si la afiliación genera satisfacción o si los clientes más satisfechos son los que se afilian.

5.4 Discusión

Estructura latente de la experiencia. La matriz de correlaciones ya mostraba tres bloques casi independientes, y el ACP lo confirma: tres componentes (autovalores 2.95, 2.47 y 1.90) retienen el 91.5 % de la información de las ocho variables, y la rotación varimax los identifica con claridad como atención del personal(amabilidad,rapidez y resolución), oferta comercial (calidad, variedad y precio) e instalaciones (limpieza y orden). El cuarto autovalor (0.27) y los siguientes están por debajo de lo esperable por azar, por lo que no hay más estructura sistemática. La comunalidad de todas las variables con 3 componentes supera 0.82 (la más baja es `PRECIO`, 0.82), de modo que ninguna se pierde en la reducción.

Sobre la interpretación de CP1 y CP2. Sin rotación, los dos primeros componentes mezclan los bloques de personal y oferta (CP1 los contrasta y CP2 los suma), porque sus autovalores son muy parecidos y el ACP no distingue entre las direcciones dentro de ese plano. Por eso se recomienda interpretar CP1 y CP2 conjuntamente (en el círculo de correlaciones los tres vectores del personal y los tres de la oferta forman dos haces separados) y apoyarse en la rotación para nombrar los factores. El tercer componente, en cambio, es limpio: solo `LIMPIEZA` y `ORDEN`, aunque definido por dos variables y con un KMO individual cercano a 0.50, por lo que convendría medir más aspectos del local en futuras encuestas para consolidarlo.

Variable cualitativa. Ser cliente frecuente se asocia a mayor satisfacción global (CP2, d ≈ −2.05) y mayor satisfacción con las instalaciones (CP3). La diferencia en CP2 es muy grande, aunque es una asociación: la encuesta no permite saber si la afiliación al programa de lealtad genera satisfacción o si los clientes más satisfechos son los que se afilian.

Conglomerados. Los tres grupos combinan de forma distinta los factores (medias de la tabla de perfiles):

Cluster	n	Personal	Oferta	Instalaciones	% clientes frecuentes	Perfil
1	98	Muy bajo (≈ 54)	Medio (≈ 72–75)	Medio (≈ 76)	0 %	Clientes insatisfechos con el personal; ninguno está afiliado
2	105	Medio (≈ 72)	Muy alto (≈ 86)	Muy alto (≈ 83)	89.5 %	Clientes más satisfechos con la oferta y las instalaciones; casi todos afiliados
3	97	Muy alto (≈ 81–82)	Muy bajo (≈ 65)	Medio (≈ 79)	47.4 %	Buen trato, pero mala valoración de calidad, variedad y precio

La asociación entre cluster y afiliación es fuerte ($\chi^2 = 163.26$, gl = 2, $p < 0.001$; V de Cramér = 0.74). La estructura de bloques independientes explica por qué aparecen perfiles “mixtos”: un cliente puede estar satisfecho con el personal y no con el producto (cluster 3), o con el producto y el local pero no tanto con la atención (cluster 2 frente a los clusters 1 y 3).

Limitaciones. Los puntajes son autoreportados y la encuesta es transversal; el ACP asume relaciones lineales y es sensible a observaciones extremas (aquí solo hay dos, moderadas y conservadas). Los grupos de HCPC dependen del número de clusters elegido.

5.5 Conclusiones

🏁 Conclusiones

1. La base está completa (0 % de datos perdidos) y solo presenta dos puntuaciones atípicas moderadas ($|Z| > 3$), que se conservaron por ser valores válidos de la escala.
2. Los datos son adecuados para el ACP: existen tres bloques de correlaciones altas (r ≈ 0.75–0.90), la prueba de Bartlett es significativa ($p < 0.001$) y el KMO global es 0.70.
3. Se retienen 3 componentes principales (autovalores 2.95, 2.47 y 1.90) que explican el 91.46 % de la varianza, según los criterios de Kaiser, sedimentación y análisis paralelo.
4. Los factores latentes de la experiencia del cliente son: atención del personal (`AMABILIDAD` , `RAPIDEZ` , `RESOLUCION`), oferta comercial (`CAL_PROD` , `VAR_PROD` , `PRECIO`) e instalaciones (`LIMPIEZA` , `ORDEN`).
5. La atención del personal es la dimensión peor valorada y más dispersa (medias ≈ 69, DE ≈ 15–16), por lo que es la principal oportunidad de mejora.
6. Los clientes frecuentes están más satisfechos, sobre todo en la dimensión global de personal y oferta (CP2, d ≈ −2.05).
7. Se identifican tres perfiles de clientes: insatisfechos con el personal (cluster 1, ningún afiliado), satisfechos con la oferta y las instalaciones (cluster 2, 89.5 % afiliados) y satisfechos con el trato pero no con la oferta (cluster 3, 47.4 % afiliados). La asociación entre cluster y afiliación es significativa y fuerte ($\chi^2 = 163.26$, gl = 2, $p < 0.001$; V de Cramér = 0.74). Las acciones deben dirigirse a cada perfil: capacitación del personal (cluster 1) y revisión de calidad, variedad y precio (cluster 3).