Code

UNIVERSIDAD NACIONAL AGRARIA LA MOLINA

Técnicas Multivariadas · Examen Parcial · Ciclo 2026-II

Técnicas multivariadas aplicadas con R

MANOVA factorial en DBCA, MANCOVA en DCA y en DBCA, regresión multivariada y análisis de componentes principales

P1 · MANOVA factorial en DBCA **P2 · MANCOVA en DCA** **P3 · MANCOVA en DBCA**

P4 · Regresión multivariada **P5 · Componentes principales**

INTEGRANTES

Flores Cueva Jose Armando

Carrasco Barrial Gian Piero

Barrientos Mauricio Fabricio Rodrigo

Puma Vilcahuaman Harly Steve

Evaristo Jacinto Gabriel Omar

Bautista Aldave Camila

Docente: C. F. Miranda Villagómez Lima, octubre de 2026

Presentación del trabajo

Este documento reúne, en un solo informe reproducible, el desarrollo de las **cinco preguntas** del Examen Parcial 2026-II de Técnicas Multivariadas. Cada pregunta utiliza una base de datos distinta a las vistas en clase y se organiza según las pautas del examen: **data general, código R, introducción, desarrollo, discusión, conclusiones y bibliografía**.

N.º	Técnica multivariada	Base de datos	Variables principales
1	MANOVA con experimento factorial en DBCA	`Datos_7_1_Caso.sav` — campaña de promoción de la cadena Mercanova (Aldás y Uriel, 2017)	Respuestas: ventas de cola y ron · Factores: semana × tipo de supermercado · Bloque: día
2	MANCOVA en DCA	`StudentsPerformance.csv` — 1000 estudiantes	Respuestas: lectura y escritura · Tratamiento: curso de preparación · Covariable: matemática
3	MANCOVA en DBCA	`Cuyes_MANCOVA_DBCA.xlsx` — 72 cuyes (base didáctica simulada)	Respuestas: ganancia de peso y rendimiento de carcasa · Tratamiento: dosis de probiótico · Bloque: lote · Covariables: peso y edad iniciales
4	Regresión multivariada	`state.x77` (incluida en R) — 50 estados de EE. UU.	Respuestas: esperanza de vida e ingreso · Predictoras: analfabetismo, graduados de secundaria y días de helada
5	Análisis de componentes principales	`Encuesta.xlsx` — 300 clientes de una cadena de supermercados	8 variables de satisfacción (0–100) · Variable ilustrativa: cliente frecuente

> **Para compilar este documento**
>
> Guardar el archivo `.Rmd` en la **misma carpeta** que las bases `StudentsPerformance.csv`, `Cuyes_MANCOVA_DBCA.xlsx` y `Encuesta.xlsx`. La base de la pregunta 1 se descarga desde GitHub (si no hay internet, el código busca `Datos_7_1_Caso.sav` en la misma carpeta). Los paquetes de R faltantes se instalan automáticamente al compilar.

1 MANOVA con experimento factorial en DBCA

> **Ficha de la pregunta**
>
> - **Técnica:** MANOVA con experimento factorial (semana × tipo de supermercado) en DBCA, con el día como bloque
> - **Base de datos:** `Datos_7_1_Caso.sav` — campaña de promoción conjunta de Mercanova (Aldás y Uriel, 2017)
> - **Variables respuesta:** ventas de cola y de ron
> - **Factores:** semana (2 niveles) y tipo de supermercado (UC, UR y R) · **Bloque:** día de la semana (6 días)

1.1 Estructura del diseño

A continuación se analizará el siguiente experimento cuya estructura es la siguiente:

$$ \mathbf{Y}_{ijk} = \boldsymbol{\mu} + \boldsymbol{\alpha}_i + \boldsymbol{\beta}_j + \boldsymbol{\gamma}_k + (\boldsymbol{\alpha\beta})_{ij} + \boldsymbol{\varepsilon}_{ijk} $$ $$ i = 1,\dots,a, \qquad j = 1,\dots,b, \qquad k = 1,\dots,r $$ $$ \boldsymbol{\varepsilon}_{ijk} \sim N_p(\mathbf{0}, \boldsymbol{\Sigma}) $$ donde:

- $\mathbf{Y}_{ijk}$: vector de p variables respuesta
- $\boldsymbol{\mu}$: media general
- $\boldsymbol{\alpha}_i$: efecto del nivel i del factor A
- $\boldsymbol{\beta}_j$: efecto del nivel j del factor B
- $\boldsymbol{\gamma}_k$: efecto del bloque k
- $(\boldsymbol{\alpha\beta})_{ij}$: efecto de la interacción A×B
- $\boldsymbol{\varepsilon}_{ijk}$: error experimental

1.1.1 Hipótesis

Para determinar si los factores A, B y los bloques tienen efecto o no sobre el vector de respuestas Y, las hipótesis nulas a formular son las siguientes: $$ H_0: \boldsymbol{\alpha}_i = \mathbf{0} $$

$$ H_0: \boldsymbol{\beta}_j = \mathbf{0} $$

$$ H_0: (\boldsymbol{\alpha\beta})_{ij} = \mathbf{0} $$

$$ H_0: \boldsymbol{\gamma}_k = \mathbf{0} $$

1.1.2 Tabla de medias muestrales para cada combinación de los factores A y B

$$ \begin{array}{c|cccc|c} \hline \text{Niveles del} & & \text{Niveles del factor B} & & & \text{Marginal A} \\ \text{factor A} & 1 & 2 & \cdots & b & \\ \hline 1 & \bar{\mathbf{y}}_{11\bullet} & \bar{\mathbf{y}}_{12\bullet} & \cdots & \bar{\mathbf{y}}_{1b\bullet} & \bar{\mathbf{y}}_{1\bullet\bullet} \\ 2 & \bar{\mathbf{y}}_{21\bullet} & \bar{\mathbf{y}}_{22\bullet} & \cdots & \bar{\mathbf{y}}_{2b\bullet} & \bar{\mathbf{y}}_{2\bullet\bullet} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ a & \bar{\mathbf{y}}_{a1\bullet} & \bar{\mathbf{y}}_{a2\bullet} & \cdots & \bar{\mathbf{y}}_{ab\bullet} & \bar{\mathbf{y}}_{a\bullet\bullet} \\ \hline \text{Marginal B} & \bar{\mathbf{y}}_{\bullet 1\bullet} & \bar{\mathbf{y}}_{\bullet 2\bullet} & \cdots & \bar{\mathbf{y}}_{\bullet b\bullet} & \bar{\mathbf{y}}_{\bullet\bullet\bullet} \\ \hline \end{array} $$

$$ \begin{array}{c|cccc|c} \hline \text{Bloque} & 1 & 2 & \cdots & r & \text{Media general} \\ \hline \text{Media del bloque} & \bar{\mathbf{y}}_{\bullet\bullet 1} & \bar{\mathbf{y}}_{\bullet\bullet 2} & \cdots & \bar{\mathbf{y}}_{\bullet\bullet r} & \bar{\mathbf{y}}_{\bullet\bullet\bullet} \\ \hline \end{array} $$

1.2 Datos a analizar

En este informe se utilizará un set de datos recopilado del libro de *Análisis multivariante aplicado con R* de Uriel, E. y Aldás, J. donde se realizó levemente un análisis multivariado factorial. Sin embargo, se buscará mejorar ese análisis añadiendo el factor bloque día al estudio como también realizar las pruebas de comparación correspondientes. El contexto del diseño va de la siguiente manera

> La cadena de supermercados Mercanova desea analizar los efectos de una campaña de promoción conjunta de dos productos: la bebida gaseosa Toca-cola y el ron Morenita. En la campaña de promoción, que ha tenido una duración de dos semanas, se ha llevado a cabo en todos los supermercados de la cadena una promoción de ventas basada en el "precio por paquete", es decir, un precio inferior por la compra conjunta a lo que supondría la compra separada de los dos productos. La acción ha venido apoyada por degustaciones en el punto de venta. Atendiendo a las características de las zonas donde están enclavados, se han agrupado los 57 supermercados de la cadena en tres grupos: urbano comercial (UC), urbano residencial (UR) y rural (R). El potencial general de ventas de cada uno de estos grupos es muy similar. La campaña de promoción comenzó a finales de mes. Concretamente, la primera semana fue del lunes 24 al sábado 29 de octubre. La segunda semana estaba situada prácticamente en los primeros días de mes. (Aldás y Uriel, 2017, p. 252)



Se buscará responder las siguientes incógnitas en las conclusiones del análisis:

- ¿Han sido análogos los resultados de la campaña en los tres tipos de supermercado?
- ¿Es relevante la distinción entre semana fin de mes y semana principio de mes en la adquisición de productos de esta clase?
- ¿Existe interacción entre semana y tipo de supermercado?

Tabla 1. Datos sobre las ventas de dos productos de la cadena Mercanova

Semana promoción		**Urbano comercial**		**Urbano residencial**		**Rural**		**Totales**		**Medias**	
Semana	**Día**	**Cola**	**Ron**	**Cola**	**Ron**	**Cola**	**Ron**	**Cola**	**Ron**	**Cola**	**Ron**
Primera	Lunes	11	5	9	4	6	2	180	96	10	5.33
	Martes	8	7	8	3	5	2				
	Miércoles	10	5	8	4	6	1				
	Jueves	14	6	9	6	7	4				
	Viernes	17	9	12	9	9	4				
	Sábado	18	10	14	10	9	5				
Segunda	Lunes	17	7	8	10	6	2	252	156	14	8.67
	Martes	19	10	10	8	7	7				
	Miércoles	22	9	12	6	10	6				
	Jueves	21	11	10	11	9	4				
	Viernes	23	14	15	12	10	5				
	Sábado	24	15	17	13	12	6				
Totales		**204**	**108**	**132**	**96**	**96**	**48**	**432**	**252**	**–**	**–**
Medias		**17**	**9**	**11**	**8**	**8**	**4**	**–**	**–**	**12**	**7**

1.3 Pruebas de hipótesis

1.3.1 Prueba de normalidad multivariada

Con el propósito de evaluar el supuesto de normalidad multivariada se dividen los datos en grupos para aplicar el test multivariante de Shapiro.

```
# Grupos por tipo de zona
grupoUC <- t(datos[datos$tipsuper == "UC", c("cola", "ron")])
grupoUR <- t(datos[datos$tipsuper == "UR", c("cola", "ron")])
grupoR  <- t(datos[datos$tipsuper == "R",  c("cola", "ron")])

# Grupos por semana
grupoSem1 <- t(datos[datos$semana == "Primera", c("cola", "ron")])
grupoSem2 <- t(datos[datos$semana == "Segunda", c("cola", "ron")])
```

Una vez realizado se procede a aplicar las pruebas por cada grupo

```
mshapiro.test(grupoUC)
```

```
#>
#>  Shapiro-Wilk normality test
#>
#> data:  Z
#> W = 0.91279, p-value = 0.2316
```

```
mshapiro.test(grupoUR)
```

```
#>
#>  Shapiro-Wilk normality test
#>
#> data:  Z
#> W = 0.88022, p-value = 0.08822
```

```
mshapiro.test(grupoR)
```

```
#>
#>  Shapiro-Wilk normality test
#>
#> data:  Z
#> W = 0.78631, p-value = 0.006574
```

```
mshapiro.test(grupoSem1)
```

```
#>
#>  Shapiro-Wilk normality test
#>
#> data:  Z
#> W = 0.96142, p-value = 0.6294
```

```
mshapiro.test(grupoSem2)
```

```
#>
#>  Shapiro-Wilk normality test
#>
#> data:  Z
#> W = 0.94767, p-value = 0.3896
```

> **🔎 Interpretación**
>
> De estos resultados, no se rechaza la hipótesis de normalidad multivariada, a excepción de lo que ocurre con el grupo de zona Rural.

De forma adicional, se puede aplicar la prueba de normalidad multivariada a los residuos del modelo.

```
mshapiro.test(t(residuals(fit)))
```

```
#>
#>  Shapiro-Wilk normality test
#>
#> data:  Z
#> W = 0.97285, p-value = 0.5083
```

> **🔎 Interpretación**
>
> A partir de esta prueba se puede concluir que efectivamente no se rechaza la hipótesis de normalidad multivariada

1.3.2 Prueba de homogeneidad de matrices de covarianza (Box's M)

\[H_0: \boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 = \boldsymbol{\Sigma}_3 = \boldsymbol{\Sigma}_4 = \boldsymbol{\Sigma}_5\] \[H_1: \text{al menos una matriz de covarianza } \boldsymbol{\Sigma}_i \text{ es distinta}\]

```
# Igualdad de matrices de covarianzas (Box's M), una vez por factor
biotools::boxM(datos[, c("cola", "ron")], datos$semana)
```

```
#>
#>  Box's M-test for Homogeneity of Covariance Matrices
#>
#> data:  datos[, c("cola", "ron")]
#> Chi-Sq (approx.) = 10.094, df = 3, p-value = 0.01779
```

```
biotools::boxM(datos[, c("cola", "ron")], datos$tipsuper)
```

```
#>
#>  Box's M-test for Homogeneity of Covariance Matrices
#>
#> data:  datos[, c("cola", "ron")]
#> Chi-Sq (approx.) = 13.049, df = 6, p-value = 0.04226
```

> **🔎 Interpretación**
>
> A partir de los valores obtenidos, se rechaza la homogeneidad de covarianzas al 5% de significancia, pero no al 1%. Al tener un diseño balanceado, se utilizará el estadístico de Pillai al ser más robusto a esta violación.

1.3.3 Prueba de esfericidad de Bartlett

Se requiere que las variables respuesta estén correlacionadas para justificar el uso de un análisis conjunto (MANOVA).

\[H_0: \mathbf{R}_p = \mathbf{I} \] \[H_1: \mathbf{R}_p \neq \mathbf{I}\]

```
r_crudo <- cor(datos[, c("cola", "ron")])
cortest.bartlett(r_crudo, n = nrow(datos))
```

```
#> $chisq
#> [1] 34.76577
#>
#> $p.value
#> [1] 0.000000003718544
#>
#> $df
#> [1] 1
```

> 🔎 **Interpretación**
>
> Con los datos originales, la prueba de Bartlett rechaza la hipótesis nula que la matriz de correlaciones sea la identidad. Por lo tanto, las ventas de cola y ron están correlacionadas y se realiza un análisis multivariado

```
W  <- summary(fit)$SS$Residuals
gl <- df.residual(fit)

COV.W <- W / gl
R     <- cov2cor(COV.W)
R                              # matriz de correlaciones residuales
```

```
#>            cola        ron
#> cola 1.00000000 0.09990648
#> ron  0.09990648 1.00000000
```

```
cortest.bartlett(R, n = gl)
```

```
#> $chisq
#> [1] 0.2257077
#>
#> $p.value
#> [1] 0.634725
#>
#> $df
#> [1] 1
```

> 🔎 **Interpretación**
>
> Sin embargo, al calcular la correlación quitando los efectos de los bloques, factores e interacción llegando a la matriz residual, la prueba de bartlett no rechaza la hipótesis nula. Esto indica que la correlación antes vista se debe en gran parte a los efectos ya mencionados. Por criterio de los datos originales, se continuará el estudio considerando que se acepta el análisis multivariado.

1.4 Análisis de varianza multivariado (MANOVA)

```
fit <- manova(cbind(cola, ron) ~ dia + semana * tipsuper, data = datos)
# Estadistico Wilks
summary(fit, test = "Wilks")
```

```
#>                 Df   Wilks approx F num Df den Df              Pr(>F)
#> dia              5 0.12711    8.663     10     48 0.000000068328819321 ***
#> semana           1 0.18634   52.398      2     24 0.000000001752794431 ***
#> tipsuper         2 0.04627   43.785      4     48 0.000000000000001912 ***
#> semana:tipsuper  2 0.36140    7.961      4     48 0.000052478875690333 ***
#> Residuals       25
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
# Estadistico Pillai
summary(fit, test = "Pillai")
```

```
#>                 Df  Pillai approx F num Df den Df           Pr(>F)
#> dia              5 1.03434    5.356     10     50 0.00002451119319 ***
#> semana           1 0.81366   52.398      2     24 0.00000000175279 ***
#> tipsuper         2 1.32367   24.464      4     50 0.00000000002968 ***
#> semana:tipsuper  2 0.69757    6.695      4     50        0.0002142 ***
#> Residuals       25
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
# Estadistico Hotelling
summary(fit, test = "Hotelling-Lawley")
```

```
#>                 Df Hotelling-Lawley approx F num Df den Df
#> dia              5           5.5973   12.874     10     46
#> semana           1           4.3665   52.398      2     24
#> tipsuper         2          12.6160   72.542      4     46
#> semana:tipsuper  2           1.6039    9.222      4     46
#> Residuals       25
#>                              Pr(>F)
#> dia                    0.000000000256 ***
#> semana                 0.000000001753 ***
#> tipsuper        < 0.0000000000000022 ***
#> semana:tipsuper        0.000014743140 ***
#> Residuals
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
# Estadístico Roy
summary(fit, test = "Roy")
```

```
#>                 Df     Roy approx F num Df den Df             Pr(>F)
#> dia              5  5.3603   26.802      5     25 0.00000000273964006 ***
#> semana           1  4.3665   52.398      2     24 0.00000000175279443 ***
#> tipsuper         2 11.9468  149.335      2     25 0.00000000000001253 ***
#> semana:tipsuper  2  1.4947   18.684      2     25 0.00001089490503107 ***
#> Residuals       25
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
# Manova univariado
summary.aov(fit)
```

```
#>  Response cola :
#>                 Df Sum Sq Mean Sq F value             Pr(>F)
#> dia              5 191.67  38.333  19.828 0.00000005619382768 ***
#> semana           1 144.00 144.000  74.483 0.00000000573619774 ***
#> tipsuper         2 504.00 252.000 130.345 0.00000000000005964 ***
#> semana:tipsuper  2  72.00  36.000  18.621 0.00001117532093453 ***
#> Residuals       25  48.33   1.933
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#>  Response ron :
#>                 Df  Sum Sq Mean Sq F value        Pr(>F)
#> dia              5 116.667  23.333 10.5422 0.00001572715 ***
#> semana           1 100.000 100.000 45.1807 0.00000048114 ***
#> tipsuper         2 168.000  84.000 37.9518 0.00000002663 ***
#> semana:tipsuper  2   8.000   4.000  1.8072        0.1849
#> Residuals       25  55.333   2.213
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# Matrices de suma de cuadrados y productos cruzados
summary(fit, intercept = TRUE)$SS
```

```
#> $`(Intercept)`
#>      cola  ron
#> cola 5184 3024
#> ron  3024 1764
#>
#> $dia
#>          cola      ron
#> cola 191.6667 137.8333
#> ron  137.8333 116.6667
#>
#> $semana
#>      cola ron
#> cola  144 120
#> ron   120 100
#>
#> $tipsuper
#>      cola ron
#> cola  504 252
#> ron   252 168
#>
#> $`semana:tipsuper`
#>      cola ron
#> cola   72  12
#> ron    12   8
#>
#> $Residuals
#>           cola       ron
#> cola 48.333333  5.166667
#> ron   5.166667 55.333333
```

> **🔎 Interpretación**
>
> Según los datos obtenidos, se puede apreciar que el efecto de la semana depende de la zona. Por consiguiente, los efectos principales de semana y zona no se leen por separado, sino de forma conjunta. De igual manera, el bloque (día) también es significativo, lo que nos indica que el bloqueo fue útil. Con $\boldsymbol{\alpha} = 0.05$ se rechazan las cuatro hipótesis nulas.

1.4.1 Bondad de ajuste

```
# Matrices SCPC de cada efecto
Matrices <- summary(fit)$SS

FDia     <- Matrices$dia
FSemana  <- Matrices$semana
FZona    <- Matrices$tipsuper
FSemZona <- Matrices$`semana:tipsuper`
W        <- Matrices$Residuals

# Matriz SCPC total
T_total <- FDia + FSemana + FZona + FSemZona + W
T_total
```

```
#>      cola ron
#> cola  960 527
#> ron   527 448
```

```
# Bondad de ajuste
eta2 <- 1 - det(FDia + W) / det(T_total)
eta2
```

```
#> [1] 0.8632697
```

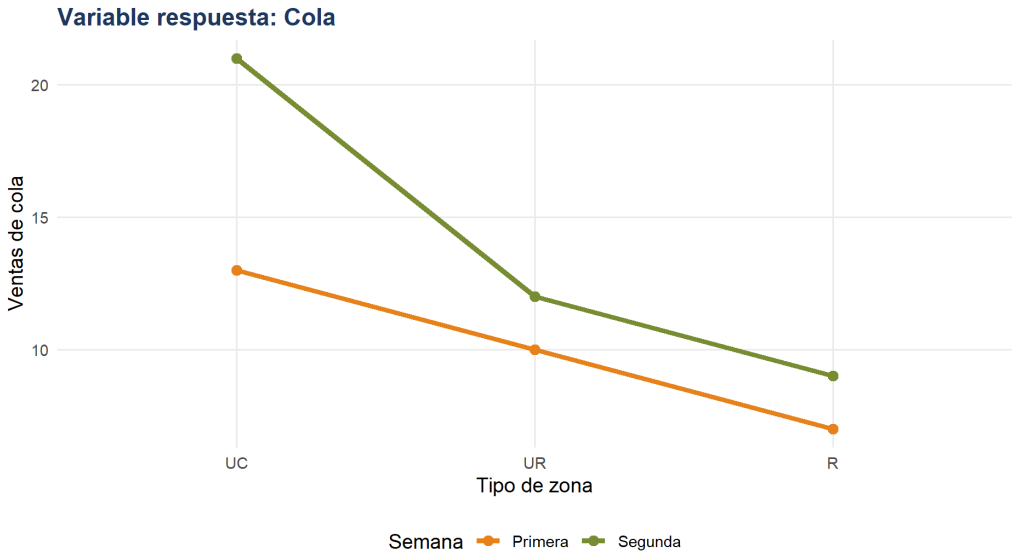
> 🔎 **Interpretación**
>
> El valor de \(\eta^2\) de 0.8633 aprox nos indica que alrededor del 86% de la variabilidad multivariada total es explicada por los tratamientos.

1.4.2 Gráficos de interacción

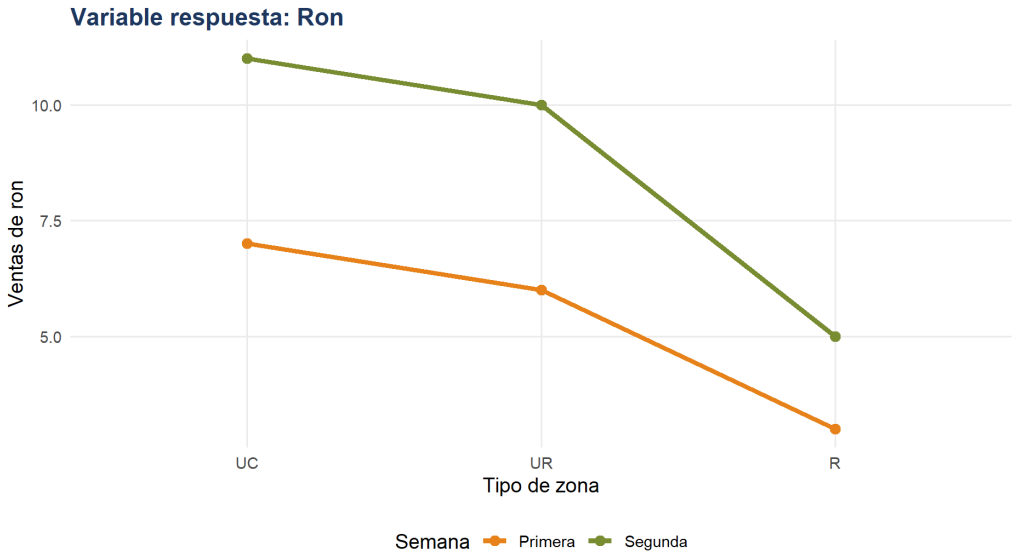
Por consiguiente, se presentan los gráficos de interacción de tipo de zona y semana por cada variable respuesta.

```
medias <- aggregate(cbind(cola, ron) ~ semana + tipsuper, data = datos, FUN = mean)

ggplot(medias, aes(x = tipsuper, y = cola, group = semana, color = semana)) +
  geom_line(linewidth = 1.5) +
  geom_point(size = 2.5) +
  scale_color_met_d("Homer2") +
  labs(x = "Tipo de zona", y = "Ventas de cola", color = "Semana", title = "Variable respuesta:
       Cola")
```




```
ggplot(medias, aes(x = tipsuper, y = ron, group = semana, color = semana)) +
  geom_line(linewidth = 1.5) +
  geom_point(size = 2.5) +
  scale_color_met_d("Homer2") +
  labs(x = "Tipo de zona", y = "Ventas de ron", color = "Semana", title = "Variable respuesta: R
       on")
```



🔎 Interpretación

Como se puede apreciar, en cuanto a las ventas de cola en la segunda semana son mayores al de la primera en los 3 tipos de zona, sin embargo la diferencia no es la misma. Las lineas no son paralelas por lo que se evidencia la interacción semana x zona. No obstante, en cuanto a las ventas de ron, la segunda semana supera a la primera semana pero la diferencia es similar en las tres zonas, por lo que la interacción es casi inexistente.

1.4.3 Análisis de efectos simples multivariados

```
# Efecto de la semana dentro de cada zona
for (z in levels(datos$tipsuper)) {
  cat("\n--- Zona =", z, "---\n")
  print(summary(manova(cbind(cola, ron) ~ dia + semana,
                       data = subset(datos, tipsuper == z)), test = "Pillai"))
}
```

```
#>
#> --- Zona = UC ---
#>           Df  Pillai approx F num Df den Df   Pr(>F)
#> dia        5 1.40754    2.376     10     10 0.094257 .
#> semana     1 0.96629   57.333      2      4 0.001136 **
#> Residuals  5
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> --- Zona = UR ---
#>           Df  Pillai approx F num Df den Df     Pr(>F)
#> dia        5 1.45420    2.664     10     10      0.069 .
#> semana     1 0.99257  267.130      2      4 0.00005522 ***
#> Residuals  5
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> --- Zona = R ---
#>           Df  Pillai approx F num Df den Df  Pr(>F)
#> dia        5 1.28916   1.8136     10     10 0.18100
#> semana     1 0.70588   4.8000      2      4 0.08651 .
#> Residuals  5
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

> 🔎 **Interpretación**
>
> A partir de estas pruebas se interpreta que la interacción observada en el MANOVA global ocurre por que el efecto de cambio de semana a semana se concentra más en las zonas Urbano Comercial y Urbano Residencial.

```
# Efecto de la zona dentro de cada semana
for (s in levels(datos$semana)) {
  cat("\n--- Semana =", s, "---\n")
  print(summary(manova(cbind(cola, ron) ~ dia + tipsuper,
                       data = subset(datos, semana == s)), test = "Pillai"))
}
```

```
#>
#> --- Semana = Primera ---
#>           Df Pillai approx F num Df den Df   Pr(>F)
#> dia        5 1.0890   2.3907     10     20 0.046573 *
#> tipsuper   2 1.0741   5.8003      4     20 0.002881 **
#> Residuals 10
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> --- Semana = Segunda ---
#>           Df Pillai approx F num Df den Df      Pr(>F)
#> dia        5 1.2155    3.099     10     20     0.01503 *
#> tipsuper   2 1.5071   15.290      4     20 0.000007048 ***
#> Residuals 10
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

> **🔎 Interpretación**
>
> Asimismo, se aprecia que en la primera semana hay evidencia de diferencia entre zonas, y esta diferencia aumenta marcadamente al pasar a la siguiente semana al comparar el efecto de las zonas dentro de cada semana.

1.4.4 Pruebas de comparación

```
fit_lm <- lm(cbind(cola, ron) ~ dia + semana * tipsuper, data = datos)

# Semana dentro de cada zona
emm_sem <- emmeans(fit_lm, ~ semana | tipsuper | rep.meas)
mvcontrast(emm_sem, "pairwise", mult.name = "rep.meas", by = "tipsuper", adjust = "holm")
```

```
mvcontrast(emm_sem, "pairwise", mult.name = "rep.meas", by = "tipsuper", adjust = "none")
```

> **🔎 Interpretación**
>
> A comparación del análisis de efectos simples anteriores, la diferencia entre semanas en la zona Rural si es significativa. Se rechaza \(H_0\) en todos los contrastes. Esto se debe a que el análisis de efectos simples hechos por subconjunto usan solo 12 observaciones (error con 5 gl), mientras que emmeans usa el error del modelo completo (25 gl), que tiene más potencia.

```
# Zona dentro de cada semana
emm_zona <- emmeans(fit_lm, ~ tipsuper | semana | rep.meas)
mvcontrast(emm_zona, "pairwise", mult.name = "rep.meas", by = "semana", adjust = "holm")
```

```
mvcontrast(emm_zona, "pairwise", mult.name = "rep.meas", by = "semana", adjust = "none")
```

> **🔎 Interpretación**
>
> De igual forma, se aprecia una diferencia significativa entre las zonas por semana. Asimismo se evidencia que en la semana 2, las distancias multivariadas entre las 3 zonas aumentan notablemente.

1.5 Conclusiones

> **🏁 Conclusiones**
>
> Gracias al análisis multivariado se puede llegar a las siguientes conclusiones:
>
> - Los resultados de las campañas difieren significativamente en los tres tipos de supermercado
> - La distinción entre semana de fin de mes y semana de principio de mes también es significativa. Las ventas de principio de mes superan a las de fin de mes.
> - La interacción semana x zona es significativa, asi que el efecto de cada factor depende el otro y no se interpretan por separado
> - Aplicar el factor de bloqueo día ayudó a potenciar la precisión del análisis multivariado

1.6 Referencias

Aldás, J. y Uriel, E. (2017) Análisis multivariante aplicado con R (2da Edición). Ediciones Paraninfo.

2 MANCOVA en un diseño completamente al azar (DCA)

> 📋 **Ficha de la pregunta**
>
> - **Técnica:** MANCOVA en DCA
> - **Base de datos:** `StudentsPerformance.csv` — 1000 estudiantes
> - **Tratamiento:** curso de preparación para el examen (`completed` / `none`)
> - **Variables respuesta:** puntaje de lectura y puntaje de escritura
> - **Covariable:** puntaje de matemáticas

2.1 Introducción

El **Análisis Multivariado de Covarianza (MANCOVA)** en un **Diseño Completamente al Azar (DCA)** permite evaluar el efecto de un tratamiento categórico sobre un conjunto de variables de respuesta continuas, controlando simultáneamente el efecto de una o más covariables continuas que influyen en las respuestas pero no son afectadas por el tratamiento.

En este estudio se evalúa el impacto del **Curso de Preparación para el Examen** (*test preparation course*, con niveles `completed` y `none`) sobre el rendimiento académico posterior en lenguaje:

- Y_1 **(Puntaje de Lectura — *reading score*):** nota en la prueba de lectura ($0 - 100$).
- Y_2 **(Puntaje de Escritura — *writing score*):** nota en la prueba de redacción ($0 - 100$).

Para aislar el sesgo derivado de la aptitud previa o habilidad académica general del alumno, se incluye como covariable:

- X_1 **(Puntaje de Matemáticas — *math score*):** nota cuantitativa en matemáticas ($0 - 100$).

El modelo es

$$ \mathbf{y}_{ij}=\boldsymbol{\mu}+\boldsymbol{\tau}_i+\mathbf{B}^{\top}\left(x_{ij}-\bar{x}\right)+\boldsymbol{\varepsilon}_{ij},\qquad \boldsymbol{\varepsilon}_{ij}\sim N_2(\mathbf{0},\boldsymbol{\Sigma}), $$

donde $\mathbf{y}_{ij}=(Y_1,Y_2)^\top$, $\boldsymbol{\tau}_i$ es el efecto del nivel i del curso y $\mathbf{B}$ el vector de coeficientes de la covariable.

2.2 Carga y Preparación de Datos

```r
# Librerías requeridas
library(tidyverse)
library(mvnormtest)
library(heplots)
library(psych)
library(emmeans)
library(knitr)

# Carga de la base de datos
datos <- read.csv("StudentsPerformance.csv", stringsAsFactors = TRUE)

# Renombrar columnas para facilitar la sintaxis en R
colnames(datos) <- c("Gender", "Race_Ethnicity", "Parental_Education",
                     "Lunch", "Test_Prep", "Math_Score", "Reading_Score", "Writing_Score")

# Estructura del dataset
str(datos)
```

```
#> 'data.frame':    1000 obs. of  8 variables:
#>  $ Gender            : Factor w/ 2 levels "female","male": 1 1 1 2 2 1 1 2 2 1 ...
#>  $ Race_Ethnicity    : Factor w/ 5 levels "group A","group B",..: 2 3 2 1 3 2 2 2 4 2 ...
#>  $ Parental_Education: Factor w/ 6 levels "associate's degree",..: 2 5 4 1 5 1 5 5 3 3 ...
#>  $ Lunch             : Factor w/ 2 levels "free/reduced",..: 2 2 2 1 2 2 2 1 1 1 ...
#>  $ Test_Prep         : Factor w/ 2 levels "completed","none": 2 1 2 2 2 2 1 2 1 2 ...
#>  $ Math_Score        : int  72 69 90 47 76 71 88 40 64 38 ...
#>  $ Reading_Score     : int  72 90 95 57 78 83 95 43 64 60 ...
#>  $ Writing_Score     : int  74 88 93 44 75 78 92 39 67 50 ...
```

```
head(datos, 10) %>% kable(caption = "Primeros 10 registros del dataset de rendimiento escolar")
```

Primeros 10 registros del dataset de rendimiento escolar

Gender	Race_Ethnicity	Parental_Education	Lunch	Test_Prep	Math_Score	Reading_Score	Writing_Score
female	group B	bachelor’s degree	standard	none	72	72	74
female	group C	some college	standard	completed	69	90	88
female	group B	master’s degree	standard	none	90	95	93
male	group A	associate’s degree	free/reduced	none	47	57	44
male	group C	some college	standard	none	76	78	75
female	group B	associate’s degree	standard	none	71	83	78
female	group B	some college	standard	completed	88	95	92
male	group B	some college	free/reduced	none	40	43	39
male	group D	high school	free/reduced	completed	64	64	67
female	group B	high school	free/reduced	none	38	60	50

2.3 Verificación de Supuestos Estadísticos

2.3.1 Normalidad Multivariada por Grupo

> **Hipótesis**
>
> \(H_0\): el vector \((Y_1, Y_2)\) sigue una distribución normal bivariada en cada nivel de `Test_Prep` , frente a \(H_1\): no la sigue. No se rechaza \(H_0\) si \(p \geq 0.05\).

```
grupos <- levels(datos$Test_Prep)

for (g in grupos) {
  sub_data <- datos %>%
    filter(Test_Prep == g) %>%
    dplyr::select(Reading_Score, Writing_Score)

  test <- mshapiro.test(t(sub_data))
  cat("Tratamiento (Test_Prep):", g, "| p-valor Shapiro-Wilk Multivariado:", round(test$p.value,
        6), "\n")
}
```

```
#> Tratamiento (Test_Prep): completed | p-valor Shapiro-Wilk Multivariado: 0.170488
#> Tratamiento (Test_Prep): none | p-valor Shapiro-Wilk Multivariado: 0.066581
```

2.3.2 Homogeneidad de Matrices de Varianza-Covarianza

> **Hipótesis**
>
> \(H_0:\ \boldsymbol{\Sigma}_{completed}=\boldsymbol{\Sigma}_{none}\) frente a \(H_1\): las matrices de covarianza difieren entre los dos niveles del curso.

```
res_boxm <- heplots::boxM(cbind(Reading_Score, Writing_Score) ~ Test_Prep, data = datos)
summary(res_boxm)
```

```
#>
#>  Box's M-test for Homogeneity of Covariance Matrices
#>
#> data:  datos
#>
#> Chi-Sq (approx.) =  11.35977
#> df:   3
#> p-value: 0.0099
#>
#> log of Covariance determinants:
#> completed      none    pooled
#>    8.1453    8.2744    8.2396
#>
#> Eigenvalues:
#>   completed     none   pooled
#> 1  355.2004 424.9643 399.9362
#> 2    9.7047   9.2295   9.4719
#>
#> Statistics based on eigenvalues:
#>           completed      none    pooled
#> product   3447.1265 3922.2211 3788.1627
#> sum        364.9051  434.1938  409.4082
#> precision    9.4466    9.0333    9.2528
#> max        355.2004  424.9643  399.9362
```

2.3.3 Correlación entre Variables Dependientes (Prueba de Esfericidad de Bartlett)

> **Hipótesis**
>
> $H_0:\ \mathbf{R}=\mathbf{I}$ (las respuestas no están correlacionadas) frente a $H_1:\ \mathbf{R}\neq\mathbf{I}$. Si se rechaza H_0, se justifica el análisis conjunto.

```
Y_mat <- datos %>% dplyr::select(Reading_Score, Writing_Score)
cortest.bartlett(cor(Y_mat), n = nrow(Y_mat))
```

```
#> $chisq
#> [1] 2415.961
#>
#> $p.value
#> [1] 0
#>
#> $df
#> [1] 1
```

2.4 Desarrollo del Modelo MANCOVA en DCA

> **Hipótesis**
>
> - **Tratamiento:** $H_0:\ \boldsymbol{\tau}_{completed}=\boldsymbol{\tau}_{none}=\mathbf{0}$ (los vectores de medias ajustadas por `Math_Score` son iguales) frente a H_1): al menos un $\boldsymbol{\tau}_i\neq\mathbf{0}$.
> - **Covariable:** $H_0:\ \mathbf{B}=\mathbf{0}$ (la matemática no explica lectura ni escritura) frente a $H_1:\ \mathbf{B}\neq\mathbf{0}$.

```r
modelo_mancova <- manova(
  cbind(Reading_Score, Writing_Score) ~ Test_Prep + Math_Score,
  data = datos
)

# Estadísticos de contraste multivariado
summary(modelo_mancova, test = "Pillai")
```

```
#>             Df  Pillai approx F num Df den Df               Pr(>F)
#> Test_Prep    1 0.23716   154.82      2    996 < 0.00000000000000022 ***
#> Math_Score   1 0.66531   989.93      2    996 < 0.00000000000000022 ***
#> Residuals  997
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
summary(modelo_mancova, test = "Wilks")
```

```
#>             Df   Wilks approx F num Df den Df               Pr(>F)
#> Test_Prep    1 0.76284   154.82      2    996 < 0.00000000000000022 ***
#> Math_Score   1 0.33469   989.93      2    996 < 0.00000000000000022 ***
#> Residuals  997
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
summary(modelo_mancova, test = "Hotelling-Lawley")
```

```
#>             Df Hotelling-Lawley approx F num Df den Df                Pr(>F)
#> Test_Prep    1          0.31089   154.82      2    996 < 0.0000000000000022
#> Math_Score   1          1.98782   989.93      2    996 < 0.0000000000000022
#> Residuals  997
#>
#> Test_Prep  ***
#> Math_Score ***
#> Residuals
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
summary(modelo_mancova, test = "Roy")
```

```
#>             Df     Roy approx F num Df den Df               Pr(>F)
#> Test_Prep    1 0.31089   154.82      2    996 < 0.00000000000000022 ***
#> Math_Score   1 1.98782   989.93      2    996 < 0.00000000000000022 ***
#> Residuals  997
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

2.4.1 Evaluación Univariada (ANCOVA por Variable Respuesta)

```r
summary.aov(modelo_mancova)
```

```
#>  Response Reading_Score :
#>              Df Sum Sq Mean Sq F value               Pr(>F)
#> Test_Prep     1  12449   12449  181.03 < 0.00000000000000022 ***
#> Math_Score    1 131944  131944 1918.74 < 0.00000000000000022 ***
#> Residuals   997  68560      69
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#>  Response Writing_Score :
#>              Df Sum Sq Mean Sq F value               Pr(>F)
#> Test_Prep     1  22591   22591  299.69 < 0.00000000000000022 ***
#> Math_Score    1 132928  132928 1763.35 < 0.00000000000000022 ***
#> Residuals   997  75158      75
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

2.5 Comparaciones Múltiples de Medias Ajustadas

> **Hipótesis**
>
> $H_0:\ \boldsymbol{\mu}^{aj}_{i}=\boldsymbol{\mu}^{aj}_{i'}$ frente a $H_1:\ \boldsymbol{\mu}^{aj}_{i}\neq\boldsymbol{\mu}^{aj}_{i'}$, con el contraste T^2 de Hotelling y ajuste de Bonferroni.

```
fit_lm <- lm(
  cbind(Reading_Score, Writing_Score) ~ Test_Prep + Math_Score,
  data = datos
)

emm <- emmeans(fit_lm, ~ Test_Prep | rep.meas)
emm
```

```
#> rep.meas = Reading_Score:
#>  Test_Prep emmean    SE  df lower.CL upper.CL
#>  completed   71.1 0.443 997     70.2     72.0
#>  none        68.1 0.329 997     67.4     68.7
#>
#> rep.meas = Writing_Score:
#>  Test_Prep emmean    SE  df lower.CL upper.CL
#>  completed   71.6 0.464 997     70.7     72.5
#>  none        66.1 0.345 997     65.4     66.7
#>
#> Confidence level used: 0.95
```

```
# Comparación por pares multivariada basada en la distribución de Hotelling
mvcontrast(emm, method = 'pairwise', mult.name = 'rep.meas', adjust = 'bonferroni')
```

2.6 Discusión

💬 Discusión

Efecto de la covariable: la covariable `Math_Score` resultó altamente significativa ($p < 0.001$), lo que demuestra que la habilidad previa en matemáticas explica una proporción sustancial de la variabilidad en los puntajes de lectura y escritura. Esto valida la elección de un MANCOVA sobre un MANOVA simple.

Efecto del tratamiento: las cuatro pruebas multivariadas (Pillai, Wilks, Hotelling-Lawley y Roy) fueron altamente significativas ($p < 0.001$), lo que indica que el hábito de completar el curso de preparación modifica significativamente el vector de medias multivariadas de lectura y escritura.

Ajuste de medias: al realizar las comparaciones *post-hoc* sobre las medias ajustadas por la covariable, se evidencia que los estudiantes que completaron el curso obtienen rendimientos promedio superiores en ambas competencias de lenguaje.

2.7 Conclusiones

🏁 Conclusiones

Se justificó estadísticamente la aplicación del modelo MANCOVA en DCA dada la alta correlación entre las competencias de lenguaje ($r = 0.955$) y la relevancia de la covariable matemática ($p < 0.001$).

Completar el curso de preparación (`completed`) incrementa de forma estadísticamente significativa el desempeño combinado en lectura y redacción, incluso al igualar a los alumnos en su nivel inicial de razonamiento matemático.

El uso de la covariable permitió remover la varianza no controlada, incrementando la precisión y la potencia del contraste del diseño DCA.

2.8 Bibliografía

- Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2019). *Multivariate Data Analysis* (8th ed.). Cengage Learning.
- Miranda Villagómez, C. F. (2026). *Notas de clase: MANOVA y MANCOVA en Diseños Experimentales*. Universidad Nacional Agraria La Molina.
- R Core Team (2026). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing, Vienna, Austria.

3 MANCOVA en un diseño en bloques completos al azar (DBCA)

> 📋 **Ficha de la pregunta**
>
> - **Técnica:** MANCOVA en DBCA
> - **Caso:** efecto de la dosis de probiótico sobre el crecimiento y la calidad de carcasa de cuyes
> - **Base de datos:** `Cuyes_MANCOVA_DBCA.xlsx` — 72 cuyes (base didáctica simulada)
> - **Tratamiento / bloque:** dosis de probiótico (0, 1, 2 y 3 g/kg) / lote (6 bloques)
> - **Respuestas / covariables:** ganancia de peso y rendimiento de carcasa / peso inicial y edad inicial

3.1 Introducción y planteamiento del caso

3.1.1 Problema experimental

La crianza de **cuyes** (*Cavia porcellus*) es una actividad pecuaria clave en la sierra y costa del Perú. Los productores buscan **mejorar el crecimiento sin deteriorar la calidad de la carcasa**, y una alternativa estudiada es incorporar **probióticos** (*Lactobacillus* + *Saccharomyces*) en el alimento. Se evaluaron cuatro dosis en un experimento de engorde de 8 semanas.

Un análisis univariado (un ANOVA por variable) sería insuficiente porque:

- la **ganancia de peso** y el **rendimiento de carcasa** son variables **correlacionadas**, así que analizarlas por separado ignora su estructura conjunta e infla el error tipo I global;
- los animales **no partieron en igualdad de condiciones**: difieren en **peso inicial** y **edad inicial**, y esa variabilidad puede enmascarar (o simular) el efecto del probiótico;
- los animales se agruparon en **lotes por peso al destete**, fuente de variación que el diseño debe controlar.

Por ello se usa un **MANCOVA en DBCA**: compara el *vector* de medias de las respuestas entre dosis, **ajustado por covariables** y **controlando el efecto del bloque**.

> 🗝 **Estructura del diseño**
>
> - **Diseño:** DBCA con 6 bloques (lotes), 4 tratamientos y 3 cuyes por combinación bloque × tratamiento ($n = 72$).
> - **Factor (tratamiento):** `Probiotico` = 0, 1, 2 y 3 g/kg de alimento (0 g/kg = control).
> - **Bloque:** `Bloque` = Lote1 … Lote6, formados por peso vivo al destete.
> - **Variables respuesta** $\mathbf{y}$: `Ganancia_peso` (g) y `Rend_carcasa` (%).
> - **Covariables** $\mathbf{x}$: `Peso_ini` (g) y `Edad_ini` (días), medidas **antes** de aplicar el tratamiento.

3.1.2 Modelo estadístico

Para el animal k del bloque j que recibe la dosis i ($i=1,\dots,4$); $j=1,\dots,6$; $k=1,2,3$):

$$ \underbrace{\mathbf{y}_{ijk}}_{2\times 1}=\boldsymbol{\mu}+\boldsymbol{\tau}_i+\boldsymbol{\beta}_j+\mathbf{B}^{\top}\left(\mathbf{x}_{ijk}-\bar{\mathbf{x}}\right)+\boldsymbol{\varepsilon}_{ijk},\qquad \boldsymbol{\varepsilon}_{ijk}\sim N_2(\mathbf{0},\boldsymbol{\Sigma}) $$

donde:

Símbolo	Significado
$\mathbf{y}_{ijk}=(\text{Ganancia}, \text{Rendimiento})^\top$	vector de respuestas
$\boldsymbol{\mu}$	vector de medias generales

Símbolo	Significado
$\boldsymbol{\tau}_i$	efecto (vectorial) de la dosis i, con $\sum_i \boldsymbol{\tau}_i=\mathbf{0}$
$\boldsymbol{\beta}_j$	efecto (vectorial) del bloque j, con $\sum_j \boldsymbol{\beta}_j=\mathbf{0}$
$\mathbf{x}_{ijk}=(\text{Peso_ini},\text{Edad_ini})^\top$	vector de covariables y $\bar{\mathbf{x}}$ su media
$\mathbf{B}$ (2×2)	matriz de coeficientes de regresión **común** a todos los tratamientos (supuesto de pendientes homogéneas)
$\boldsymbol{\varepsilon}_{ijk}$	error aleatorio, $N_2(\mathbf 0,\boldsymbol\Sigma)$, independiente entre animales

En forma matricial global: $\mathbf{Y}=\mathbf{X}\boldsymbol{\Gamma}+\mathbf{E}$, con $\mathbf{X}$ la matriz de diseño (constante + covariables + variables indicadoras de bloque y tratamiento).

3.1.3 Hipótesis a contrastar

> **Hipótesis principal (efecto del probiótico, ajustado por covariables y bloque)**
>
> $$H_0:\ \boldsymbol{\tau}_1=\boldsymbol{\tau}_2=\boldsymbol{\tau}_3=\boldsymbol{\tau}_4=\mathbf{0}\qquad\text{vs}\qquad H_1:\ \text{al menos un }\boldsymbol{\tau}_i\neq\mathbf{0}$$
>
> Equivalentemente, H_0: los **vectores de medias ajustadas** $\boldsymbol{\mu}_i^{aj}=(\mu^{aj}_{i,\text{Ganancia}},\mu^{aj}_{i,\text{Rend}})^\top$ son iguales en las 4 dosis.
>
> **Hipótesis auxiliares**
>
> - **Covariables:** $H_0:\ \mathbf{B}=\mathbf{0}$ (las covariables no explican las respuestas) vs $H_1:\ \mathbf{B}\neq\mathbf{0}$.
> - **Bloques:** $H_0:\ \boldsymbol{\beta}_1=\dots=\boldsymbol{\beta}_6=\mathbf{0}$ vs H_1: algún $\boldsymbol{\beta}_j\neq\mathbf{0}$.
>
> **Estadístico base:** con $\mathbf{H}$ = matriz de sumas de cuadrados y productos cruzados (SCPC) del efecto y $\mathbf{E}$ = SCPC del error, se usan las raíces características $\lambda_1\ge\lambda_2$ de $\mathbf{E}^{-1}\mathbf{H}$:
>
> $$\Lambda=\frac{|\mathbf{E}|}{|\mathbf{E}+\mathbf{H}|}=\prod_{k}\frac{1}{1+\lambda_k},\quad V=\sum_k\frac{\lambda_k}{1+\lambda_k},\quad T^2_{HL}=\sum_k\lambda_k,\quad \theta=\frac{\lambda_1}{1+\lambda_1}$$
>
> (Wilks, Pillai, Hotelling-Lawley y Roy, respectivamente). Nivel de significación: $\alpha=0.05$.

3.2 Base de datos y exploración previa

3.2.1 Origen y estructura

La base `Cuyes_MANCOVA_DBCA.xlsx` es **didáctica y reproducible**: se generó por simulación (semilla 2026) a partir de un modelo lineal aditivo con error normal bivariado, tomando como referencia magnitudes zootécnicas razonables para cuyes de engorde. **No proviene de un experimento real** (se declara así para fines académicos). Contiene tres hojas: `Contexto`, `Datos` y `Diccionario`.

```
datos <- read_excel("Cuyes_MANCOVA_DBCA.xlsx", sheet = "Datos") %>%
  mutate(Bloque = factor(Bloque),
         Probiotico = factor(Probiotico, levels = c("0 g/kg", "1 g/kg", "2 g/kg", "3 g/kg"))) %
        >%
  as.data.frame()

Y <- c("Ganancia_peso", "Rend_carcasa")   # respuestas
X <- c("Peso_ini", "Edad_ini")            # covariables

str(datos)
```

```
#> 'data.frame':    72 obs. of  7 variables:
#>  $ Cuy          : chr  "C01" "C02" "C03" "C04" ...
#>  $ Bloque       : Factor w/ 6 levels "Lote1","Lote2",..: 1 1 1 1 1 1 1 1 1 1 ...
#>  $ Probiotico   : Factor w/ 4 levels "0 g/kg","1 g/kg",..: 1 2 2 4 1 3 1 3 4 4 ...
#>  $ Peso_ini     : num  264 269 261 274 284 ...
#>  $ Edad_ini     : num  21 21 22 20 20 25 22 21 23 20 ...
#>  $ Ganancia_peso: num  601 627 628 662 629 ...
#>  $ Rend_carcasa : num  66.8 66.7 66.2 68.8 67.3 ...
```

```
head(datos, 10) %>% tabla("Primeras 10 observaciones")
```

Primeras 10 observaciones

Cuy	Bloque	Probiotico	Peso_ini	Edad_ini	Ganancia_peso	Rend_carcasa
C01	Lote1	0 g/kg	264.1	21	601.3	66.84
C02	Lote1	1 g/kg	268.6	21	627.4	66.69
C03	Lote1	1 g/kg	261.1	22	627.9	66.25
C04	Lote1	3 g/kg	274.5	20	661.6	68.78
C05	Lote1	0 g/kg	284.0	20	629.2	67.31
C06	Lote1	2 g/kg	284.1	25	659.9	69.18
C07	Lote1	0 g/kg	252.6	22	647.5	68.42
C08	Lote1	2 g/kg	242.9	21	661.9	68.85
C09	Lote1	3 g/kg	283.1	23	598.5	66.19
C10	Lote1	3 g/kg	258.6	20	628.6	67.71

```
as.data.frame.matrix(table(datos$Bloque, datos$Probiotico)) %>%
  tabla("Réplicas por bloque × dosis (diseño balanceado)")
```

Réplicas por bloque × dosis (diseño balanceado)

	0 g/kg	1 g/kg	2 g/kg	3 g/kg
Lote1	3	3	3	3
Lote2	3	3	3	3
Lote3	3	3	3	3
Lote4	3	3	3	3
Lote5	3	3	3	3
Lote6	3	3	3	3

El diseño es **balanceado** (3 cuyes por celda), lo que garantiza ortogonalidad entre bloques y tratamientos, y datos completos (72 de 72 filas sin valores perdidos).

3.2.2 Vectores de medias y matrices de covarianza

```
datos %>%
  group_by(Probiotico) %>%
  summarise(n = n(),
            across(all_of(c(X, Y)), list(media = mean, de = sd), .names = "{.col}_{.fn}")) %>%
  tabla("Medias y desviaciones estándar por dosis de probiótico (sin ajustar)", digits = 2)
```

Medias y desviaciones estándar por dosis de probiótico (sin ajustar)

Probiotico	n	Peso_ini_media	Peso_ini_de	Edad_ini_media	Edad_ini_de	Ganancia_peso_media	Ganancia_peso_de	Rend_c
0 g/kg	18	284.9	29.21	22.11	1.88	633.5	22.56	

Probiotico	n	Peso_ini_media	Peso_ini_de	Edad_ini_media	Edad_ini_de	Ganancia_peso_media	Ganancia_peso_de	Rend_c
1 g/kg	18	285.8	27.10	21.39	2.87	656.8	23.73	
2 g/kg	18	289.1	21.44	21.28	2.02	681.5	24.19	
3 g/kg	18	289.9	35.87	21.33	2.22	660.3	25.86	

```
datos %>%
  group_by(Bloque) %>%
  summarise(n = n(), across(all_of(c(X, Y)), mean)) %>%
  tabla("Vector de medias por bloque", digits = 2)
```

Vector de medias por bloque

Bloque	n	Peso_ini	Edad_ini	Ganancia_peso	Rend_carcasa
Lote1	12	268.4	21.75	636.7	67.68
Lote2	12	275.7	21.17	643.1	67.45
Lote3	12	288.0	21.25	664.9	68.13
Lote4	12	287.6	21.75	654.1	67.97
Lote5	12	294.9	21.50	672.2	68.41
Lote6	12	310.0	21.75	677.1	68.29

```
cat("**Matriz de covarianza de las respuestas por dosis**\n\n")
```

Matriz de covarianza de las respuestas por dosis

```
for (g in levels(datos$Probiotico)) {
  cat("\n\n*Dosis ", g, "*\n\n", sep = "")
  print(kable(cov(datos[datos$Probiotico == g, Y]), digits = 3, align = "c") %>%
          kable_styling(full_width = FALSE, bootstrap_options = c("striped", "condensed")))
}
```

Dosis 0 g/kg

	Ganancia_peso	Rend_carcasa
Ganancia_peso	509.066	7.052
Rend_carcasa	7.052	0.421

Dosis 1 g/kg

	Ganancia_peso	Rend_carcasa
Ganancia_peso	563.33	15.43
Rend_carcasa	15.43	0.92

Dosis 2 g/kg

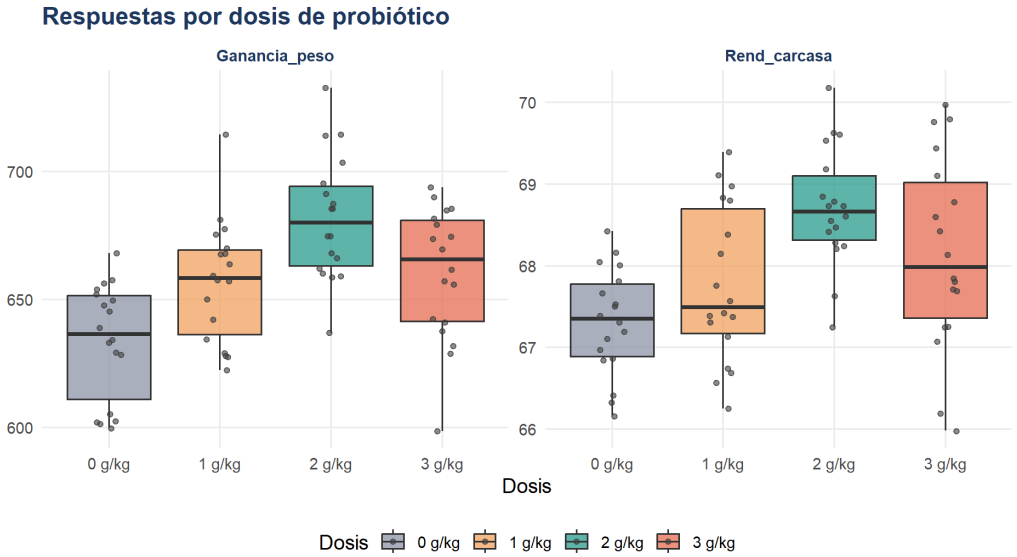
	Ganancia_peso	Rend_carcasa
Ganancia_peso	585.346	1.907
Rend_carcasa	1.907	0.521

Dosis 3 g/kg

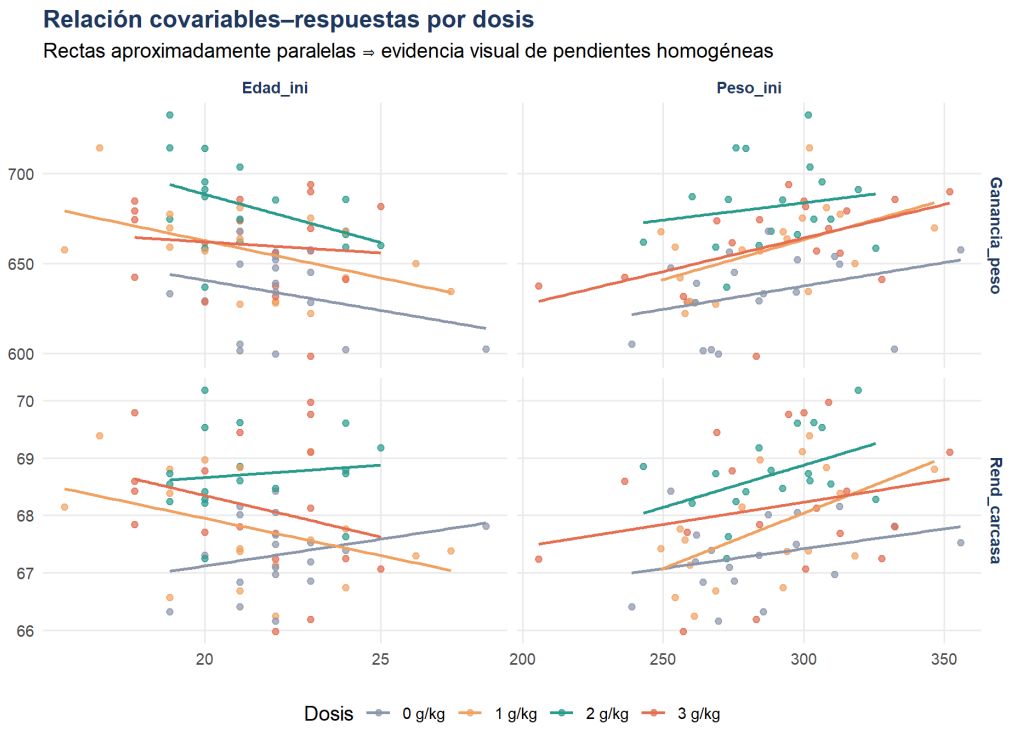
	Ganancia_peso	Rend_carcasa
Ganancia_peso	668.82	20.89
Rend_carcasa	20.89	1.40

3.2.3 Exploración gráfica

```
datos %>%
  pivot_longer(all_of(Y), names_to = "Respuesta", values_to = "valor") %>%
  ggplot(aes(Probiotico, valor, fill = Probiotico)) +
  geom_boxplot(alpha = .75, outlier.shape = NA) +
  geom_jitter(width = .12, size = 1.4, alpha = .6, colour = "grey25") +
  facet_wrap(~Respuesta, scales = "free_y") +
  scale_fill_manual(values = pal) +
  labs(title = "Respuestas por dosis de probiótico", x = "Dosis", y = NULL, fill = "Dosis")
```




```
datos %>%
  pivot_longer(all_of(X), names_to = "Covariable", values_to = "x") %>%
  pivot_longer(all_of(Y), names_to = "Respuesta", values_to = "y") %>%
  ggplot(aes(x, y, colour = Probiotico)) +
  geom_point(alpha = .7, size = 1.6) +
  geom_smooth(method = "lm", se = FALSE, linewidth = .9) +
  facet_grid(Respuesta ~ Covariable, scales = "free") +
  scale_colour_manual(values = pal) +
  labs(title = "Relación covariables-respuestas por dosis",
       subtitle = "Rectas aproximadamente paralelas ⇒ evidencia visual de pendientes homogénea
        s",
       x = NULL, y = NULL, colour = "Dosis")
```



> **🔎 Lectura exploratoria**
>
> La media de ambas respuestas aumenta con la dosis hasta 2 g/kg y baja ligeramente en 3 g/kg (patrón de **respuesta curvilínea**). En los diagramas de dispersión se observan **tendencias lineales** entre las covariables y las respuestas, y **rectas casi paralelas** entre dosis, lo que anticipa el cumplimiento de los supuestos de linealidad y pendientes homogéneas (se verifican formalmente a continuación).

3.3 Validación de supuestos

Los supuestos del MANCOVA en DBCA se verifican sobre el modelo ajustado y/o por grupo. Primero se ajusta el modelo (las covariables se colocan **primero** en la fórmula para que el tratamiento se pruebe **ajustado** por ellas).

```
mod <- manova(cbind(Ganancia_peso, Rend_carcasa) ~ Peso_ini + Edad_ini + Bloque + Probiotico,
              data = datos)
res <- residuals(mod)
n   <- nrow(res)
```

3.3.1 Normalidad multivariada

H_0: los errores siguen una distribución normal bivariada vs H_1: no la siguen. Se aplican el **Shapiro-Wilk multivariado** (Villaseñor-Alva y González-Estrada) y las pruebas de **asimetría y curtosis de Mardia** sobre los residuos del modelo.

```
# Mardia (asimetría y curtosis multivariadas)
mardia <- function(M) {
  M <- as.matrix(M); n <- nrow(M); p <- ncol(M)
  Mc <- scale(M, scale = FALSE); S <- crossprod(Mc) / n
  D  <- Mc %*% solve(S) %*% t(Mc)
  b1 <- sum(D^3) / n^2;  b2 <- sum(diag(D)^2) / n
  k1 <- n * b1 / 6;      gl <- p * (p + 1) * (p + 2) / 6
  z2 <- (b2 - p * (p + 2)) / sqrt(8 * p * (p + 2) / n)
  data.frame(Prueba = c("Asimetría de Mardia", "Curtosis de Mardia"),
             Estadistico = c(k1, z2), gl = c(gl, NA),
             p = c(pchisq(k1, gl, lower.tail = FALSE), 2 * pnorm(abs(z2), lower.tail = FALSE)))
}

# (a) Shapiro-Wilk multivariado sobre residuos globales
sw_res <- mshapiro.test(t(res))
# (b) Shapiro-Wilk multivariado por dosis (como en clase)
sw_grp <- do.call(rbind, lapply(levels(datos$Probiotico), function(g) {
  r <- mshapiro.test(t(as.matrix(datos[datos$Probiotico == g, Y])))
  data.frame(Grupo = g, W = unname(r$statistic), p = r$p.value)
}))
mar <- mardia(res)

rbind(data.frame(Prueba = "Shapiro-Wilk multivariado (residuos)",
                 Estadistico = unname(sw_res$statistic), gl = NA, p = sw_res$p.value),
      mar) %>% mutate(Decision = ifelse(p < 0.05, "No normal", "Normal"), p = fp(p)) %>%
  tabla("Normalidad multivariada de los residuos")
```

Normalidad multivariada de los residuos

Prueba	Estadistico	gl	p	Decision
Shapiro-Wilk multivariado (residuos)	0.995	NA	0.9923	Normal
Asimetría de Mardia	1.390	4	0.8460	Normal
Curtosis de Mardia	-0.951	NA	0.3415	Normal

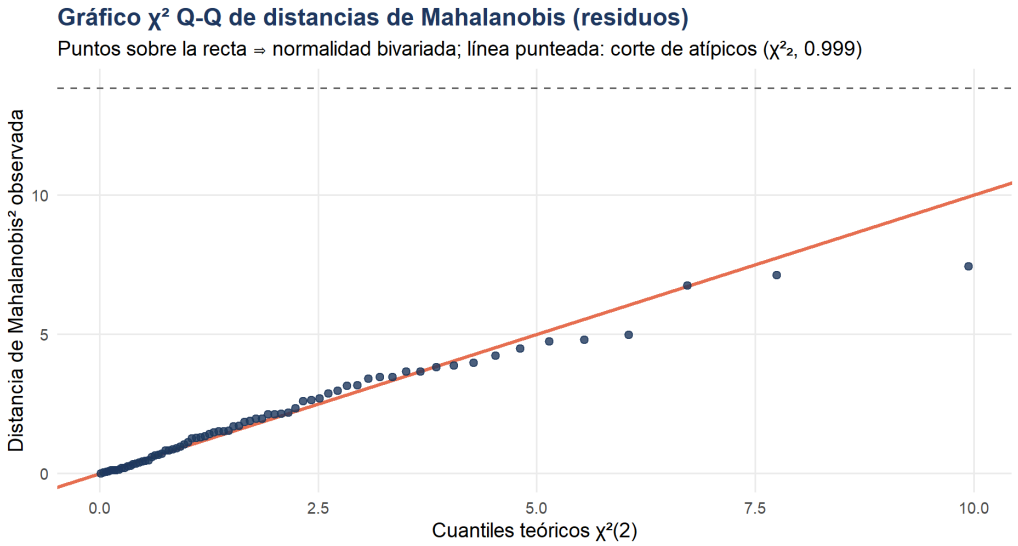
```
sw_grp %>% mutate(Decision = ifelse(p < 0.05, "No normal", "Normal"), p = fp(p)) %>%
  tabla("Shapiro-Wilk multivariado por dosis (n = 18 por grupo)")
```

Shapiro-Wilk multivariado por dosis (n = 18 por grupo)

Grupo	W	p	Decision
0 g/kg	0.934	0.2239	Normal
1 g/kg	0.943	0.3197	Normal
2 g/kg	0.950	0.4273	Normal
3 g/kg	0.934	0.2311	Normal

```
d2 <- mahalanobis(res, colMeans(res), cov(res))
qq <- data.frame(teorico = qchisq((rank(d2) - 0.5) / n, df = 2), observado = d2)
umbral <- qchisq(0.999, 2)

ggplot(qq, aes(teorico, observado)) +
  geom_abline(slope = 1, intercept = 0, colour = naranja, linewidth = 1) +
  geom_point(colour = azul, size = 2, alpha = .8) +
  geom_hline(yintercept = umbral, linetype = "dashed", colour = "grey40") +
  labs(title = "Gráfico χ² Q-Q de distancias de Mahalanobis (residuos)",
       subtitle = "Puntos sobre la recta ⇒ normalidad bivariada; línea punteada: corte de atípi
         cos (χ²₂, 0.999)",
       x = "Cuantiles teóricos χ²(2)", y = "Distancia de Mahalanobis² observada")
```




```
atipicos <- which(d2 > umbral)
txt_atip <- ifelse(length(atipicos) == 0,
  paste0("no hay observaciones atípicas multivariadas (ninguna distancia de Mahalanobis² supera
         el corte χ²(2; 0.999) = ", round(umbral, 2), ")"),
  paste0("hay ", length(atipicos), " observación(es) atípica(s) multivariada(s) (supera(n) el co
         rte χ²(2; 0.999) = ", round(umbral, 2), ")"))
```

> **✔ Interpretación**
>
> Con los residuos del modelo, el Shapiro-Wilk multivariado da \(W=\) 0.9948 (\(p=\) 0.9923) y Mardia da \(p=\) 0.8460 (asimetría) y \(p=\) 0.3415 (curtosis); en ese caso **no se rechaza** la normalidad multivariada: los residuos son compatibles con una normal bivariada. Además, no hay observaciones atípicas multivariadas (ninguna distancia de Mahalanobis² supera el corte χ²(2; 0.999) = 13.82).

3.3.2 Homogeneidad de matrices de covarianza (M de Box)

\(H_0:\ \boldsymbol\Sigma_1=\boldsymbol\Sigma_2=\boldsymbol\Sigma_3=\boldsymbol\Sigma_4\) vs \(H_1\): al menos una difiere.

```
bm <- heplots::boxM(cbind(Ganancia_peso, Rend_carcasa) ~ Probiotico, data = datos)
bm
```

```
#>
#>  Box's M-test for Homogeneity of Covariance Matrices
#>
#> data:  datos
#> Chi-Sq (approx.) = 11.68, df = 9, p-value = 0.2
```

> **✔ Interpretación**
>
> M de Box \(=\) 11.683 con 9 g.l. y \(p=\) 0.2318. Con \(\alpha=0.05\) **no** se rechaza \(H_0\): las matrices de covarianza de las cuatro dosis son homogéneas.

3.3.3 Correlación entre las variables respuesta (esfericidad de Bartlett)

El MANCOVA se justifica si las respuestas están correlacionadas. \(H_0:\ \mathbf{R}=\mathbf{I}\) (las respuestas no están correlacionadas) vs \(H_1:\ \mathbf{R}\neq\mathbf{I}\). Se aplica sobre los **residuos** (correlación una vez descontados covariables, bloque y tratamiento).

```
Rres <- cor(res)
bt <- psych::cortest.bartlett(Rres, n = n)
Rres %>% tabla("Matriz de correlación de los residuos")
```

Matriz de correlación de los residuos

	Ganancia_peso	Rend_carcasa
Ganancia_peso	1.000	0.335
Rend_carcasa	0.335	1.000

```
bt
```

```
#> $chisq
#> [1] 8.29
#>
#> $p.value
#> [1] 0.003986
#>
#> $df
#> [1] 1
```

```
r_raw <- cor.test(datos$Ganancia_peso, datos$Rend_carcasa)
```

> **✔ Interpretación**
>
> \(\chi^2=\) 8.29 (1 g.l.), \(p=\) 0.0040: se **rechaza** \(H_0\). Las respuestas están correlacionadas (r residual = 0.335); sin ajustar, la correlación simple es r = 0.653. Queda así justificado el análisis multivariado frente a dos ANCOVA separados.

3.3.4 Supuestos propios del MANCOVA

```
# (1) Linealidad: términos cuadráticos de las covariables
m_cuad <- manova(cbind(Ganancia_peso, Rend_carcasa) ~ Peso_ini + Edad_ini + Bloque + Probiotico
        +
                  I(Peso_ini^2) + I(Edad_ini^2), data = datos)
lin1 <- pull_mv(m_cuad, "I(Peso_ini^2)"); lin2 <- pull_mv(m_cuad, "I(Edad_ini^2)")

# (2) Homogeneidad de pendientes: interacción Probiotico × covariable
m_int <- manova(cbind(Ganancia_peso, Rend_carcasa) ~ Peso_ini + Edad_ini + Bloque + Probiotico +
                 Probiotico:Peso_ini + Probiotico:Edad_ini, data = datos)
pen1 <- pull_mv(m_int, "Probiotico:Peso_ini"); pen2 <- pull_mv(m_int, "Probiotico:Edad_ini")

# (3) Aditividad bloque × tratamiento (el DBCA asume que no hay interacción)
m_bxt <- manova(cbind(Ganancia_peso, Rend_carcasa) ~ Peso_ini + Edad_ini + Bloque * Probiotico,
                data = datos)
adi <- pull_mv(m_bxt, "Bloque:Probiotico")

# (4) Las covariables no deben depender del tratamiento
m_cov <- manova(cbind(Peso_ini, Edad_ini) ~ Bloque + Probiotico, data = datos)
ind <- pull_mv(m_cov, "Probiotico")

# (5) Colinealidad entre covariables
r_cov <- cor(datos$Peso_ini, datos$Edad_ini); vif <- 1 / (1 - r_cov^2)

data.frame(
  Supuesto = c("Linealidad: Peso_ini² (cuadrático)", "Linealidad: Edad_ini² (cuadrático)",
               "Pendientes homogéneas: Probiótico × Peso_ini", "Pendientes homogéneas: Probiótic
        o × Edad_ini",
               "Aditividad: Bloque × Probiótico", "Covariables independientes del tratamiento"),
  `Lambda de Wilks` = unname(c(lin1["stat"], lin2["stat"], pen1["stat"], pen2["stat"], adi["sta
        t"], ind["stat"])),
  F = unname(c(lin1["F"], lin2["F"], pen1["F"], pen2["F"], adi["F"], ind["F"])),
  gl1 = unname(c(lin1["df1"], lin2["df1"], pen1["df1"], pen2["df1"], adi["df1"], ind["df1"])),
  gl2 = unname(c(lin1["df2"], lin2["df2"], pen1["df2"], pen2["df2"], adi["df2"], ind["df2"])),
  p = unname(c(lin1["p"], lin2["p"], pen1["p"], pen2["p"], adi["p"], ind["p"])),
  check.names = FALSE) %>%
  mutate(`Conclusión` = ifelse(p >= 0.05, "Se cumple", "No se cumple"), p = fp(p)) %>%
  tabla("Contrastes de los supuestos específicos (H₀: el supuesto se cumple)", digits = 3)
```

Contrastes de los supuestos específicos (H_0: el supuesto se cumple)

Supuesto	Lambda de Wilks	F	gl1	gl2	p	Conclusión
Linealidad: Peso_ini² (cuadrático)	0.989	0.316	2	58	0.7303	Se cumple
Linealidad: Edad_ini² (cuadrático)	0.972	0.821	2	58	0.4450	Se cumple
Pendientes homogéneas: Probiótico × Peso_ini	0.944	0.528	6	108	0.7857	Se cumple
Pendientes homogéneas: Probiótico × Edad_ini	0.828	1.780	6	108	0.1100	Se cumple
Aditividad: Bloque × Probiótico	0.581	0.937	30	90	0.5661	Se cumple
Covariables independientes del tratamiento	0.967	0.344	6	124	0.9120	Se cumple

Hipótesis de cada contraste

- **Linealidad:** \(H_0\): los términos cuadráticos de las covariables no aportan (la relación es lineal).
- **Pendientes homogéneas:** \(H_0:\ \mathbf{B}_1=\mathbf{B}_2=\mathbf{B}_3=\mathbf{B}_4\) (no hay interacción tratamiento × covariable). *Es el supuesto crítico del MANCOVA*: si se rechaza, ajustar con una pendiente común no es válido.
- **Aditividad:** \(H_0\): no hay interacción bloque × tratamiento (el efecto del probiótico es el mismo en todos los lotes).
- **Independencia covariable–tratamiento:** \(H_0\): las covariables no difieren entre dosis (se miden antes del tratamiento y la aleatorización debe balancearlas).

✔ **Interpretación**

- **Linealidad: no** se rechaza \(H_0\) (p mínimo = 0.4450), por lo que las relaciones covariable–respuesta son lineales.
- **Pendientes homogéneas:** para Peso_ini \(p=\) 0.7857 y para Edad_ini \(p=\) 0.1100; no hay interacción, así que **es válido usar una pendiente común** y proceder con el MANCOVA.
- **Aditividad del DBCA:** \(p=\) 0.5661; el modelo aditivo (sin interacción bloque × dosis) es adecuado.
- **Covariables independientes del tratamiento:** \(p=\) 0.9120; la aleatorización balanceó las covariables entre dosis, de modo que el ajuste no elimina parte del efecto del tratamiento.
- **Colinealidad entre covariables:** r(Peso_ini, Edad_ini) = 0.099, VIF = 1.01 (sin problemas de colinealidad, VIF < 5).

3.3.5 Resumen de la validación

```
cumple <- function(ok) ifelse(ok,
  cell_spec("✔ Cumple", color = "white", background = verde, bold = TRUE, extra_css = "padding:2
        px 8px;border-radius:10px;"),
  cell_spec("✘ No cumple", color = "white", background = naranja, bold = TRUE, extra_css = "padd
        ing:2px 8px;border-radius:10px;"))

resumen <- data.frame(
  Supuesto = c("Normalidad multivariada (Shapiro-Wilk MV, residuos)", "Normalidad: asimetría de
        Mardia",
               "Normalidad: curtosis de Mardia", "Homogeneidad de covarianzas (M de Box)",
               "Correlación entre respuestas (Bartlett)", "Linealidad covariable-respuesta",
               "Pendientes homogéneas", "Aditividad bloque × dosis", "Covariables independientes
        del tratamiento"),
  Prueba = c("mshapiro.test", "Mardia", "Mardia", "boxM", "cortest.bartlett",
             "Términos cuadráticos", "Interacción dosis × covariable", "Interacción bloque × dos
        is", "MANOVA de covariables"),
  p = unname(c(sw_res$p.value, mar$p, bm$p.value, bt$p.value, min(lin1["p"], lin2["p"]),
        min(pen1["p"], pen2["p"]), adi["p"], ind["p"])),
  ok = unname(c(sw_res$p.value >= .05, mar$p >= .05, bm$p.value >= .05, bt$p.value < .05,
         min(lin1["p"], lin2["p"]) >= .05, min(pen1["p"], pen2["p"]) >= .05, adi["p"] >= .05, in
        d["p"] >= .05))
)
resumen %>% mutate(p = fp(p), Resultado = cumple(ok)) %>% select(-ok) %>%
  kable(format = "html", escape = FALSE, align = "llcc", caption = "Resumen de la validación de
        supuestos (α = 0.05)") %>%
  kable_styling(bootstrap_options = c("striped", "hover"), full_width = FALSE) %>%
  row_spec(0, bold = TRUE, color = "white", background = azul)
```

Resumen de la validación de supuestos (α = 0.05)

Supuesto	Prueba	p	Resultado
Normalidad multivariada (Shapiro-Wilk MV, residuos)	mshapiro.test	0.9923	✔ Cumple
Normalidad: asimetría de Mardia	Mardia	0.8460	✔ Cumple
Normalidad: curtosis de Mardia	Mardia	0.3415	✔ Cumple
Homogeneidad de covarianzas (M de Box)	boxM	0.2318	✔ Cumple
Correlación entre respuestas (Bartlett)	cortest.bartlett	0.0040	✔ Cumple
Linealidad covariable–respuesta	Términos cuadráticos	0.4450	✔ Cumple
Pendientes homogéneas	Interacción dosis × covariable	0.1100	✔ Cumple
Aditividad bloque × dosis	Interacción bloque × dosis	0.5661	✔ Cumple
Covariables independientes del tratamiento	MANOVA de covariables	0.9120	✔ Cumple

3.4 Ejecución del MANCOVA y resultados

3.4.1 Matrices de sumas de cuadrados y productos cruzados

```
SS  <- summary(mod)$SS
Tot <- Reduce("+", SS)
Wm  <- SS$Residuals            # matriz de error E
Hd  <- SS$Probiotico           # matriz de hipótesis del tratamiento

mat <- function(M, titulo) {
  cat("\n\n**", titulo, "**\n\n", sep = "")
  print(kable(M, digits = 3, align = "c") %>%
          kable_styling(full_width = FALSE, bootstrap_options = c("striped", "condensed")))
}
mat(SS$Probiotico, "H — Dosis de probiótico (SCPC ajustada por covariables y bloque)")
```

H — Dosis de probiótico (SCPC ajustada por covariables y bloque)

	Ganancia_peso	Rend_carcasa
Ganancia_peso	17180.4	511.31
Rend_carcasa	511.3	15.97

```
mat(SS$Bloque,     "Bloque")
```

Bloque

	Ganancia_peso	Rend_carcasa
Ganancia_peso	8606.6	140.339
Rend_carcasa	140.3	3.806

```
mat(SS$Peso_ini,   "Covariable 1: Peso_ini")
```

Covariable 1: Peso_ini

	Ganancia_peso	Rend_carcasa
Ganancia_peso	7659	253.05
Rend_carcasa	253	8.36

```
mat(SS$Edad_ini,   "Covariable 2: Edad_ini")
```

Covariable 2: Edad_ini

	Ganancia_peso	Rend_carcasa
Ganancia_peso	8900.2	186.622
Rend_carcasa	186.6	3.913

```
mat(Wm,            "E — Residual (error)")
```

E — Residual (error)

	Ganancia_peso	Rend_carcasa
Ganancia_peso	18082.1	293.64
Rend_carcasa	293.6	42.41

```
mat(Tot,           "T — Total corregido")
```

T — Total corregido

	Ganancia_peso	Rend_carcasa
Ganancia_peso	60428	1384.96
Rend_carcasa	1385	74.46

3.4.2 Pruebas multivariadas

```
tab_mv <- bind_rows(lapply(c("Pillai", "Wilks", "Hotelling-Lawley", "Roy"), function(ts) {
  st <- summary(mod, test = ts)$stats
  st <- st[rownames(st) != "Residuals", , drop = FALSE]
  data.frame(Termino = rownames(st), Prueba = ts, gl = st[, "Df"], Valor = st[, ts],
             F = st[, "approx F"], gl_num = st[, "num Df"], gl_den = st[, "den Df"],
             p = st[, "Pr(>F)"], row.names = NULL)
}))
g <- function(term, test, col) tab_mv[tab_mv$Termino == term & tab_mv$Prueba == test, col]

tab_mv %>%
  mutate(Sig = sig(p), p = fp(p)) %>%
  tabla("Pruebas multivariadas por término (SC secuencial: covariables → bloque → dosis)", digit
        s = 4) %>%
  row_spec(which(tab_mv$Termino == "Probiotico"), bold = TRUE, background = "#FFF1E6") %>%
  row_spec(which(tab_mv$Termino %in% c("Peso_ini", "Edad_ini")), background = "#E6F5F2") %>%
  footnote(general = "Naranja: efecto del probiótico (contraste principal). Verde: covariables.
        *** p<0.001, ** p<0.01, * p<0.05, ns no significativo. Los p de covariables y bloque de
        esta tabla son secuenciales (no ajustados por los términos posteriores); para interpreta
        rlos use la prueba tipo II de abajo.")
```

Pruebas multivariadas por término (SC secuencial: covariables → bloque → dosis)

Termino	Prueba	gl	Valor	F	gl_num	gl_den	p	Sig
Peso_ini	Pillai	1	0.3248	14.430	2	60	< 0.001	***
Edad_ini	Pillai	1	0.3322	14.925	2	60	< 0.001	***
Bloque	Pillai	5	0.3612	2.689	10	122	0.0052	**
Probiotico	**Pillai**	**3**	**0.5268**	**7.271**	**6**	**122**	**< 0.001**	***
Peso_ini	Wilks	1	0.6752	14.430	2	60	< 0.001	***
Edad_ini	Wilks	1	0.6678	14.925	2	60	< 0.001	***
Bloque	Wilks	5	0.6513	2.870	10	120	0.0030	**
Probiotico	**Wilks**	**3**	**0.4824**	**8.794**	**6**	**120**	**< 0.001**	***
Peso_ini	Hotelling-Lawley	1	0.4810	14.430	2	60	< 0.001	***
Edad_ini	Hotelling-Lawley	1	0.4975	14.925	2	60	< 0.001	***
Bloque	Hotelling-Lawley	5	0.5163	3.046	10	118	0.0018	**
Probiotico	**Hotelling-Lawley**	**3**	**1.0537**	**10.361**	**6**	**118**	**< 0.001**	***
Peso_ini	Roy	1	0.4810	14.430	2	60	< 0.001	***
Edad_ini	Roy	1	0.4975	14.925	2	60	< 0.001	***
Bloque	Roy	5	0.4760	5.807	5	61	< 0.001	***
Probiotico	**Roy**	**3**	**1.0353**	**21.050**	**3**	**61**	**< 0.001**	***

Note:
Naranja: efecto del probiótico (contraste principal). Verde: covariables. *** p<0.001, ** p<0.01, * p<0.05, ns no significativo. Los p de covariables y bloque de esta tabla son secuenciales (no ajustados por los términos posteriores); para interpretarlos use la prueba tipo II de abajo.

Como control, la prueba de **tipo II** (independiente del orden de los términos: cada efecto se ajusta por todos los demás) de `car::Manova`. Para **covariables y bloque** son estos p-valores los que se interpretan; para la dosis ambos coinciden porque es el último término:

```
car::Manova(mod, type = "II", test.statistic = "Wilks")
```

```
#>
#> Type II MANOVA Tests: Wilks test statistic
#>            Df test stat approx F num Df den Df      Pr(>F)
#> Peso_ini    1     0.901     3.28      2     60     0.04453 *
#> Edad_ini    1     0.778     8.54      2     60     0.00055 ***
#> Bloque      5     0.634     3.08     10    120     0.00163 **
#> Probiotico  3     0.482     8.79      6    120 0.000000061 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
p_prob <- g("Probiotico", "Wilks", "p")
sig_prob <- p_prob < 0.05
L  <- g("Probiotico", "Wilks", "Valor")
s_w <- min(2, 3)  # s = min(p, gl_hipotesis) = min(2, 3)
eta_w   <- 1 - L^(1 / s_w)                    # eta² parcial multivariado (Wilks)
eta_cls <- 1 - det(SS$Bloque + SS$Peso_ini + SS$Edad_ini + Wm) / det(Tot)   # criterio usado en
        clase

# Pruebas ajustadas (tipo II) de covariables y bloque: cada término se ajusta por TODOS los demá
        s.
# En la tabla secuencial, Peso_ini y Edad_ini se prueban antes del bloque, así que su p-valor sa
        le sobrestimado.
mod_lm <- lm(cbind(Ganancia_peso, Rend_carcasa) ~ Peso_ini + Edad_ini + Bloque + Probiotico, dat
        a = datos)
pull_II <- function(term) {
  rhs <- setdiff(attr(terms(mod_lm), "term.labels"), term)
  m0  <- lm(as.formula(paste("cbind(Ganancia_peso, Rend_carcasa) ~", paste(rhs, collapse = " +
        "))), data = datos)
  a   <- anova(m0, mod_lm, test = "Wilks")
  c(stat = a[2, "Wilks"], F = a[2, "approx F"], df1 = a[2, "num Df"], df2 = a[2, "den Df"], p =
        a[2, "Pr(>F)"])
}
II_peso <- pull_II("Peso_ini"); II_edad <- pull_II("Edad_ini"); II_blq <- pull_II("Bloque")

# Paso previo del MANCOVA: ¿dependen las respuestas de las covariables (H0: B = 0, conjuntament
        e)?
m_nocov <- lm(cbind(Ganancia_peso, Rend_carcasa) ~ Bloque + Probiotico, data = datos)
a_cov <- anova(m_nocov, mod_lm, test = "Wilks")
p_cov <- a_cov[2, "Pr(>F)"]
```

✔ Interpretación del contraste principal (dosis de probiótico)

- **Pillai:** $V=$ 0.5268, $F(6,122)=$ 7.271, $p=$ < 0.001.
- **Wilks:** $\Lambda=$ 0.4824, $F(6,120)=$ 8.794, $p=$ < 0.001.
- **Hotelling-Lawley:** $T=$ 1.0537, $p=$ < 0.001.
- **Roy:** $\theta=$ 1.0353, $p=$ < 0.001.

Con $\alpha=0.05$ las cuatro pruebas coinciden: se **rechaza** H_0. **Existe efecto del probiótico sobre el vector de respuestas** (ganancia de peso y rendimiento de carcasa), una vez ajustado por peso inicial, edad inicial y bloque: al menos una dosis tiene un vector de medias ajustadas distinto.

Paso previo: ¿dependen las respuestas de las covariables? Contraste conjunto $H_0:\mathbf{B}=\mathbf{0}$: $\Lambda=$ 0.7262, $F(4,120)=$ 5.203, $p=$ < 0.001. Se rechaza H_0: las respuestas dependen de las covariables, por lo que corresponde el MANCOVA (y no un MANOVA en DBCA).

Efectos secundarios (pruebas tipo II, ajustadas por los demás términos). Peso_ini ($p=$ 0.0445) y Edad_ini ($p=$ < 0.001): ambas covariables son significativas, por lo que **el ajuste por covariables es pertinente**. Bloque: $p=$ 0.0016 (el agrupamiento en lotes fue efectivo para controlar variabilidad).

3.4.3 Tamaño del efecto y eficiencia del diseño

```
# Modelos de comparación
m_sincov <- manova(cbind(Ganancia_peso, Rend_carcasa) ~ Bloque + Probiotico, data = datos)
        # MANOVA en DBCA
m_dca    <- manova(cbind(Ganancia_peso, Rend_carcasa) ~ Peso_ini + Edad_ini + Probiotico, data =
        datos) # MANCOVA en DCA

Ecm <- function(m) { E <- summary(m)$SS$Residuals; E / m$df.residual }   # matriz de cuadrados m
        edios del error
comp <- data.frame(
  Modelo = c("MANCOVA en DBCA (propuesto)", "MANOVA en DBCA (sin covariables)", "MANCOVA en DCA
        (sin bloque)"),
  gl_error = c(mod$df.residual, m_sincov$df.residual, m_dca$df.residual),
  `Lambda de Wilks (dosis)` = unname(c(L, pull_mv(m_sincov, "Probiotico")["stat"], pull_mv(m_dc
        a, "Probiotico")["stat"])),
  `F aproximado` = unname(c(g("Probiotico","Wilks","F"), pull_mv(m_sincov, "Probiotico")["F"], p
        ull_mv(m_dca, "Probiotico")["F"])),
  `Varianza generalizada del error |E/gl|` = c(det(Ecm(mod)), det(Ecm(m_sincov)), det(Ecm(m_dc
        a))),
  check.names = FALSE)
comp$`Razón |E/gl| vs. modelo propuesto` <- comp$`Varianza generalizada del error |E/gl|` / comp
        $`Varianza generalizada del error |E/gl|`[1]
comp %>% tabla("Comparación de modelos: aporte de las covariables y del bloqueo", digits = 4) %
        >%
  row_spec(1, bold = TRUE, background = "#E6F5F2")
```

Comparación de modelos: aporte de las covariables y del bloqueo

Modelo	gl_error	Lambda de Wilks (dosis)	F aproximado	Varianza generalizada del error |E/gl|	Razón |E/gl| vs. modelo propuesto
MANCOVA en DBCA (propuesto)	**61**	**0.4824**	**8.794**	**182.9**	**1.000**
MANOVA en DBCA (sin covariables)	63	0.5052	8.411	236.1	1.291
MANCOVA en DCA (sin bloque)	66	0.5855	6.649	246.6	1.348

```
ef_cov <- det(Ecm(m_sincov)) / det(Ecm(mod))
ef_blq <- det(Ecm(m_dca)) / det(Ecm(mod))
r2 <- sapply(Y, function(y) summary(lm(as.formula(paste(y, "~ Peso_ini + Edad_ini + Bloque + Pro
        biotico")), data = datos))$r.squared)
```

> **✔ Interpretación**
>
> - **Tamaño del efecto de la dosis:** $\eta^2_{parcial}=1-\Lambda^{1/s}=$ 0.305 (con $s=\min(p,\,gl_H)=2$): la dosis explica cerca del 30.5% de la variabilidad multivariada no atribuible a covariables y bloque. Con el criterio usado en clase, $\eta^2=1-|\mathbf{B}+\mathbf{X}_1+\mathbf{X}_2+\mathbf{E}|/|\mathbf{T}|=$ 0.316.
> - **R² univariado del modelo completo:** Ganancia de peso = 0.701; Rendimiento de carcasa = 0.43.
> - **Eficiencia:** la varianza generalizada del error del modelo con covariables es 1.29 veces menor que la del MANOVA sin covariables, y 1.35 veces menor que la del MANCOVA en DCA (sin bloque). Ambos controles (covariables y bloques) **aumentan la precisión** del experimento.

3.4.4 Análisis univariado de seguimiento (ANCOVA por respuesta)

Como el contraste multivariado fue significativo (condición cumplida), se explora **en cuál(es) respuesta(s)** se manifiesta el efecto. Para controlar el error tipo I global al hacer 2 pruebas se usa la corrección de **Bonferroni**: $\alpha^*=0.05/2=0.025$.

```
uni <- lapply(setNames(Y, Y), function(y) {
  fit <- lm(as.formula(paste(y, "~ Peso_ini + Edad_ini + Bloque + Probiotico")), data = datos)
  list(fit = fit, aov = car::Anova(fit, type = "II"))
})

tab_uni <- bind_rows(lapply(Y, function(y) {
  a <- uni[[y]]$aov
  a <- a[rownames(a) != "Residuals", ]
  data.frame(Respuesta = y, Fuente = rownames(a), SC = a[["Sum Sq"]], gl = a[["Df"]],
             CM = a[["Sum Sq"]] / a[["Df"]], F = a[["F value"]], p = a[["Pr(>F)"]], row.names =
       NULL)
}))

tab_uni %>% mutate(Sig = sig(p), `Sig. Bonferroni` = ifelse(p < 0.025, "Sí", "No"), p = fp(p)) %
       >%
  tabla("ANCOVA univariado en DBCA (SC tipo II)", digits = 3) %>%
  row_spec(which(tab_uni$Fuente == "Probiotico"), bold = TRUE, background = "#FFF1E6") %>%
  collapse_rows(columns = 1, valign = "top")
```

ANCOVA univariado en DBCA (SC tipo II)

Respuesta	Fuente	SC	gl	CM	F	p	Sig	Sig. Bonferroni
Ganancia_peso	Peso_ini	1152.304	1	1152.304	3.887	0.0532	ns	No
	Edad_ini	5106.796	1	5106.796	17.228	< 0.001	***	Sí
	Bloque	9401.955	5	1880.391	6.344	< 0.001	***	Sí
	Probiotico	**17180.449**	**3**	**5726.816**	**19.319**	**< 0.001**	***	**Sí**
Rend_carcasa	Peso_ini	3.463	1	3.463	4.981	0.0293	•	No
	Edad_ini	2.081	1	2.081	2.994	0.0886	ns	No
	Bloque	4.096	5	0.819	1.178	0.3302	ns	No
	Probiotico	**15.974**	**3**	**5.325**	**7.659**	**< 0.001**	***	**Sí**

```
coef_cov <- bind_rows(lapply(Y, function(y) {
  cf <- summary(uni[[y]]$fit)$coefficients[c("Peso_ini", "Edad_ini"), ]
  data.frame(Respuesta = y, Covariable = rownames(cf), Coeficiente = cf[, 1], EE = cf[, 2],
             t = cf[, 3], p = fp(cf[, 4]), row.names = NULL)
}))
coef_cov %>% tabla("Coeficientes de regresión de las covariables (pendiente común)", digits = 4)
       %>%
  collapse_rows(columns = 1, valign = "top")
```

Coeficientes de regresión de las covariables (pendiente común)

Respuesta	Covariable	Coeficiente	EE	t	p
Ganancia_peso	Peso_ini	0.1630	0.0827	1.972	0.0532
	Edad_ini	-3.8468	0.9268	-4.151	< 0.001
Rend_carcasa	Peso_ini	0.0089	0.0040	2.232	0.0293
	Edad_ini	-0.0777	0.0449	-1.730	0.0886

```
p_gp <- tab_uni$p[tab_uni$Respuesta == "Ganancia_peso" & tab_uni$Fuente == "Probiotico"]
p_rc <- tab_uni$p[tab_uni$Respuesta == "Rend_carcasa" & tab_uni$Fuente == "Probiotico"]
```

✔ **Interpretación**

- **Ganancia de peso:** el efecto de la dosis es significativo (\(p=\) < 0.001; umbral Bonferroni 0.025).
- **Rendimiento de carcasa:** el efecto de la dosis es significativo (\(p=\) < 0.001).
- **Covariables:** por cada gramo adicional de peso inicial, la ganancia de peso cambia en 0.163 g; por cada día adicional de edad inicial cambia en -3.85 g (manteniendo lo demás constante). Para el rendimiento de carcasa los cambios son de 0.0089 y -0.078 puntos porcentuales, respectivamente. El signo negativo de la edad refleja que **animales más viejos al inicio crecen menos** en el periodo.

3.4.5 Medias ajustadas

Las **medias ajustadas** (marginales estimadas) son las medias de cada dosis evaluadas en el *valor promedio de las covariables*; permiten comparar dosis "como si" todos los cuyes hubieran partido con el mismo peso y edad.

```
emm_u <- lapply(uni, function(u) emmeans(u$fit, ~ Probiotico))

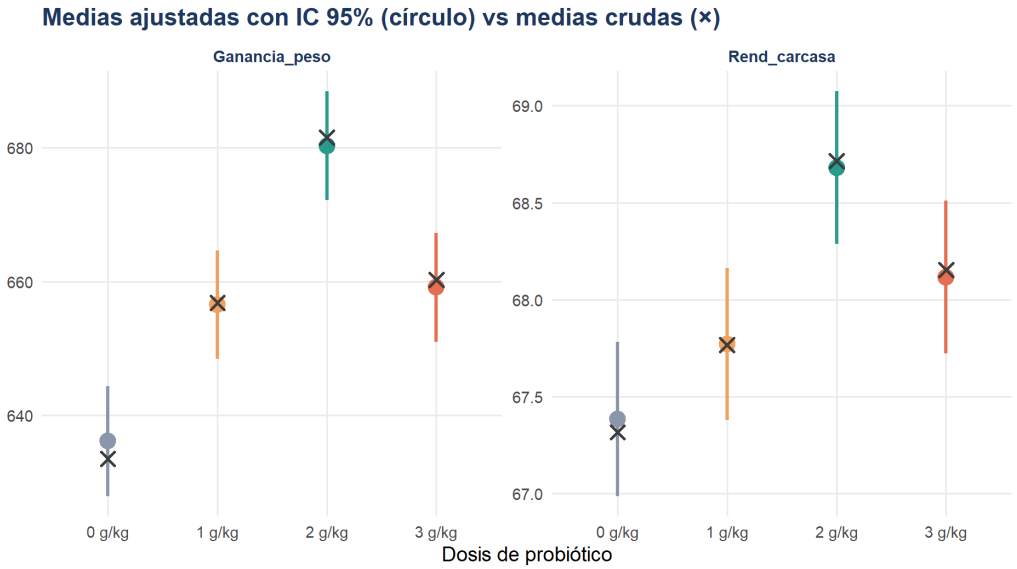
ajustadas <- bind_rows(lapply(Y, function(y) cbind(Respuesta = y, as.data.frame(emm_u[[y]]))))
crudas <- datos %>% group_by(Probiotico) %>% summarise(across(all_of(Y), mean)) %>%
  pivot_longer(all_of(Y), names_to = "Respuesta", values_to = "media_cruda")
ajustadas <- left_join(ajustadas, crudas, by = c("Respuesta", "Probiotico"))

ajustadas %>% select(Respuesta, Probiotico, `Media cruda` = media_cruda, `Media ajustada` = emme
        an,
                    EE = SE, `IC inf` = lower.CL, `IC sup` = upper.CL) %>%
  tabla("Medias crudas vs medias ajustadas por covariables (IC 95%)", digits = 3) %>%
  collapse_rows(columns = 1, valign = "top")
```

Medias crudas vs medias ajustadas por covariables (IC 95%)

Respuesta	Probiotico	Media cruda	Media ajustada	EE	IC inf	IC sup
Ganancia_peso	0 g/kg	633.49	636.15	4.102	627.95	644.35
	1 g/kg	656.82	656.54	4.062	648.42	664.67
	2 g/kg	681.51	680.28	4.068	672.14	688.41
	3 g/kg	660.27	659.12	4.068	650.99	667.25
Rend_carcasa	0 g/kg	67.32	67.38	0.199	66.99	67.78
	1 g/kg	67.77	67.77	0.197	67.38	68.16
	2 g/kg	68.71	68.68	0.197	68.29	69.07
	3 g/kg	68.15	68.12	0.197	67.72	68.51

```
ggplot(ajustadas, aes(Probiotico, emmean, colour = Probiotico)) +
  geom_pointrange(aes(ymin = lower.CL, ymax = upper.CL), linewidth = 1, size = .9) +
  geom_point(aes(y = media_cruda), shape = 4, size = 3, stroke = 1.2, colour = "grey25") +
  facet_wrap(~Respuesta, scales = "free_y") +
  scale_colour_manual(values = pal, guide = "none") +
  labs(title = "Medias ajustadas con IC 95% (círculo) vs medias crudas (×)",
       x = "Dosis de probiótico", y = NULL)
```



3.4.6 Comparaciones múltiples multivariadas entre dosis

Para ubicar **qué dosis difieren** se comparan los vectores de medias ajustadas por pares con \(T^2\) de Hotelling (`emmeans::mvcontrast`), ajustando el valor \(p\) por **Bonferroni** y por **Holm**.

\(H_0:\ \boldsymbol\mu^{aj}_i=\boldsymbol\mu^{aj}_{i'}\) vs \(H_1:\ \boldsymbol\mu^{aj}_i\neq\boldsymbol\mu^{aj}_{i'}\)

```
fit_lm <- lm(cbind(Ganancia_peso, Rend_carcasa) ~ Peso_ini + Edad_ini + Bloque + Probiotico, dat
        a = datos)
emm_mv <- emmeans(fit_lm, ~ Probiotico | rep.meas)

mv_bonf <- as.data.frame(mvcontrast(emm_mv, method = "pairwise", mult.name = "rep.meas", adjust
        = "bonferroni"))
mv_holm <- as.data.frame(mvcontrast(emm_mv, method = "pairwise", mult.name = "rep.meas", adjust
        = "holm"))

mv_bonf$p.holm <- mv_holm$p.value
mv_bonf %>%
  transmute(Contraste = contrast, `T²` = T.square, gl1 = df1, gl2 = df2, F = F.ratio,
            `p (Bonferroni)` = fp(p.value), `p (Holm)` = fp(p.holm),
            Decisión = ifelse(p.value < 0.05, "Difieren", "No difieren")) %>%
  tabla("Comparaciones por pares de vectores de medias ajustadas", digits = 3)
```

Comparaciones por pares de vectores de medias ajustadas

	Contraste	T²	gl1	gl2	F	p (Bonferroni)	p (Holm)	Decisión
1	(0 g/kg) - (1 g/kg)	12.500	2	60	6.147	0.0224	0.0075	Difieren
3	(0 g/kg) - (2 g/kg)	62.546	2	60	30.760	< 0.001	< 0.001	Difieren
5	(0 g/kg) - (3 g/kg)	17.502	2	60	8.608	0.0031	0.0021	Difieren
7	(1 g/kg) - (2 g/kg)	21.043	2	60	10.349	< 0.001	< 0.001	Difieren
9	(1 g/kg) - (3 g/kg)	1.537	2	60	0.756	1.0000	0.4740	No difieren
11	(2 g/kg) - (3 g/kg)	14.295	2	60	7.030	0.0108	0.0054	Difieren

```
# Cada dosis frente al control (0 g/kg)
mv_ctrl <- as.data.frame(mvcontrast(emm_mv, method = "trt.vs.ctrl1", mult.name = "rep.meas", adj
        ust = "bonferroni"))
mv_ctrl %>%
  transmute(Contraste = contrast, `T²` = T.square, gl1 = df1, gl2 = df2, F = F.ratio,
            `p (Bonferroni)` = fp(p.value), Decisión = ifelse(p.value < 0.05, "Difiere del contr
        ol", "Igual al control")) %>%
  tabla("Cada dosis vs. control (0 g/kg)", digits = 3)
```

Cada dosis vs. control (0 g/kg)

	Contraste	T²	gl1	gl2	F	p (Bonferroni)	Decisión
1	(1 g/kg) - (0 g/kg)	12.50	2	60	6.147	0.0112	Difiere del control
3	(2 g/kg) - (0 g/kg)	62.55	2	60	30.760	< 0.001	Difiere del control
5	(3 g/kg) - (0 g/kg)	17.50	2	60	8.608	0.0016	Difiere del control

Pruebas **univariadas** por pares (Tukey) para precisar en qué variable difieren:

```
tuk <- bind_rows(lapply(Y, function(y) cbind(Respuesta = y, as.data.frame(pairs(emm_u[[y]], adju
        st = "tukey")))))
tuk %>% transmute(Respuesta, Contraste = contrast, Diferencia = estimate, EE = SE, t = t.ratio,
                  `p (Tukey)` = fp(p.value), Decisión = ifelse(p.value < 0.05, "Difieren", "No d
        ifieren")) %>%
  tabla("Comparaciones univariadas por pares (medias ajustadas, Tukey)", digits = 3) %>%
  collapse_rows(columns = 1, valign = "top")
```

Comparaciones univariadas por pares (medias ajustadas, Tukey)

Respuesta	Contraste	Diferencia	EE	t	p (Tukey)	Decisión
Ganancia_peso	(0 g/kg) - (1 g/kg)	-20.396	5.779	-3.529	0.0043	Difieren
	(0 g/kg) - (2 g/kg)	-44.127	5.806	-7.600	< 0.001	Difieren
	(0 g/kg) - (3 g/kg)	-22.973	5.804	-3.958	0.0011	Difieren
	(1 g/kg) - (2 g/kg)	-23.731	5.747	-4.129	< 0.001	Difieren
	(1 g/kg) - (3 g/kg)	-2.576	5.749	-0.448	0.9698	No difieren
	(2 g/kg) - (3 g/kg)	21.155	5.740	3.686	0.0027	Difieren
Rend_carcasa	(0 g/kg) - (1 g/kg)	-0.387	0.280	-1.382	0.5150	No difieren
	(0 g/kg) - (2 g/kg)	-1.296	0.281	-4.610	< 0.001	Difieren
	(0 g/kg) - (3 g/kg)	-0.732	0.281	-2.604	0.0547	No difieren
	(1 g/kg) - (2 g/kg)	-0.909	0.278	-3.267	0.0094	Difieren
	(1 g/kg) - (3 g/kg)	-0.345	0.278	-1.239	0.6046	No difieren
	(2 g/kg) - (3 g/kg)	0.564	0.278	2.030	0.1885	No difieren

```
pares_mv  <- paste(mv_bonf$contrast[mv_bonf$p.value < 0.05], collapse = "; ")
mejor_gp  <- as.character(ajustadas$Probiotico[ajustadas$Respuesta == "Ganancia_peso"][which.max
        (ajustadas$emmean[ajustadas$Respuesta == "Ganancia_peso"])])
mejor_rc  <- as.character(ajustadas$Probiotico[ajustadas$Respuesta == "Rend_carcasa"][which.max
        (ajustadas$emmean[ajustadas$Respuesta == "Rend_carcasa"])])
```

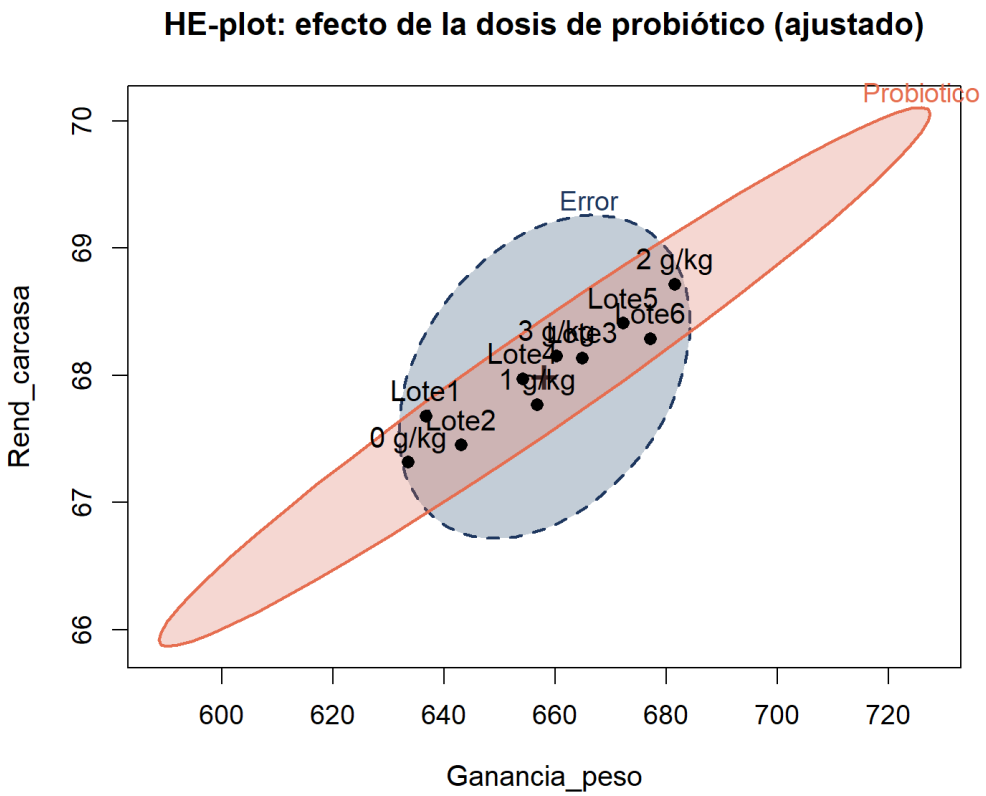
> **✔ Interpretación**
>
> Con Bonferroni, los pares de dosis cuyos vectores de medias ajustadas difieren son: **(0 g/kg) - (1 g/kg); (0 g/kg) - (2 g/kg); (0 g/kg) - (3 g/kg); (1 g/kg) - (2 g/kg); (2 g/kg) - (3 g/kg)**. La mayor media ajustada de ganancia de peso corresponde a la dosis **2 g/kg** y la de rendimiento de carcasa a **2 g/kg**. Ambas variables coinciden en la mejor dosis, lo que facilita la recomendación. Que la dosis más alta (3 g/kg) no supere a la intermedia sugiere una **respuesta curvilínea** (efecto de saturación).

3.4.7 Representación gráfica multivariada

3.4.7.1 Elipse de hipótesis–error (HE-plot)

La elipse **H** (naranja) resume la variación entre dosis y la elipse **E** (azul) la variación residual. El efecto es significativo cuando la elipse H *sobresale* de la E escalada; los centros de los tratamientos aparecen como puntos y su separación indica la dirección del efecto.

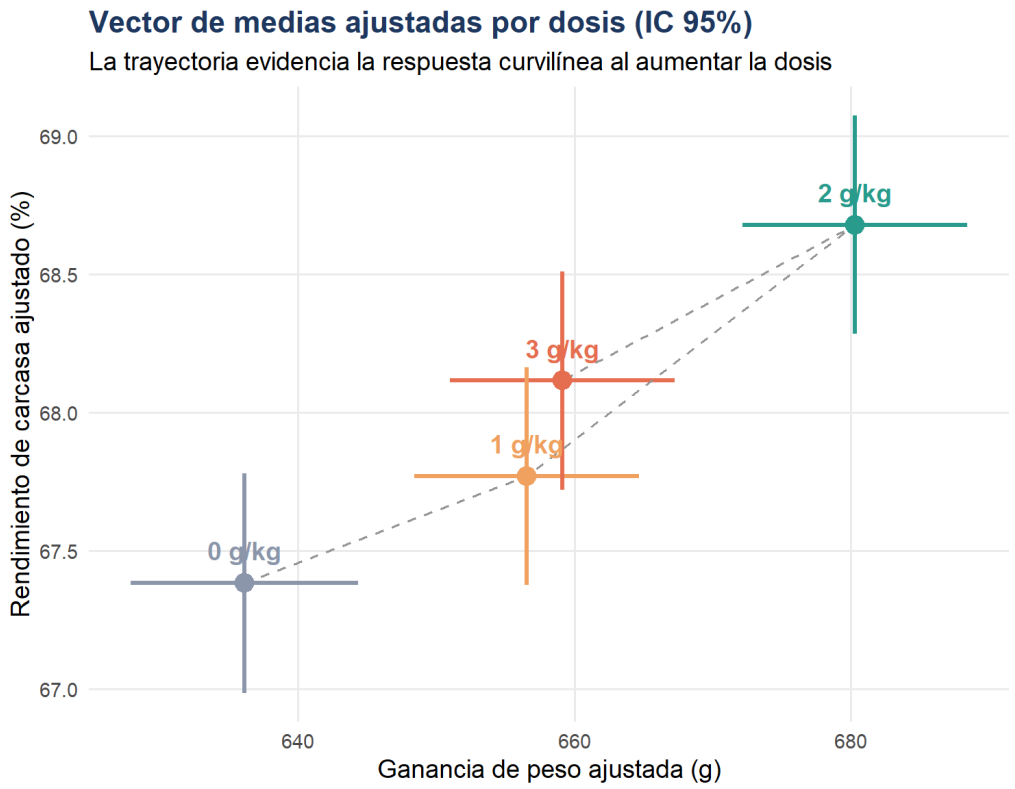
```r
heplot(mod, terms = "Probiotico", variables = c(1, 2), fill = TRUE, fill.alpha = 0.25,
       col = c(azul, naranja), lwd = 2, cex = 1.1, cex.lab = 1.1,
       main = "HE-plot: efecto de la dosis de probiótico (ajustado)")
```



3.4.7.2 Vectores de medias ajustadas en el plano de respuestas

```r
em2 <- as.data.frame(emm_mv) %>%
  select(Probiotico, rep.meas, emmean, lower.CL, upper.CL) %>%
  pivot_wider(names_from = rep.meas, values_from = c(emmean, lower.CL, upper.CL))

ggplot(em2, aes(emmean_Ganancia_peso, emmean_Rend_carcasa, colour = Probiotico)) +
  geom_segment(aes(x = lower.CL_Ganancia_peso, xend = upper.CL_Ganancia_peso,
                   y = emmean_Rend_carcasa, yend = emmean_Rend_carcasa), linewidth = 1) +
  geom_segment(aes(x = emmean_Ganancia_peso, xend = emmean_Ganancia_peso,
                   y = lower.CL_Rend_carcasa, yend = upper.CL_Rend_carcasa), linewidth = 1) +
  geom_path(aes(group = 1), colour = "grey60", linetype = "dashed") +
  geom_point(size = 4) +
  geom_text(aes(label = Probiotico), vjust = -1.2, fontface = "bold", show.legend = FALSE) +
  scale_colour_manual(values = pal, guide = "none") +
  labs(title = "Vector de medias ajustadas por dosis (IC 95%)",
       subtitle = "La trayectoria evidencia la respuesta curvilínea al aumentar la dosis",
       x = "Ganancia de peso ajustada (g)", y = "Rendimiento de carcasa ajustado (%)")
```



✔ Interpretación gráfica

El HE-plot confirma visualmente la prueba multivariada: la elipse H se proyecta claramente fuera de la elipse de error, es decir, la variación entre dosis es mayor que la esperada por azar. Los centros de las dosis se ordenan a lo largo de una **diagonal positiva**: las dosis que más aumentan la ganancia de peso también incrementan el rendimiento de carcasa, coherente con la correlación positiva entre las respuestas.

3.5 Discusión

💬 Contraste con el problema práctico

1. **Por qué el enfoque multivariado.** Las respuestas están correlacionadas (r residual = 0.34), de modo que la decisión sobre la dosis debe tomarse sobre el vector \((\text{ganancia}, \text{rendimiento})\) y no sobre cada variable aislada. El MANCOVA protege el error tipo I global y aprovecha la covarianza entre respuestas.
2. **Papel de las covariables.** Peso inicial y edad inicial resultaron significativas (Wilks tipo II \(p=\) 0.0445 y < 0.001). Al ajustar por ellas, la varianza generalizada del error se redujo 1.29 veces respecto del MANOVA simple, lo que hace al contraste de la dosis más potente y evita atribuir al probiótico diferencias que se deben a que algunos cuyes partieron más pesados o más jóvenes.
3. **Papel del bloque.** El bloqueo por peso al destete fue efectivo (p = 0.0016) y el modelo aditivo bloque + dosis se sostiene (p de la interacción = 0.5661); el DBCA con covariables es 1.35 veces más eficiente que el DCA con covariables.
4. **Efecto del probiótico.** El efecto multivariado es significativo (\(\Lambda=\) 0.482, \(p=\) < 0.001, \(\eta^2_p=\) 0.31). Las comparaciones por pares identifican como mejor dosis a **2 g/kg** (ganancia de peso) y **2 g/kg** (rendimiento de carcasa); la dosis de 3 g/kg no mejora a la de 2 g/kg, lo que desde el punto de vista económico desaconseja el sobre-uso del aditivo.
5. **Robustez y limitaciones.** Los supuestos se verificaron formalmente (ver resumen de la sección 3.3). El MANCOVA es sensible a la violación del supuesto de pendientes homogéneas, que aquí se cumple. Las pruebas de Pillai, Wilks, Hotelling-Lawley y Roy coinciden, por lo que la conclusión no depende de la elección del estadístico. Los datos son simulados; en un estudio real convendría confirmar con más repeticiones por bloque y considerar la jaula como unidad experimental si los animales comparten corral (seudorreplicación).

3.6 Conclusiones

🏁 Conclusiones

1. **Existe efecto multivariado del probiótico** sobre el vector (ganancia de peso, rendimiento de carcasa) tras ajustar por peso inicial, edad inicial y bloque: \(\Lambda=\) 0.482, \(F(6,120)=\) 8.79, \(p=\) < 0.001, con una magnitud de efecto \(\eta^2_p=\) 0.31. Se rechaza \(H_0\) y se concluye que al menos una dosis produce un vector de medias ajustadas distinto.
2. **Las covariables y el bloqueo mejoraron la precisión del experimento.** Se cumplen los supuestos de normalidad multivariada, homogeneidad de covarianzas, correlación entre respuestas, linealidad, pendientes homogéneas, aditividad e independencia de las covariables, y el MANCOVA en DBCA fue más eficiente que el MANOVA sin covariables (×1.29) y que el MANCOVA en DCA (×1.35).
3. **Recomendación aplicada:** la dosis de **2 g/kg de probiótico** maximiza la ganancia de peso ajustada y el rendimiento de carcasa; la dosis superior no aporta mejoras adicionales, por lo que resulta técnica y económicamente la más conveniente para la crianza de cuyes de engorde.

3.7 Preguntas de sustentación (defensa oral)

1. ¿Por qué usar un MANCOVA y no dos ANCOVA separados?

Porque las respuestas están correlacionadas. El MANCOVA contrasta el *vector* de medias ajustadas con una sola prueba (control del error tipo I global), usa la matriz de covarianza \(\boldsymbol\Sigma\) completa y puede detectar diferencias en combinaciones lineales de las respuestas que ninguna ANCOVA univariada detectaría. Los ANCOVA se usan solo como **seguimiento**, con corrección de Bonferroni, cuando el contraste multivariado es significativo.

2. ¿Qué es el supuesto de homogeneidad de pendientes, cómo se prueba y qué pasa si se viola?

Es que la relación entre cada covariable y las respuestas (matriz $\mathbf B$) es la misma en todos los tratamientos. Se prueba incluyendo la interacción tratamiento × covariable y contrastando H_0: no hay interacción. Si se rechaza, la diferencia entre tratamientos depende del nivel de la covariable, por lo que las "medias ajustadas" a una pendiente común carecen de sentido; se debe modelar con pendientes separadas (y comparar tratamientos a valores fijos de la covariable) o usar la técnica de Johnson-Neyman. Aquí el contraste no fue significativo, de modo que el MANCOVA es válido.

3. ¿Qué cambia entre DCA y DBCA, y por qué las covariables van primero en la fórmula?

El DBCA agrega el efecto de bloque, que retira de $\mathbf E$ la variación entre lotes (aquí, eficiencia relativa de 1.35). En `manova()` la suma de cuadrados es **secuencial (tipo I)**: cada término se ajusta solo por los anteriores. Si las covariables se escribieran al final, el tratamiento se probaría *sin* ajustar por ellas. Colocándolas primero, el tratamiento (último término) queda ajustado por covariables y bloque, que es lo que define un MANCOVA; la prueba tipo II de `car::Manova` da el mismo resultado para el tratamiento porque este es el último término (queda ajustado por todos los demás). Para las covariables y el bloque, en cambio, se interpretan los p-valores tipo II, porque los secuenciales no están ajustados por los términos que vienen después.

4. ¿Qué estadístico multivariado se reporta y cómo se relacionan?

Los cuatro se derivan de las raíces características λ_k de $\mathbf E^{-1}\mathbf H$: Wilks $=\prod 1/(1+\lambda_k)$, Pillai $=\sum\lambda_k/(1+\lambda_k)$, Hotelling-Lawley $=\sum\lambda_k$ y Roy $=\lambda_1/(1+\lambda_1)$. Pillai es el más robusto ante desviaciones de normalidad y de homogeneidad de covarianzas (Olson, 1974); Roy es el más potente cuando hay una sola dimensión dominante pero el más sensible a violaciones. Con $s=1$ los cuatro coinciden. Aquí los cuatro concluyen igual.

5. ¿Por qué la covariable debe medirse antes del tratamiento y qué son las medias ajustadas?

Si el tratamiento afecta a la covariable, ajustar por ella elimina parte del efecto real del tratamiento y sesga la conclusión. Por eso se verifica que las covariables no difieran entre dosis (aquí $p=$ 0.9120). Las medias ajustadas son las medias de cada tratamiento evaluadas en el valor promedio de las covariables, $\bar y_i^{aj}=\bar y_i-\mathbf{b}^{\top}(\bar{\mathbf x}_i-\bar{\mathbf x})$; permiten comparar tratamientos como si todos los animales hubieran partido en las mismas condiciones.

3.8 Bibliografía (APA 7.ª edición)

- Bartlett, M. S. (1954). A note on the multiplying factors for various χ² approximations. *Journal of the Royal Statistical Society: Series B, 16*(2), 296–298.
- Box, G. E. P. (1949). A general distribution theory for a class of likelihood criteria. *Biometrika, 36*(3/4), 317–346.
- Fox, J., & Weisberg, S. (2019). *An R companion to applied regression* (3.ª ed.). SAGE.
- Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2019). *Multivariate data analysis* (8.ª ed.). Cengage.
- Huitema, B. E. (2011). *The analysis of covariance and alternatives: Statistical methods for experiments, quasi-experiments, and single-case studies* (2.ª ed.). Wiley.
- Johnson, R. A., & Wichern, D. W. (2007). *Applied multivariate statistical analysis* (6.ª ed.). Pearson Prentice Hall.
- Mardia, K. V. (1970). Measures of multivariate skewness and kurtosis with applications. *Biometrika, 57*(3), 519–530.
- Montgomery, D. C. (2017). *Design and analysis of experiments* (9.ª ed.). Wiley.
- Olson, C. L. (1974). Comparative robustness of six tests in multivariate analysis of variance. *Journal of the American Statistical Association, 69*(348), 894–908.
- R Core Team. (2025). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing. https://www.R-project.org/ (https://www.R-project.org/)
- Rencher, A. C., & Christensen, W. F. (2012). *Methods of multivariate analysis* (3.ª ed.). Wiley.

- Villaseñor Alva, J. A., & González Estrada, E. (2009). A generalization of Shapiro–Wilk's test for multivariate normality. *Communications in Statistics – Theory and Methods, 38*(11), 1870–1883.
- Wilks, S. S. (1932). Certain generalizations in the analysis of variance. *Biometrika, 24*(3/4), 471–494.

Paquetes de R utilizados (para el año y versión exactos use `citation("paquete")`): `car` (Fox & Weisberg), `heplots` (Fox, Friendly & Monette), `emmeans` (Lenth), `mvnormtest` (Jarek), `psych` (Revelle), `ggplot2` (Wickham), `dplyr` y `tidyr` (Wickham et al.), `readxl` (Wickham & Bryan), `knitr` (Xie) y `kableExtra` (Zhu).

4 Regresión multivariada

Ficha de la pregunta

- **Técnica:** Regresión lineal multivariada (`lm(cbind(...) ~ ...)`) con las cuatro pruebas MANOVA
- **Base de datos:** `state.x77` (incluida en R) — estadísticas de los 50 estados de EE. UU.
- **Variables respuesta:** esperanza de vida (`Life.Exp`) e ingreso per cápita (`Income`)
- **Variables predictoras:** analfabetismo (`Illiteracy`), graduados de secundaria (`HS.Grad`) y días de helada (`Frost`)

4.1 Introducción

En estudios sociodemográficos y económicos, evaluar múltiples variables de respuesta de forma aislada mediante modelos univariados ignora la estructura de correlación subyacente y puede incrementar el error estadístico global. Para evitar esto, el análisis de regresión multivariado permite modelar conjuntamente un grupo de variables dependientes en función de un conjunto común de predictoras.

En este estudio empleamos la base de datos oficial `state.x77` (integrada en R), la cual recopila estadísticas de los 50 estados de los Estados Unidos. El objetivo es determinar si la Esperanza de vida (`Life.Exp`) y el Ingreso per cápita (`Income`) dependen conjuntamente de tres variables predictoras: el Analfabetismo (`Illiteracy`), el Porcentaje de graduados de secundaria (`HS.Grad`) y los Días de helada anuales (`Frost`).

4.2 Lectura e Ingreso de Datos

Cargamos las librerías estadísticas necesarias y preparamos el dataset nativo state.x77 para la estimación del modelo.

```
# Cargar librerías necesarias
library(mvnormtest)
library(psych)
library(car)

# Importación y preparación del dataset nativo de R
datos <- as.data.frame(state.x77)

# Renombrar variables clave para mayor claridad
colnames(datos)[c(2, 4, 6, 7)] <- c("Income", "Life.Exp", "HS.Grad", "Frost")

# Visualización inicial y dimensiones
head(datos)
```

```
dim(datos)
```

```
#> [1] 50  8
```

4.3 Pruebas Preliminares de Supuestos

Antes de ajustar el modelo, es necesario verificar el cumplimiento de los supuestos estadísticos correspondientes.

4.3.1 Prueba de Normalidad Multivariada

Evaluamos si el vector de las variables dependientes (`Life.Exp` e `Income`) sigue una distribución normal multivariada.

- **Hipótesis:**
  - \(H_0\): Las variables dependientes siguen una distribución normal multivariada.

- H_1: Las variables dependientes no siguen una distribución normal multivariada.

```
# Selección de las variables dependientes
datos_dep <- datos[c("Life.Exp", "Income")]

# Supuesto de normalidad multivariada
mshapiro.test(t(datos_dep))
```

```
#>
#>  Shapiro-Wilk normality test
#>
#> data:  Z
#> W = 0.92328, p-value = 0.003105
```

> ✔ **Conclusión**
>
> Dado que el p-valor (0.0031) es menor al nivel de significancia ($\alpha = 0.05$), se rechaza H_0. Por lo tanto, las variables dependientes no se ajustan estrictamente a una distribución normal multivariada. No obstante, los estadísticos de prueba multivariados posteriores son robustos ante violaciones moderadas de este supuesto.

4.3.2 Prueba de Esfericidad de Bartlett

El análisis multivariado exige que las variables dependientes estén correlacionadas entre sí. * **Hipótesis:** * H_0: La matriz de correlación de las variables dependientes es una matriz identidad ($\mathbf{R} = \mathbf{I}$), no hay correlación). * H_1: La matriz de correlación de las variables dependientes no es una matriz identidad ($\mathbf{R} \neq \mathbf{I}$), sí existe correlación).

```
# Prueba de esfericidad de Bartlett
cortest.bartlett(cor(datos_dep), n = nrow(datos_dep))
```

```
#> $chisq
#> [1] 5.844507
#>
#> $p.value
#> [1] 0.01562575
#>
#> $df
#> [1] 1
```

> ✔ **Conclusión**
>
> Dado que el p-valor (0.0156) es menor al nivel de significancia ($\alpha = 0.05$), se rechaza H_0. Se concluye que las variables dependientes sí están significativamente correlacionadas, lo que justifica plenamente el uso del enfoque multivariado.

4.4 Ajuste del Modelo y Prueba de Significación Conjunta

Ajustamos el modelo de regresión multivariada mediante mínimos cuadrados utilizando la función `lm()` y `cbind()`, evaluando de forma conjunta el efecto de los predictores (`Illiteracy`, `HS.Grad`, `Frost`) sobre las respuestas (`Life.Exp`, `Income`).

4.4.1 Prueba de Significación Global del Modelo

Evaluamos si el conjunto de variables independientes en su totalidad influye de manera significativa sobre las variables dependientes.

- **Hipótesis:**

- H_0: Ninguna de las variables independientes influye sobre las variables dependientes ($\mathbf{B} = \mathbf{0}$).
- H_1: Al menos una de las variables independientes influye sobre las variables dependientes ($\mathbf{B} \neq \mathbf{0}$).

```
# Ajuste del modelo de regresión multivariada
modelo1 <- lm(cbind(Life.Exp, Income) ~ Illiteracy + HS.Grad + Frost, data = datos)
alias(modelo1)
```

```
#> Model :
#> cbind(Life.Exp, Income) ~ Illiteracy + HS.Grad + Frost
```

```
# Prueba de hipótesis lineal general conjunta
lh.out <- linearHypothesis(modelo1,
                           hypothesis.matrix = c("Illiteracy = 0", "HS.Grad = 0", "Frost = 0"))
lh.out
```

```
#>
#> Sum of squares and products for the hypothesis:
#>             Life.Exp     Income
#> Life.Exp    38.41596   15213.28
#> Income   15213.28006 7158044.88
#>
#> Sum of squares and products for error:
#>             Life.Exp       Income
#> Life.Exp    49.88304    -1460.784
#> Income   -1460.78406 11343047.122
#>
#> Multivariate Tests:
#>                  Df test stat  approx F num Df den Df          Pr(>F)
#> Pillai            3 0.6399075  7.214152      6     92 0.0000025029275 ***
#> Wilks             3 0.3902340  9.012020      6     90 0.0000001044258 ***
#> Hotelling-Lawley  3 1.4853254 10.892386      6     88 0.0000000048604 ***
#> Roy               3 1.4313632 21.947569      3     46 0.0000000057134 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

> **✔ Conclusión**
>
> Dado que los p-valores asociados a los estadísticos de prueba son menores a $\alpha = 0.05$, se rechaza H_0. Se concluye que el conjunto de variables independientes (Illiteracy, HS.Grad, Frost) influye de manera conjunta y estadísticamente significativa sobre el vector de variables dependientes (Life.Exp, Income).

4.5 Pruebas Estadísticas MANOVA (Los Cuatro Criterios)

Evaluamos la significancia global utilizando los cuatro criterios clásicos del MANOVA y los desglosamos mediante sumas de cuadrados tipo II y III.

- **Hipótesis:**
  - H_0: Los vectores de coeficientes de regresión para cada variable dependiente son iguales a cero.
  - H_1: Al menos un vector de coeficientes es diferente de cero.

```
# Criterios estadísticos MANOVA
summary(manova(modelo1), test = "Pillai")
```

```
#>            Df  Pillai approx F num Df den Df       Pr(>F)
#> Illiteracy  1 0.49545  22.0944      2     45 0.0000002067 ***
#> HS.Grad     1 0.31623  10.4056      2     45     0.000193 ***
#> Frost       1 0.03928   0.9199      2     45     0.405939
#> Residuals  46
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
summary(manova(modelo1), test = "Wilks")
```

```
#>            Df   Wilks approx F num Df den Df       Pr(>F)
#> Illiteracy  1 0.50455  22.0944      2     45 0.0000002067 ***
#> HS.Grad     1 0.68377  10.4056      2     45     0.000193 ***
#> Frost       1 0.96072   0.9199      2     45     0.405939
#> Residuals  46
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
summary(manova(modelo1), test = "Hotelling-Lawley")
```

```
#>            Df Hotelling-Lawley approx F num Df den Df       Pr(>F)
#> Illiteracy  1          0.98197  22.0944      2     45 0.0000002067 ***
#> HS.Grad     1          0.46247  10.4056      2     45     0.000193 ***
#> Frost       1          0.04088   0.9199      2     45     0.405939
#> Residuals  46
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
summary(manova(modelo1), test = "Roy")
```

```
#>            Df     Roy approx F num Df den Df       Pr(>F)
#> Illiteracy  1 0.98197  22.0944      2     45 0.0000002067 ***
#> HS.Grad     1 0.46247  10.4056      2     45     0.000193 ***
#> Frost       1 0.04088   0.9199      2     45     0.405939
#> Residuals  46
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# Pruebas individuales de los coeficientes según el tipo de suma de cuadrados
Manova(modelo1, type = "II")  # Sin intercepto
```

```
#>
#> Type II MANOVA Tests: Pillai test statistic
#>            Df test stat approx F num Df den Df    Pr(>F)
#> Illiteracy  1  0.147762   3.9011      2     45 0.0273920 *
#> HS.Grad     1  0.300084   9.6467      2     45 0.0003262 ***
#> Frost       1  0.039277   0.9199      2     45 0.4059392
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Manova(modelo1, type = "III") # Con intercepto
```

```
#>
#> Type III MANOVA Tests: Pillai test statistic
#>             Df test stat approx F num Df den Df                Pr(>F)
#> (Intercept)  1   0.97067   744.61      2     45 < 0.00000000000000022 ***
#> Illiteracy   1   0.14776     3.90      2     45             0.0273920 *
#> HS.Grad      1   0.30008     9.65      2     45             0.0003262 ***
#> Frost        1   0.03928     0.92      2     45             0.4059392
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

> ✔ **Conclusión**
>
> - Para **Illiteracy** y **HS.Grad**, dado que sus p-valores son menores a \(\alpha = 0.05\), **se rechaza \(H_0\)**, concluyendo que estas variables independientes influyen de manera significativa sobre el vector de respuestas (`Life.Exp` , `Income`).
> - Para **Frost**, dado que su p-valor (\(0.4059\)) es mayor a \(0.05\), **no se rechaza \(H_0\)**, lo que indica que esta variable no presenta un efecto estadísticamente significativo sobre el conjunto de respuestas en presencia de los demás predictores.

4.6 Validación Predictiva y Cálculo del Error (MAPE)

Para evaluar la capacidad predictiva del modelo fuera de la muestra, empleamos las primeras 10 observaciones como conjunto de prueba (`test data`), generamos las predicciones y calculamos el error porcentual absoluto medio (MAPE) junto con los coeficientes de determinación (\(R^2\)) de cada respuesta individual.

```
# Uso de las 10 primeras filas como data de prueba
test.data <- datos[c(1:10), c("Illiteracy", "HS.Grad", "Frost")]
predictions <- predict(modelo1, test.data)
reales <- datos[c(1:10), c("Life.Exp", "Income")]

comparacion <- cbind(predictions, reales)
colnames(comparacion) <- c("Life.Exp_predicha", "Income_predicho", "Life.Exp_real", "Income_rea
        l")
comparacion
```

```
# Función para calcular el error (MAPE)
mape = function(y_pred, y_real){
  n = length(y_pred)
  mape_res = abs(y_pred - y_real)/(y_real*n)
  return(sum(mape_res))
}

# Cálculo del MAPE para cada variable dependiente
mape(comparacion$Life.Exp_predicha, comparacion$Life.Exp_real)
```

```
#> [1] 0.01212993
```

```
mape(comparacion$Income_predicho, comparacion$Income_real)
```

```
#> [1] 0.08298859
```

```
# Extracción de los R^2 individuales para cada modelo de respuesta
res = summary(modelo1)
c(res$`Response Life.Exp`$r.squared,
  res$`Response Income`$r.squared)
```

```
#> [1] 0.4350668 0.3868985
```

✔ Interpretación

Los valores obtenidos de MAPE permiten cuantificar el error porcentual de predicción fuera de la muestra, mientras que los R^2 individuales (≈ 0.4351 para Life.Exp y ≈ 0.3869 para Income) muestran la proporción de la variabilidad explicada por los predictores en cada variable dependiente por separado.

4.7 Discusión y Conclusiones

🏁 Conclusiones

- **Significancia Global:** Las pruebas de hipótesis multivariadas (Pillai, Wilks, Hotelling-Lawley y Roy) evidenciaron de manera conjunta que el conjunto de variables predictoras (Illiteracy, HS.Grad, Frost) influye de manera estadísticamente significativa sobre el vector de respuestas (Life.Exp, Income) ($p < 0.05$).
- **Efecto de los Predictores Individuales:** Al evaluar el MANOVA por cada predictor, se concluyó que Illiteracy y HS.Grad ejercen un efecto multivariado estadísticamente significativo sobre el sistema de respuestas, mientras que Frost no muestra significancia estadística ($p = 0.4059$) en presencia de los demás predictores.
- **Capacidad Predictiva:** Los errores de predicción evaluados mediante el MAPE y el análisis de los coeficientes de determinación (R^2) demostraron una adecuada consistencia predictiva del modelo frente a datos fuera de la muestra.
- **Justificación Metodológica:** La prueba de esfericidad de Bartlett respaldó formalmente el uso del análisis de regresión multivariado debido a la correlación existente entre las variables dependientes, evitando los sesgos y la inflación del error tipo I que se presentarían al evaluarlas mediante modelos univariados independientes.

5 Análisis de componentes principales (ACP)

Ficha de la pregunta

- **Técnica:** ACP sobre la matriz de correlaciones, análisis paralelo de Horn, rotación varimax y conglomerados jerárquicos (HCPC)
- **Base de datos:** `Encuesta.xlsx` — encuesta de satisfacción a 300 clientes de una cadena de supermercados
- **Variables activas:** `AMABILIDAD`, `RAPIDEZ`, `RESOLUCION`, `CAL_PROD`, `VAR_PROD`, `PRECIO`, `LIMPIEZA` y `ORDEN` (escala 0–100)
- **Variable ilustrativa:** `CLIENTE_FRECUENTE` (Sí / No)

5.1 Data general

5.1.1 Contexto del problema

Se aplicó una encuesta de satisfacción a 300 clientes de una cadena de supermercados. El objetivo del Análisis de Componentes Principales (ACP) es reducir las respuestas de la encuesta a factores latentes que expliquen la experiencia del cliente.

Diccionario de variables

Variable	Tipo en el ACP	Descripción
`ID_ENCUESTA`	Identificador	Identificador único del cliente
`AMABILIDAD`	0 - 100	Amabilidad del personal
`RAPIDEZ`	0 - 100	Velocidad de atención en caja
`RESOLUCION`	0 - 100	Capacidad del personal para resolver dudas
`CAL_PROD`	0 - 100	Calidad de los productos
`VAR_PROD`	0 - 100	Variedad de marcas y opciones
`PRECIO`	0 - 100	Percepción de relación calidad–precio
`LIMPIEZA`	0 - 100	Higiene de las instalaciones
`ORDEN`	0 - 100	Distribución y orden en los pasillos
`CLIENTE_FRECUENTE`	Cualitativa	Afiliado al programa de lealtad (“Sí” / “No”)

5.1.2 Lectura de la base de datos

Los paquetes necesarios se cargan en la configuración inicial del documento.

```
# Lectura de datos
datos <- read_excel("Encuesta.xlsx")
datos$CLIENTE_FRECUENTE <- factor(datos$CLIENTE_FRECUENTE, levels = c("No", "Sí"))

# Base sin el identificador
datos1 <- as.data.frame(datos[, -1])

# Variables para realizar el ACP
datosacp <- datos1[, -9]
tt(head(datosacp))
```

AMABILIDAD	RAPIDEZ	RESOLUCION	CAL_PROD	VAR_PROD	PRECIO	LIMPIEZA	ORDEN
56	60	62	83	81	77	94	90
87	86	93	63	65	69	73	74
83	82	72	66	65	81	83	86
46	53	46	83	85	80	77	79

AMABILIDAD	RAPIDEZ	RESOLUCION	CAL_PROD	VAR_PROD	PRECIO	LIMPIEZA	ORDEN
60	58	53	77	81	67	95	97
94	88	91	82	93	88	85	83

```
dim(datos)
```

```
#> [1] 300  10
```

La base tiene 300 clientes y 10 columnas: el identificador, las 8 variables activas y la variable ilustrativa `CLIENTE_FRECUENTE` (140 afiliados y 160 no afiliados).

5.2 Introducción

La satisfacción de un cliente con un supermercado no es una sola percepción: se forma a partir de la atención del personal, de lo que se compra (calidad, variedad, precio) y del lugar donde se compra (limpieza, orden). Una encuesta con ocho preguntas de satisfacción genera ocho variables que, al estar relacionadas entre sí, contienen información repetida. El Análisis de Componentes Principales (ACP) transforma esas variables correlacionadas en un conjunto menor de componentes no correlacionados que conservan la mayor parte de la variabilidad, lo que permite identificar los factores latentes de la experiencia del cliente.

Objetivo general. Reducir las respuestas de la encuesta a factores latentes que expliquen la experiencia del cliente.

Objetivos específicos

1. Verificar la calidad de los datos (datos perdidos y valores atípicos) y describirlos.
2. Evaluar si la matriz de correlaciones justifica aplicar un ACP.
3. Extraer los componentes principales y decidir cuántos retener (criterio de Kaiser, porcentaje de varianza, gráfico de sedimentación y análisis paralelo de Horn).
4. Interpretar los componentes mediante los vectores propios y las correlaciones variable–componente.
5. Proyectar la variable ilustrativa `CLIENTE_FRECUENTE` sobre el plano factorial.
6. Agrupar a los clientes (conglomerados jerárquicos sobre componentes principales) y perfilar cada grupo.

Variables activas: `AMABILIDAD`, `RAPIDEZ`, `RESOLUCION`, `CAL_PROD`, `VAR_PROD`, `PRECIO`, `LIMPIEZA` y `ORDEN`, todas en escala de 0 a 100. Como comparten escala, el ACP se aplica sobre la matriz de correlaciones (variables estandarizadas, `scale = TRUE`).

5.3 Desarrollo

5.3.1 Calidad de los datos

Datos perdidos.

```
per.miss.col <- 100 * colSums(is.na(datosacp)) / dim(datosacp)[1]
kable(data.frame(Variable = names(per.miss.col), Porcentaje_perdidos = as.numeric(per.miss.co
        l)),
      digits = 2, row.names = FALSE, caption = "Porcentaje de datos perdidos por variable")
```

Porcentaje de datos perdidos por variable

Variable	Porcentaje_perdidos
AMABILIDAD	0
RAPIDEZ	0
RESOLUCION	0
CAL_PROD	0
VAR_PROD	0
PRECIO	0

Variable	Porcentaje_perdidos
LIMPIEZA	0
ORDEN	0

No hay datos perdidos en ninguna de las variables activas, por lo que no se requiere imputación.

Valores atípicos (criterio de la puntuación Z, |Z| > 3).

```
is_outlier3 <- function(x, k = 3) {
  return(abs(scale(x)) > k)
}

# Número de observaciones atípicas por variable
mat_out <- sapply(datosacp, is_outlier3)
kable(data.frame(Variable = colnames(mat_out), N_atipicos = colSums(mat_out)),
      row.names = FALSE, caption = "Observaciones con |Z| > 3 por variable")
```

Observaciones con |Z| > 3 por variable

Variable	N_atipicos
AMABILIDAD	1
RAPIDEZ	0
RESOLUCION	0
CAL_PROD	0
VAR_PROD	0
PRECIO	0
LIMPIEZA	1
ORDEN	0

```
# Detalle de las filas señaladas (equivale a datosacp[is_outlier3(variable), ] para cada variabl
        e)
filas_atipicas <- which(rowSums(mat_out) > 0)
kable(cbind(Fila = filas_atipicas, ID = datos$ID_ENCUESTA[filas_atipicas],
            datosacp[filas_atipicas, ]),
      row.names = FALSE, caption = "Clientes con al menos una puntuación atípica")
```

Clientes con al menos una puntuación atípica

FilaID	AMABILIDAD	RAPIDEZ	RESOLUCION	CAL_PROD	VAR_PROD	PRECIO	LIMPIEZA	ORDEN
165ENC-1165	82	93	66	82	82	87	47	55
196ENC-1196	13	35	27	85	75	83	68	68

Solo dos puntuaciones superan |Z| > 3: una en `LIMPIEZA` (valor 47) y otra en `AMABILIDAD` (valor 13). Ambas son valores posibles dentro de la escala 0–100 (clientes realmente insatisfechos y no errores de registro) y representan menos del 1 % de la muestra, de modo que se conservan.

5.3.2 Análisis descriptivo

Estadísticos descriptivos globales y por tipo de cliente.

```
desc_global <- as.data.frame(summarytools::descr(datosacp, transpose = TRUE))
kable(round(desc_global, 2), caption = "Estadísticos descriptivos de las variables activas")
```

Estadísticos descriptivos de las variables activas

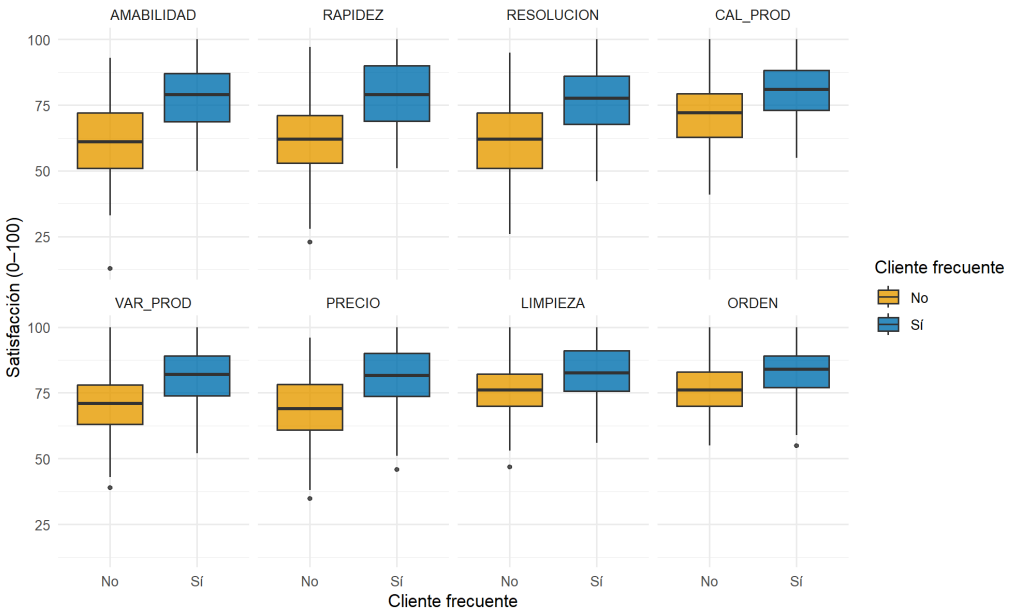
	Mean	Std.Dev	Min	Q1	Median	Q3	Max	MAD	IQR	CV	Skewness	SE.Skewness	Kurtosis	N.Valid	N	Pct.Valid
AMABILIDAD	69.18	15.70	13	59.0	70.0	80.0	100	16.31	21.00	0.23	-0.18	0.14	-0.19	300	300	100
CAL_PROD	75.33	12.28	41	68.0	76.0	84.0	100	11.86	16.00	0.16	-0.26	0.14	-0.19	300	300	100
LIMPIEZA	79.16	10.50	47	72.0	79.0	86.5	100	10.38	14.25	0.13	-0.03	0.14	-0.42	300	300	100
ORDEN	79.74	10.35	55	72.0	79.0	88.0	100	11.86	16.00	0.13	-0.03	0.14	-0.63	300	300	100
PRECIO	74.72	13.95	35	65.0	75.0	85.0	100	14.83	20.00	0.19	-0.24	0.14	-0.32	300	300	100
RAPIDEZ	69.89	15.92	23	59.0	70.0	81.0	100	16.31	22.00	0.23	-0.07	0.14	-0.36	300	300	100
RESOLUCION	68.81	15.26	26	58.5	69.5	78.5	100	15.57	19.50	0.22	-0.10	0.14	-0.35	300	300	100
VAR_PROD	75.22	12.45	39	66.0	75.0	85.0	100	14.83	19.00	0.17	-0.15	0.14	-0.45	300	300	100

```r
# Estadísticos por CLIENTE_FRECUENTE (equivale a stby(variable, CLIENTE_FRECUENTE, descr))
desc_grupos <- datos1 %>%
  pivot_longer(cols = -CLIENTE_FRECUENTE, names_to = "Variable", values_to = "Puntaje") %>%
  mutate(Variable = factor(Variable, levels = names(datosacp))) %>%
  group_by(Variable, CLIENTE_FRECUENTE) %>%
  summarise(n = n(), Media = mean(Puntaje), DE = sd(Puntaje), Min = min(Puntaje),
            Mediana = median(Puntaje), Max = max(Puntaje), .groups = "drop")
kable(desc_grupos, digits = 2, caption = "Estadísticos por tipo de cliente")
```

Estadísticos por tipo de cliente

Variable	CLIENTE_FRECUENTE	n	Media	DE	Min	Mediana	Max
AMABILIDAD	No	160	61.34	13.68	13	61.0	93
AMABILIDAD	Sí	140	78.14	12.83	50	79.0	100
RAPIDEZ	No	160	61.89	13.58	23	62.0	97
RAPIDEZ	Sí	140	79.04	13.28	51	79.0	100
RESOLUCION	No	160	61.44	13.47	26	62.0	95
RESOLUCION	Sí	140	77.23	12.63	46	77.5	100
CAL_PROD	No	160	70.65	11.80	41	72.0	100
CAL_PROD	Sí	140	80.69	10.54	55	81.0	100
VAR_PROD	No	160	70.21	11.48	39	71.0	100
VAR_PROD	Sí	140	80.96	10.97	52	82.0	100
PRECIO	No	160	69.08	12.90	35	69.0	96
PRECIO	Sí	140	81.16	12.24	46	81.5	100
LIMPIEZA	No	160	76.30	10.24	47	76.0	100
LIMPIEZA	Sí	140	82.43	9.84	56	82.5	100
ORDEN	No	160	76.96	10.24	55	76.0	100
ORDEN	Sí	140	82.91	9.56	55	84.0	100

```r
datos1 %>%
  pivot_longer(cols = -CLIENTE_FRECUENTE, names_to = "Variable", values_to = "Puntaje") %>%
  mutate(Variable = factor(Variable, levels = names(datosacp))) %>%
  ggplot(aes(x = CLIENTE_FRECUENTE, y = Puntaje, fill = CLIENTE_FRECUENTE)) +
  geom_boxplot(alpha = 0.8, outlier.size = 1) +
  facet_wrap(~Variable, nrow = 2) +
  scale_fill_manual(values = c("No" = "#E69F00", "Sí" = "#0072B2")) +
  labs(x = "Cliente frecuente", y = "Satisfacción (0-100)", fill = "Cliente frecuente") +
  theme_minimal()
```



> **🔎 Interpretación**
>
> **Interpretación.** Las puntuaciones medias son más altas en `ORDEN` (79.7) y `LIMPIEZA` (79.2), y más bajas en `RESOLUCION` (68.8), `AMABILIDAD` (69.2) y `RAPIDEZ` (69.9): el punto débil de la experiencia es el personal. Esas tres variables son además las más dispersas (desviación estándar ≈ 15–16 puntos), mientras que `LIMPIEZA` y `ORDEN` son las más homogéneas (≈ 10 puntos). La asimetría y la curtosis son cercanas a 0 en todas las variables (distribuciones aproximadamente simétricas). Los clientes frecuentes puntúan más alto en las ocho variables, con la mayor diferencia en las tres variables del personal (≈ 78 frente a ≈ 61 puntos).

5.3.3 Análisis de correlación

Matriz de correlaciones, prueba estadística y gráficos.

```
# Coeficientes de correlación de Pearson
kable(round(cor(datosacp), 3), caption = "Matriz de correlaciones de Pearson")
```

Matriz de correlaciones de Pearson

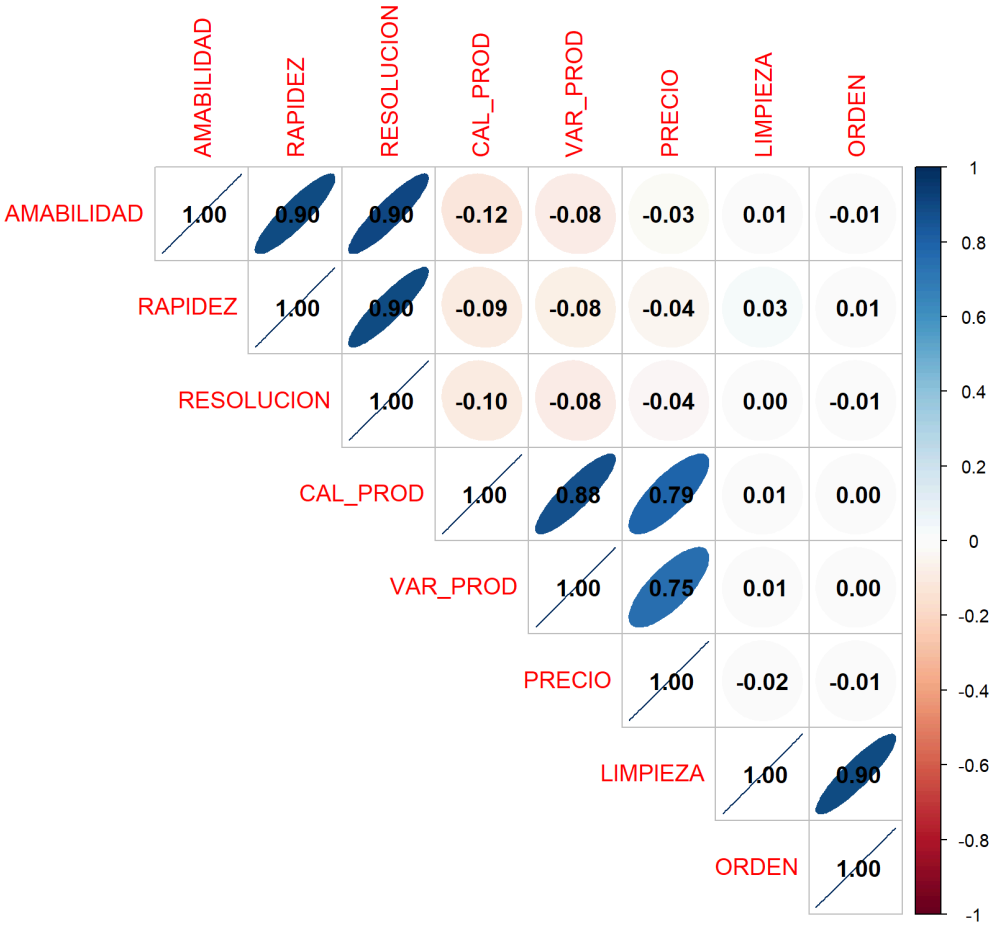
	AMABILIDAD	RAPIDEZ	RESOLUCION	CAL_PROD	VAR_PROD	PRECIO	LIMPIEZA	ORDEN
AMABILIDAD	1.000	0.896	0.902	-0.119	-0.084	-0.029	0.008	-0.006
RAPIDEZ	0.896	1.000	0.900	-0.093	-0.075	-0.042	0.032	0.009
RESOLUCION	0.902	0.900	1.000	-0.100	-0.083	-0.037	0.005	-0.014
CAL_PROD	-0.119	-0.093	-0.100	1.000	0.878	0.790	0.008	0.000
VAR_PROD	-0.084	-0.075	-0.083	0.878	1.000	0.754	0.012	-0.005
PRECIO	-0.029	-0.042	-0.037	0.790	0.754	1.000	-0.018	-0.013
LIMPIEZA	0.008	0.032	0.005	0.008	0.012	-0.018	1.000	0.898
ORDEN	-0.006	0.009	-0.014	0.000	-0.005	-0.013	0.898	1.000

```
# Prueba estadística : p-valores sin ajuste (debajo de la diagonal)
# y ajustados por Holm (encima de la diagonal)
ct <- corr.test(datosacp)
kable(round(ct$p, 4), caption = "p-valores de la prueba de correlación")
```

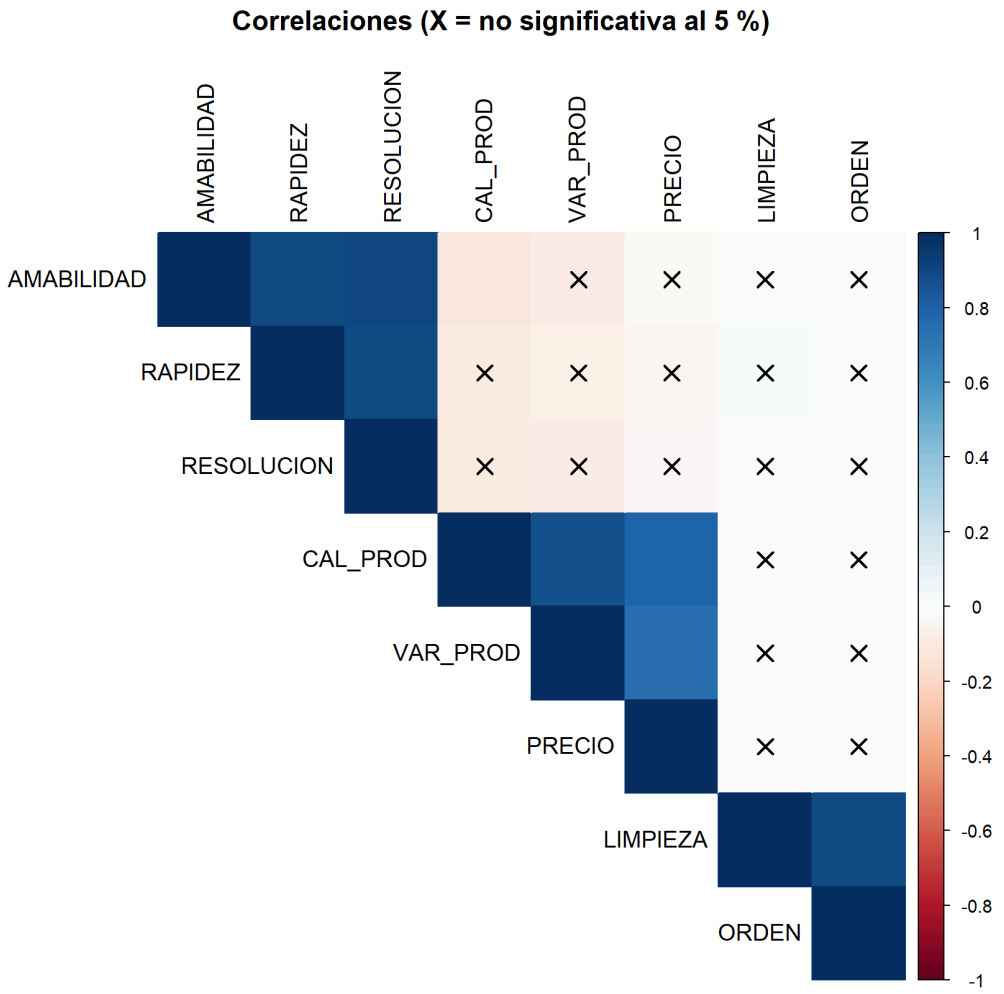
p-valores de la prueba de correlación

	AMABILIDAD	RAPIDEZ	RESOLUCION	CAL_PROD	VAR_PROD	PRECIO	LIMPIEZA	ORDEN
AMABILIDAD	0.0000	0.0000	0.0000	0.8173	1.0000	1.0000	1	1
RAPIDEZ	0.0000	0.0000	0.0000	1.0000	1.0000	1.0000	1	1
RESOLUCION	0.0000	0.0000	0.0000	1.0000	1.0000	1.0000	1	1
CAL_PROD	0.0389	0.1084	0.0838	0.0000	0.0000	0.0000	1	1
VAR_PROD	0.1454	0.1922	0.1534	0.0000	0.0000	0.0000	1	1
PRECIO	0.6224	0.4734	0.5242	0.0000	0.0000	0.0000	1	1
LIMPIEZA	0.8952	0.5841	0.9328	0.8847	0.8365	0.7621	0	0
ORDEN	0.9232	0.8751	0.8040	0.9937	0.9338	0.8182	0	0

```
# Gráfico de correlación
i <- cor(datosacp, method = "pearson")
corrplot(i, method = "ellipse", order = "original", addCoef.col = "black", type = "upper")
```




```
# Matriz de p-valores
res1 <- cor.mtest(datosacp, conf.level = 0.95)
corrplot(i, method = "color", type = "upper", p.mat = res1$p, sig.level = 0.05,
         insig = "pch", pch.cex = 1.5, tl.col = "black",
         title = "Correlaciones (X = no significativa al 5 %)", mar = c(0, 0, 2, 0))
```



Interpretación. La matriz muestra tres bloques de variables muy correlacionadas entre sí y casi incorrelacionadas con los demás:

- **Personal:** `AMABILIDAD`, `RAPIDEZ` y `RESOLUCION` ($r \approx 0.90$).
- **Oferta comercial:** `CAL_PROD`, `VAR_PROD` y `PRECIO` (r entre 0.75 y 0.88).
- **Instalaciones:** `LIMPIEZA` y `ORDEN` ($r \approx 0.90$).

Las correlaciones entre bloques son prácticamente nulas ($|r| \leq 0.12$); la única con $p < 0.05$ sin ajuste, `AMABILIDAD` – `CAL_PROD` ($r = -0.12$), deja de ser significativa al ajustar por Holm. Esta estructura anticipa tres factores latentes.

Adecuación de los datos para el ACP . Se aplican la prueba de esfericidad de Bartlett (H_0: la matriz de correlaciones es la identidad) y la medida de Kaiser–Meyer–Olkin (KMO).

```
bart <- cortest.bartlett(cor(datosacp), n = nrow(datosacp))
kmo  <- KMO(datosacp)

kable(data.frame(Estadístico = c("Chi-cuadrado de Bartlett", "gl", "p-valor",
                                 "Determinante de R", "KMO global"),
                 Valor = c(round(bart$chisq, 2), bart$df, format.pval(bart$p.value, eps = 0.00
        1),
                           signif(det(cor(datosacp)), 3), round(kmo$MSA, 3))),
      caption = "Pruebas de adecuación muestral")
```

Pruebas de adecuación muestral

Estadístico	Valor
Chi-cuadrado de Bartlett	2292.2
gl	28

Estadístico	Valor
p-valor	< 0.001
Determinante de R	0.000428
KMO global	0.7

```
kable(data.frame(Variable = names(kmo$MSAi), MSA = round(kmo$MSAi, 3)),
      row.names = FALSE, caption = "KMO individual (MSA) por variable")
```

KMO individual
(MSA) por variable

Variable	MSA
AMABILIDAD	0.770
RAPIDEZ	0.786
RESOLUCION	0.777
CAL_PROD	0.675
VAR_PROD	0.717
PRECIO	0.834
LIMPIEZA	0.497
ORDEN	0.498

La prueba de Bartlett rechaza que la matriz de correlaciones sea la identidad ($\chi^2 = 2292.2$, gl = 28, $p < 0.001$) y el determinante de la matriz es muy cercano a cero (0.000428), lo que confirma que existen correlaciones que el ACP puede resumir. El KMO global es 0.7 (aceptable). `LIMPIEZA` y `ORDEN` obtienen un MSA cercano a 0.50 porque solo se correlacionan entre ellas y con ninguna otra variable; esto no indica un problema de ajuste, sino que forman una dimensión propia e independiente de las demás.

5.3.4 Análisis de Componentes Principales

Extracción de los componentes. ACP sobre la matriz de correlaciones (`scale = TRUE`), conservando inicialmente los 8 componentes.

```
acp <- dudi.pca(datosacp, scannf = FALSE, scale = TRUE, nf = ncol(datosacp))
summary(acp)
```

```
#> Class: pca dudi
#> Call: dudi.pca(df = datosacp, scale = TRUE, scannf = FALSE, nf = ncol(datosacp))
#>
#> Total inertia: 8
#>
#> Eigenvalues:
#>     Ax1     Ax2     Ax3     Ax4     Ax5
#>  2.9493  2.4681  1.8990  0.2650  0.1247
#>
#> Projected inertia (%):
#>     Ax1     Ax2     Ax3     Ax4     Ax5
#>  36.867  30.851  23.737   3.312   1.559
#>
#> Cumulative projected inertia (%):
#>     Ax1   Ax1:2   Ax1:3   Ax1:4   Ax1:5
#>   36.87   67.72   91.46   94.77   96.33
#>
#> (Only 5 dimensions (out of 8) are shown)
```

```
# Valores propios (autovalores)
varianza <- 100 * acp$eig / sum(acp$eig)
tab_eig <- data.frame(Componente = paste0("CP", seq_along(acp$eig)),
                      Autovalor = acp$eig,
                      Varianza_pct = varianza,
                      Acumulada_pct = cumsum(varianza))
kable(tab_eig, digits = 3, caption = "Valores propios y varianza explicada")
```

Valores propios y varianza explicada

Componente	Autovalor	Varianza_pct	Acumulada_pct
CP1	2.949	36.867	36.867
CP2	2.468	30.851	67.718
CP3	1.899	23.737	91.455
CP4	0.265	3.312	94.767
CP5	0.125	1.559	96.327
CP6	0.104	1.297	97.623
CP7	0.099	1.234	98.857
CP8	0.091	1.143	100.000

```
inertia.dudi(acp)
```

```
#> Inertia information:
#> Call: inertia.dudi(x = acp)
#>
#> Decomposition of total inertia:
#>     inertia     cum  cum(%)
#> Ax1 2.94934   2.949   36.87
#> Ax2 2.46808   5.417   67.72
#> Ax3 1.89899   7.316   91.46
#> Ax4 0.26498   7.581   94.77
#> Ax5 0.12475   7.706   96.33
#> Ax6 0.10373   7.810   97.62
#> Ax7 0.09871   7.909   98.86
#> Ax8 0.09142   8.000  100.00
```

> 🔎 **Interpretación**
>
> Los dos primeros autovalores (2.949 y 2.468) explican 67.72 % de la varianza ; con el tercero (1.899) se llega a **91.46 %**.

Vectores propios y correlaciones variable–componente.

```
# Vectores propios (coeficientes de las combinaciones lineales)
kable(round(acp$c1, 3), caption = "Vectores propios (acp$c1)")
```

Vectores propios (acp$c1)

	CS1	CS2	CS3	CS4	CS5	CS6	CS7	CS8
AMABILIDAD	-0.481	-0.318	0.011	0.059	0.361	0.310	-0.074	0.657
RAPIDEZ	-0.478	-0.322	-0.004	-0.081	-0.246	-0.471	-0.579	-0.206
RESOLUCION	-0.480	-0.321	0.016	-0.025	-0.135	0.182	0.645	-0.445
CAL_PROD	0.342	-0.479	-0.008	-0.288	-0.657	0.190	0.035	0.320
VAR_PROD	0.327	-0.481	-0.007	-0.492	0.594	-0.078	-0.036	-0.243
PRECIO	0.292	-0.481	0.010	0.812	0.075	-0.108	-0.002	-0.082
LIMPIEZA	-0.013	-0.009	-0.707	-0.037	0.026	-0.541	0.355	0.283
ORDEN	-0.006	0.003	-0.707	0.058	-0.019	0.550	-0.338	-0.283

```
# Correlaciones entre las variables originales y las componentes principales (cargas)
kable(round(acp$co, 3), caption = "Correlaciones variable-componente (acp$co)")
```

Correlaciones variable–componente (acp$co)

	Comp1	Comp2	Comp3	Comp4	Comp5	Comp6	Comp7	Comp8
AMABILIDAD	-0.827	-0.499	0.015	0.030	0.127	0.100	-0.023	0.199
RAPIDEZ	-0.821	-0.506	-0.006	-0.042	-0.087	-0.152	-0.182	-0.062
RESOLUCION	-0.825	-0.504	0.021	-0.013	-0.048	0.059	0.203	-0.134
CAL_PROD	0.587	-0.752	-0.011	-0.148	-0.232	0.061	0.011	0.097
VAR_PROD	0.561	-0.756	-0.010	-0.253	0.210	-0.025	-0.011	-0.073

	Comp1	Comp2	Comp3	Comp4	Comp5	Comp6	Comp7	Comp8
PRECIO	0.501	-0.756	0.014	0.418	0.027	-0.035	-0.001	-0.025
LIMPIEZA	-0.022	-0.014	-0.974	-0.019	0.009	-0.174	0.111	0.086
ORDEN	-0.010	0.004	-0.974	0.030	-0.007	0.177	-0.106	-0.086

```
# Comunalidad con 3 componentes: proporción de la varianza de cada variable que retienen
kable(data.frame(Variable = rownames(acp$co),
                 Comunalidad_3CP = round(rowSums(acp$co[, 1:3]^2), 3)),
      row.names = FALSE, caption = "Comunalidad de cada variable con los 3 primeros componente
        s")
```

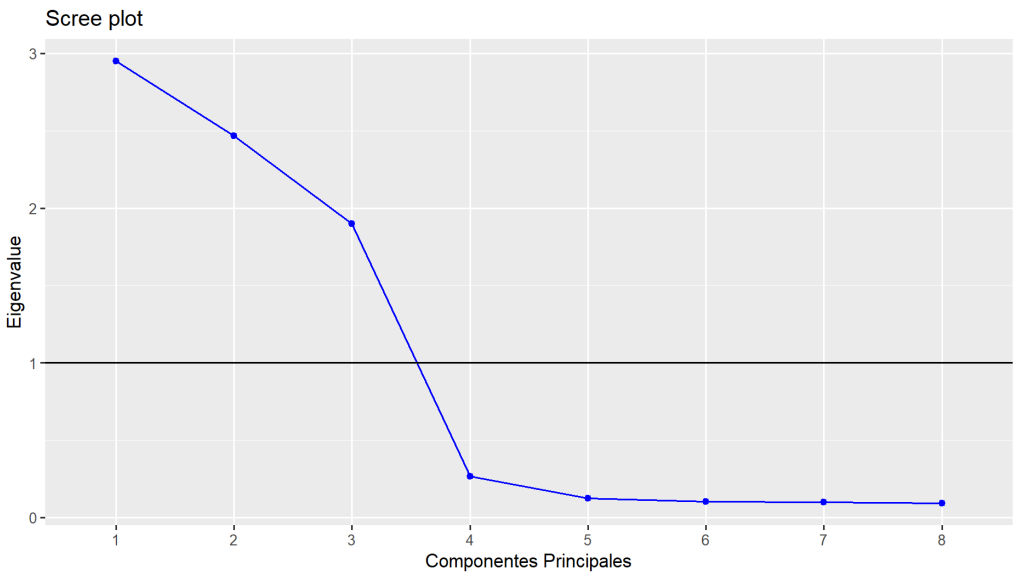
Comunalidad de cada variable con los 3 primeros componentes

Variable	Comunalidad_3CP
AMABILIDAD	0.933
RAPIDEZ	0.931
RESOLUCION	0.935
CAL_PROD	0.911
VAR_PROD	0.886
PRECIO	0.823
LIMPIEZA	0.950
ORDEN	0.949

5.3.4.1 Cuántos componentes retener

Gráfico de sedimentación (criterio de Kaiser).

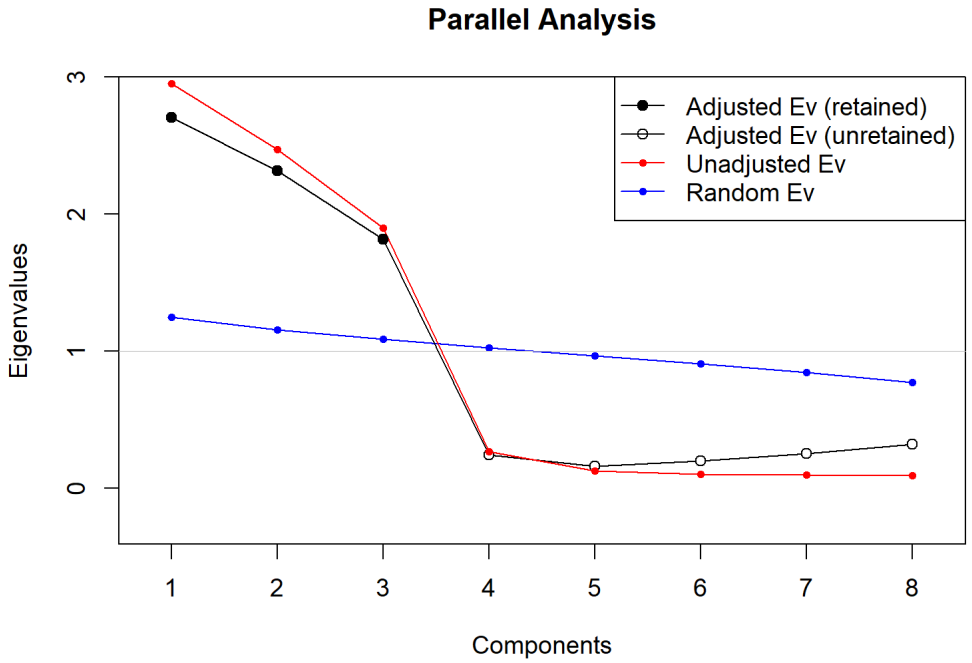
```
a <- fviz_eig(acp, choice = 'eigenvalue', geom = "line", linecolor = 'blue',
              xlab = 'Componentes Principales') +
  geom_hline(yintercept = 1, color = 'black') +
  theme_grey()
a
```



Método paralelo de Horn. Un componente se retiene si su autovalor supera al que se obtendría con datos aleatorios no correlacionados del mismo tamaño.

```
paran(datosacp, iterations = 5000, graph = TRUE, color = TRUE)
```

```
#>
#> Computing: 10%  20%  30%  40%  50%  60%  70%  80%  90%  100%
```




```
# Comprobación: autovalores observados vs. percentil 95 de autovalores de datos aleatorios
set.seed(2024)
n <- nrow(datosacp); p <- ncol(datosacp)
sim <- replicate(2000, eigen(cor(matrix(rnorm(n * p), n, p)), only.values = TRUE)$values)
tab_horn <- data.frame(Componente = paste0("CP", 1:p),
                       Observado = acp$eig,
                       Aleatorio_p95 = apply(sim, 1, quantile, probs = 0.95),
                       Retener = ifelse(acp$eig > apply(sim, 1, quantile, probs = 0.95), "Sí",
        "No"))
kable(tab_horn, digits = 3, caption = "Análisis paralelo de Horn (2 000 simulaciones)")
```

Análisis paralelo de Horn (2 000 simulaciones)

Componente	Observado	Aleatorio_p95	Retener
CP1	2.949	1.329	Sí
CP2	2.468	1.214	Sí
CP3	1.899	1.131	Sí
CP4	0.265	1.065	No
CP5	0.125	1.004	No
CP6	0.104	0.950	No
CP7	0.099	0.892	No
CP8	0.091	0.829	No

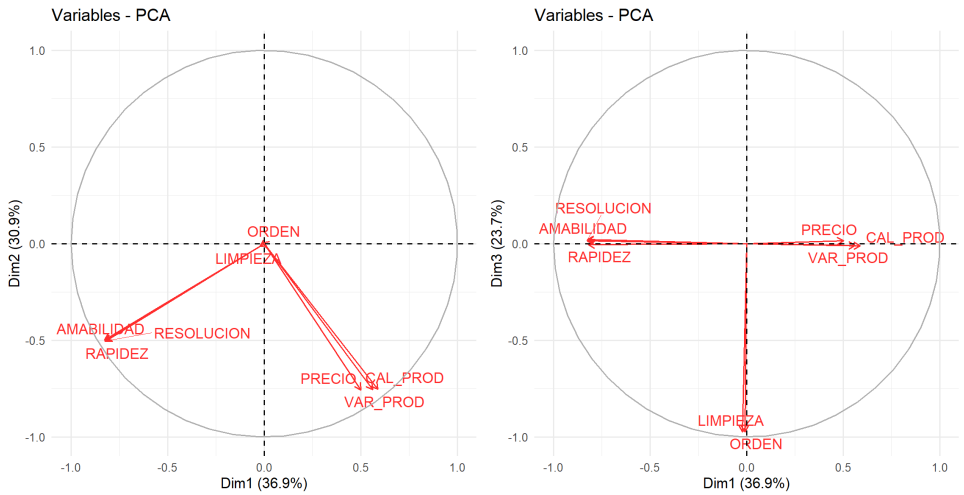
Decisión

Decisión. Los tres criterios coinciden: (i) hay 3 autovalores mayores que 1; (ii) el gráfico de sedimentación muestra una caída brusca entre el tercer (1.90) y el cuarto autovalor (0.27); (iii) el análisis paralelo retiene 3 componentes, y (iv) estos explican 91.46 % de la varianza total. Se retienen 3 componentes principales.

5.3.4.2 Representación de las variables

Círculo de correlaciones.

```
b <- fviz_pca_var(acp, col.var = "#FF3030", repel = TRUE) + theme_minimal()
b13 <- fviz_pca_var(acp, axes = c(1, 3), col.var = "#FF3030", repel = TRUE) + theme_minimal()
b + b13
```



5.3.4.3 Interpretación de los componentes

Con el umbral |r| ≥ 0.45 se resume la estructura retenida:

```
cargas <- round(acp$co[, 1:3], 3)
cargas_mostrar <- apply(cargas, c(1, 2), function(v) ifelse(abs(v) >= 0.45, sprintf("%.3f", v),
        ""))
kable(cargas_mostrar, caption = "Cargas con |r| ≥ 0.45 (resto omitido)", align = "ccc")
```

Cargas con |r| ≥ 0.45 (resto omitido)

	Comp1	Comp2	Comp3
AMABILIDAD	-0.827	-0.499	
RAPIDEZ	-0.821	-0.506	
RESOLUCION	-0.825	-0.504	
CAL_PROD	0.587	-0.752	
VAR_PROD	0.561	-0.756	
PRECIO	0.501	-0.756	
LIMPIEZA			-0.974
ORDEN			-0.974

- **CP1 (36.9 %) — "Preferencia a la atención del personal".** Es un eje *bipolar*: `AMABILIDAD`, `RAPIDEZ` y `RESOLUCION` cargan con signo negativo (≈ −0.82) y `CAL_PROD`, `VAR_PROD` y `PRECIO` con signo positivo (0.50–0.59). Separa a los clientes que valoran más el trato de los que valoran más el producto.
- **CP2 (30.9 %) — "Satisfacción total con personal y productos".** Las seis variables cargan con el mismo signo (−0.50 a −0.76): es un eje de satisfacción global con la atención y la oferta. Al ser el signo negativo, *las puntuaciones más negativas en CP2 indican clientes más satisfechos*.
- **CP3 (23.7 %) — "Preferencia a las instalaciones".** `LIMPIEZA` y `ORDEN` cargan casi exclusivamente aquí (−0.974 ambas) y las demás variables no tienen relación con este eje.

Los dos primeros autovalores son parecidos (2.95 y 2.47), por lo que el plano CP1–CP2 es en la práctica un plano en el que las direcciones "personal" y "oferta" pueden girar. Como verificación se aplica una rotación varimax a los 3 componentes retenidos:

```
pc_var <- principal(datosacp, nfactors = 3, rotate = "varimax")
kable(round(unclass(pc_var$loadings), 3), caption = "Cargas rotadas (varimax)")
```

Cargas rotadas (varimax)

	RC1	RC2	RC3
AMABILIDAD	0.965	-0.042	-0.003
RAPIDEZ	0.964	-0.034	0.019
RESOLUCION	0.966	-0.037	-0.009
CAL_PROD	-0.073	0.952	0.007
VAR_PROD	-0.048	0.940	0.006

	RC1	RC2	RC3
PRECIO	0.002	0.907	-0.017
LIMPIEZA	0.013	0.003	0.974
ORDEN	-0.007	-0.006	0.974

```
kable(round(pc_var$Vaccounted[1:3, ], 3), caption = "Varianza explicada tras la rotación")
```

Varianza explicada tras la rotación

	RC1	RC2	RC3
SS loadings	2.801	2.616	1.899
Proportion Var	0.350	0.327	0.237
Cumulative Var	0.350	0.677	0.915

> **Interpretación**
>
> Tras la rotación la estructura es nítida: RC1 = Atención del personal (cargas ≈ 0.96), RC2 = Oferta comercial (0.91–0.95) y RC3 = Instalaciones (0.97), con la misma varianza acumulada (91.5 %). Es decir, las ocho variables se resumen en tres factores latentes de la experiencia del cliente.

5.3.4.4 Puntuaciones (Scores) de los clientes

Coordenadas de los individuos y biplot.

```
# Scores (primeros 10 clientes)
kable(cbind(ID = datos$ID_ENCUESTA[1:10], round(acp$li[1:10, 1:3], 3)),
      caption = "Scores de los 10 primeros clientes en los 3 primeros componentes")
```

Scores de los 10 primeros clientes en los 3 primeros componentes

ID	Axis1	Axis2	Axis3
ENC-1001	1.307	-0.001	-1.724
ENC-1002	-2.516	-0.118	0.852
ENC-1003	-1.295	-0.051	-0.661
ENC-1004	2.524	0.434	0.154
ENC-1005	1.146	0.729	-2.280
ENC-1006	-1.085	-2.749	-0.587
ENC-1007	2.842	3.215	-2.850
ENC-1008	1.245	0.195	1.139
ENC-1009	-1.132	-2.015	-1.138
ENC-1010	1.324	1.083	0.246

```
options(scipen = 999)
# Matriz de covarianzas de los scores: la diagonal son los autovalores y el resto es 0
kable(round(cov(acp$li), 4), caption = "Covarianza de los componentes (diagonal = autovalores)")
```

Covarianza de los componentes (diagonal = autovalores)

	Axis1	Axis2	Axis3	Axis4	Axis5	Axis6	Axis7	Axis8
Axis1	2.9592	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
Axis2	0.0000	2.4763	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
Axis3	0.0000	0.0000	1.9053	0.0000	0.0000	0.0000	0.0000	0.0000
Axis4	0.0000	0.0000	0.0000	0.2659	0.0000	0.0000	0.0000	0.0000
Axis5	0.0000	0.0000	0.0000	0.0000	0.1252	0.0000	0.0000	0.0000
Axis6	0.0000	0.0000	0.0000	0.0000	0.0000	0.1041	0.0000	0.0000
Axis7	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0990	0.0000
Axis8	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0917

```
kable(round(cor(acp$li), 4), caption = "Correlación de los componentes (ortogonales)")
```

Correlación de los componentes (ortogonales)

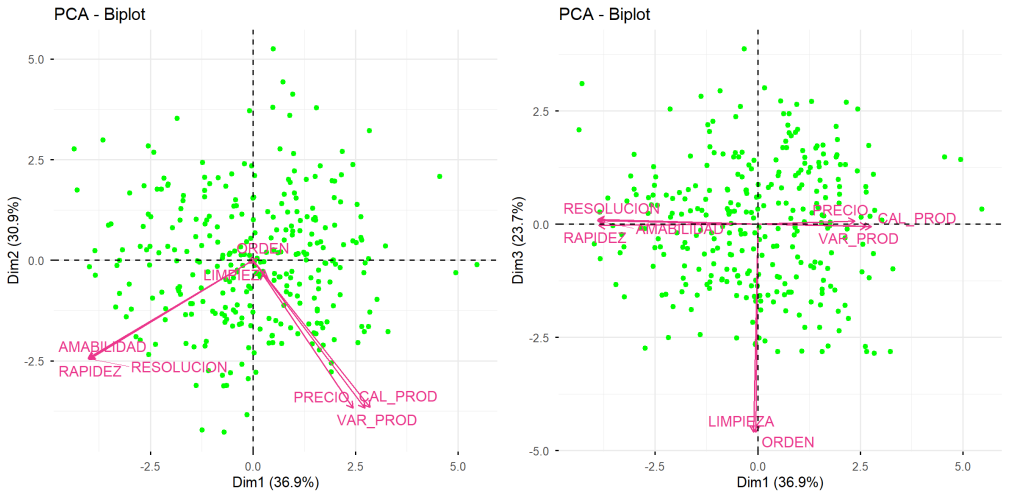
	Axis1	Axis2	Axis3	Axis4	Axis5	Axis6	Axis7	Axis8
Axis1	1	0	0	0	0	0	0	0
Axis2	0	1	0	0	0	0	0	0
Axis3	0	0	1	0	0	0	0	0
Axis4	0	0	0	1	0	0	0	0
Axis5	0	0	0	0	1	0	0	0
Axis6	0	0	0	0	0	1	0	0
Axis7	0	0	0	0	0	0	1	0
Axis8	0	0	0	0	0	0	0	1

```
kable(round(describe(acp$li)[, c("n", "mean", "sd", "min", "max", "skew", "kurtosis")], 3),
      caption = "Descriptivos de los scores")
```

Descriptivos de los scores

	n	mean	sd	min	max	skew	kurtosis
Axis1	300	0	1.720	-4.354	5.463	-0.105	-0.152
Axis2	300	0	1.574	-4.279	5.247	0.217	0.134
Axis3	300	0	1.380	-2.850	3.863	0.017	-0.534
Axis4	300	0	0.516	-1.372	1.563	-0.070	0.117
Axis5	300	0	0.354	-1.101	0.991	-0.297	0.054
Axis6	300	0	0.323	-1.156	0.965	-0.058	0.472
Axis7	300	0	0.315	-1.302	0.869	-0.319	0.724
Axis8	300	0	0.303	-0.935	0.830	-0.044	-0.155

```
# Individuos y variables sobre el primer plano (biplot)
c1 <- fviz_pca_biplot(acp, repel = TRUE, geom.ind = "point", col.var = "#EE3A8C", col.ind = "gre
   en")
c2 <- fviz_pca_biplot(acp, axes = c(1, 3), repel = TRUE, geom.ind = "point", col.var = "#EE3A8
   C", col.ind = "green")
c1 + c2
```



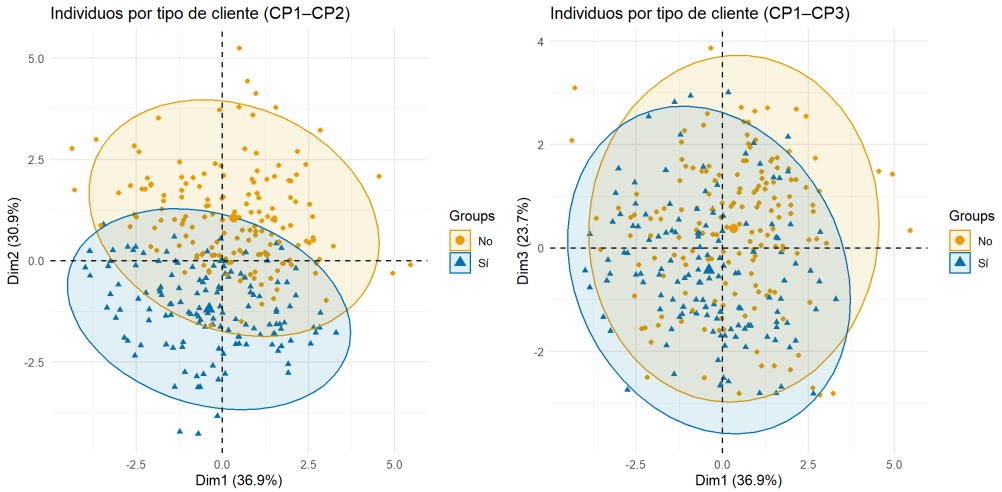
> **🔎 Interpretación**
>
> Los scores son incorrelacionados (covarianzas 0) y su varianza es igual al autovalor correspondiente, como exige la teoría del ACP.

5.3.5 Variable cualitativa: `CLIENTE_FRECUENTE`

Proyección de la variable cualitativa ilustrativa. La variable no interviene en el cálculo de los componentes; solo se utiliza para colorear los individuos y comparar los grupos sobre los ejes.

```
grupo <- datos1$CLIENTE_FRECUENTE

p12 <- fviz_pca_ind(acp, geom.ind = "point", habillage = grupo, addEllipses = TRUE,
                    ellipse.level = 0.95, palette = c("#E69F00", "#0072B2"),
                    title = "Individuos por tipo de cliente (CP1-CP2)") + theme_minimal()
p13 <- fviz_pca_ind(acp, axes = c(1, 3), geom.ind = "point", habillage = grupo, addEllipses = TR
       UE,
                    ellipse.level = 0.95, palette = c("#E69F00", "#0072B2"),
                    title = "Individuos por tipo de cliente (CP1-CP3)") + theme_minimal()
p12 + p13
```




```
scores3 <- data.frame(Grupo = grupo, acp$li[, 1:3])
kable(aggregate(. ~ Grupo, data = scores3, FUN = mean), digits = 3,
      caption = "Centroides de cada categoría en los tres primeros ejes")
```

Centroides de cada categoría en los tres primeros ejes

Grupo	Axis1	Axis2	Axis3
No	0.338	1.05	0.374
Sí	-0.387	-1.20	-0.428

```
# Comparación de los scores entre grupos (t de Welch) y tamaño del efecto (d de Cohen)
comp <- do.call(rbind, lapply(1:3, function(k) {
  s  <- acp$li[[k]]
  tt_ <- t.test(s ~ grupo)
  d  <- (mean(s[grupo == "Sí"]) - mean(s[grupo == "No"])) /
        sqrt((var(s[grupo == "Sí"]) + var(s[grupo == "No"])) / 2)
  data.frame(Eje = paste0("CP", k), t = unname(tt_$statistic), p_valor = tt_$p.value, d_Cohen =
        d)
}))
kable(comp, digits = c(0, 2, 6, 2), caption = "Diferencias entre clientes frecuentes y no frecue
        ntes")
```

Diferencias entre clientes frecuentes y no frecuentes

Eje	t	p_valor	d_Cohen
CP1	3.73	0.000233	-0.43
CP2	17.82	0.000000	-2.05

Eje	t	p_valor	d_Cohen
CP3	5.26	0.000000	-0.61

> **🔎 Interpretación**
>
> Los clientes frecuentes (`Sí`) se ubican hacia los valores negativos de CP2 y CP3, es decir, hacia mayor satisfacción. La diferencia es enorme en CP2 (t = 17.8; d ≈ −2.05), moderada en CP3 (d ≈ −0.61) y pequeña en CP1 (d ≈ −0.43). Los centroides están bien separados en el eje de satisfacción general, aunque las elipses se solapan parcialmente en los otros ejes.

5.3.6 Conglomerados jerárquicos sobre componentes principales

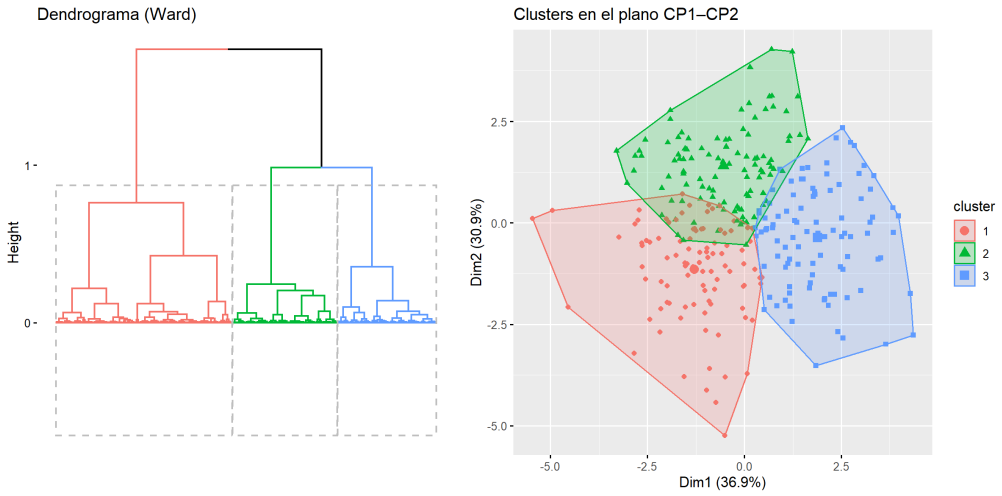
Clasificación jerárquica (HCPC).

```
respca <- PCA(datosacp, scale.unit = TRUE, ncp = 8, graph = FALSE)
res.hcpc <- HCPC(respca, nb.clust = 3, graph = FALSE)

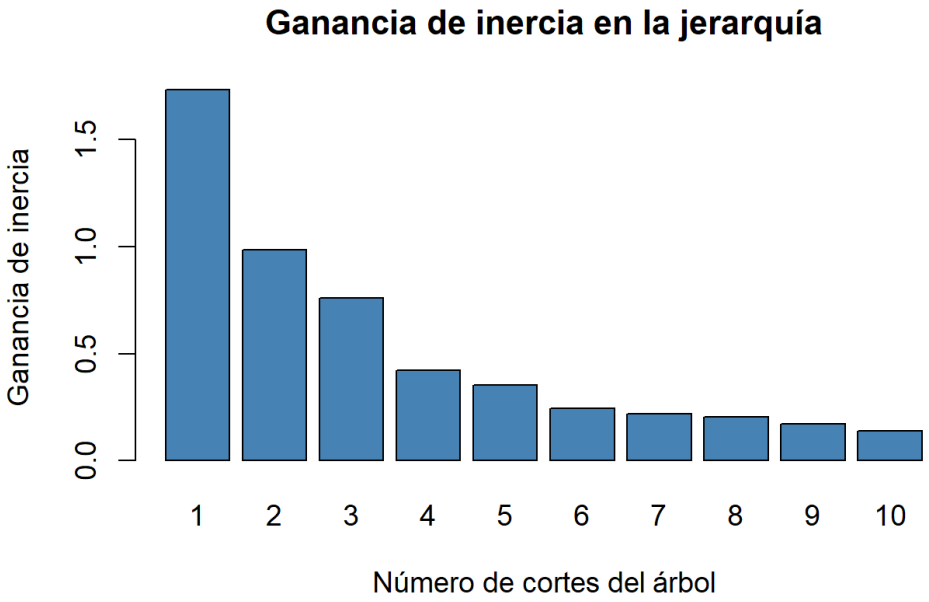
Grupos <- res.hcpc$data.clust$clust
table(Grupos)
```

```
#> Grupos
#>   1   2   3
#>  98 105  97
```

```
d1_ <- fviz_dend(res.hcpc, show_labels = FALSE, rect = TRUE, main = "Dendrograma (Ward)")
d2_ <- fviz_cluster(res.hcpc, geom = "point", show.clust.cent = TRUE, main = "Clusters en el pla
       no CP1-CP2")
d1_ + d2_
```




```
barplot(res.hcpc$call$t$inert.gain[1:10], names.arg = 1:10, col = "steelblue",
        xlab = "Número de cortes del árbol", ylab = "Ganancia de inercia",
        main = "Ganancia de inercia en la jerarquía")
```



> **🔎 Interpretación**
>
> El criterio automático de HCPC (mayor ganancia de inercia) sugiere 3 grupos, que es la solución adoptada. Cada grupo tiene un perfil distinto e interpretable en términos de los tres factores (ver tabla de medias) y los tamaños son parecidos (97 a 105 clientes). Los clusters se solapan en el plano CP1–CP2 porque parte de lo que los distingue (instalaciones) está en CP3.

Descripción de los clusters.

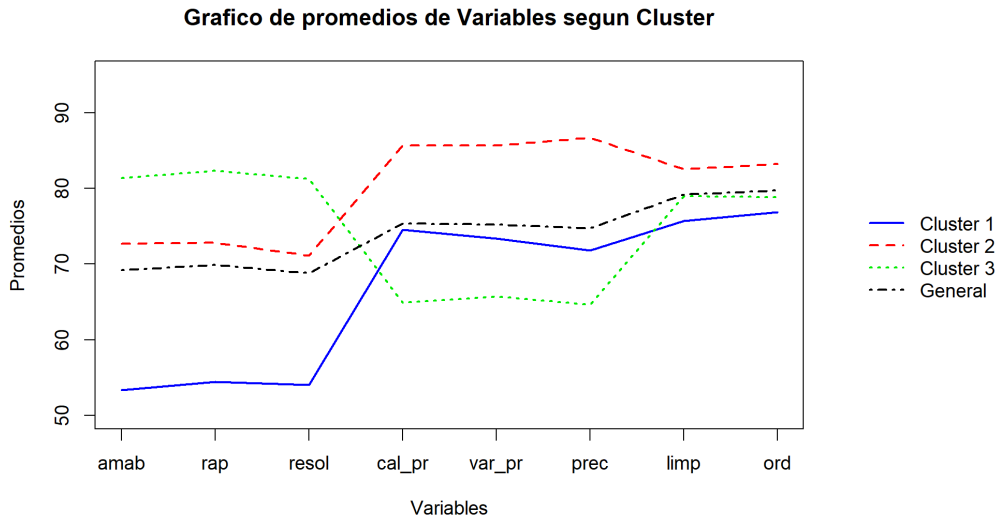
```
datosf <- cbind(datos1, Grupos)

# Perfil en base a las medias de cada variable por cluster
medias <- t(sapply(datosacp, function(v) tapply(v, Grupos, mean)))
colnames(medias) <- paste("Cluster", colnames(medias))
medias <- cbind(medias, General = colMeans(datosacp))
kable(round(medias, 2), caption = "Medias de cada variable por cluster")
```

Medias de cada variable por cluster

	Cluster 1	Cluster 2	Cluster 3	General
AMABILIDAD	53.38	72.70	81.35	69.18
RAPIDEZ	54.43	72.84	82.33	69.89
RESOLUCION	54.02	71.14	81.22	68.81
CAL_PROD	74.57	85.69	64.90	75.33
VAR_PROD	73.39	85.69	65.75	75.22
PRECIO	71.83	86.71	64.66	74.72
LIMPIEZA	75.70	82.53	79.00	79.16
ORDEN	76.88	83.21	78.87	79.74

```
layout(matrix(1:2, nrow = 1), widths = c(4, 1))
colores <- c("blue", "red", "green2", "black")
nombres <- c("Cluster 1", "Cluster 2", "Cluster 3", "General")
par(mar = c(5, 4, 4, 1))
matplot(medias,
        main = "Grafico de promedios de Variables segun Cluster",
        xlab = "Variables",
        ylab = "Promedios",
        type = "l",
        xaxt = "n",
        ylim = c(50, 95),
        col  = colores,
        lty  = 1:4,
        lwd  = 2)
axis(1, at = 1:8,
     labels = c("amab", "rap", "resol", "cal_pr", "var_pr", "prec", "limp", "ord"))
par(mar = c(0, 0, 0, 0))
plot.new()
legend("center", legend = nombres, col = colores, lty = 1:4, lwd = 2, cex = 1, bty = "n")
```




```
layout(1)
```

```
# Relación de los clusters con la variable ilustrativa
tab_cf <- table(Cluster = Grupos, Cliente_frecuente = datosf$CLIENTE_FRECUENTE)
kable(cbind(tab_cf, `% Sí` = round(100 * prop.table(tab_cf, 1)[, "Sí"], 1)),
      caption = "Clusters según cliente frecuente")
```

Clusters según cliente frecuente

	No	Sí	% Sí
1	98	0	0.0
2	11	94	89.5
5	146	131	47.4

```
# Prueba chi-cuadrado de independencia
ch <- chisq.test(tab_cf)
ch
```

```
#>
#>  Pearson's Chi-squared test
#>
#> data:  tab_cf
#> X-squared = 163.26, df = 2, p-value < 0.00000000000000022
```

```
# Frecuencias esperadas bajo independencia (deben ser >= 5)
round(ch$expected, 1)
```

```
#>        Cliente_frecuente
#> Cluster   No   Sí
#>       1 52.3 45.7
#>       2 56.0 49.0
#>       3 51.7 45.3
```

```
# V de Cramér: magnitud de la asociación (0 = nula, 1 = perfecta)
V <- sqrt(unname(ch$statistic) / (sum(tab_cf) * (min(dim(tab_cf)) - 1)))
round(V, 3)
```

```
#> [1] 0.738
```

> 🔎 **Interpretación**
>
> **Interpretación de la prueba chi-cuadrado.** Se contrasta H_0: el cluster al que pertenece un cliente es independiente de que sea cliente frecuente, frente a H_1: existe asociación entre ambas variables. El estadístico es $\chi^2 = 163.26$ con gl = 2 (= (3 − 1)(2 − 1)) y p < 2.2e-16, muy inferior a $\alpha = 0.05$. Por tanto se rechaza H_0: hay evidencia muy fuerte de que los clusters y la afiliación al programa de lealtad están asociados.

Esto es relevante porque los clusters se construyeron solo con las 8 variables de satisfacción, sin usar `CLIENTE_FRECUENTE`, y aun así reproducen diferencias reales entre afiliados y no afiliados: el cluster 1 (los más insatisfechos con el personal) no tiene ningún cliente frecuente (0 %), el cluster 2 (los más satisfechos) es casi todo afiliado (89.5 %) y el cluster 3 es intermedio (47.4 %). El V de Cramér es 0.74, lo que indica una asociación fuerte. La aproximación chi-cuadrado es válida porque todas las frecuencias esperadas son mayores que 5 (la menor es 45.3). La prueba muestra que existe asociación, pero no su causa: no permite saber si la afiliación genera satisfacción o si los clientes más satisfechos son los que se afilian.

5.4 Discusión

Estructura latente de la experiencia. La matriz de correlaciones ya mostraba tres bloques casi independientes, y el ACP lo confirma: tres componentes (autovalores 2.95, 2.47 y 1.90) retienen el 91.5 % de la información de las ocho variables, y la rotación varimax los identifica con claridad como atención del personal(amabilidad,rapidez y resolución), oferta comercial (calidad, variedad y precio) e instalaciones (limpieza y orden). El cuarto autovalor (0.27) y los siguientes están por debajo de lo esperable por azar, por lo que no hay más estructura sistemática. La comunalidad de todas las variables con 3 componentes supera 0.82 (la más baja es `PRECIO`, 0.82), de modo que ninguna se pierde en la reducción.

Sobre la interpretación de CP1 y CP2. Sin rotación, los dos primeros componentes mezclan los bloques de personal y oferta (CP1 los contrasta y CP2 los suma), porque sus autovalores son muy parecidos y el ACP no distingue entre las direcciones dentro de ese plano. Por eso se recomienda interpretar CP1 y CP2 conjuntamente (en el círculo de correlaciones los tres vectores del personal y los tres de la oferta forman dos haces separados) y apoyarse en la rotación para nombrar los factores. El tercer componente, en cambio, es limpio: solo `LIMPIEZA` y `ORDEN`, aunque definido por dos variables y con un KMO individual cercano a 0.50, por lo que convendría medir más aspectos del local en futuras encuestas para consolidarlo.

Variable cualitativa. Ser cliente frecuente se asocia a mayor satisfacción global (CP2, d ≈ −2.05) y mayor satisfacción con las instalaciones (CP3). La diferencia en CP2 es muy grande, aunque es una asociación: la encuesta no permite saber si la afiliación al programa de lealtad genera satisfacción o si los clientes más satisfechos son los que se afilian.

Conglomerados. Los tres grupos combinan de forma distinta los factores (medias de la tabla de perfiles):

Cluster	n	Personal	Oferta	Instalaciones	% clientes frecuentes	Perfil
1	98	Muy bajo (≈ 54)	Medio (≈ 72–75)	Medio (≈ 76)	0 %	Clientes insatisfechos con el personal; ninguno está afiliado
2	105	Medio (≈ 72)	Muy alto (≈ 86)	Muy alto (≈ 83)	89.5 %	Clientes más satisfechos con la oferta y las instalaciones; casi todos afiliados
3	97	Muy alto (≈ 81–82)	Muy bajo (≈ 65)	Medio (≈ 79)	47.4 %	Buen trato, pero mala valoración de calidad, variedad y precio

La asociación entre cluster y afiliación es fuerte ($\chi^2 = 163.26$, gl = 2, $p < 0.001$; V de Cramér = 0.74). La estructura de bloques independientes explica por qué aparecen perfiles “mixtos”: un cliente puede estar satisfecho con el personal y no con el producto (cluster 3), o con el producto y el local pero no tanto con la atención (cluster 2 frente a los clusters 1 y 3).

Limitaciones. Los puntajes son autoreportados y la encuesta es transversal; el ACP asume relaciones lineales y es sensible a observaciones extremas (aquí solo hay dos, moderadas y conservadas). Los grupos de HCPC dependen del número de clusters elegido.

5.5 Conclusiones

🏁 Conclusiones

1. La base está completa (0 % de datos perdidos) y solo presenta dos puntuaciones atípicas moderadas ($|Z| > 3$), que se conservaron por ser valores válidos de la escala.
2. Los datos son adecuados para el ACP: existen tres bloques de correlaciones altas (r ≈ 0.75–0.90), la prueba de Bartlett es significativa ($p < 0.001$) y el KMO global es 0.70.
3. Se retienen 3 componentes principales (autovalores 2.95, 2.47 y 1.90) que explican el 91.46 % de la varianza, según los criterios de Kaiser, sedimentación y análisis paralelo.
4. Los factores latentes de la experiencia del cliente son: atención del personal (`AMABILIDAD` , `RAPIDEZ` , `RESOLUCION`), oferta comercial (`CAL_PROD` , `VAR_PROD` , `PRECIO`) e instalaciones (`LIMPIEZA` , `ORDEN`).
5. La atención del personal es la dimensión peor valorada y más dispersa (medias ≈ 69, DE ≈ 15–16), por lo que es la principal oportunidad de mejora.
6. Los clientes frecuentes están más satisfechos, sobre todo en la dimensión global de personal y oferta (CP2, d ≈ −2.05).
7. Se identifican tres perfiles de clientes: insatisfechos con el personal (cluster 1, ningún afiliado), satisfechos con la oferta y las instalaciones (cluster 2, 89.5 % afiliados) y satisfechos con el trato pero no con la oferta (cluster 3, 47.4 % afiliados). La asociación entre cluster y afiliación es significativa y fuerte ($\chi^2 = 163.26$, gl = 2, $p < 0.001$; V de Cramér = 0.74). Las acciones deben dirigirse a cada perfil: capacitación del personal (cluster 1) y revisión de calidad, variedad y precio (cluster 3).

5.6 Bibliografía

- Bartlett, M. S. (1954). A note on the multiplying factors for various χ² approximations. *Journal of the Royal Statistical Society, Series B, 16*(2), 296–298.
- Cattell, R. B. (1966). The scree test for the number of factors. *Multivariate Behavioral Research, 1*(2), 245–276.

Síntesis general del trabajo

Pregunta	Técnica	Resultado principal (según el desarrollo de cada sección)
1	MANOVA factorial en DBCA	El efecto de la semana depende de la zona (interacción semana × zona significativa); el bloque día resultó útil y las ventas de principio de mes superan a las de fin de mes.
2	MANCOVA en DCA	Completar el curso de preparación modifica significativamente el vector (lectura, escritura) incluso ajustando por matemática.
3	MANCOVA en DBCA	Efecto multivariado significativo de la dosis de probiótico, con covariables y bloque que aumentan la precisión; la dosis más alta no mejora a la intermedia.
4	Regresión multivariada	El analfabetismo y los graduados de secundaria influyen conjuntamente en la esperanza de vida y el ingreso; los días de helada no son significativos.
5	ACP	Tres componentes (91.46 % de la varianza): atención del personal, oferta comercial e instalaciones; se identifican tres perfiles de clientes asociados a la afiliación.

🏁 Idea central

En las cinco preguntas, la **estructura de correlación entre las variables respuesta** justificó el enfoque multivariado frente a análisis univariados separados: el control del error tipo I global, el ajuste por covariables o bloques y la reducción de dimensión permitieron conclusiones más precisas que las que darían las variables por separado.

Información de la sesión

```
sessionInfo()
```

```
#> R version 4.6.1 (2026-06-24 ucrt)
#> Platform: x86_64-w64-mingw32/x64
#> Running under: Windows 11 x64 (build 26200)
#>
#> Matrix products: default
#>   LAPACK version 3.12.1
#>
#> locale:
#> [1] LC_COLLATE=Spanish_Peru.utf8  LC_CTYPE=Spanish_Peru.utf8
#> [3] LC_MONETARY=Spanish_Peru.utf8 LC_NUMERIC=C
#> [5] LC_TIME=Spanish_Peru.utf8
#>
#> time zone: America/Lima
#> tzcode source: internal
#>
#> attached base packages:
#> [1] stats     graphics  grDevices utils     datasets  methods   base
#>
#> other attached packages:
#>  [1] lubridate_1.9.5    stringr_1.6.0      purrr_1.2.2        readr_2.2.0
#>  [5] tibble_3.3.1       tidyverse_2.0.0    dplyr_1.2.1        forcats_1.0.1
#>  [9] tidyr_1.3.2        paran_1.5.6        FactoMineR_2.17    patchwork_1.3.2
#> [13] factoextra_2.2.0   ade4_1.7-24        corrplot_0.95      summarytools_1.1.5
#> [17] tinytable_0.18.0   car_3.1-5          carData_3.0-6      heplots_1.8.4
#> [21] broom_1.0.13       readxl_1.5.0       MetBrewer_0.2.0    ggplot2_4.0.3
#> [25] emmeans_2.0.4      mvnormtest_0.1-9-3 kableExtra_1.4.1   knitr_1.52
#> [29] psych_2.6.5        haven_2.5.5        biotools_4.3       MASS_7.3-65
#>
#> loaded via a namespace (and not attached):
#>  [1] mnormt_2.1.2         gridExtra_2.3.1      tcltk_4.6.1
#>  [4] sandwich_3.1-3       rlang_1.3.0          magrittr_2.0.5
#>  [7] multcomp_1.4-32      otel_0.2.0           matrixStats_1.5.0
#> [10] compiler_4.6.1       mgcv_1.9-4           systemfonts_1.3.2
#> [13] vctrs_0.7.3          reshape2_1.4.5       sysfonts_0.8.9
#> [16] pkgconfig_2.0.3      fastmap_1.2.0        backports_1.5.1
#> [19] magick_2.9.1         labeling_0.4.3       pander_0.6.6
#> [22] rmarkdown_2.32       tzdb_0.5.0           xfun_0.60
#> [25] showtext_0.9-8       cachem_1.1.0         litedown_0.11
#> [28] jsonlite_2.0.0       flashClust_1.1-4     irlba_2.3.7
#> [31] parallel_4.6.1       cluster_2.1.8.2      R6_2.6.1
#> [34] bslib_0.12.0         stringi_1.8.9        RColorBrewer_1.1-3
#> [37] boot_1.3-32          jquerylib_0.1.4      cellranger_1.1.0
#> [40] estimability_2.0.0   Rcpp_1.1.2           zoo_1.9-0
#> [43] base64enc_0.1-6      Matrix_1.7-5         splines_4.6.1
#> [46] timechange_0.4.0     tidyselect_1.2.1     viridis_0.6.5
#> [49] rstudioapi_0.19.0    abind_1.4-8          yaml_2.3.12
#> [52] codetools_0.2-20     curl_8.0.0           lattice_0.22-9
#> [55] plyr_1.8.9           withr_3.0.3          S7_0.2.2
#> [58] coda_0.19-4.1        evaluate_1.0.5       survival_3.8-6
#> [61] xml2_1.6.0           ggpubr_1.0.0         pillar_1.11.1
#> [64] checkmate_2.3.4      DT_0.34.0            generics_0.1.4
#> [67] hms_1.1.4            scales_1.4.0         xtable_1.8-8
#> [70] leaps_3.2            glue_1.8.1           scatterplot3d_0.3-45
#> [73] tools_4.6.1          dendextend_1.19.1    ggsignif_0.6.4
#> [76] mvtnorm_1.4-2        rgl_1.3.36           rapportools_1.2
#> [79] grid_4.6.1           nlme_3.1-169         showtextdb_3.0
#> [82] Formula_1.2-6        cli_3.6.6            textshaping_1.0.5
#> [85] viridisLite_0.4.3    svglite_2.2.2        gtable_0.3.6
#> [88] rstatix_1.1.0        sass_0.4.10          digest_0.6.39
#> [91] ggrepel_0.9.8        TH.data_1.1-5        htmlwidgets_1.6.4
#> [94] farver_2.1.2         htmltools_0.5.9      lifecycle_1.0.5
#> [97] multcompView_0.1-12
```